GUIA DE ENGENHARIA DA MODELAGEM TEMPORAL (LSTM)

Entendimento Conceitual, Decisões de Projeto e Argumentação de Defesa

Aluno: Andrio Gabriel Epp | **Curso:** Engenharia da Computação (Unisinos) | **Foco:** Módulo Temporal (Track A)

---

1 Visão Geral: O que este módulo faz e por quê?

No nosso TCC, antes de classificar o tipo de falha do transformador com o XGBoost, nós construímos um **módulo de previsão temporal** baseado em rede neural profunda recorrente (**Stacked LSTM**).

A pergunta prática de engenharia que este módulo responde é simples:

> *"Olhando o histórico recente das medições dos sensores de gases dissolvidos no óleo de um transformador de potência, quais serão as concentrações desses gases daqui a 7 dias ($h = 14$) e daqui a 14 dias ($h = 28$)?"*

A ideia original da arquitetura híbrida era: se entregarmos ao classificador não apenas a foto do instante atual (*snapshot*), mas também **para onde os gases estão caminhando no futuro**, o modelo terá muito mais inteligência para identificar falhas graves antes que o transformador queime.

Abaixo estão explicadas, de forma direta e sem formalismo matemático desnecessário, as 5 grandes decisões de engenharia desta etapa.

---

2 Decisão 1: Por que a janela deslizante ótima é $w = 50$ (25 dias)?

O que é a Janela Deslizante (w)?

Pense na janela deslizante como um **buffer circular (fila FIFO)** na memória do computador.

- Nossos dados registram medições a cada **12 horas** (1 passo temporal = 12 horas).
- Uma janela $w = 10$ armazena 10 medições passadas = **5 dias de histórico**.
- Uma janela $w = 50$ armazena 50 medições passadas = **25 dias de histórico**.

Como chegamos em $w = 50$ e qual foi a lógica de escolha?

Nós não chutamos esse número. Foi realizado um **Grid Search** (busca em grade exaustiva), treinando e avaliando a rede LSTM com quatro tamanhos de buffer diferentes:

$$w \in \{10, 20, 30, 50\}$$

A física do transformador e os testes computacionais ditaram o resultado:

1. **Janelas curtas ($w = 10$ e $w = 20$ / 5 a 10 dias):** Transformadores de potência operam imersos em dezenas de toneladas de óleo isolante. A difusão dos gases e o aquecimento são fenômenos físicos de inércia muito lenta. Em 5 ou 10 dias, a rede enxerga apenas pequenas flutuações diárias de carga e temperatura ambiente. O erro de predição foi significativamente mais alto porque a rede confundia ruído com tendência real.
2. **Janela longa ($w = 50$ / 25 dias):** Com 25 dias contínuos de histórico, o buffer contém quase um mês de operação. A rede consegue enxergar a inclinação real da curva de degradação térmica do óleo.
3. **Por que não testar janelas ainda maiores (ex: $w = 100$)?** Cada série da base Katser possui 420 passos no total. Se usássemos uma janela de 100 passos, perderíamos quase um quarto dos dados apenas para "encher a fila" antes de gerar o primeiro alvo, além de aumentar o consumo de memória RAM e GPU sem trazer ganho perceptível.

Resultado Numérico Real: $w^* = 50$ alcançou o menor Erro Absoluto Médio global (MAE $= 5,59 \times 10^{-5}$ normalizado) e coeficiente de determinação quase perfeito ($R^2 > 0,999$ no primeiro passo), sendo o vencedor absoluto do teste.

---

3 Decisão 2: Para que serve a Normalização Min-Max e por que é estritamente no Treino?

O Problema Físico da Escala dos Gases

Em um transformador em serviço, os gases dissolvidos coexistem em ordens de grandeza absurdamente desiguais:

- O Monóxido de Carbono (CO) atinge facilmente 1.000 **a** 3.000 **ppm** (partes por milhão).
- O Acetileno (C_2H_2) aparece em concentrações diminutas de 1 **a** 15 **ppm**.

O perigo computacional: Se você injetar esses números brutos na rede neural, o valor de 3.000 do CO domina o cálculo do gradiente e do erro quadrático. A rede fica cega para o Acetileno, porque um erro de 2 ppm no acetileno parece insignificante perto de 3.000 ppm do CO.
A gravidade na Engenharia Elétrica: O Acetileno (C_2H_2) é exatamente o gás mais perigoso de todos! Qualquer fração de ppm dele indica a ocorrência de arco elétrico em altíssima temperatura ($> 1.000°C$), com risco iminente de explosão do transformador. A rede jamais poderia negligenciar o acetileno.

A Solução: ScalerPerGas e a Blindagem de Treino

Para resolver isso, implementamos o `ScalerPerGas`, que aplica a fórmula Min-Max $[0, 1]$ **individualmente para cada gás**:

$$x_{\text{norm}}^{(g)} = \frac{x^{(g)} - \min(x^{(g)})}{\max(x^{(g)}) - \min(x^{(g)}) + \epsilon}$$

Agora, tanto o CO quanto o C_2H_2 variam entre 0 e 1. Para o algoritmo de otimização, uma variação no acetileno ganha o mesmo peso matemático que uma variação no monóxido de carbono.
Por que calcular os limites ESTRITAMENTE na partição de treino? Isso é um princípio fundamental de Engenharia de Software e Machine Learning chamado **Prevenção de Vazamento de Dados (*Data Leakage*)**:

- Se calcularmos o máximo e o mínimo usando o dataset inteiro (treino + teste), o modelo já estará "sabendo o futuro" (ele saberá qual é o pico máximo que só ocorre no teste).
- Na vida real, um sistema em produção numa subestação em 2024 só conhece o histórico do passado; ele não tem como prever o valor máximo de 2025.
- Por isso, salvamos a régua de $(\min, \max)$ calculada **apenas nas 1.785 séries de treino**. Os dados de validação e de teste são transformados passivamente usando essa mesma régua do passado.

---

4 Decisão 3: O que significa uma LSTM de 2 camadas com 64 unidades e Dropout 0,20?

Entendendo a Arquitetura em Termos de Computação

A rede LSTM (*Long Short-Term Memory*) é uma evolução das redes neurais tradicionais projetada para reter contexto ao longo do tempo através de portas lógicas internas (*Gates*: Esquecer, Guardar e Passar adiante).

- **O que são as 64 unidades?** Cada unidade é uma célula de memória com seus próprios registradores de estado. Ter 64 unidades significa que a camada mantém um vetor interno de 64 números para descrever o estado dinâmico do transformador naquele instante (se os gases estão subindo com aceleração, se estão estáveis, se houve oscilação cíclica, etc.). Sessenta e quatro é um valor equilibrado: tem capacidade de memória de sobra para 4 gases, sem sobrecarregar o processador.
- **Por que 2 Camadas Empilhadas (*Stacked*)?**
  - *1ª Camada (64 unidades, return_sequences = True):* Funciona como um filtro digital que processa a sequência temporal passo a passo e extrai padrões de curto prazo (variações entre uma medição de 12h e a seguinte).
  - *2ª Camada (64 unidades, return_sequences = False):* Lê a sequência de saídas da 1ª camada e consolida tudo em um único vetor resumo de 64 números, representando a **tendência macro** do equipamento nos 25 dias.

- **O que é o Dropout de 0,20?** Durante o treinamento, a cada iteração, **20% das conexões entre neurônios são desligadas aleatoriamente**. Isso impede que neurônios vizinhos combinem respostas decoradas para transformadores específicos. A rede é forçada a aprender padrões robustos e generalizáveis, evitando o temido sobreajuste (*overfitting*).
- **Camada Densa Final (4 neurônios com ativação Linear):** Pega o vetor resumo de 64 características e projeta nas 4 saídas contínuas normalizadas correspondentes aos 4 gases no próximo instante. A ativação é linear para permitir a predição de grandezas físicas contínuas sem corte artificial.

---

5 Decisão 4: Como funciona a Previsão Recursiva ($h = 14$ e $h = 28$)?

O Mecanismo de Malha Fechada / Feedback Loop

Nossa rede LSTM foi treinada para prever **apenas 1 passo à frente** ($h = 1$, equivalente a 12 horas).
Como fazemos então para olhar 7 dias ($h = 14$) ou 14 dias ($h = 28$) no futuro? Utilizamos a técnica de **Previsão Recursiva (*Autoregressive Roll-forward*)**:

1. Injetamos as 50 medições reais observadas no buffer da rede. A rede cospe a previsão do passo $t + 1$ (daqui a 12h).
2. Pegamos essa previsão, **colocamos no final do buffer** e descartamos a medição mais antiga do início da fila (deslizando a janela).
3. Agora o buffer contém 49 dados reais e 1 previsão gerada pela própria rede. Alimentamos a rede novamente, e ela cospe o passo $t + 2$ (daqui a 24h).
4. Repetimos esse laço recursivo:
   - Para $h = 14$ passos (7 dias / 168 horas): o laço roda **14 vezes**.
   - Para $h = 28$ passos (14 dias / 336 horas): o laço roda **28 vezes**.

---

6 Decisão 5: Avaliação até 112 Passos e a Escolha de $h = 14$ e $h = 28$

O Efeito "Telefone Sem Fio" da Recursão e o Teste de Estresse

Na previsão recursiva, qualquer pequeno erro no passo 1 entra como dado de entrada no passo 2. O passo 2 acumula um erro ligeiramente maior e joga no passo 3. Com o tempo, o erro se propaga como em um jogo de telefone sem fio.
Para descobrir até onde a rede se mantinha confiável antes de começar a "alucinar", nós submetemos o modelo a um teste de estresse em 11 horizontes futuros diferentes:

$$h \in [1, 2, 4, 7, 14, 28, 42, 56, 70, 84, 98, 112 \text{ passos}]$$

Definimos uma regra de corte de engenharia clara:

> **Critério de Confiabilidade Técnica:** A previsão só é aceita se o R^2 médio entre os gases for $\geq 0,80$ (isto é, se a rede ainda explicar pelo menos 80% do comportamento real dos gases).

Passo (h)	Tempo Físico	Semanas	R^2 Médio	R^2 H_2	R^2 CO	R^2 C_2H_4	R^2 C_2H_2	Avaliação Operacional
$h = 1$	12 horas	0,07 sem	**0,9996**	0,9995	0,9996	0,9996	0,9996	Precisão quase absoluta ($e < 0,5\%$)
$h = 2$	24 horas (1 dia)	0,14 sem	**0,9996**	0,9995	0,9996	0,9996	0,9996	Confiabilidade máxima
$h = 4$	48 horas (2 dias)	0,29 sem	**0,9994**	0,9993	0,9994	0,9994	0,9994	Confiabilidade máxima
$h = 7$	84 horas (3,5 dias)	0,50 sem	**0,9991**	0,9991	0,9992	0,9992	0,9991	Confiabilidade máxima
$h = 14$	**7 dias (1 sem)**	**1,00 sem**	**0,9979**	0,9976	0,9981	0,9980	0,9978	**[ADOTADO NO XGBOOST] (Erro 2%)**
$h = 28$	**14 dias (2 sem)**	**2,00 sem**	**0,9928**	0,9914	0,9939	0,9932	0,9928	**[ADOTADO NO XGBOOST] (Erro 3,7%)**
$h = 42$	21 dias (3 sem)	3,00 sem	**0,9836**	0,9797	0,9865	0,9843	0,9839	Excelente aderência
$h = 56$	28 dias (4 sem)	4,00 sem	**0,9684**	0,9598	0,9748	0,9700	0,9691	Excelente aderência
$h = 70$	35 dias (5 sem)	5,00 sem	**0,9350**	0,9179	0,9486	0,9388	0,9346	Boa aderência (Erro 10%)
$h = 84$	42 dias (6 sem)	6,00 sem	**0,9163**	0,8923	0,9349	0,9204	0,9177	Degradação progressiva
$h = 98$	49 dias (7 sem)	7,00 sem	**0,8798**	0,8458	0,9068	0,8859	0,8807	Degradação progressiva
$h = 112$	**56 dias (8 sem)**	**8,00 sem**	**0,8380**	0,7877	0,8744	0,8493	0,8407	**LIMITE MÁXIMO ACEITÁVEL** ($R^2 \geq 0,80$)

Por que escolhemos $h = 14$ e $h = 28$ para o XGBoost em vez de $h = 112$?

Os números reais do projeto mostram que a rede é tão potente que ainda segura $R^2 = 83,8\%$ aos **112 passos (8 semanas / quase dois meses)**. Contudo, selecionamos $h = 14$ **(1 semana) e** $h = 28$ **(2 semanas)** para o classificador por dois motivos pragmáticos de engenharia:

1. **Pureza de Sinal:** Em 7 e 14 dias, o R^2 é de $99,79\%$ **e** $99,28\%$, com erro médio entre 2% e $3,7\%$. Não queríamos poluir o classificador com projeções que já carregassem 17% de desvio acumulado (como ocorre em $h = 112$).
2. **Janela Operacional da Subestação:** Uma ou duas semanas é a janela de tempo perfeita para uma concessionária de energia programar uma equipe de manutenção, fazer manobra de alívio de carga na rede e abrir o transformador com total segurança sem causar apagão na cidade.

7 Guia Rápido de Respostas para a Banca Examinadora

Pergunta 1: "Por que fixar w=50 e não uma janela menor de 5 dias?"

Resposta Ideal: "Professor, em transformadores de potência, a quebra térmica do óleo e a difusão dos gases são processos de inércia física lenta. Uma janela de 5 dias ($w = 10$) é curta demais e capta apenas variações diárias de carga e temperatura ambiente. Nós executamos um Grid Search entre 10, 20, 30 e 50 passos: o tamanho de 50 passos (25 dias) alcançou o menor erro quadrático e forneceu à rede o histórico necessário para distinguir uma oscilação passageira de uma tendência real de degradação."

Pergunta 2: "Por que a normalização Min-Max foi calculada estritamente no treino?"

Resposta Ideal: "Para evitar vazamento de dados (*Data Leakage*). Na operação real de uma subestação, o sistema não sabe qual será o pico máximo de gás no ano seguinte. Se utilizássemos o dataset inteiro para extrair os valores máximos, estaríamos contaminando a rede com informações do futuro. Por isso, ajustamos o escalonador unicamente sobre as séries de treino e aplicamos essa mesma régua fixa nas partições de teste."

Pergunta 3: "Por que usar uma Stacked LSTM com Dropout em vez de uma rede mais profunda?"

Resposta Ideal: "Por parcimônia arquitetural e controle de variância. Nosso problema possui 4 variáveis de entrada em 50 passos temporais. Duas camadas de 64 unidades formam a profundidade ideal: a primeira extrai a dinâmica sequencial de curto prazo e a segunda consolida o vetor de contexto global do equipamento. Adicionar mais camadas causaria sobreajuste (*overfitting*) e lentidão sem ganho preditivo. O Dropout de 0,20 desliga 20% das vias no treino, impedindo a memorização de máquinas específicas."

Pergunta 4: "Se a rede aguentou prever até 112 passos, por que vocês só passaram h=14 e h=28 para o XGBoost?"

Resposta Ideal: "Nosso teste de estresse provou que a LSTM mantém $R^2 \geq 80\%$ até 112 passos (8 semanas à frente), demonstrando a alta capacidade da rede recorrente. Porém, para alimentar o classificador, selecionamos 7 e 14 dias ($h = 14$ e 28) porque nesses horizontes o R^2 ainda é cirúrgico ($> 99\%$, com erro de apenas 2% a 3,7%), evitando a injeção de ruído no XGBoost. Além disso, 7 a 14 dias é o tempo operacional padrão para uma concessionária planejar a manutenção preventiva de campo."

DOCUMENTO DE APOIO E PREPARAÇÃO PARA A DEFESA DE TCC – ENGENHARIA DA COMPUTAÇÃO