FOLHA DE REFERÊNCIA OFICIAL PARA A DEFESA DE TCC

Consolidação de Números Oficiais, Dimensões de Tensores, Hiperparâmetros, Equações e Argumentos de Defesa

1. Panorama Oficial das Bases de Dados e Eixos Experimentais

Dimensão / Critério	Eixo Track A (Hibridização Temporal)	Eixo Track B (Diagnóstico Multiclasse IEC)
Fonte Oficial	Katser et al. (2022) – Skoltech / Rosatom	Li et al. (2019) / DGALab (Ibrahim et al., 2018)
Natureza dos Dados	Séries temporais de sensores *online* ($\Delta t = 12$h)	Medições pontuais estáticas (campo, lab e literatura)
Escala Original	Pré-normalizada na origem (ordem de 10^{-3})	Concentrações absolutas em ppm
Gases Monitorados	**4 gases:** H_2, CO, C_2H_4, C_2H_2	**5 gases:** $H_2, CH_4, C_2H_6, C_2H_4, C_2H_2$
Auditoria / Limpeza	Sem duplicatas (3.000 séries de $T = 420$ passos = 210 dias)	De 2.321 brutas → removidas **359** (15,5%: 303 réplicas idênticas + 56 conflitos de rótulo) → **1.962 únicas**
Divisão de Dados	**3.000 total: 2.100** desenv. (70%) e **900** teste (30%). Na LSTM: **1.785** treino (85%) e **315** val. (15%)	**1.962 total (70/15/15): 1.372** treino (70%), **295** validação (15%) e **295** teste independente (15%). Desenv. CV = 1.667
Classes Operacionais	**4 classes:** Normal, PD, D1, T1 (rótulo constante nos 420 passos)	**7 classes IEC 60599:** Normal, PD, D1, D2, T1, T2, T3
Suporte no Teste	**900 total:** 731 Normal, 38 PD, 49 D1, 82 T1	**295 total:** 106 Normal e **189 falhas** (17 PD, 41 D1, 33 D2, 16 T1, 16 T2, 66 T3)
Normalização	Min-Max por gás ajustada nas 1.785 séries de treino	Razões calculadas em ppm bruto → $\ln(x+1)$ → Min-Max
Desbalanceamento	`sample_weight` analítico: $w_c = N/(C \cdot N_c)$	`CustomSMOTE` ($k = 5$) nos 5 gases brutos + recálculo físico
Ordem no Pipeline	`[("select", selector), ("clf", clf)]`	`[("smote", sampler), ("select", selector), ("clf", clf)]`

2. Engenharia de Atributos e Seleção Dimensional pelo IGA

Atributos Candidatos vs. Subconjuntos Selecionados pelo IGA

- **Track A – 17 Candidatos (`FEATURES_TRACK_A`):**
  - *Grupo 1 (4 gases observados em $t = 420$):* $H_{2,obs}, CO_{obs}, C_2H_{4,obs}, C_2H_{2,obs}$.
  - *Grupo 2 (5 derivados):* C_2H_2/C_2H_4, H_2/C_2H_2, $TH_{katser} = C_2H_4 + C_2H_2$, C_2H_2/TH_{katser}, C_2H_4/TH_{katser}.
  - *Grupo 3 (8 previsões LSTM):* H_2, CO, C_2H_4, C_2H_2 projetados para $h = 14$ (1 semana) e $h = 28$ (2 semanas).
  - **Selecionados em C1 pelo IGA (8 de 17 → redução de 53%):** CO_{obs}, $\mathbf{H_2}/\mathbf{C_2H_2}$, $\mathbf{C_2H_2}/TH_{katser}$, $\mathbf{C_2H_4}/TH_{katser}$, $H_{\mathbf{2},h14}$, $H_{\mathbf{2},h28}$, $C_{\mathbf{2}}H_{\mathbf{4},h28}$ e $C_{\mathbf{2}}H_{\mathbf{2},h28}$. (Descartou $H_{2,obs}$ em favor de $H_{2,h14}$ e $H_{2,h28}$).
- **Track B – 19 Candidatos (`FEATURES_TRACK_B`):**
  - *Grupo 1 (5 gases brutos):* $H_2, CH_4, C_2H_6, C_2H_4, C_2H_2$.
  - *Grupo 2 (5 razões IEC/Doernenburg/Wu):* CH_4/H_2, C_2H_2/C_2H_4, C_2H_4/C_2H_6, C_2H_2/CH_4, C_2H_2/C_2H_6.
  - *Grupo 2B (2 somas + 7 proporções):* $TH = CH_4 + C_2H_4 + C_2H_2$, $TH_1 = TH + C_2H_6$; proporções sobre TH ($\%CH_4, \%C_2H_4, \%C_2H_2$) e sobre TH_1 ($\%CH_4, \%C_2H_6, \%C_2H_4, \%C_2H_2$).
  - **Selecionados em C3 pelo IGA (16 de 19):** Descartou apenas **3 variáveis**: $\mathbf{C_2H_2}$ **bruto**, $\mathbf{C_2H_2}/\mathbf{CH_4}$ e $\%\mathbf{CH_4}/TH_1$.
  - **Modelo M3 (Wu et al., 2021):** Parte de 18 candidatos (sem C_2H_2/CH_4) → IGA selecionou **14 atributos**.

3. Números Oficiais de Desempenho Experimental

3.1 Módulo de Previsão Temporal LSTM (Track A – 900 Séries de Teste, 5 Sementes)

Desempenho em Um Passo ($h = 1$, 333.000 janelas)				**Degradação Multi-Horizonte Recursiva (5 seeds, 200 séries/seed)**				
Gás	**MAE** ($\times 10^{-5}$)	**RMSE** ($\times 10^{-4}$)	R^2 ($h = 1$)	**Horizonte**	**Tempo**	R^2 **Persist.**	R^2 **LSTM**	**MAE% LSTM**
H_2	$1{,}44 \pm 0{,}13$	$0{,}18 \pm 0{,}02$	0,9995	$h = 1$	12h	1,0000	0,9996	0,90%
CO	$16{,}15 \pm 2{,}72$	$2{,}06 \pm 0{,}31$	0,9997	$h = 14$	1 sem	0,9970	**0,9979**	2,05%
C_2H_4	$4{,}58 \pm 0{,}59$	$0{,}58 \pm 0{,}07$	0,9996	$h = 28$	2 sem	0,9886	**0,9928**	3,76%
C_2H_2	$0{,}19 \pm 0{,}01$	$0{,}02 \pm 0{,}01$	0,9996	$h = 98$	7 sem	0,8940	**0,8846***	14,96%
Média	$\mathbf{5{,}59 \pm 0{,}74}$	$\mathbf{1{,}07 \pm 0{,}15}$	**0,9996**	$h = 112$	8 sem	0,8696	0,8380**	17,68%

* $h = 98$ (7 semanas) é o horizonte máximo operacional uniforme ($R^2 \geq 0{,}80$ em todos os gases, $H_2 = 0{,}8483$). Em ** $h = 112$, H_2 cai para $0{,}7877 < 0{,}80$.

3.2 Resultados de Classificação e Ablação no Track A ($N = 900$ Teste, 5.000 Bootstraps)

Configuração	**Atrib.** (p)	F_1**-macro Teste**	**Desvio** (σ)	**IC 95% Bootstrap**	**Contraste Pareado**	ΔF_1	**Valor** p	**Signif.**
C2: Ref. fixa com LSTM	17	**0,8911**	0,0034	[0,8574; 0,9229]	C2 vs. C5a (efeito LSTM fixo)	+0,0056	0,2384	Não sig.
C1: IGA com LSTM	**8**	**0,8909**	0,0011	[0,8549; 0,9230]	C2 vs. C6 (todos vs. só LSTM)	+0,0023	0,6604	Não sig.
C6: Ref. fixa só LSTM	8	0,8888	0,0011	[0,8547; 0,9212]	C1 vs. C2 (IGA vs. 17 atrib.)	−0,0003	0,9956	Não sig.
C5a: Ref. fixa sem LSTM	9	**0,8855**	0,0029	[0,8507; 0,9177]	C1 vs. C5b (efeito LSTM no IGA)	+0,0112	0,3308	Não sig.
C5b: IGA sem LSTM	8	0,8796	0,0051	[0,8469; 0,9110]	C5b vs. C5a (IGA vs. fixo s/ LSTM)	−0,0059	0,5412	Não sig.
C1 s/ LSTM (pós-hoc)	4	0,8280	0,0030	[0,7876; 0,8656]	**Correlação Obs vs. LSTM:** $r > 0{,}997$ ($r^2 > 0{,}994$) em todos os gases!			

Desempenho por Classe em C1 (Teste $N = 900$**):** Normal: 709/731 (recall 97,0%, $F_1 = 0{,}979$) | PD: 34/38 (recall 89,5%, $F_1 = 0{,}895$) | D1: 47/49 (recall 95,9%, $F_1 = 0{,}904$) | T1: 67/82 (81,7%, $F_1 = 0{,}779$).

3.3 Resultados Multiclasse no Track B ($N = 295$ Teste Global 7 Classes | $N = 189$ Falhas 6 Classes | CV 5×5)

Modelo / Método Avaliado	**Atributos**	F_1 **Teste (7 classes)**	**IC 95% (7 classes)**	F_1 **Falhas (6 classes)**	**IC 95% (6 classes)**	F_1 **CV** 5×5 **(25 folds)**
C3: IGA-XGBoost (Proposto)	**16**	**0,7970**	[0,7392; 0,8515]	**0,8000**	[0,7323; 0,8578]	$0{,}7516 \pm 0{,}0281$
C4: XGBoost Ref. Fixa	19	0,7843	[0,7259; 0,8376]	0,7780	[0,7100; 0,8395]	$0{,}7616 \pm 0{,}0226$
M3: Wu et al. (2021) + IGA	14	0,7829	[0,7261; 0,8376]	0,7845	[0,7175; 0,8448]	$0{,}7654 \pm 0{,}0252$
M2: Triângulo 1 de Duval	3 gases	0,3634	[0,3101; 0,4135]	0,4499	[0,3815; 0,5157]	– (93,1% fora de DT)
M1: Razões IEC 60599	5 gases	0,2569	[0,1944; 0,3143]	0,3301	[0,2519; 0,4020]	– (57,1% conclusivos)
Linha de Base (5 gases brutos)	5	0,7250	[0,6587; 0,7851]	–	–	0,7082

Contrastes Bootstrap Track B: C3 vs. M3: $\Delta F_1 = +0{,}0141$ ($[-0{,}0054; +0{,}0368]$, $p = 0{,}1824$, NS) | C3 vs. C4: $\Delta F_1 = +0{,}0127$ ($[-0{,}0211; +0{,}0490]$, $p = 0{,}4680$, NS).

4. Hiperparâmetros Calibrados e Rastreamento Dimensional de Tensores

Hiperparâmetros do Classificador XGBoost					**Configuração da LSTM e do IGA**		
Parâmetro	**Busca IGA**	**Fixo (C2/C4)**	**Track A (C1)**	**Track B (C3)**	**Componente**	**Parâmetro**	**Valor Oficial**
`learning_rate` (η)	[0,01; 0,30]	0,10	**0,1282**	**0,0596**	**LSTM**	Arquitetura	2 camadas × 64 unid.
`max_depth` (D)	[3; 12]	6	**12**	**12**	**LSTM**	Janela / Saída	$w = 50$ passos $\rightarrow$ 4 gases
`n_estimators` (T)	[50; 500]	100	**422**	**342**	**LSTM**	Dropout / LR	0,20 / Adam ($\text{lr} = 10^{-3}$)
`subsample`	[0,50; 1,00]	0,90	**1,0000**	**0,9654**	**LSTM**	Batch / Épocas	1.024 / Paciência 15 ($\approx$ 16 ép.)
`colsample_bytree`	[0,30; 1,00]	1,00	**0,9453**	**0,3433**	**IGA**	População / Ger.	$P = 50$ / $G_{\max} = 100$ (pac. 20)
`gamma` (γ)	[0,00; 5,00]	0,00	**0,0000**	**1,4356**	**IGA**	Crossover (P_c)	0,90 (Unif. bin. + BLX-0,5)
`min_child_weight`	[1; 10]	1	**3**	**3**	**IGA**	Mutação (P_m)	0,10 (Bit-flip + Gauss $\sigma = 0{,}1$)
`reg_alpha` (α, L_1)	[0,00; 1,00]	0,00	**0,1054**	**0,3182**	**IGA**	Seleção / Elitismo	Torneio $k = 3$ / Elitismo = 2
`reg_lambda` (λ, L_2)	[0,00; 5,00]	1,00	**1,5461**	**3,9425**	**IGA**	Viés Inicial IEC	P(razão IEC = 1) = 0,80 (demais 0,5)

Módulo	Tensor / Estrutura	Shape Exato (Dimensões)	Significado Físico e Algorítmico no Código
LSTM	Séries Brutas Track A	Treino $(1785, 420, 4)$ | Val $(315, 420, 4)$ | Teste $(900, 420, 4)$	$N_{\text{séries}} \times 420$ passos de 12h $\times$ 4 gases (H_2, CO, C_2H_4, C_2H_2)
LSTM	Janelas Deslizantes ($w = 50$)	Treino $(660450, 50, 4)$ | Val $(116550, 50, 4)$ | Teste $(333000, 50, 4)$	$N_{\text{séries}} \times (420 - 50) = N_{\text{séries}} \times 370$ janelas por partição
LSTM	Estados Internos / Saída	$\mathbf{h}_t, \mathbf{c}_t \in \mathbb{R}^{B\times 64}$ (Camadas 1 e 2) $\rightarrow \hat{\mathbf{y}} \in \mathbb{R}^{B\times 4}$	Lote $B = 1024$; camada densa linear projeta os 4 gases em $t + 1$
IGA	Cromossomo Bipartido $\mathbf{c}$	Track A: $(26,)$ [17 bin + 9 real] | Track B: $(28,)$ [19 bin + 9 real]	Máscara booleana de seleção + hiperparâmetros normalizados em $[0, 1]$
XGBoost	Matrizes Track A (C2 / C1)	Treino: $(2100, 17) \rightarrow (2100, 8)$ | Teste: $(900, 17) \rightarrow (900, 8)$	Snapshot em $t = 420$ + razões + projeções LSTM ($h = 14, 28$)
XGBoost	Matrizes Track B (C4 / C3)	Treino: $(1372, 19) \rightarrow (1372, 16)$ | Val: $(295, 16)$ | Teste: $(295, 16)$	Pós-`CustomSMOTE` no treino: classes minoritárias igualadas à majoritária
TreeSHAP	`contribs` (*log-odds*)	Track A C1: $(900, 4, 9)$ | Track B C3: $(295, 7, 17)$	$(N_{\text{teste}}, K, p + 1)$: p valores de Shapley $\phi_j^{(c)}$ + última coluna $\phi_0^{(c)}$
TreeSHAP	`interactions` ($\Phi_{i,j}$)	Track B C3: $(295, 7, 17, 17) \rightarrow$ Diagonal `shap_main`: $(295,)$	Diagonal $\Phi_{j,j}^{(c)}$ isola o efeito principal univariado sem sinergias

5. Formulário Matemático Essencial (As Equações-Chave do Projeto)

Equações Fundamentais de Todos os Módulos

1. Transformação Logarítmica, Min-Max e Ponderação (Módulo 1):

$$x_{\log} = \ln(x+1), \quad x_{\text{norm}} = \frac{x_{\log} - x_{\min,\text{treino}}}{x_{\max,\text{treino}} - x_{\min,\text{treino}}}, \quad w_c = \frac{N}{C \cdot N_c} \text{ (Track A)}, \quad \mathbf{g}_{\text{sint}} = \mathbf{g}_i + \lambda(\mathbf{g}_{\text{viz}} - \mathbf{g}_i) \xrightarrow{\text{recálculo}} 19 \text{ atrib. (Track B)}$$

2. Dinâmica Celular da LSTM e Extrapolação Recursiva (Módulo 2):

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{b}_f), \quad \mathbf{i}_t = \sigma(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{b}_i), \quad \tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{o}_t = \sigma(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{b}_o), \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t), \quad \mathbf{X}_{t+1}^{(w)} = \left[\mathbf{x}_{t-w+2}, \ldots, \mathbf{x}_t, \hat{\mathbf{y}}_{t+1}\right]$$

3. Decodificação Afim e Cruzamento BLX-α do IGA (Módulo 3):

$$\theta_k = \text{clip}\Big(a_k + g_k(b_k - a_k),\, a_k,\, b_k\Big), \quad I_k = [c_{\min} - \alpha\Delta_k,\, c_{\max} + \alpha\Delta_k] \text{ com } \Delta_k = |p_{1,k} - p_{2,k}|, \quad \text{Fitness}(\mathbf{c}) = \frac{1}{5}\sum_{k=1}^{5} F_{1,\text{macro}}^{(k)}$$

4. Objetivo Regularizado de 2ª Ordem, Peso Foliar e Ganho de Divisão do XGBoost (Módulo 4):

$$\tilde{\mathcal{L}}^{(t)} \approx \sum_{i=1}^{n}\left[g_i f_t(\mathbf{x}_i) + \frac{1}{2}h_i f_t^2(\mathbf{x}_i)\right] + \gamma T_L + \frac{1}{2}\lambda\sum_{j=1}^{T_L} w_j^2 + \alpha\sum_{j=1}^{T_L}|w_j|, \quad g_{i,c} = p_{i,c} - y_{i,c}, \quad h_{i,c} = p_{i,c}(1-p_{i,c}) \in (0, 0{,}25]$$

$$w_j^* = -\frac{\text{sign}(G_j)\max(0, |G_j| - \alpha)}{H_j + \lambda} \quad \Big(\text{sem } L_1 : w_j^* = -\frac{G_j}{H_j+\lambda}\Big), \quad \text{Gain} = \frac{1}{2}\left[\frac{G_L^2}{H_L+\lambda} + \frac{G_R^2}{H_R+\lambda} - \frac{(G_L+G_R)^2}{H_L+H_R+\lambda}\right] - \gamma$$

5. Valores de Shapley, Aditividade em *Log-Odds*, Interações e Coordenadas de Duval (Módulo 5):

$$\phi_i(v) = \sum_{S\subseteq N\setminus\{i\}} \frac{|S|!(|N|-|S|-1)!}{|N|!}\Big[v(S\cup\{i\}) - v(S)\Big], \quad f_c(\mathbf{x}_i) = \phi_0^{(c)} + \sum_{j=1}^{p}\phi_j^{(c)}(\mathbf{x}_i), \quad \phi_i^{(c)} = \underbrace{\Phi_{i,i}^{(c)}}_{\text{Efeito Principal}} + \sum_{j\neq i}\Phi_{i,j}^{(c)}$$

$$x_{\text{Duval}} = \frac{0{,}5\cdot(2\cdot\%C_2H_4 + \%CH_4)}{100}, \quad y_{\text{Duval}} = \frac{\frac{\sqrt{3}}{2}\cdot\%CH_4}{100} \quad \text{com TH} = CH_4 + C_2H_4 + C_2H_2$$

6. Síntese da Auditoria Normativa e Interpretabilidade Físico-Química (Fase 6)

Parâmetro Químico	Alvo	Norma	TreeSHAP ($\Phi_{i,i} = 0$)	Interpretação Física e Argumento de Defesa
$\%C_2H_4$ (C_2H_4/TH)	D1	$< 23\%$ (Duval)	**20% a 25%**	**Convergência exata:** o modelo aprendeu sozinho a fronteira de 23% que separa descargas puras de falhas térmicas.
$\%C_2H_2$ (C_2H_2/TH)	D1	$\geq 13\%$ (Duval)	$\approx$ **8,0%**	**Maior sensibilidade:** detecta descargas reais de campo antes do corte conservador de 13% fixado na norma.
$\%C_2H_2$ (C_2H_2/TH)	D2	$\geq 13\%/29\%$	$\approx$ **8,6%**	Idem: $\Phi_{i,i} = 0$ marca o início da contribuição aditiva positiva em conjunto com outras razões, não um corte isolado.
Razão C_2H_4/C_2H_6	T3	$> 4{,}0$ (IEC)	$\approx$ **2,97**	Na base real, a mediana de C_2H_4/C_2H_6 em T3 é 0,25; o modelo compensa usando $\%C_2H_6/TH_1$ e antecipa a pirólise.

Estabilidade do Ranking SHAP: Correlação de postos de Spearman entre as 5 sementes no Track B (C3) foi $\rho =$ **0,9541** (muito acima do critério $\rho > 0{,}80$). **Estudo de Caso Local (Waterfall Amostra 11):** Rótulo original de campo era D1, mas XGBoost previu D2 ($f(x) = 2{,}214$ vs. $\phi_0 = 0{,}153$) devido a $\%C_2H_4 = 37{,}7\% > 23\%$ (+0,23) e $\%C_2H_2 \approx 42\%$. Pela própria geometria canônica do Triângulo 1 de Duval, a amostra cai na zona D2 → o modelo corrigiu uma inconsistência de laudo da base!

7. Guia Rápido de Respostas para as 8 Perguntas Mais Difíceis da Banca

Argumentos Técnicos Prontos para Sustentação Oral

1. **"Por que a LSTM não melhorou o diagnóstico no Track A ($\Delta F_1 = +0{,}0056$, $p = 0{,}2384$)? O trabalho falhou?"**
   Defesa: Não falhou; um resultado negativo rigorosamente comprovado é uma contribuição científica valiosa. As séries industriais de Katser possuem altíssima inércia temporal: o baseline de persistência ($\hat{y}_{t+h} = y_t$) já atinge $R^2 = 0{,}9970$ em 1 semana e 0,9886 em 2 semanas. A correlação entre o gás observado e a projeção da LSTM supera $r = 0{,}997$. O TreeSHAP provou o fenômeno de **migração de crédito**: no modelo C1, o crédito oscila entre $H_{2,\text{h}14}$ (65,9%) e $H_{2,\text{h}28}$ (34,1%) entre sementes, mas a soma permanece cravada em $0{,}4734 \pm 0{,}0131$. Logo, para diagnóstico de estado atual em regime lento, um modelo estático enxuto (C5a, $F_1 = 0{,}8855$) dispensa o custo computacional da LSTM.

2. **"Vocês afirmam prever falhas com antecedência, mas os rótulos do Track A são constantes nos 420 passos!"**
   Defesa: Declaramos explicitamente nas Seções 3.1, 3.2.1 e 5.3 que o Track A **não avalia transição de estado ou tempo até a falha** (*Remaining Useful Life*), pois não existe base pública de DGA com séries transicionando espontaneamente do estado

normal para falha. O que avaliamos foi se a extrapolação futura das concentrações gasosas auxiliaria a discriminar o estado operacional associado à série. Como trabalho futuro (Seção 5.4), propomos aplicar a LSTM para prever o instante em que a curva de gases cruzará os limites de alarme em ppm.

3. **"Houve vazamento de dados (*data leakage*) ao gerar previsões da LSTM no treino do XGBoost?"**
   Defesa: As 900 séries de teste permaneceram **100% isoladas e intocadas** durante todo o treinamento da LSTM, do IGA e dos scalers. Reconhecemos na Seção 3.6.1 e na Seção 5.3 que, dentro das 2.100 séries de desenvolvimento, as previsões da LSTM para treinar o XGBoost vieram das mesmas séries que treinaram a LSTM (não foi *out-of-fold*). Contudo, mesmo nesse cenário otimista para a LSTM no treino, ela não trouxe ganho estatístico no teste independente, reforçando ainda mais a nossa conclusão de redundância temporal.

4. **"Por que o desempenho no Track B estacionou em $F_1 \approx 0{,}7970$ (teste) e $0{,}75 - 0{,}76$ (CV), enquanto artigos como Wu et al. (2021) reportam $> 99\%$?"**
   Defesa: Dois motivos fundamentais: (1) Artigos que reportam 99% avaliam partições minúsculas (Wu et al. usaram apenas 25 amostras de teste!) ou não removem duplicatas. Na nossa auditoria, descobrimos que 15,5% da base pública (359 de 2.321) eram cópias idênticas ou conflitantes; sem deduplicação prévia, cópias caem no treino e no teste inflando artificialmente o F_1. (2) Há um **teto empírico imposto pelos dados**: a base reúne laudos heterogêneos com forte sobreposição física (ex.: na classe T3, a mediana de C_2H_4/C_2H_6 é 0,25, quando a IEC exige $> 4{,}0$), o que levou os próprios criadores da base (Li et al., 2019) a proporem lógica difusa.

5. **"Como uma árvore com `max_depth = 12` ($2^{12} = 4.096$ folhas potenciais) não sofreu overfitting severo nas 1.372 amostras de treino do Track B?"**
   Defesa: Porque `max_depth = 12` é apenas um teto teórico, e o IGA compensou essa profundidade com uma **tríade agressiva de regularização**: (1) `colsample_bytree = 0,3433` (cada árvore só enxerga ≈ 5 dos 16 atributos, descorrelacionando o ensemble como uma Random Forest); (2) `reg_lambda = 3,9425` (forte amortecimento Ridge L_2 no denominador do peso foliar $w_j^* = -G_j/(H_j + 3{,}9425)$); e (3) `gamma = 1,4356` e `min_child_weight = 3` (poda severa que exige suporte mínimo de ≈ 12 amostras incertas por folha, visto que $h_{i,c} \leq 0{,}25$).

6. **"Por que a Validação Cruzada Repetida 5×5 (25 dobras) não re-executou o IGA dentro de cada dobra?"**
   Defesa: Por inviabilidade computacional documentada na Seção 3.6.3: uma única corrida do IGA ($P = 50, G = 100, K = 5$) treina até 25.000 modelos XGBoost; aninhar isso nas 25 dobras exigiria 625.000 treinamentos. Por isso, a CV 5×5 (sem SMOTE e com atributos fixos) foi usada estritamente como diagnóstico de estabilidade paramétrica sobre as 1.667 amostras de desenvolvimento, enquanto a prova isenta de viés de seleção é garantida pelo conjunto de teste independente ($N = 295$), que jamais foi visto pelo IGA.

7. **"Por que calcular as razões antes do log/Min-Max e colocar o `CustomSMOTE` antes do `select` no Pipeline?"**
   Defesa: Porque razões molares (C_2H_2/C_2H_4) são grandezas estequiométricas adimensionais definidas na escala física em ppm ($\ln(a+1)/\ln(b+1) \neq a/b$). E no `ImbPipeline`, o `CustomSMOTE` precisa vir antes do `select` porque ele fatia as 5 primeiras colunas ($\mathbf{X}[:, :5]$, gases brutos), interpola os vizinhos no espaço físico e recalcula analiticamente as 14 razões/proporções antes que o seletor do IGA filtre o subconjunto de 16 variáveis.

8. **"Por que o TreeSHAP é calculado na escala de *log-odds* (margens brutas) e não em probabilidades?"**
   Defesa: Porque a função Softmax ($p_{i,c} = e^{f_c} / \sum_k e^{f_k}$) é altamente não-linear e acopla todas as classes no denominador. Na escala de probabilidades, a soma dos efeitos marginais não iguala a predição. Na escala linear das árvores (*log-odds*), o Axioma da Eficiência de Shapley é matematicamente exato: $\sum_{j=1}^{p} \phi_j^{(c)} + \phi_0^{(c)} = f_c(\mathbf{x}_i)$, verificado em código com tolerância $< 10^{-4}$.