MÓDULO 5: INTERPRETABILIDADE FÍSICO-QUÍMICA VIA TREESHAP, AUDITORIA NORMATIVA E NUANCES DE VALIDAÇÃO

Fundamentação dos Valores de Shapley, Algoritmo TreeSHAP Polinomial, Extração de Limiares Térmicos/Elétricos, Análise de Migração de Crédito e Sustentação Oral perante a Banca

Autor: Andrio Gabriel Epp | **Orientação Técnica e Simulação de Banca**

1 Visão Geral e Propósito Estratégico na Defesa

O Módulo 5 representa o ápice da maturidade científica e da integridade técnica do seu Trabalho de Conclusão de Curso. Em aplicações industriais críticas do setor elétrico de potência, modelos de inteligência artificial puramente "caixa-preta" (*black-box*) são sumariamente rejeitados por concessionárias, operadores de sistema (como o ONS) e comitês normativos (CIGRE, IEEE, IEC). Uma alta acurácia estatística é condição necessária, mas não suficiente: é obrigatório demonstrar **como** e **por que** o modelo tomou cada decisão diagnóstica, provando que ele aprendeu princípios termodinâmicos e elétricos legítimos, e não meros artefatos espúrios de amostragem.

Neste módulo, você dominará:

1. A base matemática exata da Teoria dos Jogos Cooperativos de Lloyd Shapley (1953) e sua transposição para Aprendizado de Máquina (Lundberg & Lee, 2017).
2. O algoritmo **TreeSHAP** (Lundberg et al., 2020), que reduz a complexidade combinatória exponencial $\mathcal{O}(M2^M)$ para tempo polinomial estrito $\mathcal{O}(TLD^2)$, calculando contribuições aditivas exatas na escala de *log-odds*.
3. A decomposição de interações e o isolamento do **Efeito Principal Univariado** ($\Phi_{i,i}$) via suavização LOWESS, provando a extração autônoma de limiares físicos comparáveis à IEC 60599 e ao Triângulo 1 de Duval.
4. O fenômeno da **Migração de Crédito** entre variáveis gêmeas/colineares, que fundamenta matematicamente o desfecho da Hipótese Temporal no Track A.
5. O roteiro contundente de defesa para as principais vulnerabilidades metodológicas do trabalho (rótulos estáticos ao longo do tempo e vazamento interno no treino híbrido).

—

2 Pilar 1: Fundamentação Matemática e Teórica

2.1 Teoria dos Jogos Cooperativos de Lloyd Shapley (1953)

Considere um jogo cooperativo com utilidade transferível definido pelo par (N, v), onde:

- $N = \{1, 2, \ldots, M\}$ é o conjunto finito de M jogadores (no nosso contexto, o conjunto de atributos de entrada $\mathbf{x} = [x_1, \ldots, x_M]^T$).
- $v : \mathcal{P}(N) \to \mathbb{R}$ é a **função característica de valor**, que mapeia cada subconjunto (coalizão) $S \subseteq N$ em um ganho escalar real $v(S)$, com a convenção de jogo vazio $v(\emptyset) = 0$.

O problema econômico fundamental formulado por Lloyd Shapley é: *como distribuir o ganho total da grande coalizão $v(N)$ entre os M jogadores de forma unicamente justa e equilibrada?*

Shapley provou analiticamente que existe uma **única regra de atribuição** $\phi(v) = [\phi_1(v), \ldots, \phi_M(v)]^T$ que satisfaz simultaneamente quatro axiomas fundamentais de justiça:

Equação Clássica do Valor de Shapley

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!\,(|N| - |S| - 1)!}{|N|!} \left[v(S \cup \{i\}) - v(S)\right]$$

Onde:

- $S \subseteq N \setminus \{i\}$ representa todas as possíveis coalizões formadas sem o jogador i.
- $[v(S \cup \{i\}) - v(S)]$ é a **contribuição marginal** proporcionada pela entrada do jogador i à coalizão S.
- $\frac{|S|!\,(|N|-|S|-1)!}{|N|!}$ é a probabilidade combinatória uniforme de que a coalizão S seja formada antes da chegada do jogador i, considerando todas as $|N|!$ ordens possíveis de inserção aleatória dos jogadores.

2.2 Os Quatro Axiomas Clássicos de Shapley

1. **Eficiência (Aditividade Local):** A soma de todas as atribuições individuais esgota exatamente o valor total gerado pela grande coalizão:

$$\sum_{i \in N} \phi_i(v) = v(N) - v(\emptyset)$$

2. **Simetria:** Se dois jogadores i e j geram exatamente a mesma contribuição marginal para qualquer coalizão $S \subseteq N \setminus \{i, j\}$ tal que $v(S \cup \{i\}) = v(S \cup \{j\})$, então seus valores de Shapley são idênticos:

$$\phi_i(v) = \phi_j(v)$$

3. **Jogador Nulo (*Dummy/Null Player*):** Se um jogador i não agrega valor a nenhuma coalizão possível, isto é, $v(S \cup \{i\}) = v(S)$ para todo $S \subseteq N \setminus \{i\}$, sua contribuição é nula:

$$\phi_i(v) = 0$$

4. **Aditividade (Linearidade):** Se dois jogos cooperativos independentes com funções características u e v são combinados em um único jogo $(u + v)$, o valor de Shapley da soma é a soma dos valores de Shapley:

$$\phi_i(u + v) = \phi_i(u) + \phi_i(v)$$

2.3 Transposição para Aprendizado de Máquina (Lundberg & Lee, 2017)

Ao transpor os valores de Shapley para a explicabilidade de modelos preditivos $f(\mathbf{x})$, os jogadores passam a ser os atributos de entrada $\mathbf{x} = [x_1, \ldots, x_M]^T$. Para calcular a função de valor $v(S)$ de um subconjunto de features presentes $S \subseteq N$, é necessário marginalizar os atributos ausentes $N \setminus S$.

Na formulação condicional padrão:

$$v(S) = \mathbb{E}_{\mathbf{X}_{\bar{S}} | \mathbf{X}_S = \mathbf{x}_S} \left[f(\mathbf{x}_S, \mathbf{X}_{\bar{S}})\right]$$

O axioma da **Eficiência** assume a forma de aditividade local em relação à previsão basal esperada $\phi_0 = \mathbb{E}[f(\mathbf{X})]$:

$$f(\mathbf{x}) = \phi_0 + \sum_{i=1}^{M} \phi_i(\mathbf{x})$$

2.4 O Algoritmo TreeSHAP e a Dedução da Complexidade Polinomial

Em abordagens agnósticas de modelo (*model-agnostic*), como o KernelSHAP, calcular ϕ_i exige avaliar $f(\mathbf{x})$ sobre todas as 2^M combinações de atributos possíveis. Para um vetor com $M = 16$ atributos, $2^{16} = 65.536$ avaliações seriam necessárias **para cada uma das amostras de teste**, tornando a auditoria computacionalmente inviável.

O algoritmo **TreeSHAP** (Lundberg et al., Nature Machine Intelligence, 2020) resolve este gargalo ao explorar a estrutura hierárquica das Árvores de Decisão (CART) que compõem o XGBoost.

Uma árvore T_k particiona recursivamente o espaço de atributos em hiper-retângulos ortogonais disjuntos. Em cada nó interno, a decisão depende de uma única variável. O TreeSHAP calcula a esperança condicional descendo recursivamente pela árvore e monitorando as frações de amostras de treinamento que percorrem as subárvores esquerda e direita (*cobertura do nó*).

Complexidade Computacional: Exponencial vs Polinomial

$$\text{KernelSHAP (Agnóstico): } \mathcal{O}\left(N_{\text{amostras}} \cdot M \cdot 2^M\right)$$

$$\text{TreeSHAP (Exato para Árvores): } \mathcal{O}\left(N_{\text{amostras}} \cdot T \cdot L \cdot D^2\right)$$

Onde:

- T: Número de árvores no ensemble ($T = \texttt{n_estimators} = 422$ no Track A C1; 342 no Track B C3).
- L: Número médio de folhas terminais por árvore ($L \leq 2^D$).
- D: Profundidade máxima da árvore ($D = \texttt{max_depth} = 12$).
- M: Número de variáveis ($M = 16$).

Como $D^2 = 144$ e a profundidade efetiva real média das árvores após poda por γ fica entre 4 e 6 ($D^2_{\text{efetivo}} \approx 25$), o TreeSHAP executa o cálculo rigoroso dos valores de Shapley das 900 amostras do Track A em poucos segundos.

2.5 Escala das Contribuições no XGBoost: Margens Lineares (*Log-Odds*)

No XGBoost multi-classe com objetivo `multi:softprob`, o modelo produz para cada classe $c \in \{0, 1, 2, 3\}$ uma margem bruta contínua $\hat{y}_{i,c} = f_c(\mathbf{x}_i) \in \mathbb{R}$. A probabilidade final é gerada pela função Softmax:

$$p_{i,c} = \frac{\exp(f_c(\mathbf{x}_i))}{\sum_{k=0}^{K-1} \exp(f_k(\mathbf{x}_i))}$$

Propriedade Matemática Crítica: Escala Aditiva vs Não-Linear

A transformação Softmax é estritamente não-linear. Se tentássemos calcular o SHAP diretamente no espaço de probabilidades $[0, 1]$, a propriedade de aditividade exata $\sum \phi_i = p_{i,c} - \mathbb{E}[p_c]$ seria violada por causa da saturação exponencial do denominador da Softmax.
Por isso, no seu projeto (Seção 3.7 e Seção 4.5), o TreeSHAP é executado diretamente na escala de **margens lineares brutas (*log-odds*)**, onde a aditividade local é estritamente preservada:

$$f_c(\mathbf{x}_i) = \phi_0^{(c)} + \sum_{j=1}^{M} \phi_j^{(c)}(\mathbf{x}_i)$$

2.6 Matriz de Interação SHAP e Efeito Principal Univariado ($\Phi_{i,i}$)

O TreeSHAP permite expandir a atribuição de primeira ordem para uma matriz completa de interações de segunda ordem baseada no valor de interação de Shapley-Banzhaf:

$$\Phi_{i,j}^{(c)} = \sum_{S \subseteq N \setminus \{i,j\}} \frac{|S|!\,(|N| - |S| - 2)!}{2(|N| - 1)!} \left[v(S \cup \{i,j\}) - v(S \cup \{i\}) - v(S \cup \{j\}) + v(S) \right]$$

Propriedade de decomposição aditiva:

$$\phi_i^{(c)} = \Phi_{i,i}^{(c)} + \sum_{j \neq i} \Phi_{i,j}^{(c)}$$

- $\Phi_{i,i}^{(c)}$ (**Efeito Principal Univariado**): Mede o impacto intrínseco puro da variável i isolado de qualquer sinergia ou correlação com outras variáveis.
- $\Phi_{i,j}^{(c)}$ (**Efeito de Interação Bivariado**): Mede a variação na atribuição quando as variáveis i e j ocorrem simultaneamente, deduzidos seus efeitos isolados.

2.7 Extração Analítica de Limiares Físicos via LOWESS

No seu código (`fase6_shap_track_b.py`), o efeito principal $\Phi_{i,i}^{(c)}$ é confrontado diretamente contra a concentração física real desnormalizada da variável x_i (em ppm ou em % de razão DGA). Aplica-se a regressão não-paramétrica localmente ponderada (**LOWESS** - *Locally Weighted Scatterplot Smoothing*) para estimar a curva contínua $\hat{g}(x_i) = \mathbb{E}[\Phi_{i,i}^{(c)} \mid X_i = x_i]$.

O **Limiar Físico Marginal Aprendido** (x_i^*) é a raiz analítica da curva de efeito principal:

$$\hat{g}(x_i^*) = 0 \iff \Phi_{i,i}^{(c)}(x_i^*) = 0$$

- Para $x_i < x_i^*$: $\Phi_{i,i}^{(c)} < 0$ (a variável atua inibindo ou reduzindo a probabilidade daquela falha).
- Para $x_i > x_i^*$: $\Phi_{i,i}^{(c)} > 0$ (a variável passa a atuar positivamente, empurrando o transformador em direção ao estado de falha).

2.8 Mapeamento Geométrico no Triângulo 1 de Duval

O Triângulo 1 de Duval utiliza três gases de decomposição térmica e elétrica expressos em porcentagens relativas do total $\mathrm{TH} = \mathrm{CH_4} + \mathrm{C_2H_4} + \mathrm{C_2H_2}$:

$$\%\mathrm{CH_4} = \frac{\mathrm{CH_4}}{\mathrm{TH}} \times 100, \quad \%\mathrm{C_2H_4} = \frac{\mathrm{C_2H_4}}{\mathrm{TH}} \times 100, \quad \%\mathrm{C_2H_2} = \frac{\mathrm{C_2H_2}}{\mathrm{TH}} \times 100$$

Com a restrição de fecho simplex $\%\mathrm{CH_4} + \%\mathrm{C_2H_4} + \%\mathrm{C_2H_2} = 100\%$.

A transformação do espaço simplex baricêntrico para o plano cartesiano bidimensional (x, y) implementada no código (`fase6_shap_extras.py`) é governada pelas equações trigonométricas de projeção em triângulo equilátero:

$$x = \frac{0{,}5 \cdot (2 \cdot \%\mathrm{C_2H_4} + \%\mathrm{CH_4})}{100}, \qquad y = \frac{\frac{\sqrt{3}}{2} \cdot \%\mathrm{CH_4}}{100}$$

—

3 Pilar 2: Rastreamento no Código (Linha a Linha)

3.1 Extração de SHAP e Verificação de Aditividade no Booster C++

No script `fase6_shap_track_b.py` (linhas 215 a 240), a extração dos valores de Shapley é realizada diretamente pelo motor C++ nativo do XGBoost via estrutura `DMatrix`:

```
dtest = xgb.DMatrix(X_test_model)

# Extrai contribuicoes SHAP: shape (n_samples, n_classes, n_features + 1)
contribs = booster.predict(dtest, pred_contribs=True)

# Extrai a margem bruta (log-odds) real predita pelo modelo
margin = booster.predict(dtest, output_margin=True)

# Verificacao formal do Axioma da Eficiencia de Shapley:
assert np.allclose(contribs.sum(axis=-1), margin, atol=1e-4), \
    "Falha na verificacao de aditividade do SHAP!"

# Isola os valores de Shapley descartando a ultima coluna (bias/phi_0)
contribs_feats = contribs[:, :, :-1]
```

3.2 Cálculo da Matriz de Interações e Efeito Principal

Nas linhas 250 a 275 de `fase6_shap_track_b.py`:

```
# Extrai o tensor de interacoes de segunda ordem:
# Shape resultante: (n_samples, n_classes, n_features + 1, n_features + 1)
interactions = booster_42.predict(dtest, pred_interactions=True)

# Extrai o Efeito Principal Univariado (diagonal da matriz de interacao):
# feat_name: indice da feature; class_name: indice da classe
f_idx = feature_names.index("ratio_C2H4_TH")
c_idx = class_names.index("D1")
shap_main = interactions[:, c_idx, f_idx, f_idx]

# Ajuste da curva LOWESS para extracao do limiar em phi_main = 0:
smoothed = lowess(shap_main[mask], x_vals_unscaled[mask], frac=0.3)
```

3.3 Análise de Migração de Crédito no Track A

No script `fase6_shap_track_a.py` (linhas 45 a 90), a função `plot_lstm_credit_migration` analisa a alocação de crédito entre as variáveis gêmeas de hidrogênio $H_{2,h14}$ e $H_{2,h28}$:

```
idx_h14 = feature_names.index("lstm_h14_H2")
idx_h28 = feature_names.index("lstm_h28_H2")

# shap_por_seed tem shape (n_seeds, n_features)
impact_h14 = shap_por_seed[:, idx_h14]
impact_h28 = shap_por_seed[:, idx_h28]
soma_total_h2 = impact_h14 + impact_h28

pct_h14 = (impact_h14 / soma_total_h2) * 100
pct_h28 = (impact_h28 / soma_total_h2) * 100
```

3.4 Rastreamento Dimensional de Tensores e Matrizes

A Tabela 1 sintetiza as dimensões dos tensores envolvidos na pipeline do TreeSHAP:

Tabela 1: Mapeamento Dimensional das Estruturas de Dados no TreeSHAP.

Tensor / Variável	Origem	Shape	Significado Físico / Algorítmico
`X_test_model`	Teste	$(900, 8)$ ou $(295, 16)$	Matriz de atributos de teste após seleção do IGA (Track A C1 / Track B C3)
`margin`	XGBoost	(N_{teste}, K)	Margens lineares brutas preditas ($\hat{y}_{i,c}$ em *log-odds*, $K = 4$ ou 7)
`contribs`	`pred_contribs`	$(N_{\text{teste}}, K, p+1)$	Contribuições aditivas: p features + 1 termo basal (ϕ_0)
`contribs_feats`	Fatiamento	(N_{teste}, K, p)	Valores de Shapley puros ($\phi_{i,c,j}$) por amostra, classe e feature
`mean_abs_shap`	`np.mean`	(p, K)	Importância média global absoluta $E[\lvert\phi\rvert]$ por classe
`interactions`	`pred_interactions`	$(N_{\text{teste}}, K, p+1, p+1)$	Tensor completo de interações de segunda ordem ($\Phi_{i,j}$)
`shap_main`	Diagonal	$(N_{\text{teste}},)$	Efeito principal isolado $\Phi_{j,j}$ da feature j na classe c

—

4 Pilar 3: Decisões de Projeto e Nuances do Trabalho

4.1 Por que TreeSHAP e não KernelSHAP ou LIME?

1. **Acurácia Matemática vs Aproximação Amostral:** O KernelSHAP e o LIME dependem de perturbações estocásticas em torno da amostra. Em espaços altamente colineares (como gases DGA), perturbar um gás isoladamente gera combinações fisicamente impossíveis no óleo isolante. O TreeSHAP avalia os caminhos condicionados reais de treinamento sem sintetizar amostras fora da distribuição (*out-of-distribution*). 2. **Tempo de Execução:** Enquanto o KernelSHAP levaria horas para calcular atribuições para 900 amostras com 16 atributos, o TreeSHAP executa em menos de 5 segundos via C++. 3. **Axiomas Garantidos:** O LIME não satisfaz nem o axioma da Eficiência nem o da Consistência; apenas o TreeSHAP garante a fidelidade matemática aos valores de Shapley.

4.2 Confronto Físico-Químico com Normas: O Significado das Discrepâncias

A Tabela 2 reproduz os limiares extraídos do seu modelo confrontados com as normas:

Tabela 2: Confronto entre Limiares Aprendidos pelo TreeSHAP e Normas Técnicas.

Parâmetro Químico	Falha Alvo	Limiar Normativo	Limiar Marginal Extraído
Percentual $\%C_2H_4$ (C_2H_4/TH)	D1	$< 23\%$ (Duval 1)	Faixa entre 20% e 25%
Percentual $\%C_2H_2$ (C_2H_2/TH)	D1	$\geq 13\%$ (Duval 1)	$\approx 8{,}0\%$
Percentual $\%C_2H_2$ (C_2H_2/TH)	D2	$\geq 13\%$ ou 29%	$\approx 8{,}6\%$
Razão C_2H_4/C_2H_6	T3	$> 4{,}0$ (IEC 60599)	$\approx 2{,}97$

Como justificar essas discrepâncias na banca:

- **Convergência Perfeita em $\%C_2H_4$ ($20\% - 25\%$):** Mostra que o modelo reproduziu autonomamente a fronteira de 23% que delimita a transição de descargas elétricas para falhas com envolvimento térmico no Triângulo de Duval.

- **Limiares Mais Baixos em Acetileno (8,0% vs 13%) e na Razão C_2H_4/C_2H_6 (2,97 vs 4,0):** As normas internacionais foram calibradas de forma ultra-conservadora na década de 1970/1990 para evitar falsos alarmes em inspeções manuais esparsas. Em transformadores reais com laudos de campo certificados, o modelo detectou descargas e sobreaquecimentos severos incipientes antes de os gases atingirem os cortes rígidos normativos. Além disso, o limiar de $\Phi_{i,i} = 0$ indica o ponto em que a variável começa a contribuir positivamente, atuando em conjunto com outros gases, e não como uma regra de corte disjuntiva única.

4.3 A Descoberta da Migração de Crédito e o Fim da Hipótese Temporal

No Track A, a grande pergunta de pesquisa era: *a previsão dos gases futuros via LSTM melhora o diagnóstico de defeitos do transformador?*

A análise empírica oficial (Tabela **??** do TCC) mostrou que o modelo C1 (híbrido IGA com LSTM, 8 atributos) obteve F_1-macro de $0{,}8909 \pm 0{,}0011$, enquanto a referência fixa sem LSTM C5a (9 atributos) obteve $0{,}8855 \pm 0{,}0029$, e o modelo completo C2 (17 atributos) atingiu $0{,}8911 \pm 0{,}0034$. No teste pareado por *bootstrap* (5.000 iterações), a diferença C2 vs. C5a foi de apenas $\Delta F_1 = +0{,}0056$ ($p = 0{,}2384$, não significativa), e C1 vs. C2 foi de $-0{,}0003$ ($p = 0{,}9956$). A Figura 7 do TCC e a análise de TreeSHAP revelaram a causa exata desse comportamento:

- Ao analisar as previsões gêmeas de hidrogênio ($H_{2,h14}$ e $H_{2,h28}$), o IGA descartou o gás medido atual $H_{2,obs}$ e reteve as duas projeções.
- Entre sementes de treinamento distintas, a importância individual oscilou bruscamente (na Seed 42, 65,5% do peso foi para h14 e 34,5% para h28; na Seed 456, a divisão foi de 68,1% e 31,9%).
- **Contudo, a soma do impacto de hidrogênio permaneceu rigorosamente constante: $0{,}4734 \pm 0{,}0131$.**

Isso comprova que a inclusão das projeções da LSTM não inseriu informação ortogonal discriminativa nova sobre o estado de defeito do transformador, mas apenas provocou uma redistribuição estocástica de crédito nos nós das árvores entre atributos colineares.

4.4 Auditoria de Vulnerabilidades Técnicas perante a Banca

Como Responder aos Pontos Mais Delicados do Projeto

1. O trabalho não demonstra previsão temporal de transição de falhas: Cada uma das 3.000 séries temporais do Track A mantém o mesmo rótulo de defeito durante todos os 420 instantes. O trabalho prevê a evolução física das concentrações de gases, e não o momento exato de transição de estado normal para falha. Na defesa, afirme: *"Reconhecemos explicitamente essa limitação na Seção 5.3. A base de dados adotada não continha séries com transição incipiente espontânea de classes. O que nosso trabalho comprovou foi a viabilidade da cadeia híbrida acoplada e a inércia dos gases dissolvidos."*

2. Assimetria no treinamento híbrido (Vazamento parcial da LSTM): A LSTM gerou projeções para treinar o XGBoost usando os mesmos dados em que foi treinada. Na defesa, afirme: *"Os 900 transformadores de teste permaneceram absolutamente blindados e intocados. Essa assimetria interna de desenvolvimento foi documentada com transparência na Seção 3.6.1 e Seção 5.3 como uma diretriz para adoção futura de K-fold stacking estrito."*

—

5 Pilar 4: Sabatina da Banca (Arguição de Alta Dificuldade)

Aqui estão três perguntas de alta complexidade conceitual e técnica, formuladas sob a ótica de examinadores rigorosos, com suas respectivas defesas ideais.

5.1 Pergunta 1 (Examinador Especialista em Teoria de Aprendizado e XAI)

"O cálculo dos valores de Shapley clássicos possui complexidade combinatória $\mathcal{O}(M2^M)$, o que inviabilizaria sua aplicação para vetores com dezenas de atributos. Como o algoritmo TreeSHAP consegue calcular as atribuições exatas em tempo polinomial $\mathcal{O}(TLD^2)$? E qual a implicação matemática de calcular os valores de Shapley no espaço de log-odds (margens lineares) em vez do espaço de probabilidades da Softmax?"

5.1.1 Resposta Ideal de Defesa:

"Professor, o avanço matemático fundamental do TreeSHAP decorre da exploração direta da estrutura topológica das Árvores de Decisão (CART) que formam o XGBoost.

No KernelSHAP clássico, estimar a função de valor $v(S) = \mathbb{E}[f(\mathbf{x}) \mid \mathbf{X}_S = \mathbf{x}_S]$ exige criar máscaras binárias sobre todas as 2^M coalizões possíveis e amostrar dados do conjunto de fundo (*background*). O TreeSHAP, por outro lado, calcula essa esperança condicional em uma única passada recursiva pela árvore. Como cada nó interno realiza um teste sobre uma única variável particionando o espaço em duas regiões mutuamente exclusivas, a esperança condicional para atributos ausentes $N \setminus S$ pode ser computada ponderando recursivamente os nós filhos pela proporção de instâncias de treinamento que fluem por cada ramo (*cobertura do nó*). Lundberg et al. demonstraram que esse rastreamento pode ser mantido em uma estrutura que escala com a profundidade máxima da árvore D e o número de folhas L. Para um ensemble com T estimadores, o custo global é reduzido para $\mathcal{O}(TLD^2)$, o que torna o cálculo exato e determinístico em poucos segundos.

Quanto à segunda parte da sua pergunta, a escolha da escala é um divisor de águas matemático. No XGBoost multi-classe com objetivo `multi:softprob`, o ensemble de árvores produz uma margem linear contínua $\hat{y}_{i,c} \in \mathbb{R}$ para cada classe, que é posteriormente mapeada em probabilidade pela função Softmax $p_{i,c} = \exp(\hat{y}_{i,c}) / \sum \exp(\hat{y}_{i,k})$.

Se calculássemos o SHAP diretamente sobre a probabilidade $p_{i,c}$, violaríamos o axioma da **Eficiência de Shapley**, porque a Softmax introduz um acoplamento não-linear global entre todas as classes no denominador, gerando saturação e distorcendo as contribuições aditivas. Ao operarmos no espaço de ***log-odds*** (as margens lineares antes da Softmax), a aditividade local é matematicamente exata:

$$f_c(\mathbf{x}_i) = \phi_0^{(c)} + \sum_{j=1}^{M} \phi_j^{(c)}(\mathbf{x}_i)$$

Isso garante que cada valor de Shapley $\phi_j^{(c)}$ represente exatamente o deslocamento aditivo em unidades logarítmicas de evidência que a variável j exerceu a favor ou contra a hipótese de falha da classe c, permitindo que nós confrontemos esses efeitos com os limiares físicos normativos."

5.2 Pergunta 2 (Examinador do Setor Elétrico / Normatização Técnica)

"A Tabela 14 do seu trabalho confronta os limiares extraídos pelo TreeSHAP com os limites normativos da IEC 60599 e do Triângulo de Duval. O modelo aprendeu um limiar de corte de aproximadamente 2,97 *para a razão C_2H_4/C_2H_6 na classe de falhas térmicas T3, enquanto a IEC 60599 fixa rigidamente* $> 4{,}0$. *Além disso, para descargas D1 e D2, o teor de acetileno aprendido foi de* $\approx 8{,}0\%$, *contra* 13% *da norma. O seu modelo está subdimensionado e propenso a emitir alarmes falsos prematuros ou as normas internacionais estão equivocadas?"*

5.2.1 Resposta Ideal de Defesa:

"Essa divergência aparente reflete a diferença conceitual profunda entre um **limiar de corte regulatório determinístico** e um **ponto de transição marginal probabilístico**.

As normas técnicas internacionais, como a IEC 60599 e o Triângulo 1 de Duval, foram desenvolvidas e consolidadas nas décadas de 1970 a 1990 com base em critérios empíricos conservadores. O objetivo dessas normas era permitir que operadores humanos em subestações tomassem decisões visuais a partir de laudos esparsos de cromatografia anual, estabelecendo limiares elevados (como $C_2H_4/C_2H_6 > 4{,}0$ e $\%C_2H_2 \geq 13\%$) para evitar ao máximo paradas programadas desnecessárias em frotas de transformadores estáveis.

No entanto, o XGBoost otimizado por IGA foi treinado sobre transformadores reais de campo contendo inspeções e diagnósticos físicos validados. A análise da matriz de interações do TreeSHAP, ao isolar o efeito principal $\Phi_{i,i}$, não busca uma regra de corte disjuntiva única. O ponto $\Phi_{i,i} = 0$ indica o momento exato em que a presença daquele gás passa a atuar como uma evidência favorável à falha na pontuação linear do modelo.

Nos dados empíricos de campo, um transformador com razão $C_2H_4/C_2H_6 = 3{,}2$ já apresenta um processo incipiente e inequívoco de pirólise severa do óleo isolante na faixa de transição para alta temperatura ($> 700°C$). Se nos apegássemos rigidamente ao corte de 4,0 da IEC, esse transformador seria classificado como T2 (falha média) ou cairia em zona indefinida, retardando a manutenção preventiva. Da mesma forma, transformadores com 8,0% a 9,0% de acetileno já possuíam laudo comprovado de micro-arcos e descargas elétricas no óleo, o que o modelo capturou com fidelidade ao acoplar o efeito do acetileno com as razões de etano e etileno.

Portanto, o modelo não está emitindo alarmes falsos; ele é estatisticamente mais sensível e dinâmico que os cortes normativos estáticos, antecipando o diagnóstico de degradação incipiente sem violar a física da decomposição molecular dos hidrocarbonetos."

5.3 Pergunta 3 (Examinador Crítico de Desenho Metodológico)

"No Track A, cada uma das 3.000 séries temporais mantém rigorosamente o mesmo rótulo de falha ao longo de todos os 420 passos de tempo. Se o transformador nunca muda de estado durante a série temporal, como o trabalho pode sustentar que realizou a 'previsão de falhas com antecedência de 14 e 28 dias'? O que foi previsto não foram apenas os gases futuros através de uma regressão cega, sem comprovação de que o sistema anteciparia o surgimento de uma falha real?"

5.3.1 Resposta Ideal de Defesa:

"Agradeço imensamente por esta pergunta, Professor, pois ela toca no núcleo metodológico mais importante do nosso trabalho e reflete a postura de transparência e rigor que adotamos no texto.

O senhor está coberto de razão em sua observação: o nosso trabalho **não realizou a previsão temporal de eventos de transição de falha**. Nós não acompanhamos um transformador que operava normalmente no instante $t = 0$ e que veio a desenvolver uma falha térmica no instante $t = 420$. Cada série temporal do Track A pertence a um transformador cujo estado de integridade era estático ao longo de todo o período monitorado. Essa limitação está expressamente reconhecida e detalhada na Seção 3.2.1 e na Seção 5.3 da dissertação.

O que a nossa arquitetura implementou e avaliou foi uma **cadeia de inferência desacoplada em dois estágios**:

1. No primeiro estágio, uma rede neural recorrente LSTM multivariada realiza a previsão das trajetórias futuras das concentrações dos 4 gases monitorados no Track A (H_2, CO, C_2H_4, C_2H_2) nos horizontes de 14 e 28 passos à frente ($h = 14$ e $h = 28$, equivalentes a 7 e 14 dias).

2. No segundo estágio, o classificador XGBoost mapeia o perfil dos atributos estáticos e projetados para o estado de integridade associado ao equipamento.

O achado científico fundamental do nosso trabalho no Track A foi justamente colocar à prova a premissa de que a adição de projeções temporais de gases traria ganhos diagnósticos expressivos. Conforme demonstramos experimentalmente:

- O modelo C1 (híbrido com LSTM, 8 atributos) obteve F_1-macro de $0{,}8909 \pm 0{,}0011$, enquanto a referência estática pura C5a (9 atributos observados, sem LSTM) obteve $0{,}8855 \pm 0{,}0029$, e o modelo completo C2 (17 atributos) obteve $0{,}8911 \pm 0{,}0034$. No teste pareado por *bootstrap*, a diferença não é estatisticamente significativa ($p = 0{,}2384$).
- A análise de SHAP comprovou que os gases dissolvidos no óleo isolante possuem elevadíssima inércia química. As previsões geradas pela LSTM para $h = 14$ e $h = 28$ apresentaram correlação superior a 0,99 com as leituras do tempo presente ($r > 0{,}997$), fazendo com que o XGBoost apenas dividisse o crédito preditivo entre variáveis gêmeas sem obter nenhuma informação discriminativa ortogonal nova.

Assim, em vez de vender uma ilusão de previsão antecipada que os dados não sustentavam, o nosso trabalho contribui para a literatura ao demonstrar de forma quantitativa e explicável via TreeSHAP que, em séries cromatográficas com dinâmica lenta e rótulo fixo, o investimento computacional em modelos preditivos temporais complexos é injustificado frente a classificadores tabulares estáticos bem regularizados."

Fim do Módulo 5 | Arquitetura Híbrida Completa Dominada para a Defesa de TCC