**UNIVERSIDADE DO VALE DO RIO DOS SINOS – UNISINOS**

**UNIDADE ACADÊMICA DE GRADUAÇÃO**

**CURSO DE ENGENHARIA DA COMPUTAÇÃO**

**ÂNDRIO GABRIEL EPPING**

# PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

**SÃO LEOPOLDO**

**2026**

ÂNDRIO GABRIEL EPPING

# PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

Trabalho de Conclusão de curso apresentado como requisito parcial para obtenção do título de Bacharel em Engenharia da Computação, pelo curso de Engenharia da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS).

Orientador: Profa. Me. Janaína Conceição Sutil Lemos

SÃO LEOPOLDO

2026

# RESUMO

Os transformadores de potência são equipamentos essenciais nos sistemas de energia elétrica, apresentando alto custo e grande impacto operacional. Falhas nesses equipamentos podem provocar interrupções no fornecimento de energia e prejuízos significativos. Nesse contexto, a Análise de Gases Dissolvidos (DGA) destaca-se como uma das principais técnicas para o monitoramento da condição interna dos transformadores. Entretanto, métodos tradicionais de interpretação dos resultados da DGA, como o Triângulo de Duval e o Método de Rogers, apresentam limitações devido às suas fronteiras fixas, o que pode levar a diagnósticos imprecisos ou indeterminados. Com o avanço das técnicas de Inteligência Artificial, novas abordagens têm sido propostas para superar essas limitações. No entanto, grande parte dessas soluções ainda se concentra na identificação de falhas já existentes, caracterizando uma abordagem reativa. Diante disso, este trabalho propõe o desenvolvimento de um modelo híbrido com foco em manutenção preditiva, estruturado em dois estágios. No primeiro estágio, é utilizada uma rede neural do tipo LSTM para prever, a partir de séries temporais, a concentração futura dos gases dissolvidos. No segundo estágio, aplica-se um Algoritmo Genético Melhorado (IGA) com o objetivo de selecionar as variáveis mais relevantes e otimizar os hiperparâmetros de um classificador baseado no algoritmo XGBoost. Espera-se que a abordagem proposta contribua para melhorar a precisão na previsão de falhas incipientes, possibilitando uma gestão mais eficiente dos ativos e antecipando a tomada de decisão em sistemas elétricos.

**Palavras-chave**: Transformadores de Potência, Análise de Gases Dissolvidos, Previsão de Falhas, Redes LSTM, XGBoost, Algoritmo Genético.

# ABSTRACT

Power transformers are essential components in electrical power systems, involving high costs and significant operational impact. Failures in these devices can lead to power supply interruptions and substantial economic losses. In this context, Dissolved Gas Analysis (DGA) stands out as one of the main techniques for monitoring the internal condition of transformers. However, traditional methods for interpreting DGA results, such as the Duval Triangle and Rogers Ratio Method, present limitations due to their fixed boundaries, which may result in imprecise or inconclusive diagnoses. With the advancement of Artificial Intelligence techniques, new approaches have been proposed to overcome these limitations. Nevertheless, most of these solutions still focus on identifying faults that have already occurred, representing a reactive approach. Therefore, this work proposes the development of a hybrid model focused on predictive maintenance, structured in two stages. In the first stage, a Long Short-Term Memory (LSTM) neural network is used to forecast the future concentration of dissolved gases based on time series data. In the second stage, an Improved Genetic Algorithm (IGA) is applied to select the most relevant features and to optimize the hyperparameters of an Extreme Gradient Boosting (XGBoost) classifier. The proposed approach is expected to improve the accuracy of incipient fault prediction, enabling more efficient asset management and supporting earlier decision-making in electrical power systems.



**Keywords**: Power transformers, Dissolved Gas Analysis, Fault Prediction, LSTM neural network, XGBoost, Improved Genetic Algorithm.

# LISTA DE ILUSTRAÇÕES

Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA abordagem reativa (métodos tradicionais) e abordagem preditiva (proposta deste trabalho). Fonte: Elaborado pelo autor . . . . . 12
Figura 2 – Triângulo de Duval. Fonte: Extraído de (ALI et al., 2023) . . . . . 18
Figura 3 – Esquema de construção sequencial no XGBoost. Fonte: elaborado pelo autor. . . . . 25
Figura 4 – Estrutura da Célula LSTM. Fonte: Elaborado pelo autor com auxílio de ferramenta de inteligência artificial generativa, baseado em (HOCHREITER; SCHMIDHUBER, 1997) . . . . . 27
Figura 5 – LSTM empilhadas. Fonte: Elaborado pelo autor com auxílio de ferramenta de inteligência artificial generativa, baseado em (HOCHREITER; SCHMIDHUBER, 1997) . . . . . 28
Figura 6 – Ciclo evolutivo do Algoritmo Genético Melhorado aplicado à otimização de atributos e hiperparâmetros do XGBoost. Fonte: Elaborado pelo autor com base em (WU et al., 2021) . . . . . 30
Figura 7 – Arquitetura geral do sistema híbrido proposto, composta por quatro módulos sequenciais: entrada de dados, previsão temporal via LSTM, engenharia de atributos e classificação via IGA-XGBoost. O Grupo 3 de atributos ($\star$) representa a integração entre os dois estágios. Fonte: Elaborado pelo autor. . . . . 36
Figura 8 – Em walk-forward validation, a validação sempre ocorre sobre dados futuros em relação ao treino, preservando a causalidade temporal. Fonte: Elaborado pelo autor. . . . . 39

..

# LISTA DE TABELAS

Tabela 1 – Comparação entre algoritmos de machine learning aplicados à DGA 19
Tabela 2 – Comparação entre trabalhos relacionados e a proposta deste estudo 32
Tabela 3 – Cronograma de desenvolvimento do trabalho . . . . . 45

# LISTA DE ABREVIATURAS E SIGLAS

| | |
|---|---|
| ABNT | Associação Brasileira de Normas Técnicas |
| AG | Algoritmo Genético |
| ANFIS | *Adaptive Neuro-Fuzzy Inference System* (Sistema de Inferência Neuro-Fuzzy Adaptativo) |
| AUC-ROC | *Area Under the Curve – Receiver Operating Characteristic* (Área sob a Curva – Característica de Operação do Receptor) |
| BPTT | *Backpropagation Through Time* (Retropropagação Através do Tempo) |
| CNN | *Convolutional Neural Network* (Rede Neural Convolucional) |
| CRISP-DM | *Cross-Industry Standard Process for Data Mining* (Processo Padrão Intersetorial para Mineração de Dados) |
| DGA | *Dissolved Gas Analysis* (Análise de Gases Dissolvidos) |
| GA | *Genetic Algorithm* (Algoritmo Genético) |
| IEC | *International Electrotechnical Commission* (Comissão Eletrotécnica Internacional) |
| IGA | *Improved Genetic Algorithm* (Algoritmo Genético Melhorado) |
| KNN | *k-Nearest Neighbors* (k-Vizinhos Mais Próximos) |
| LightGBM | *Light Gradient Boosting Machine* (Máquina de Aumento de Gradiente Leve) |
| LSTM | *Long Short-Term Memory* (Memória de Curto e Longo Prazo) |
| MAE | *Mean Absolute Error* (Erro Médio Absoluto) |
| MLP | *Multilayer Perceptron* (Perceptron Multicamadas) |
| PSO | *Particle Swarm Optimization* (Otimização por Enxame de Partículas) |
| RMSE | *Root Mean Squared Error* (Raiz do Erro Quadrático Médio) |
| RNN | *Recurrent Neural Network* (Rede Neural Recorrente) |
| SHAP | *SHapley Additive exPlanations* (Explicações Aditivas de Shapley) |

| | |
|---|---|
| SMOTE | *Synthetic Minority Over-sampling Technique* (Técnica de Sobreamostragem de Minorias Sintéticas) |
| SVM | *Support Vector Machine* (Máquina de Vetores de Suporte) |
| XGBoost | *Extreme Gradient Boosting* (Aumento Extremo de Gradiente) |

# LISTA DE SÍMBOLOS

| | |
|---|---|
| $w$ | Tamanho da janela temporal (número de passos históricos) |
| $h$ | Horizonte de previsão (passos à frente) |
| $x_t$ | Vetor de concentrações dos gases no instante $t$ |
| $\hat{y}$ | Saída predita pelo modelo |
| $h_t$ | Estado oculto da rede recorrente no instante $t$ |
| $C_t$ | Estado da célula (memória) da LSTM no instante $t$ |
| $f_k(x)$ | Árvore $k$ no ensemble de *gradient boosting* |
| $L(y, \hat{y})$ | Função de perda |
| $N$ | Tamanho da população no AG/IGA |
| $G$ | Número máximo de gerações no AG/IGA |
| $P_c$ | Taxa de cruzamento (*crossover rate*) |
| $P_m$ | Taxa de mutação |
| $\delta$ | Limiar de diversidade populacional (desvio padrão da aptidão) |

SUMÁRIO


**1 INTRODUÇÃO . . . . . 11**
**1.1 Tema . . . . . 13**
**1.2 Justificativa . . . . . 13**
**1.3 Objetivos . . . . . 13**
**1.4 Organização do Texto . . . . . 14**

**2 FUNDAMENTAÇÃO TEÓRICA . . . . . 16**
**2.1 Transformadores de Potência . . . . . 16**
2.1.1 Sistema de Isolamento . . . . . 16
2.1.2 Geração de Gases Dissolvidos . . . . . 17
2.1.3 Tipos de Falhas e Relevância para a Classificação . . . . . 17
2.1.4 Análise de Gases Dissolvidos (DGA) . . . . . 19
**2.2 Algoritmos de Machine Learning Aplicados à DGA . . . . . 19**
2.2.1 Panorama dos Algoritmos Aplicados à DGA . . . . . 19
2.2.2 Classificadores Clássicos . . . . . 23
2.2.3 Ensembles e Boosting . . . . . 23
2.2.4 Redes Neurais . . . . . 25
2.2.5 Modelos de Séries Temporais . . . . . 28
2.2.6 Otimização Evolutiva . . . . . 28
2.2.7 Justificativa das Escolhas e Lacuna Identificada . . . . . 30
**2.3 Trabalhos Relacionados . . . . . 31**

**3 METODOLOGIA . . . . . 35**
**3.1 Visão Geral da Abordagem . . . . . 35**
**3.2 Desenho Metodológico . . . . . 37**
**3.3 Bases de Dados e Definição do Problema . . . . . 37**
**3.4 Pré-processamento dos Dados . . . . . 38**
**3.5 Modelagem Temporal com LSTM . . . . . 39**
3.5.1 Representação dos dados como séries temporais . . . . . 39
3.5.2 Arquitetura e treinamento . . . . . 40
**3.6 Engenharia de Atributos . . . . . 40**
**3.7 Seleção de Atributos e Otimização com IGA . . . . . 41**
**3.8 Classificação com XGBoost . . . . . 42**
**3.9 Protocolo Experimental e Avaliação . . . . . 42**
**3.10 Reprodutibilidade e Implementação . . . . . 43**
**3.11 Limitações Metodológicas . . . . . 43**

**3.12 Cronograma . . . . . 44**

**4 CONSIDERAÇÕES FINAIS . . . . . 46**

**REFERÊNCIAS . . . . . 47**

# 1 INTRODUÇÃO

O fornecimento contínuo de energia elétrica sustenta a operação de infraestruturas críticas em setores industriais, hospitalares e de telecomunicações. Nesse contexto, os transformadores de potência constituem elementos fundamentais das redes de transmissão e distribuição. Como operam de forma contínua e, muitas vezes, sob condições elevadas de carga, esses equipamentos sofrem desgaste ao longo do tempo, o que pode comprometer sua estrutura interna. Falhas nesse tipo de equipamento podem causar interrupções no fornecimento de energia, além de gerar prejuízos significativos. Por isso, o monitoramento e a manutenção dos transformadores são aspectos importantes para o setor elétrico (TIGHTIZ et al., 2020).

A degradação dos materiais isolantes do transformador ocorre principalmente devido a estresses térmicos e elétricos durante a operação normal. Esse processo de envelhecimento leva à formação de gases dissolvidos no óleo isolante, como hidrogênio ($H_2$), metano ($CH_4$) e acetileno($C_2H_2$), cuja composição e concentração estão diretamente relacionadas ao tipo e à severidade das anomalias internas. A análise dessas substâncias, conhecida como Análise de Gases Dissolvidos (DGA - *Dissolved Gas Analysis*), é amplamente utilizada para avaliar a condição interna do equipamento, da qual é possível identificar indícios de falhas em estágio inicial (ALI et al., 2023).

A Figura 1 ilustra a cadeia causal que conecta a operação do transformador ao diagnóstico de falhas. Os estresses térmicos e elétricos atuam continuamente sobre o sistema de isolamento, provocando a degradação progressiva do óleo mineral e do papel celulósico. Esse processo resulta na formação de gases dissolvidos cujas concentrações são analisadas pela DGA. A figura também evidencia a bifurcação central que motiva este trabalho. Enquanto os métodos tradicionais realizam o diagnóstico de forma reativa, a abordagem proposta busca antecipar a ocorrência de falhas por meio de modelagem preditiva.

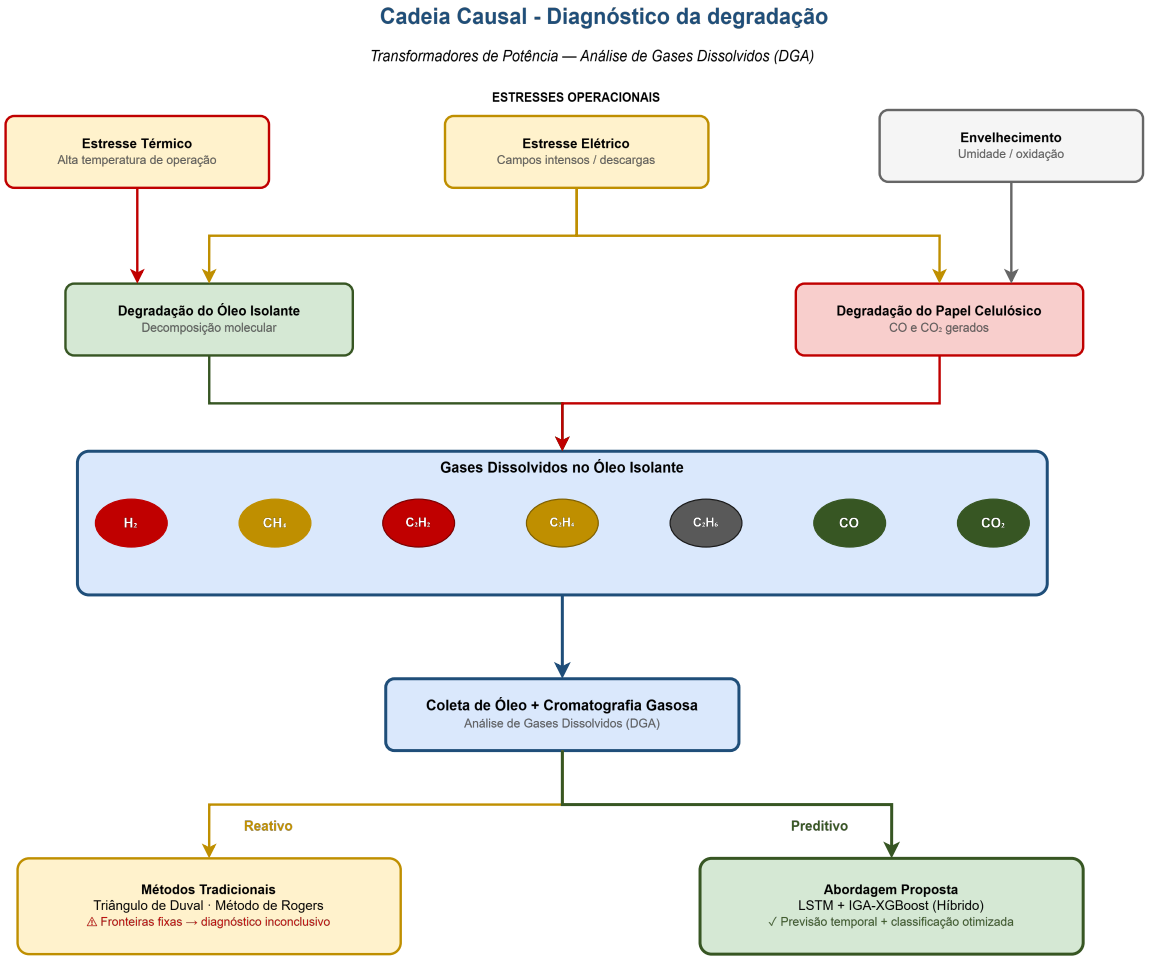



Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA abordagem reativa (métodos tradicionais) e abordagem preditiva (proposta deste trabalho). Fonte: Elaborado pelo autor

Diante do cenário apresentado, este trabalho propõe uma arquitetura híbrida de dois estágios para a predição proativa de falhas incipientes em transformadores de potência. No primeiro estágio, uma rede neural do tipo Long Short-Term Memory (LSTM) é empregada para modelar a evolução temporal das concentrações dos gases dissolvidos, gerando estimativas futuras que alimentam o segundo estágio. Neste, um classificador XGBoost com atributos e hiperparâmetros otimizados por um Algoritmo Genético Melhorado (IGA), determina a condição operacional do transformador. A integração dessas duas perspectivas, previsão temporal e classificação otimizada, representa uma lacuna identificada na literatura recente e é o principal diferencial da proposta.

## 1.1 TEMA

Desenvolvimento e avaliação um modelo híbrido para a predição proativa de falhas incipientes em transformadores de potência a partir de dados de Análise de Gases Dissolvidos e com uso de modelos de aprendizado de máquina.

## 1.2 JUSTIFICATIVA

Tradicionalmente, a interpretação dos dados de DGA é feita por meio de métodos baseados em regras e limites predefinidos, como o Triângulo de Duval e o Método de Rogers. Apesar de serem amplamente utilizados, esses métodos apresentam limitações, principalmente quando os dados não se enquadram claramente nos padrões estabelecidos. Nesses casos, o diagnóstico pode se tornar impreciso ou inconclusivo (AL-SAKINI et al., 2025). Além disso, tais métodos operam de forma estática, desconsiderando a evolução temporal das concentrações de gases - informação relevante para a detecção preococe de falhas incipientes.

Com o avanço das técnicas de aprendizado de máquina, diferentes abordagens têm sido propostas para superar essas limitações. Algoritmos como o XGBoost demonstraram desempenho superior aos métodos tradicionais na classificação de falhas a partir de dados de DGA, especialmente quando combinados com técnicas de otimização evolutiva (WU et al., 2021). No entanto, a maioria dessas abordagens opera sobre snapshots estáticos dos dados, ignorando a dinâmica temporal da degradação. Por outro lado, modelos baseados em séries temporais, como redes neurais do tipo Long Short-Term Memory (LSTM), permitem capturar dependências temporais e prever a evolução futura dos gases, mas frequentemente carecem de um estágio de classificação otimizado (WANG; LITTLER; LIU, 2023).

A integração dessas duas perspectivas, previsão temporal e classificação otimizada. Representa uma lacuna identificada na literatura recente. Modelos que combinam a capacidade preditiva das redes LSTM com classificadores robustos e otimizados por algoritmos evolutivos ainda são escassos, particularmente no contexto de manutenção preditiva proativa, em que o objetivo é antecipar a ocorrência de falhas antes que estas se manifestem de forma catastrófica.

## 1.3 OBJETIVOS

Este trabalho tem como objetivo desenvolver e avaliar um modelo híbrido para a predição proativa de falhas incipientes em transformadores de potência, a partir de dados de Análise de Gases Dissolvidos. A abordagem proposta combina redes neurais do tipo Long Short-Term Memory para modelar a evolução temporal das concentrações

dos gases, com um classificador XGBoost otimizado por Algoritmo Genético Melhorado, visando antecipar a identificação de falhas e superar limitações associadas aos métodos tradicionais de diagnóstico baseados em regras e aos modelos estáticos de aprendizado de máquina.

Para alcançar o objetivo geral, este trabalho busca, inicialmente, organizar e preparar bases de dados de Análise de Gases Dissolvidos em formato adequado para modelagem temporal, considerando a evolução das concentrações dos principais gases associados à degradação interna de transformadores de potência. Em seguida, pretende-se implementar um modelo baseado em redes LSTM, capaz de prever o comportamento futuro desses gases, de modo a incorporar informações temporais ao processo de diagnóstico. A partir dessas previsões, será construído um conjunto de atributos destinado ao classificador XGBoost, permitindo que a etapa de classificação considere tanto os valores observados quanto as tendências previstas.

Além disso, o trabalho busca aplicar um Algoritmo Genético Melhorado para otimizar os principais hiperparâmetros do classificador, com o objetivo de aumentar a capacidade de identificação de falhas em um cenário multiclasse e possivelmente desbalanceado. Por fim, o desempenho do modelo híbrido proposto será avaliado por meio de métricas adequadas, como acurácia, precisão, e F1-score, comparando seus resultados com métodos tradicionais de interpretação de DGA e com abordagens de referência da literatura.

## 1.4 ORGANIZAÇÃO DO TEXTO

O restante deste texto está organizado conforme segue:

- **Capítulo 2 – Fundamentação Teórica:** apresenta os principais conceitos necessários para compreender a proposta, incluindo transformadores de potência, Análise de Gases Dissolvidos (DGA), algoritmos de aprendizado de máquina aplicados à DGA (classificadores clássicos, ensembles, redes neurais, modelos de séries temporais e otimização evolutiva) e os trabalhos relacionados ao tema.
- **Capítulo 3 – Metodologia:** descreve a abordagem metodológica adotada, abrangendo a visão geral da arquitetura híbrida de dois estágios, o desenho metodológico baseado no CRISP-DM, as bases de dados utilizadas, o pré-processamento dos dados, a modelagem temporal com LSTM, a engenharia de atributos, a seleção e otimização via IGA, a classificação com XGBoost, o protocolo experimental de avaliação, aspectos de reprodutibilidade, as limitações metodológicas identificadas e o cronograma de atividades.

- **Capítulo 4 – Considerações Finais:** sintetiza as contribuições do trabalho desenvolvido até o momento, retoma as lacunas identificadas na literatura e apresenta os próximos passos previstos para o TCC II, incluindo a implementação dos módulos, a realização dos experimentos comparativos e a análise dos resultados.

# 2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os principais conceitos necessários para compreender a proposta desenvolvida neste trabalho. Primeiramente, são apresentados os transformadores de potência, destacando sua importância no sistema elétrico e os principais mecanismos associados à degradação interna desses equipamentos. Em seguida, discute-se a Análise de Gases Dissolvidos (DGA), técnica amplamente utilizada para o monitoramento da condição dos transformadores e para a identificação de possíveis falhas em estágio inicial.

Na sequência, são abordadas técnicas de aprendizado de máquina aplicadas ao diagnóstico por DGA, incluindo métodos clássicos de classificação, algoritmos de ensemble, redes neurais, modelos voltados a séries temporais e estratégias de otimização evolutiva. Por fim, são apresentados trabalhos relacionados ao tema, com o objetivo de compreender como a literatura recente tem tratado o problema e de evidenciar o espaço em que a proposta deste estudo se insere.

## 2.1 TRANSFORMADORES DE POTÊNCIA

Os transformadores de potência são dispositivos eletromagnéticos estáticos responsáveis pela transferência de energia elétrica entre circuitos, por meio do princípio da indução eletromagnética (ALI et al., 2023). Esses equipamentos desempenham um papel fundamental nos sistemas elétricos de potência, permitindo a elevação ou redução dos níveis de tensão para transmissão e distribuição de energia de forma eficiente.

O funcionamento de um transformador baseia-se na Lei de Faraday, segundo a qual uma variação de fluxo magnético em um circuito induz uma força eletromotriz em outro circuito acoplado magneticamente (TIGHTIZ et al., 2020). Estruturalmente, um transformador é composto por um núcleo magnético e enrolamentos isolados entre si. Do ponto de vista do diagnóstico por aprendizado de máquina, três características operacionais são particularmente relevantes: a composição do sistema de isolamento, os mecanismos de geração de gases dissolvidos e a taxonomia das falhas internas.

### 2.1.1 SISTEMA DE ISOLAMENTO

O sistema de isolamento é um dos componentes mais críticos de um transformador de potência, sendo responsável por garantir a integridade elétrica entre os enrolamentos e o núcleo (ALI et al., 2023). Esse sistema é geralmente composto por óleo mineral isolante e materiais sólidos, como papel celulósico e pressboard.

Durante a operação, o sistema de isolamento é submetido a diversos fatores de estresse, incluindo altas temperaturas, campos elétricos intensos, presença de umidade e processos de oxidação. Esses fatores contribuem para a degradação dos materiais isolantes ao longo do tempo, comprometendo a confiabilidade do equipamento.

### 2.1.2 GERAÇÃO DE GASES DISSOLVIDOS

A degradação térmica e elétrica do óleo e do papel isolante resulta na formação de gases dissolvidos no óleo do transformador (ALI et al., 2023). Entre os principais gases gerados estão o hidrogênio ($H_2$), metano ($CH_4$), acetileno ($C_2H_2$), etileno ($C_2H_4$) e etano ($C_2H_6$), além de monóxido (CO) e dióxido de carbono ($CO_2$), associados à degradação do papel isolante.

A composição e a concentração desses gases estão diretamente relacionadas ao tipo e à severidade das falhas internas. Essa relação entre composição gasosa e mecanismo de falha é o fundamento físico da DGA (ALI et al., 2023).

Do ponto de vista do aprendizado de máquina, os dados de DGA apresentam características que impõem desafios específicos de modelagem, como: excesso de dimensões em relação ao número de amostras disponíveis, especialmente para classes de falha raras; distribuição diversa, com sobreposição entre classes adjacentes (ex.: T2 e T3) e forte dependência temporal, pois a trajetória de variação dos gases ao longo do tempo carrega informação diagnóstica que amostras pontuais estáticas não capturam.

### 2.1.3 TIPOS DE FALHAS E RELEVÂNCIA PARA A CLASSIFICAÇÃO

As falhas em transformadores podem ser classificadas em falhas térmicas, falhas elétricas e combinadas, dependendo da natureza do fenômeno (AL-SAKINI et al., 2025). Sâo essas as três categorias principais:

- **Falhas térmicas**: associadas ao superaquecimento do óleo ou do papel isolante, podendo ser classificadas em diferentes níveis de temperatura (T1, T2 e T3);
- **Falhas elétricas**: incluem descargas parciais (PD), descargas de baixa energia (D1) e descargas de alta energia (D2);
- **Falhas combinadas**: envolvem a ocorrência simultânea de fenômenos térmicos e elétricos.

A distribuição dessas classes em bases de dados públicas é inerentemente desbalanceada. Falhas do tipo PD e D1, por exemplo, são significativamente mais raras do que falhas térmicas moderadas (T2), o que introduz viés nos modelos treinados por minimização de perda global. Esse desbalanceamento exige estratégias específicas,

discutidas na seção 3.4, para garantir que as classes minoritárias, justamente as mais críticas operacionalmente, sejam corretamente identificadas.

A Figura 2 apresenta o Triângulo de Duval, um dos métodos tradicionais mais utilizados para a interpretação de dados de DGA. O triângulo é construído com base nas concentrações relativas de três gases: metano ($CH_4$), etileno ($C_2H_4$) e acetileno ($C_2H_2$). O Triângulo de Duval divide o espaço em regiões associadas a diferentes tipos de falha. A principal limitação do método torna-se visível na figura: as fronteiras entre as regiões são fixas e predefinidas, de modo que amostras localizadas nas zonas de transição resultam em diagnóstico inconclusivo. Essa característica estrutural é a principal motivação para a adoção de abordagens baseadas em aprendizado de máquina.

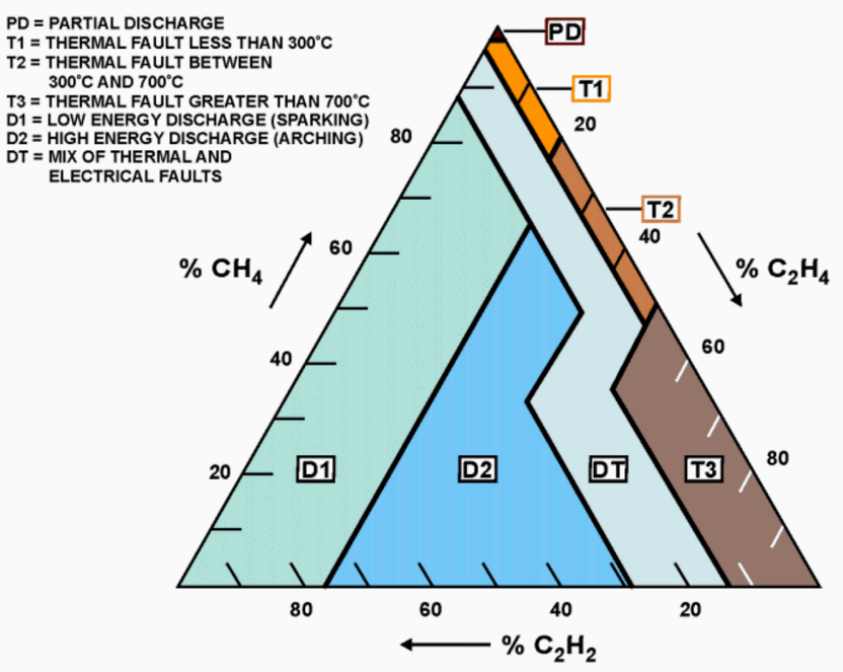



Figura 2 – Triângulo de Duval. Fonte: Extraído de (ALI et al., 2023)

O Método de Rogers classifica falhas por meio do cálculo de razões entre pares de gases dissolvidos, especificamente $CH_4/H_2$, $C_2H_2/C_2H_4$ e $C_2H_4/C_2H_6$. Cada combinação de valores dessas razões corresponde a uma região de diagnóstico predefinida, associada a um tipo específico de falha. Assim como o Triângulo de Duval, o método opera com fronteiras fixas, de modo que amostras localizadas nas zonas de transição entre regiões resultam em diagnóstico indeterminado (AL-SAKINI et al., 2025).

### 2.1.4 ANÁLISE DE GASES DISSOLVIDOS (DGA)

A Análise de Gases Dissolvidos (DGA) é uma das principais técnicas utilizadas para o monitoramento da condição interna de transformadores de potência. Essa técnica consiste na coleta do óleo isolante e na análise das concentrações de gases dissolvidos por meio de cromatografia gasosa (ALI et al., 2023).

A DGA permite identificar falhas incipientes antes que ocorram falhas catastróficas, possibilitando a implementação de estratégias de manutenção preditiva. No entanto, a interpretação dos resultados pode ser complexa, especialmente em casos em que os dados não se enquadram claramente nos padrões definidos pelos métodos tradicionais.

## 2.2 ALGORITMOS DE MACHINE LEARNING APLICADOS À DGA

Esta seção apresenta um panorama dos principais algoritmos de aprendizado de máquina utilizados no diagnóstico de falhas em transformadores por meio de dados de DGA. O objetivo não é catalogar todas as técnicas existentes, mas contextualizar as escolhas metodológicas deste trabalho a partir das características específicas do problema. A análise cobre classificadores clássicos, métodos de ensemble, redes neurais, modelos de séries temporais e técnicas de otimização evolutiva.

### 2.2.1 PANORAMA DOS ALGORITMOS APLICADOS À DGA

A Tabela 1 apresenta uma comparação entre as principais técnicas empregadas na literatura, considerando suas vantagens e limitações no contexto do diagnóstico por DGA.

Tabela 1 – Comparação entre algoritmos de machine learning aplicados à DGA

| **Algoritmo** | **Referência em DGA** | **Vantagem principal** | **Limitação para este problema** |
|---|---|---|---|
| *Classificadores clássicos* | | | |
| SVM | Al-Sakini et al. (2025) | Boa separação em espaços de alta dimensão | Dificuldade com classes sobrepostas (T2 $\times$ T3); fronteiras binárias limitam classificação multiclasse nativa |

*Continua na próxima página*

Tabela 1 – continuação

| **Algoritmo** | **Referência em DGA** | **Vantagem principal** | **Limitação para este problema** |
|---|---|---|---|
| KNN | Ali et al. (2023) | Simples e sem fase de treinamento explícita | Alta sensibilidade a ruído; custo computacional elevado na predição; inadequado para dados desbalanceados sem ajuste |
| Árvore de Decisão | Ali et al. (2023) | Alta interpretabilidade; regras extraíveis diretamente | Alta variância; overfitting sem poda agressiva; desempenho inferior a ensembles com dados limitados |
| Random Forest | Al-Sakini et al. (2025) | Robusto a overfitting; importância de atributos nativa | Sem otimização integrada de hiperparâmetros; menos eficiente que XGBoost em dados tabulares desbalanceados |
| Naive Bayes | Ali et al. (2023) | Rápido e funcional com poucos dados | Assume independência entre gases, premissa violada em DGA onde os gases co-evoluem por mecanismo físico comum |
| *Ensembles e boosting* | | | |

*Continua na próxima página*

Tabela 1 – continuação

| **Algoritmo** | **Referência em DGA** | **Vantagem principal** | **Limitação para este problema** |
|---|---|---|---|
| **XGBoost** ✓ | Wu et al. (2021) | Regularização nativa; tratamento de valores faltantes; suporte a desbalanceamento via *scale_pos_weight* | Operação estática, sem modelagem temporal; hiperparâmetros sensíveis sem otimização adequada |
| LightGBM | – | Mais rápido em datasets maiores; crescimento *leaf-wise* pode melhorar precisão | Menor adoção no domínio DGA; maior risco de overfitting em datasets pequenos, especialmente com menos de 500 amostras |
| *Redes neurais* | | | |
| MLP / ANN | Ali et al. (2023) | Alta capacidade de modelagem não linear; flexível para múltiplas saídas | Requer volume maior de dados rotulados; sem memória temporal; sensível à inicialização |
| CNN | LeCun et al. (1998) | Extração automática de padrões locais | Projetada para dados com estrutura espacial; dados de DGA em formato tabular não possuem essa propriedade naturalmente |
| *Modelos de séries temporais* | | | |

*Continua na próxima página*

Tabela 1 – continuação

| **Algoritmo** | **Referência em DGA** | **Vantagem principal** | **Limitação para este problema** |
|---|---|---|---|
| ARIMA | Ali et al. (2023) | Modelo clássico, interpretável e eficiente para séries estacionárias curtas | Univariado por natureza; incapaz de capturar não linearidades nem a coevolução de múltiplos gases |
| **LSTM** ✓ | Wang et al. (2023) | Captura dependências temporais de longo prazo; multivariado nativo; adequado para degradação gradual | Custo computacional maior que modelos clássicos; sensível a hiperparâmetros |
| Transformer | Zhu et al. (2023) | Atenção global para dependências longas; estado da arte em séries extensas | Requer volume de dados superior ao disponível nas bases públicas de DGA; ainda incipiente no domínio |
| *Otimização evolutiva* | | | |
| GA convencional | Ali et al. (2023) | Busca global sem gradiente; aplicável à seleção de atributos e hiperparâmetros | Convergência prematura; inicialização aleatória ineficiente nas gerações iniciais |
| **IGA** ✓ | Wu et al. (2021) | Inicialização heurística; cruzamento adaptativo; elitismo para preservar melhores soluções | Custo computacional proporcional ao número de avaliações do classificador |

*Continua na próxima página*

Tabela 1 – continuação

| **Algoritmo** | **Referência em DGA** | **Vantagem principal** | **Limitação para este problema** |
|---|---|---|---|
| PSO / Bayesiana | – | Otimização bayesiana eficiente em número de avaliações | Não escala bem para espaços mistos, binários e contínuos, como a seleção simultânea de atributos e hiperparâmetros |

Fonte: elaborado pelo autor com base em Ali et al. (2023), Al-Sakini et al. (2025), Wu et al. (2021), Zhu et al. (2023) e LeCun et al. (1998)

Nota: ✓ indica as técnicas adotadas neste trabalho.

### 2.2.2 CLASSIFICADORES CLÁSSICOS

Entre os classificadores clássicos, o SVM demonstra bom desempenho em espaços de alta dimensão, porém apresenta dificuldades quando as classes são sobrepostas. Esse é um problema frequente em dados de DGA, já que as classes T2 e T3, por exemplo, compartilham faixas de concentração similares para determinados gases (AL-SAKINI et al., 2025). O KNN e as Árvores de Decisão individuais apresentam limitações de robustez e generalização, sendo tipicamente superados por métodos de ensemble quando o volume de dados é limitado (ALI et al., 2023).

O Random Forest oferece boa generalização e produz importância de atributos de forma nativa, mas não incorpora mecanismos de otimização de hiperparâmetros nem tratamento direto do desbalanceamento de classes. O Naive Bayes, embora útil como linha de base probabilística, assume independência entre as variáveis de entrada, premissa que é claramente violada em dados de DGA, onde os gases co-evoluem por um mecanismo físico comum (ALI et al., 2023).

### 2.2.3 ENSEMBLES E BOOSTING

Métodos de *ensemble* combinam múltiplos modelos de aprendizado de máquina para obter desempenho superior ao de um modelo isolado. A agregação tende a reduzir a variância e tornar a predição mais estável, especialmente quando os modelos individuais cometem erros não perfeitamente correlacionados. No *bagging* (*bootstrap aggregating*), os modelos são treinados em subconjuntos reamostrados e agregados por média ou votação. No *boosting*, em contraste, os modelos são adicionados de forma

sequencial, concentrando-se progressivamente nos exemplos em que o ensemble atual ainda erra.

**Gradient Boosting e XGBoost.** No *gradient boosting*, o modelo é construído iterativamente pela adição sucessiva de árvores de decisão rasas. A cada iteração, uma nova árvore é treinada para ajustar os resíduos, isto é, a diferença entre a predição corrente do ensemble e o valor real (FRIEDMAN, 2001). Formalmente, para uma amostra $x$, a predição após $K$ árvores pode ser escrita como:

$$\hat{y}(x) = \sum_{k=1}^{K} f_k(x), \tag{2.1}$$

em que cada $f_k$ representa uma árvore adicionada para minimizar uma função de perda $L(y, \hat{y})$ via descida de gradiente no espaço funcional.

O XGBoost (*Extreme Gradient Boosting*) é uma implementação otimizada do *gradient boosting* que incorpora melhorias relevantes para diagnóstico por DGA, incluindo regularização explícita, construção eficiente de árvores e tratamento interno de valores ausentes (CHEN; GUESTRIN, 2016). Do ponto de vista prático, essas características são especialmente pertinentes neste trabalho:

- a regularização L1/L2 reduz *overfitting* quando se utiliza um vetor de atributos com múltiplas variáveis derivadas;
- a eficiência computacional é necessária para viabilizar centenas de avaliações do classificador no processo de otimização evolutiva;
- para mitigar o desbalanceamento de dados no XGBoost multiclasse, as amostras receberão pesos inversamente proporcionais à sua frequência durante o treinamento, garantindo a representatividade das classes minoritárias. Já para cenários binários, será avaliada a utilização do parâmetro *scale_pos_weight* (WU et al., 2021).

A Figura 3 ilustra o processo de construção sequencial do XGBoost. O modelo parte de uma predição inicial $\hat{y}_0$ e adiciona, de forma iterativa, árvores de decisão ao ensemble. Cada nova árvore $f_k(x)$ é treinada para corrigir o resíduo produzido pelo conjunto de árvores anteriores, reduzindo progressivamente o erro da predição.

Como indicado na Figura 3, a redução do resíduo ocorre de maneira gradual, passando de um erro inicialmente elevado para um erro menor após a adição sucessiva das árvores. Essa estratégia torna o XGBoost adequado para problemas de classificação com relações não lineares entre os atributos, como ocorre na análise de gases dissolvidos em transformadores de potência.

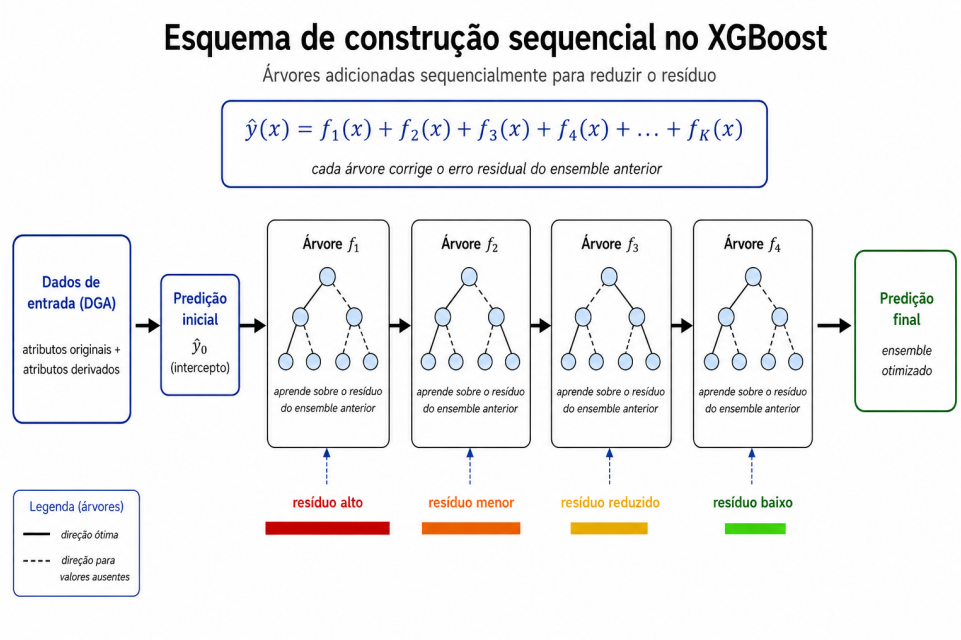



Figura 3 – Esquema de construção sequencial no XGBoost. Fonte: elaborado pelo autor.

Em comparação com o LightGBM, o XGBoost apresenta adoção mais consolidada no domínio de DGA e comportamento mais conservador em *datasets* de tamanho reduzido, que é a realidade das bases públicas disponíveis para este trabalho (WU et al., 2021).

### 2.2.4 REDES NEURAIS

Redes neurais artificiais são modelos compostos por camadas de neurônios artificiais que transformam entradas em saídas por meio de combinações lineares seguidas de funções de ativação não lineares. As redes do tipo *multilayer perceptron* (MLP) oferecem alta capacidade de modelagem não linear, mas não possuem mecanismo interno para processar sequências ordenadas no tempo, cada amostra é tratada de forma independente, sem incorporar o histórico temporal. As redes convolucionais (CNN), embora eficientes na extração de padrões locais em dados com estrutura espacial, foram projetadas principalmente para imagens; dados de DGA em formato tabular não apresentam a mesma noção de localidade espacial, o que limita sua aplicabilidade direta (ALI et al., 2023).

**Redes recorrentes e gradiente desaparecente.** As Redes Neurais Recorrentes (RNN) foram desenvolvidas para processamento de sequências, pois incorporam um estado oculto $h_t$ que depende da entrada atual $x_t$ e do estado anterior $h_{t-1}$. Em uma formulação simples:

$$h_t = \tanh\left(W_x x_t + W_h h_{t-1} + b\right). \tag{2.2}$$

Entretanto, no treinamento por *backpropagation through time* (BPTT), os gradientes são multiplicados repetidamente ao longo dos passos temporais. Em sequências longas, esse processo tende a levar ao gradiente desaparecente, impedindo a aprendizagem de dependências de longo prazo (HOCHREITER; SCHMIDHUBER, 1997). Para dados de DGA, cuja degradação pode evoluir ao longo de meses ou anos, essa limitação é particularmente relevante.

**Long Short-Term Memory (LSTM).** A arquitetura LSTM introduz uma célula com estado de memória e mecanismos de portão explícitos (esquecimento, entrada e saída), permitindo controlar adições e remoções de informação no estado da célula e favorecendo a propagação de gradientes por longas sequências (HOCHREITER; SCHMIDHUBER, 1997).

Como ilustrado na Figura 4, a célula LSTM recebe como entrada a concatenação do estado oculto anterior $h_{t-1}$ e da entrada atual $x_t$. A **porta de esquecimento** $f_t$, aplicando uma função sigmoide, determina quais informações do estado anterior $C_{t-1}$ devem ser descartadas, conforme a equação:

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right) \tag{2.3}$$

A **porta de entrada** $i_t$ controla quais novas informações serão armazenadas na célula, enquanto o **estado candidato** $\tilde{C}_t$, calculado por uma tangente hiperbólica, representa o conteúdo a ser potencialmente adicionado à memória:

$$i_t = \sigma\left(W_i[h_{t-1}, x_t] + b_i\right) \tag{2.4}$$

$$\tilde{C}_t = \tanh\left(W_c[h_{t-1}, x_t] + b_c\right) \tag{2.5}$$

O estado da célula é então atualizado pela combinação do que deve ser esquecido e do que deve ser adicionado:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{2.6}$$

onde $\odot$ denota a multiplicação elemento a elemento. Por fim, a **porta de saída** $o_t$ define quais informações do estado atualizado serão expostas como saída oculta $h_t$:

$$o_t = \sigma\left(W_o[h_{t-1}, x_t] + b_o\right) \tag{2.7}$$

$$h_t = o_t \odot \tanh(C_t) \tag{2.8}$$

Em todas as equações da célula LSTM, $W_f$, $W_i$, $W_c$ e $W_o$ representam matrizes de pesos aprendidas durante o treinamento, e $b_f$, $b_i$, $b_c$ e $b_o$ são os respectivos vetores de viés. A notação $[h_{t-1}, x_t]$ representa a concatenação dos vetores de estado oculto e entrada, equivalente à forma expandida $W_x * x_t + W_h * h_{t-1}$ apresentada na Equação 2.2.

É justamente o fluxo direto de $C_{t-1}$ para $C_t$, modulado predominantemente por operações aditivas, controlado por multiplicações elemento a elemnto pelos portões, que permite a propagação de gradientes por longas sequências sem degradação (HOCHREITER; SCHMIDHUBER, 1997). Diferentemente da RNN simples apresentada na Equação 2.2, onde os gradientes são multiplicados repetidamente a cada passo temporal, a célula LSTM controla explicitamente o quanto do gradiente é preservado ou descartado por meio de seus portões, tornando-a especialmente adequada para modelar processos de degradação gradual como o envelhecimento do sistema de isolamento dos transformadores.

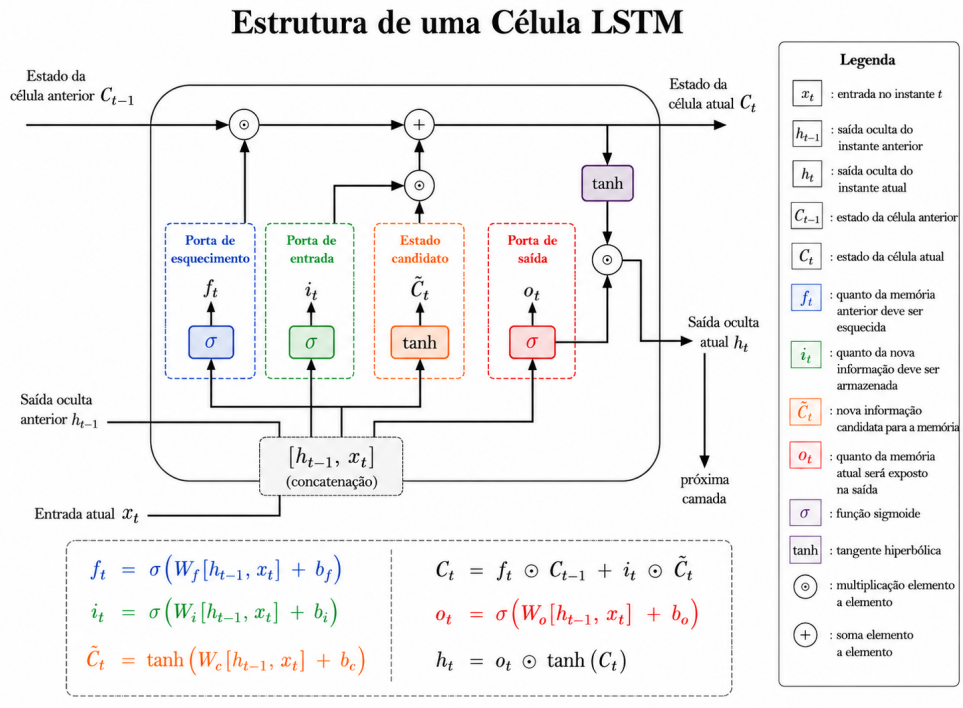



Figura 4 – Estrutura da Célula LSTM. Fonte: Elaborado pelo autor com auxílio de ferramenta de inteligência artificial generativa, baseado em (HOCHREITER; SCHMIDHUBER, 1997)

Conforme a figura 5, a LSTM empilhada (*stacked LSTM*) conecta múltiplas camadas recorrentes em sequência: a saída $h_t$ de uma camada é utilizada como entrada da camada seguinte. Isso permite que camadas inferiores capturem padrões temporais de curta escala, enquanto camadas superiores aprendem representações de nível mais abstrato, como tendências de degradação progressiva.

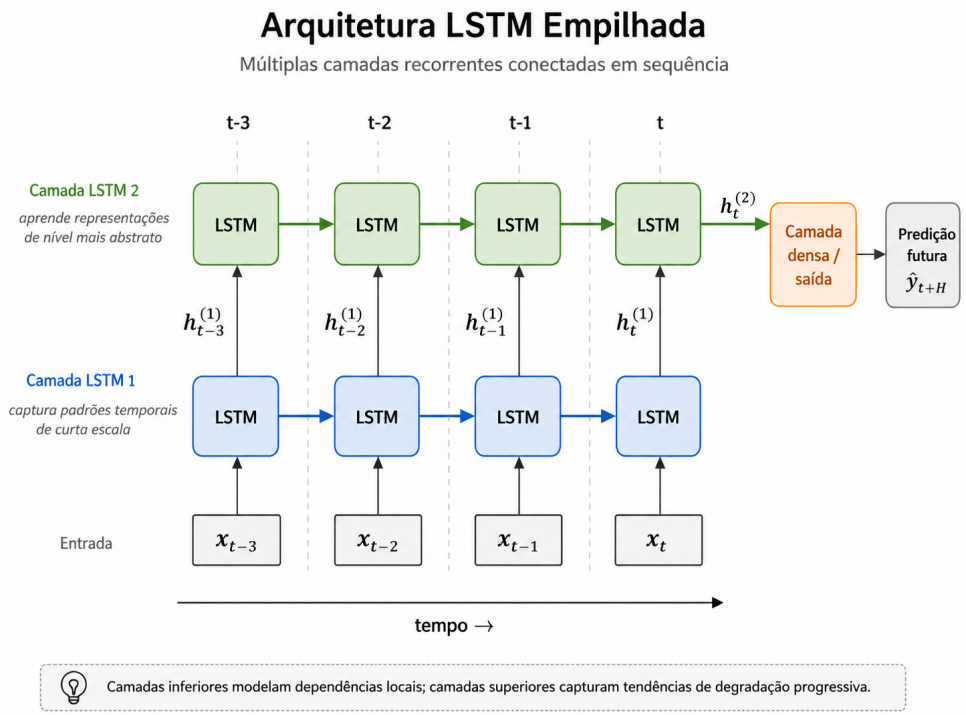



Figura 5 – LSTM empilhadas. Fonte: Elaborado pelo autor com auxílio de ferramenta de inteligência artificial generativa, baseado em (HOCHREITER; SCHMIDHUBER, 1997)

### 2.2.5 MODELOS DE SÉRIES TEMPORAIS

O ARIMA é um modelo clássico e bem estabelecido para séries temporais, mas opera de forma univariada e assume linearidade. A LSTM, cuja arquitetura foi detalhada na Seção 2.2.4, supera as restrições do ARIMA ao modelar dependências temporais de longo prazo em entradas multivariadas sem assumir linearidade. Essa característica é especialmente relevante para o problema em questão, pois a co-evolução não linear de múltiplos gases dissolvidos não pode ser capturada por modelos univariados clássicos (WANG; LITTLER; LIU, 2023). Arquiteturas baseadas em mecanismos de atenção, como os Transformers, surgem como alternativas promissoras para séries longas, mas requerem volumes de dados superiores aos disponíveis nas bases públicas de DGA (ZHU et al., 2023). A comparação entre LSTM e Transformer está prevista como experimento complementar no TCC II.

### 2.2.6 OTIMIZAÇÃO EVOLUTIVA

Algoritmos Genéticos (AG) são métodos de otimização inspirados no processo de evolução biológica por seleção natural. A ideia central é manter uma população de soluções candidatas (indivíduos), avaliá-las por uma função de aptidão e aplicar operadores genéticos de forma iterativa para explorar o espaço de busca (ALI et al.,

2023).

Um ciclo evolutivo típico é composto por:

- inicialização de uma população com $N$ indivíduos;
- avaliação de cada indivíduo pela função de aptidão;
- seleção dos indivíduos com maior aptidão para reprodução;
- cruzamento (*crossover*) para recombinar cromossomos e gerar descendentes;
- mutação para introduzir diversidade;
- substituição da geração anterior, frequentemente com elitismo para preservar as melhores soluções.

Em aplicações de aprendizado de máquina, o principal desafio dos AGs convencionais é o custo computacional: com $N$ indivíduos e $G$ gerações, são necessárias até $N \times G$ avaliações do modelo. No presente trabalho, cada avaliação implica treinar e validar o classificador XGBoost, o que torna necessária uma estratégia evolutiva eficiente.

**Algoritmo Genético Melhorado (IGA).** O IGA proposto por (WU et al., 2021) introduz três modificações principais em relação ao AG convencional:

1. inicialização guiada por heurísticas, incorporando conhecimento prévio sobre a importância de atributos;
2. taxa de cruzamento adaptativa em função da diversidade populacional, visando evitar estagnação e convergência prematura;
3. elitismo explícito, garantindo a preservação das melhores soluções entre gerações.

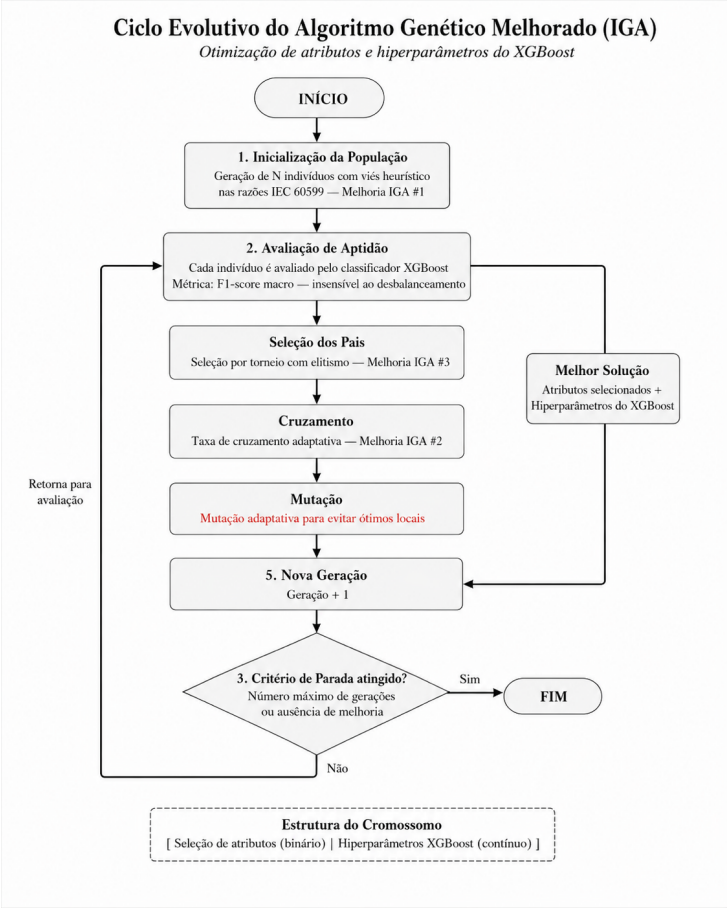



Figura 6 – Ciclo evolutivo do Algoritmo Genético Melhorado aplicado à otimização de atributos e hiperparâmetros do XGBoost. Fonte: Elaborado pelo autor com base em (WU et al., 2021)

A otimização bayesiana seria uma alternativa competitiva em termos de eficiência por avaliação, mas não escala bem para espaços de busca mistos que combinam variáveis binárias (seleção de atributos) e contínuas (hiperparâmetros), que é exatamente a estrutura do problema de otimização proposto.

### 2.2.7 JUSTIFICATIVA DAS ESCOLHAS E LACUNA IDENTIFICADA

A análise apresentada evidencia que nenhuma técnica isolada resolve simultaneamente os três desafios centrais do problema: a dinâmica temporal dos dados de DGA, a classificação multiclasse com distribuição desbalanceada de classes e a otimização conjunta de atributos e hiperparâmetros. Os classificadores clássicos operam de forma estática e não tratam o desbalanceamento adequadamente. Os modelos temporais carecem de uma etapa de classificação otimizada. Os métodos de otimização, quando aplicados de forma independente, ignoram a interdependência entre seleção de atributos e hiperparâmetros.

Essa constatação sustenta a proposta deste trabalho, uma arquitetura híbrida

que combina LSTM para modelagem temporal, XGBoost para classificação e IGA para otimização simultânea, detalhada nas Seções 2.2.3, 2.2.4 e 2.2.6.

## 2.3 TRABALHOS RELACIONADOS

O diagnóstico de falhas em transformadores de potência por meio da Análise de Gases Dissolvidos (DGA) tem evoluído significativamente nas últimas décadas, migrando de abordagens baseadas em regras empíricas para métodos fundamentados em aprendizado de máquina e inteligência artificial. Essa evolução é motivada, principalmente, pelas limitações dos métodos tradicionais, como baixa capacidade de generalização, sensibilidade a ruídos e dificuldade na interpretação de cenários ambíguos.A Tabela 2 sintetiza os trabalhos discutidos, posicionando a proposta deste estudo em relação às principais contribuições e limitações identificadas.

Tabela 2 – Comparação entre trabalhos relacionados e a proposta deste estudo

| **Trabalho** | **Abordagem** | **Tipo** | **Vantagens** | **Limitações** |
|---|---|---|---|---|
| Wu et al. (2021) | IGA + XGBoost | Classificação | Alta acurácia ($\sim$99%) e otimização conjunta de atributos e hiperparâmetros | Não considera a evolução temporal dos dados;Dataset desbalanceado sem métricas por classe |
| Wang et al. (2023) | LSTM + Classificadores | Previsão + Classificação | Modelagem temporal e previsão de falhas incipientes | Classificação não otimizada de forma integrada |
| Ali et al. (2023) | Métodos tradicionais + ML (review) | Revisão | Visão abrangente das técnicas de DGA e diagnóstico | Não propõe modelo específico; sem contribuição experimental direta |
| Al-Sakini et al. (2025) | Machine Learning aplicado à DGA | Classificação | Aplicação prática de ML em dados reais | Abordagem focada em diagnóstico estático |
| Tightiz et al. (2020) | ANFIS + Regras de associação | Classificação | Combina interpretabilidade fuzzy e regras de associação | Exige ajuste fino intensivo e não incorpora modelagem temporal |
| Zhu et al. (2023) | Transformer para séries temporais | Previsão | Captura dependências longas por mecanismo de atenção | Alto custo computacional e necessidade de maior volume de dados |
| **Proposta deste trabalho** | LSTM + IGA + XGBoost | Híbrido | Integra previsão temporal e classificação otimizada; abordagem proativa; trata desbalanceamento | Maior complexidade computacional; dependente de séries temporais rotuladas |

Nesse contexto, destacam-se abordagens que utilizam modelos de aprendizado supervisionado e técnicas híbridas para melhorar a precisão do diagnóstico. Entre os avanços recentes, (WU et al., 2021) propõem um modelo híbrido que combina um Algoritmo Genético Melhorado (IGA) com o algoritmo XGBoost. A principal contribuição dessa abordagem reside na otimização simultânea da seleção de atributos e dos hiperparâmetros do modelo, explorando a interdependência entre essas etapas. O

modelo utiliza dados de DGA como entrada e realiza a classificação em múltiplos estágios, permitindo o refinamento progressivo da identificação dos tipos de falha, evitando o subótimo resultante da otimização squencial independente. Os experimentos, conduzidos sobre o dataset IEC 60599 com 430 amostras e seis classes de falha, reportam acurácia média superior a 99%, evidenciando o potencial da integração entre técnicas evolutivas e modelos baseados em árvores de decisão. Contudo, três limitações merecem atenção crítica.

Primeiro, a abordagem proposta por (WU et al., 2021) é caracterizada como um modelo de diagnóstico estático, uma vez que considera apenas dados observados em um instante específico. Dessa forma, não há exploração explícita da dinâmica temporal das concentrações de gases, o que pode limitar sua aplicação em cenários onde a evolução dos sinais é um fator determinante para a detecção precoce de falhas. Segundo, o dataset utilizado é desbalanceado, visto que algumas classes de falhas possuem menos de 30 amostras, e os autores reportam apenas acurácia global sem detalhar métricas por classe. Isso impede avaliar se o modelo é realmente eficaz na detecção das classes minoritárias, que correspondem aos tipos de falhas mais críticos e raros. Terceiro, os experimentos são conduzidos em ambiente controlado com dados históricos rotulados, não há avaliação em cenário de implantação com dados de séries temporais reais.

Em uma linha complementar, (WANG; LITTLER; LIU, 2023) propõem um modelo baseado em redes neurais recorrentes do tipo Long Short-Term Memory (LSTM), para prever a evolução temporal das concentrações de gases dissolvidos. As redes LSTM, introduzidas por (HOCHREITER; SCHMIDHUBER, 1997), são capazes de capturar dependências de longo prazo em séries temporais, sendo amplamente utilizadas em problemas de previsão. No trabalho de (WANG; LITTLER; LIU, 2023), o modelo é empregado para prever tendências futuras nos dados de DGA. A abordagem é conceitualmente complementar à de (WU et al., 2021): enquanto esta última classifica com alta precisão estados já estabelecidos, o modelo (WANG; LITTLER; LIU, 2023) antecipa a trajetória de degradação. Os resultados demonstram que a modelagem temporal captura padrões que modelos estáticos não representam adequadamente, reduzindo o tempo médio de detecção de falhas incipientes.

No entanto, o trabalho apresenta limitações relevantes para o presente estudo. A etapa de classificação posterior à previsão é tratada como módulo independente, classificadores são aplicados sobre as previsões sem qualquer mecanismo de otimização conjunta. Isso implica que erros de previsão da LSTM se propagam para a classificação sem correção, potencialmente amplificando imprecisões. Além disso, o trabalho não testa a robustez do modelo frente a séries temporais com dados faltantes ou irregulares, problema comum em datasets industriais de DGA.

(AL-SAKINI et al., 2025) conduzem uma avaliação comparativa de técnicas de aprendizado de máquina aplicadas à classificação de falhas em transformadores com dados reais de DGA, incluindo SVM, Random Forest, KNN e redes neurais. Os resultados indicam que métodos de ensemble superam classificadores individuais na maioria dos cenários, especialmente em condições de dados desbalanceados. A principal contribuição do estudo é a validação experimental com dados de campo, que introduz ruído, valores ausentes e irregularidades temporais ausentes nos experimentos de (WU et al., 2021). A limitação central é a ausência de uma etapa de previsão: o modelo opera exclusivamente sobre dados observados, sem capacidade de antecipar tendências de degradação.

(ALI et al., 2023) realizam uma revisão abrangente dos métodos de interpretação de DGA, cobrindo desde técnicas baseadas em regras até abordagens de aprendizado profundo. Os autores identificam três lacunas recorrentes na literatura:

- ausência de tratamento adequado para dados desbalanceados;
- falta de modelos que integrem previsão temporal e classificação otimizada;
- escassez de estudos que avaliem a robustez dos modelos frente a dados industriais reais.

Essas lacunas são diretamente endereçadas pela proposta do presente trabalho.

(TIGHTIZ et al., 2020) propõem um sistema de diagnóstico baseado em ANFIS (Adaptive Neuro-Fuzzy Inference System) combinado com regras de associação, buscando integrar interpretabilidade e precisão na classificação de falhas. Os resultados são competitivos em relação a classificadores tradicionais, mas o modelo exige ajuste fino intensivo dos parâmetros fuzzy, o que limita sua aplicabilidade em novos domínios sem re-treinamento extensivo. A abordagem não incorpora modelagem temporal.

Além dos trabalhos citados anteriormente, a literatura recente registra o surgimento de abordagens baseadas em mecanismos de atenção e arquiteturas Transformer para séries temporais de sinais elétricos (VASWANI et al., 2017). Estudos aplicando Transformers à previsão de grandezas em sistemas de potência reportam vantagens em séries longas, onde o mecanismo de atenção supera a memória recorrente da LSTM ao capturar dependências de longo alcance sem degradação do gradiente (ZHU et al., 2023). Embora ainda incipiente na literatura específica de DGA, essa tendência representa um concorrente direto à abordagem LSTM adotada neste trabalho e será considerada na análise comparativa dos resultados.

# 3 METODOLOGIA

Este capítulo descreve a metodologia adotada para o desenvolvimento do modelo híbrido proposto. São apresentados, em sequência a visão geral da abordagem de dois estágios, o desenho metodológico baseado no CRISP-DM, as bases de dados utilizadas, o pré-processamento dos dados, a modelagem temporal com redes LSTM, a engenharia de atributos, a seleção e otimização via IGA, a classificação com XGBoost, o protocolo experimental de avaliação, aspectos de reprodutibilidade e as limitações metodológicas identificadas. O capítulo encerra com o cronograma de atividades previsto para as fases do TCC.

## 3.1 VISÃO GERAL DA ABORDAGEM

A metodologia proposta é estruturada em dois estágios sequenciais e complementares. O primeiro estágio compreende um módulo de previsão temporal, em que uma rede LSTM multivariada será empregada para estimar a concentração futura dos gases dissolvidos com base em séries temporais históricas. O horizonte de previsão $h$ será determinado durante a fase experimental, a partir de experimentos que avaliarão diferentes valores e seus impactos no desempenho do módulo de classificação subsequente. As previsões geradas, combinadas com os valores observados e atributos derivados, constituirão o vetor de entrada do segundo estágio, em que um classificador XGBoost, com atributos e hiperparâmetros otimizados pelo IGA, determinará a condição operacional do transformador.

A Figura 7 apresenta a arquitetura geral do sistema proposto. O fluxo inicia com dois conjuntos de dados distintos: séries temporais de DGA, utilizadas para treinar o módulo de previsão, e snapshots rotulados, utilizados para o módulo de classificação. Após o pré-processamento, as séries temporais alimentam a rede LSTM, que produz estimativas das concentrações futuras dos gases. Essas estimativas, combinadas com as concentrações observadas e as razões padronizadas pela norma IEC 60599, compõem o vetor de atributos do módulo de classificação. O Grupo 3 de atributos, destacado na figura pelo marcador ($\star$), representa a contribuição específica desta arquitetura híbrida: ao incorporar informação prospectiva gerada pela LSTM, o classificador passa a operar com dados que modelos puramente estáticos não possuem. O vetor unificado é então submetido ao IGA, que otimiza simultaneamente a seleção de atributos e os hiperparâmetros do XGBoost, cujo resultado é o diagnóstico da classe de falha do transformador.

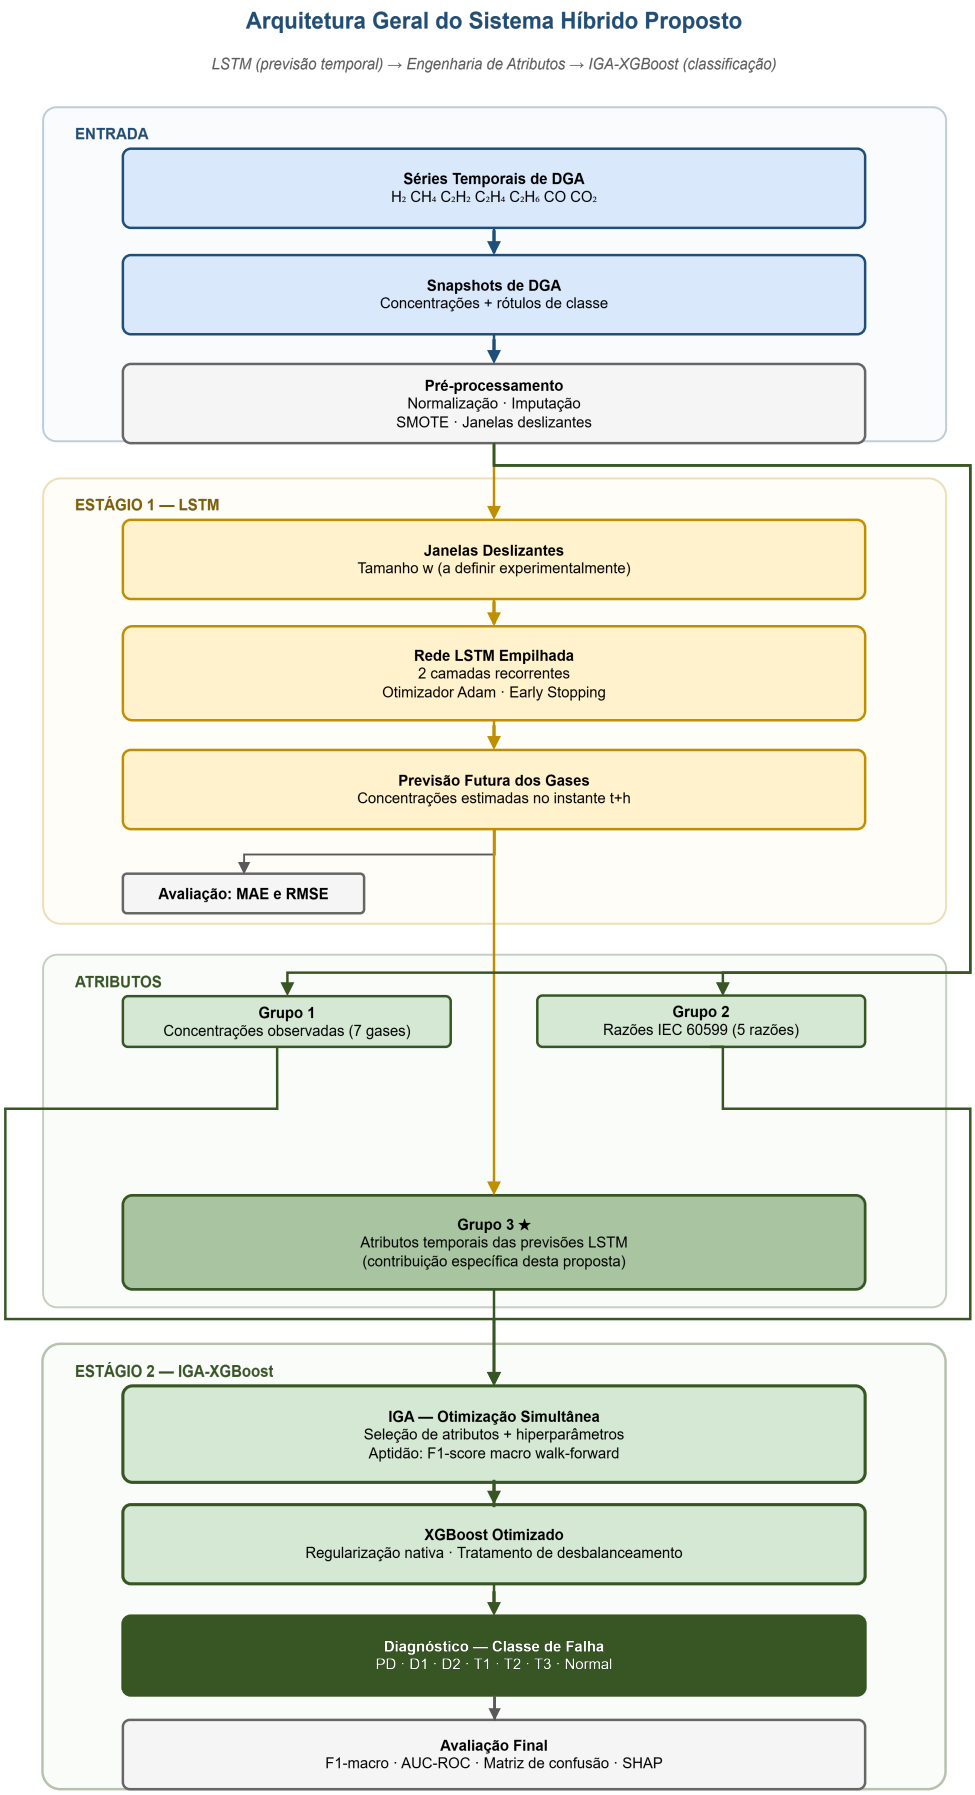



Figura 7 – Arquitetura geral do sistema híbrido proposto, composta por quatro módulos sequenciais: entrada de dados, previsão temporal via LSTM, engenharia de atributos e classificação via IGA-XGBoost. O Grupo 3 de atributos ($\star$) representa a integração entre os dois estágios. Fonte: Elaborado pelo autor.

Os dois módulos foram separados por uma razão prática a LSTM trabalha sobre janelas de séries temporais e produz valores contínuos de concentração, enquanto o XGBoost opera sobre vetores de atributos de dimensão fixa e classifica entre categorias discretas. A interface entre eles é definida pela etapa de engenharia de atributos, descrita na Seção 3.6. Espera-se que a inclusão de atributos temporais eleve o F1-macro em relação ao baseline sem LSTM.

## 3.2 DESENHO METODOLÓGICO

A pesquisa é de natureza aplicada e quantitativa, com abordagem experimental baseada na construção e avaliação de modelos computacionais. O desenvolvimento segue a metodologia para mineração de dados: CRISP-DM, com iterações entre as etapas de preparação de dados, modelagem e avaliação.

## 3.3 BASES DE DADOS E DEFINIÇÃO DO PROBLEMA

O estudo adota dois conjuntos de dados públicos, selecionados pela complementaridade que oferecem aos dois módulos da arquitetura proposta.

Para o módulo de classificação, será utilizada a base compilada por Wu et al. (2021) a partir do dataset IEC 60599, disponibilizada pelos autores como material suplementar. O conjunto contém 430 amostras distribuídas em sete categorias: seis tipos de falha (PD, D1, D2, T1, T2 e T3) e uma classe normal. Os atributos primários são as concentrações dos gases $H_2$, $CH_4$, $C_2H_2$, $C_2H_4$ e $C_2H_6$. A distribuição é desbalanceada: as classes T2 e T3 concentram cerca de 40% das amostras, enquanto PD e D1 juntas representam menos de 15%. Esse desequilíbrio será tratado conforme descrito na Seção 3.4.

Para o módulo de previsão temporal, será utilizada a base de séries temporais de DGA disponibilizada por Wang, Littler e Liu (2023), que contém medições longitudinais de múltiplos transformadores com intervalos irregulares. Caso a disponibilidade dessa base não seja confirmada até o início da fase experimental, a alternativa considerada será as séries sintéticas geradas por simulação de Monte Carlo com base nos parâmetros estatísticos reportados por Ali et al. (2023), estratégia adotada em estudos similares quando dados longitudinais rotulados são escassos.

O problema é formulado em duas tarefas. A primeira é de regressão multivariada: dado um histórico de $w$ passos temporais das concentrações dos gases, estimar as concentrações no instante $t + h$. A segunda é de classificação multiclasse: dado um vetor de atributos derivado de medições observadas e previstas, determinar a classe operacional do transformador.

## 3.4 PRÉ-PROCESSAMENTO DOS DADOS

O pré-processamento é organizado em quatro etapas, todas aplicadas de forma independente sobre os conjuntos de treino e teste para evitar vazamento de informação.

**Tratamento de valores ausentes.**Valores faltantes em séries temporais serão imputados por interpolação linear entre os pontos adjacentes, desde que a lacuna não ultrapasse três períodos consecutivos. Lacunas maiores serão tratadas como sequências independentes. Valores negativos, que são fisicamente impossíveis para concentrações de gases, e pontos fora da curva, acima de 99,5%, serão sinalizados e removidos após inspeção manual.

**Normalização.** As concentrações dos gases operam em escalas muito diferentes: o $H_2$ pode alcançar milhares de ppm, enquanto o $C_2H_2$ raramente excede algumas centenas. Por isso, será aplicada normalização min-max por variável, com os parâmetros calculados exclusivamente sobre o conjunto de treinamento e aplicados ao conjunto de teste. Para o módulo LSTM, a normalização ocorre por série temporal antes da construção das janelas deslizantes.

**Tratamento do desbalanceamento de classes.** Três estratégias serão avaliadas de forma combinada. A primeira é o SMOTE, aplicado sobre o conjunto de treinamento de cada dobra para gerar amostras sintéticas das classes minoritárias por interpolação no espaço de atributos até atingir o equilíbro entre as amostras mantendo a tendência linear das variáveis originais. A segunda é o ajuste do parâmetro *scale_pos_weight* do XGBoost, que pondera as amostras por classe durante o treinamento. A terceira é o uso do F1-score macro como métrica de otimização do IGA, tornando a função de aptidão insensível ao desbalanceamento. A combinação mais eficaz entre essas estratégias será determinada por teste comparativo.

**Construção de janelas temporais.** Para o módulo LSTM, as séries serão segmentadas em janelas deslizantes de tamanho $w$, com passo 1. O valor de $w$ representa o número de passos temporais históricos fornecidos como entrada para a rede e será investigado durante a fase experimental, considerando diferentes tamanhos dentro de um intervalo coerente com a literatura de séries temporais aplicadas a dados de DGA (WANG; LITTLER; LIU, 2023). A variável-alvo de cada janela é o vetor de concentrações no instante $w + h$. A divisão entre treino, validação e teste respeita a ordem cronológica das sequências.

A Figura 8 mostra a estratégia adotada de validação cruzada consideradas para dados temporais. O *walk-forward validation* respeita a ordem cronológica das observações, o conjunto de treinamento cresce progressivamente a cada dobra, e a validação sempre ocorre sobre dados futuros em relação ao treino. Essa abordagem preserva a causalidade do processo e garante que o modelo nunca tenha acesso a

informações do futuro durante o treinamento.

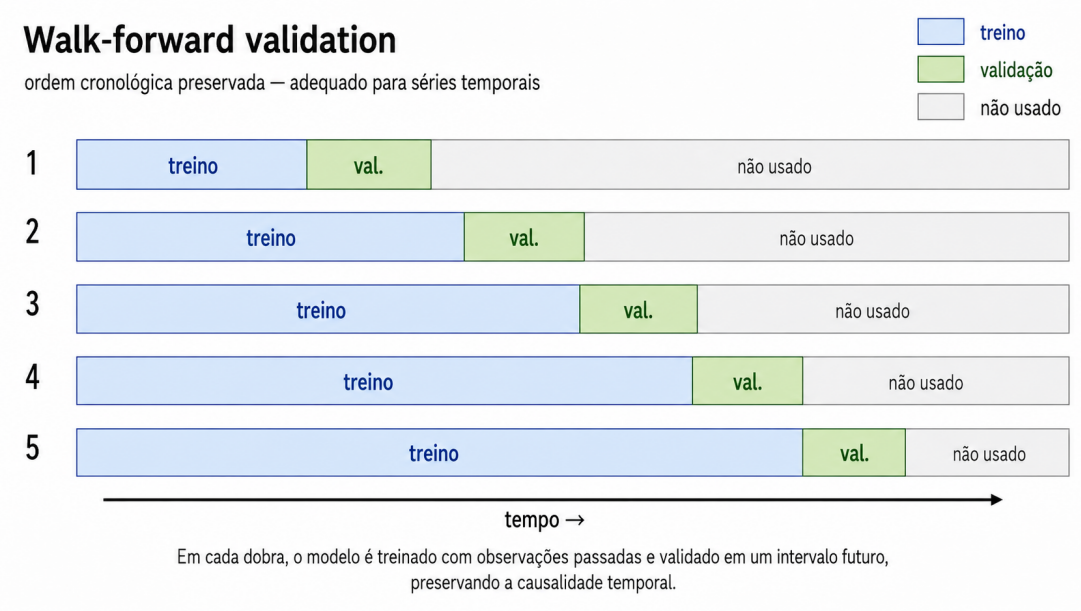



Figura 8 – Em walk-forward validation, a validação sempre ocorre sobre dados futuros em relação ao treino, preservando a causalidade temporal. Fonte: Elaborado pelo autor.

## 3.5 MODELAGEM TEMPORAL COM LSTM

Esta seção detalha o módulo de previsão temporal da arquitetura proposta. São descritos, em sequência, a representação dos dados de DGA como séries temporais por meio de janelas deslizantes e os aspectos de arquitetura e treinamento da rede LSTM empilhada utilizada para estimar as concentrações futuras dos gases dissolvidos.

### 3.5.1 REPRESENTAÇÃO DOS DADOS COMO SÉRIES TEMPORAIS

Para que a rede LSTM aprenda padrões de evolução temporal dos gases, os dados de DGA precisam ser representados como sequências. Essa transformação é realizada pela técnica de janelas deslizantes (*sliding windows*). Dado um histórico de $T$ instantes, uma janela de tamanho $w$ percorre a série com passo 1, gerando pares (entrada, alvo): a entrada é a sequência $[x_{t-w+1}, \ldots, x_t]$ e o alvo é o vetor futuro $x_{t+h}$, com horizonte de previsão $h$.

Cada amostra de entrada tem, portanto, formato $(w \times 7)$: $w$ passos temporais e 7 variáveis ($H_2$, $CH_4$, $C_2H_2$, $C_2H_4$, $C_2H_6$, CO e $CO_2$). O valor de $w$ (tamanho da janela de contexto) controla o compromisso entre capacidade de capturar tendências de longo prazo e custo computacional.

### 3.5.2 ARQUITETURA E TREINAMENTO

A rede LSTM será implementada com arquitetura empilhada de duas camadas recorrentes. Essa escolha é motivada pela literatura de previsão de DGA (WANG; LITTLER; LIU, 2023), que indica que, para séries de tamanho moderado, camadas adicionais além de duas tendem a aumentar a dificuldade de treinamento sem ganhos consistentes. A camada de saída será densa com ativação linear, produzindo simultaneamente as concentrações previstas dos sete gases no instante $t + h$.

O treinamento utilizará o otimizador Adam, amplamente adotado em modelos LSTM pela adaptabilidade da taxa de aprendizado (WANG; LITTLER; LIU, 2023). Para reduzir *overfitting*, será aplicado *early stopping* com base na *loss* de validação, o early stopping interrompe o treinamento quando a função de perda no conjunto de validação para de melhorar por um número predefinido de épocas consecutivas, evitando que o modelo memorize os dados de treino. A função de perda adotada será o erro quadrático médio calculado sobre a saída multivariada normalizada.

O desempenho do módulo será avaliado por MAE e RMSE na escala original (após desnormalização), reportados por variável e de forma agregada. Também será analisado como erros de previsão do primeiro estágio se propagam ao módulo de classificação subsequente, quantificando o impacto dessas imprecisões no diagnóstico final.

## 3.6 ENGENHARIA DE ATRIBUTOS

O vetor de atributos do módulo de classificação será construído a partir de três grupos de variáveis, cada um capturando uma perspectiva distinta do estado do transformador.

O **primeiro grupo** contém as concentrações observadas dos sete gases no instante corrente ($H_2$, $CH_4$, $C_2H_2$, $C_2H_4$, $C_2H_6$, CO e $CO_2$). Esses valores brutos refletem o estado atual do sistema de isolamento e são a base sobre a qual métodos tradicionais de DGA operam.

O **segundo grupo** é composto pelas razões entre gases padronizadas pela norma IEC 60599: $CH_4/H_2$, $C_2H_2/C_2H_4$, $C_2H_4/C_2H_6$, $C_2H_2/CH_4$ e $CO_2/CO$. Essas razões incorporam conhecimento físico dos mecanismos de geração de gases e seu poder discriminativo para classes de falha é amplamente documentado (ALI et al., 2023).

O **terceiro grupo** incluirá atributos temporais derivados das previsões do módulo LSTM: o valor previsto no instante $t + h$, a diferença entre previsto e observado e uma taxa de variação estimada para o horizonte $h$. Esse conjunto representa a contribuição específica da arquitetura híbrida, pois incorpora informação prospectiva ao vetor de

atributos, algo indisponível em abordagens puramente estáticas.

A relevância efetiva de cada grupo será avaliada pelo IGA e por análise SHAP sobre o modelo final, verificando empiricamente se os atributos temporais contribuem para a classificação ou introduzem ruído. A análise SHAP (SHapley Additive exPlanations) é uma técnica de interpretabilidade baseada na teoria dos jogos cooperativos que atribui a cada atributo uma pontuação de importância para cada predição individual do modelo. Diferentemente de métricas globais de importância, o SHAP permite identificar quais atributos mais influenciaram cada decisão de classificação, possibilitando verificar empiricamente se os atributos temporais do Grupo 3, derivados das previsões da LSTM, contribuem de forma consistente para o diagnóstico ou introduzem ruído no vetor de entrada.

## 3.7 SELEÇÃO DE ATRIBUTOS E OTIMIZAÇÃO COM IGA

No IGA, cada indivíduo é codificado como um vetor que combina uma parte binária e uma parte contínua. A parte binária representa a máscara de seleção de atributos: o valor 1 indica que o atributo está incluído no modelo, e o valor 0 indica que está excluído. A parte contínua codifica os hiperparâmetros do XGBoost. Os hiperparâmetros a serem otimizados e seus respectivos espaços de busca serão definidos com base nos intervalos utilizados por Wu et al. (2021) no mesmo domínio de aplicação, podendo ser ajustados após experimentos preliminares caso o comportamento dos dados justifique uma exploração diferente.

A população inicial conterá 50 indivíduos, valor adotado por Wu et al. (2021) e considerado adequado para o tamanho do espaço de busca deste problema. Os genes correspondentes às razões IEC 60599 serão inicializados com probabilidade 0,8 de ativação, refletindo o poder discriminativo já documentado para esses atributos. Os demais genes serão inicializados aleatoriamente com probabilidade 0,5. Essa inicialização heurística, que diferencia o IGA do GA convencional, reduz o número de gerações necessárias para a convergência, conforme demonstrado por Wu et al. (2021).

A função de aptidão será o F1-score macro obtido por validação cruzada walk-forward com 5 dobras sobre o conjunto de treinamento. Quando a diversidade da população cair abaixo de um limiar $\delta$, medido pelo desvio padrão das aptidões, a taxa de cruzamento será reduzida e a taxa de mutação será aumentada para evitar convergência prematura. O critério de parada adotado é de 100 gerações, valor estabelecido por Wu et al. (2021), ou ausência de melhoria por 20 gerações consecutivas, o que ocorrer primeiro.

O principal custo computacional está nas avaliações de aptidão: com 50 indi-

víduos e até 100 gerações, são necessárias até 5.000 execuções do XGBoost. Para reduzir esse custo sem comprometer a qualidade da busca, serão investigadas estratégias de avaliação parcial nas gerações iniciais, reservando a avaliação completa para as gerações finais. Essas estratégias serão descritas e avaliadas durante a fase experimental do TCC II.

## 3.8 CLASSIFICAÇÃO COM XGBOOST

O modelo XGBoost final será treinado com os atributos selecionados e os hiperparâmetros definidos pelo IGA, sobre o conjunto completo de treinamento. A estratégia de tratamento do desbalanceamento de classes a ser aplicada nesta etapa será determinada pelos experimentos comparativos descritos na Seção 3.4.

## 3.9 PROTOCOLO EXPERIMENTAL E AVALIAÇÃO

Os dados serão divididos na proporção 70/15/15 para treinamento, validação e teste, respeitando a ordem temporal das sequências. O conjunto de teste é reservado exclusivamente para a avaliação final e não será utilizado para ajuste de limiar nem para seleção de modelo. Para garantir a estabilidade dos resultados, os experimentos serão repetidos com múltiplas sementes aleatórias distintas, reportando média e desvio padrão das métricas. O número de repetições será definido durante a fase experimental em função do custo computacional observado, seguindo prática comum na literatura de otimização por algoritmos evolutivos.

Para o módulo LSTM, as métricas principais são o MAE e o RMSE por variável e de forma agregada. O MAE (Mean Absolute Error) mede o erro médio absoluto entre os valores previstos e os reais, enquanto o RMSE (Root Mean Squared Error) penaliza mais fortemente os erros maiores por elevar as diferenças ao quadrado antes de calcular a média.

Para o módulo de classificação, serão reportadas acurácia, F1-score macro, F1-score por classe, matriz de confusão e AUC-ROC multiclasse. O F1-score macro calcula a média aritmética do F1-score individual de cada classe, onde o F1 de cada classe é a média harmônica entre precisão e revocação. Por tratar todas as classes com peso igual independentemente de sua frequência, essa métrica não é distorcida pelo desbalanceamento de classes, ao contrário da acurácia global. A AUC-ROC (Area Under the Curve — Receiver Operating Characteristic) mede a capacidade discriminativa do modelo entre classes de forma independente do limiar de decisão adotado. Valores próximos a 1 indicam separação quase perfeita entre classes; valores próximos a 0,5 indicam desempenho equivalente a classificação aleatória.

As comparações serão feitas contra quatro referências: o Triângulo de Duval e o Método de Rogers como baselines tradicionais; o XGBoost com hiperparâmetros padrão e sem seleção de atributos, para isolar a contribuição do IGA; o XGBoost com IGA mas sem os atributos temporais, para isolar a contribuição do módulo LSTM; e a reprodução do modelo de Wu et al. (2021) sobre os mesmos dados. Esse protocolo ablativo permitirá quantificar a contribuição independente de cada componente da arquitetura proposta.

## 3.10 REPRODUTIBILIDADE E IMPLEMENTAÇÃO

A implementação será feita em Python com as seguintes bibliotecas: TensorFlow/Keras para o módulo LSTM, XGBoost, scikit-learn para pré-processamento e validação cruzada, e DEAP como framework para o algoritmo evolutivo. As versões específicas de cada biblioteca serão fixadas e documentadas ao início da fase experimental, garantindo que o ambiente de execução seja reproduzível. O código-fonte será disponibilizado em repositório público no GitHub, com controle de versão via Git e sementes aleatórias fixadas. Um arquivo `requirements.txt` será fornecido para facilitar a reprodução do ambiente.

## 3.11 LIMITAÇÕES METODOLÓGICAS

A principal limitação da metodologia está na heterogeneidade entre as bases de dados utilizadas. Como o módulo LSTM e o módulo de classificação serão treinados sobre conjuntos distintos, existe um desalinhamento de distribuição que a engenharia de atributos mitiga, mas não elimina completamente. Esse problema só seria resolvido com um único dataset longitudinal rotulado de larga escala, que atualmente não existe no domínio público para DGA.

Uma segunda limitação diz respeito à qualidade das previsões do módulo LSTM. Erros sistemáticos de previsão para certas classes de falha podem degradar o desempenho do classificador de forma assimétrica. O estudo de componentes, que comparará o modelo com e sem os atributos temporais, permitirá quantificar esse impacto. Se os atributos temporais introduzirem ruído sem ganho discriminativo, a arquitetura terá flexibilidade para operar sem eles, o que será avaliado durante a fase experimental.

Uma terceira limitação diz respeito à disponibilidade da base de dados para o módulo de previsão temporal. Caso a base de séries temporais de DGA de (WANG; LITTLER; LIU, 2023) não esteja acessível até o início da fase experimental, o módulo LSTM será treinado sobre dados sintéticos gerados por simulação de Monte Carlo com base nos parâmetros estatísticos reportados por (ALI et al., 2023). Embora essa

estratégia seja adotada em estudos similares quando dados rotulados são escassos, ela introduz uma limitação adicional relevante, na qual as séries sintéticas podem não capturar adequadamente a distribuição real dos gases em condições de campo, incluindo irregularidades de coleta, ruídos instrumentais e correlações não lineares entre gases que emergem de mecanismos físicos reais. Nesse cenário, os resultados do módulo LSTM devem ser interpretados com cautela, e a comparação com o módulo de classificação precisa considerar que os atributos do Grupo 3, teriam sua qualidade condicionada à fidelidade da simulação em relação aos dados reais.

Por fim, o custo computacional do IGA representa uma limitação prática relevante nesta etapa do trabalho. A viabilidade das estratégias de redução de custo será verificada durante os experimentos preliminares do TCC II, podendo levar a ajustes no tamanho da população ou no número máximo de gerações.

## 3.12 CRONOGRAMA

O cronograma de desenvolvimento deste trabalho foi organizado considerando o calendário acadêmico da UNISINOS para o ano de 2026, tomando como referência o curso de Graduação Presencial. Dessa forma, as atividades foram distribuídas entre o primeiro e o segundo semestre letivo, contemplando as etapas de definição do tema, revisão da literatura, elaboração da metodologia, implementação dos modelos, realização dos experimentos, análise dos resultados e finalização do texto.

As atividades relacionadas ao TCC 1 concentram-se principalmente no primeiro semestre de 2026, enquanto o desenvolvimento experimental, a análise dos resultados e a finalização do TCC 2 estão previstos para o segundo semestre. O mês de julho foi considerado como período de transição, destinado à incorporação das correções da orientadora e à preparação para a continuidade do trabalho.

Tabela 3 – Cronograma de desenvolvimento do trabalho

| **Mês / Período de 2026** | **Atividades** |
|---|---|
| Fevereiro / Março | Definição do tema, revisão inicial da literatura e levantamento de bases de dados. |
| Março | Aprofundamento da fundamentação teórica, contemplando Análise de Gases Dissolvidos (DGA), LSTM, XGBoost e Algoritmo Genético Aprimorado (IGA); escrita do Capítulo 2. |
| Abril | Definição e escrita da metodologia; levantamento dos conjuntos de dados; escrita do Capítulo 3. |
| Maio / Junho | Finalização do TCC 1; ajustes no texto; preparação para entrega TCC 1. |
| Junho / Julho | incorporação das correções da orientadora; organização para início do TCC 2. |
| Agosto | Pré-processamento dos dados; implementação do módulo LSTM; realização dos experimentos preliminares. |
| Setembro | Implementação do IGA-XGBoost; integração dos módulos; realização dos experimentos comparativos. |
| Outubro / Novembro | Análise dos resultados; comparação com modelos de referência; análise SHAP; escrita do Capítulo 4. |
| Novembro / Dezembro | Escrita das conclusões; revisão geral do texto; formatação final; entrega do TCC 2; preparação da apresentação e defesa final. |

# 4 CONSIDERAÇÕES FINAIS

Este trabalho apresentou a proposta de um modelo híbrido para predição proativa de falhas incipientes em transformadores de potência a partir de dados de Análise de Gases Dissolvidos (DGA). A revisão da literatura evidenciou que os métodos tradicionais de interpretação da DGA, como o Triângulo de Duval e o Método de Rogers, apresentam limitações estruturais decorrentes de suas fronteiras fixas, o que resulta em diagnósticos imprecisos ou inconclusivos em cenários ambíguos. Constatou-se, ainda, que as abordagens baseadas em aprendizado de máquina disponíveis na literatura, embora superiores aos métodos tradicionais em termos de acurácia classificatória, concentram-se predominantemente no diagnóstico estático de falhas já estabelecidas, desconsiderando a dinâmica temporal das concentrações dos gases.

Diante dessa lacuna, foi proposta uma arquitetura em dois estágios que integra uma rede LSTM para previsão multivariada das concentrações futuras dos gases a um classificador XGBoost com atributos e hiperparâmetros otimizados por um Algoritmo Genético Melhorado (IGA). A fundamentação teórica consolidou os conceitos necessários para a implementação de cada componente, e a metodologia definiu o protocolo experimental, as bases de dados a serem utilizadas, as estratégias de pré-processamento e os critérios de avaliação.

Como próximos passos, o TCC II contemplará a implementação dos módulos propostos, a realização dos experimentos comparativos e a análise dos resultados por meio de métricas como F1-*score* macro, AUC-ROC e matriz de confusão, incluindo análise de interpretabilidade via SHAP. Espera-se que a integração da informação temporal ao processo de classificação represente um avanço em relação às abordagens estáticas, contribuindo para uma gestão mais eficiente de ativos em sistemas elétricos de potência.

# REFERÊNCIAS

AL-SAKINI, S. R. et al. Dissolved gas analysis for fault prediction in power transformers using machine learning techniques. *Applied Sciences*, MDPI, v. 15, n. 1, p. 118, 2025. Citado 5 vezes nas páginas 13, 17, 18, 23 e 34.

ALI, M. S. et al. Conventional methods of dissolved gas analysis using oil-immersed power transformer for fault diagnosis: A review. *Electric Power Systems Research*, Elsevier, v. 216, p. 109064, 2023. Citado 13 vezes nas páginas 4, 11, 16, 17, 18, 19, 23, 25, 29, 34, 37, 40 e 43.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*. ACM, 2016. p. 785–794. Disponível em: <https://www.kdd.org/kdd2016/papers/files/rfp0697-chenAemb.pdf>. Citado na página 24.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 24.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural computation*, 1997. Citado 5 vezes nas páginas 4, 26, 27, 28 e 33.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 1998. Citado na página 23.

TIGHTIZ, L. et al. An intelligent system based on optimized anfis and association rules for power transformer fault diagnosis. *ISA Transactions*, Elsevier, v. 103, p. 63–74, 2020. Citado 3 vezes nas páginas 11, 16 e 34.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30. Citado na página 34.

WANG, L.; LITTLER, T.; LIU, X. Dynamic incipient fault forecasting for power transformers using an lstm model. *IEEE Transactions on Dielectrics and Electrical Insulation*, IEEE, 2023. Citado 7 vezes nas páginas 13, 28, 33, 37, 38, 40 e 43.

WU, Z. et al. Improved genetic algorithm and xgboost classifier for power transformer fault diagnosis. *Frontiers in Energy Research*, Frontiers Media, v. 9, 2021. Citado 13 vezes nas páginas 4, 13, 23, 24, 25, 29, 30, 32, 33, 34, 37, 41 e 43.

ZHU, L. et al. Transformer-based model for long-sequence time-series forecasting in power systems. *IEEE Transactions on Power Systems*, v. 38, n. 4, 2023. Citado 3 vezes nas páginas 23, 28 e 34.