UNIVERSIDADE DO VALE DO RIO DOS SINOS – UNISINOS

UNIDADE ACADÊMICA DE GRADUAÇÃO

CURSO DE ENGENHARIA DA COMPUTAÇÃO

ÂNDRIO GABRIEL EPPING

PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

SÃO LEOPOLDO

2026

ÂNDRIO GABRIEL EPPING

PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

Trabalho de Conclusão de curso apresentado como requisito parcial para obtenção do título de Bacharel em Engenharia da Computação, pelo curso de Engenharia da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS).

Orientador: Profa. Me. Janaína Conceição Sutil Lemos

SÃO LEOPOLDO

2026

RESUMO

Os transformadores de potência são equipamentos essenciais nos sistemas de energia elétrica, apresentando alto custo e grande impacto operacional. Falhas nesses equipamentos podem provocar interrupções no fornecimento de energia e prejuízos significativos. Nesse contexto, a Análise de Gases Dissolvidos (DGA) destaca-se como uma das principais técnicas para o monitoramento da condição interna dos transformadores. Entretanto, métodos tradicionais de interpretação dos resultados da DGA, como o Triângulo de Duval e as razões da norma IEC 60599, apresentam limitações devido às suas fronteiras fixas, o que pode levar a diagnósticos imprecisos ou indeterminados. Com o avanço das técnicas de Inteligência Artificial, novas abordagens têm sido propostas para superar essas limitações. No entanto, grande parte dessas soluções ainda se concentra na identificação de falhas já existentes, caracterizando uma abordagem reativa. Diante disso, este trabalho desenvolve e avalia um sistema híbrido baseado em redes neurais recorrentes LSTM para previsão de gases e no classificador XGBoost otimizado por Algoritmo Genético Melhorado (IGA) para o diagnóstico de falhas. A investigação foi estruturada em dois eixos experimentais para contemplar as características dos dados industriais abertos disponíveis. No eixo A, foram analisadas 3.000 séries temporais com quatro gases para avaliar se a inclusão das projeções da LSTM melhora o desempenho do classificador. Os testes pareados por bootstrap demonstraram que, devido à forte correlação entre as leituras do momento e as projeções futuras, as estimativas temporais não trouxeram ganho estatístico no diagnóstico pontual. Por outro lado, o algoritmo genético selecionou um subconjunto de apenas 8 atributos a partir dos 17 candidatos, mantendo o mesmo desempenho ($F_1 \approx 0,89$). No eixo B, com 1.962 registros estáticos de cinco gases e sete classes de falhas, os modelos baseados em árvores alcançaram F_1-macro de até 0,797 no conjunto de teste independente e cerca de 0,76 na validação cruzada repetida, sugerindo que a sobreposição física entre diferentes tipos de degradação impõe um limite prático ao diagnóstico baseado unicamente em gases. Por fim, a técnica TreeSHAP permitiu analisar as regras aprendidas pelo modelo, evidenciando convergência direta entre a fronteira aprendida para etileno e o Triângulo de Duval, além de fundamentar as divergências empíricas e explicar os casos fronteiriços de erro de classificação.

Palavras-chave: Transformadores de Potência, Análise de Gases Dissolvidos, Redes LSTM, XGBoost, Algoritmo Genético Melhorado, TreeSHAP.

ABSTRACT

Power transformers are essential components in electrical power systems, involving high costs and significant operational impact. Failures in these devices can lead to power supply interruptions and substantial economic losses. In this context, Dissolved Gas Analysis (DGA) stands out as one of the main techniques for monitoring the internal condition of transformers. However, traditional methods for interpreting DGA results, such as the Duval Triangle and the IEC 60599 ratio method, present limitations due to their fixed boundaries, which may result in imprecise or inconclusive diagnoses. With the advancement of Artificial Intelligence techniques, new approaches have been proposed to overcome these limitations. Nevertheless, most of these solutions still focus on identifying faults that have already occurred, representing a reactive approach. Therefore, this work develops and evaluates a system based on Long Short-Term Memory (LSTM) recurrent neural networks for gas forecasting and an XGBoost classifier optimized by an Improved Genetic Algorithm (IGA) for fault diagnosis. The investigation was structured into two experimental tracks to accommodate the characteristics of available open industrial datasets. In Track A, 3,000 time series covering four gases were analyzed to test whether adding LSTM forecasts improves classification performance. Paired bootstrap tests showed that, due to the high correlation between current concentrations and future projections, temporal estimates provided no statistically significant gain for instantaneous diagnosis; on the other hand, the genetic algorithm reduced the required feature set from 17 to 8 variables while maintaining the same diagnostic performance ($F_1 \approx 0.89$). In Track B, using 1,962 static records with five gases and seven fault classes, tree-based models reached an F_1-macro of up to 0.797 on the independent test set and approximately 0.76 in repeated cross-validation, indicating that physical overlap between fault mechanisms imposes a practical limit on pure gas-based diagnosis. Finally, TreeSHAP was applied to explain the learned decision patterns, showing direct alignment between the learned ethylene threshold and the Duval Triangle, while clarifying borderline classification errors.

Keywords: Power Transformers, Dissolved Gas Analysis, LSTM Networks, XGBoost, Improved Genetic Algorithm, TreeSHAP.

LISTA DE ILUSTRAÇÕES

Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA, confrontando a abordagem normativa reativa com a modelagem preditiva orientada a dados. 13
Figura 2 – Triângulo de Duval para interpretação de gases dissolvidos em óleo mineral. 20
Figura 3 – Esquema conceitual do processo iterativo de minimização de resíduos em ensembles de gradient boosting. 26
Figura 4 – Diagrama conceitual da arquitetura interna de uma célula de memória recorrente LSTM. 28
Figura 5 – Diagrama conceitual da topologia de rede neural recorrente LSTM empilhada para modelagem temporal. 29
Figura 6 – Fluxo operacional do Algoritmo Genético Melhorado para busca conjunta. 30
Figura 7 – Fluxograma metodológico do trabalho estruturado na divisão entre os eixos Track A e Track B. 37
Figura 8 – Evolução do coeficiente de determinação (R^2) da LSTM em múltiplos horizontes temporais no conjunto de teste oficial. 51
Figura 9 – Relação entre complexidade dimensional e desempenho diagnóstico nos Tracks A e B. 55
Figura 10 – Matriz de confusão das predições diagnósticas para o Track A no conjunto de teste oficial. 56
Figura 11 – Matriz de confusão do modelo C3 (IGA-XGBoost) no teste de sete classes do Track B. 59
Figura 12 – Mapa de calor da importância média absoluta do SHAP por classe operacional no Track B. 63
Figura 13 – Importância agregada por famílias de gases para as sete categorias de integridade operacional. 63
Figura 14 – Distribuição dos valores de SHAP para a classe de Descargas de Baixa Energia (D1). 64
Figura 15 – Efeito principal isolado do TreeSHAP para a razão C_2H_4/TH na classe D1. 65
Figura 16 – Mapeamento das amostras de teste no Triângulo 1 de Duval com a localização dos erros diagnósticos. 67
Figura 17 – Decomposição aditiva via Waterfall plot de um caso classificado de D1 para D2 (amostra 11). 68

Figura 18 – Divisão da importância média absoluta do SHAP entre as projeções temporais de hidrogênio no modelo C1. 69

LISTA DE TABELAS

Tabela 1 – Comparação entre algoritmos de aprendizado de máquina aplicados à DGA 22
Tabela 2 – Comparação entre trabalhos relacionados e o escopo investigado neste estudo. 33
Tabela 3 – Desempenho do módulo LSTM no conjunto de teste oficial para previsão de um passo ($h = 1$, escala normalizada). 50
Tabela 4 – Desempenho da LSTM recursiva e do baseline de persistência em função do horizonte temporal (5 sementes, 200 séries/semente). . . 51
Tabela 5 – Desempenho comparativo e teste de ablação da hipótese temporal no Track A (900 amostras de teste, 5 sementes). 53
Tabela 6 – Comparações pareadas via bootstrap (5.000 iterações) no Track A. 53
Tabela 7 – Desempenho diagnóstico multiclasse no Track B sobre o conjunto de teste e validação cruzada. 57
Tabela 8 – Concordância entre os rótulos da base e os diagnósticos da IEC 60599 e do Triângulo de Duval. 61
Tabela 9 – Comparação entre limiares analíticos normativos e pontos de transição marginal do TreeSHAP. 65

LISTA DE ABREVIATURAS E SIGLAS

AG	Algoritmo Genético
ANFIS	*Adaptive Neuro-Fuzzy Inference System* (Sistema de Inferência Neuro-Fuzzy Adaptativo)
ANOVA	*Analysis of Variance* (Análise de Variância)
BPTT	*Backpropagation Through Time* (Retropropagação Através do Tempo)
CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
CRISP-DM	*Cross-Industry Standard Process for Data Mining* (Processo Padrão Intersetorial para Mineração de Dados)
DGA	*Dissolved Gas Analysis* (Análise de Gases Dissolvidos)
DP	Desvio Padrão
GA	*Genetic Algorithm* (Algoritmo Genético)
IC	Intervalo de Confiança
IEC	*International Electrotechnical Commission* (Comissão Eletrotécnica Internacional)
IGA	*Improved Genetic Algorithm* (Algoritmo Genético Melhorado)
KNN	*k-Nearest Neighbors* (k-Vizinhos Mais Próximos)
LightGBM	*Light Gradient Boosting Machine* (Máquina de Aumento de Gradiente Leve)
LSTM	*Long Short-Term Memory* (Memória de Curto e Longo Prazo)
MAE	*Mean Absolute Error* (Erro Médio Absoluto)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
OOF	*Out-of-Fold* (Fora da Dobra)
PSO	*Particle Swarm Optimization* (Otimização por Enxame de Partículas)
RMSE	*Root Mean Squared Error* (Raiz do Erro Quadrático Médio)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)

SHAP	*SHapley Additive exPlanations* (Explicações Aditivas de Shapley)
SMOTE	*Synthetic Minority Over-sampling Technique* (Técnica de Sobreamostragem de Minorias Sintéticas)
SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
XGBoost	*Extreme Gradient Boosting* (Aumento Extremo de Gradiente)

LISTA DE SÍMBOLOS

w	Tamanho da janela temporal (número de passos históricos)
h	Horizonte de previsão (passos à frente)
x_t	Vetor de concentrações dos gases no instante t
$\hat{y}$	Saída predita pelo modelo
h_t	Estado oculto da rede recorrente no instante t
C_t	Estado da célula (memória) da LSTM no instante t
$f_k(x)$	Árvore k no ensemble de *gradient boosting*
$L(y, \hat{y})$	Função de perda
N	Tamanho da população no AG/IGA
G	Número máximo de gerações no AG/IGA
P_c	Taxa de cruzamento (*crossover rate*)
P_m	Taxa de mutação

SUMÁRIO

1 INTRODUÇÃO 12
1.1 Tema 14
1.2 Justificativa 14
1.3 Objetivos 15
1.4 Organização do Texto 15

2 FUNDAMENTAÇÃO TEÓRICA 17
2.1 Transformadores de Potência 17
2.1.1 Sistema de Isolamento e Mecanismos de Degradação 17
2.1.2 Geração de Gases Dissolvidos 18
2.1.3 Taxonomia e Severidade de Falhas Internas 18
2.2 Métodos Normativos de Diagnóstico em DGA 19
2.2.1 Triângulo de Duval 19
2.2.2 Método das Razões da IEC 60599 21
2.3 Algoritmos de Aprendizado de Máquina Aplicados à DGA 22
2.3.1 Panorama e Classificadores Clássicos 22
2.3.2 Ensembles de Árvores e o Algoritmo XGBoost 25
2.3.3 Redes Neurais Recorrentes e Modelagem Temporal 27
2.3.4 Otimização Evolutiva por Algoritmo Genético Melhorado (IGA) 29
2.4 Interpretabilidade em Aprendizado de Máquina (XAI) 31
2.4.1 Fundamentos Conceituais dos Valores de Shapley 31
2.4.2 O Algoritmo TreeSHAP e Decomposição de Contribuições 32
2.5 Trabalhos Relacionados 33

3 METODOLOGIA 35
3.1 Desenho Metodológico e Arquitetura em Dois Eixos 35
3.2 Bases de Dados e Procedimentos de Auditoria 38
3.2.1 Base de Séries Temporais Industriais (Track A) 38
3.2.2 Base Compilada de Diagnóstico Estático (Track B) 38
3.2.3 Critérios de Exclusão e Descarte de Bases de Dados 40
3.3 Pré-processamento e Engenharia de Atributos 40
3.3.1 Tratamento de Escala e Normalização 40
3.3.2 Espaço de Atributos do Track A 41
3.3.3 Espaço de Atributos do Track B 41
3.3.4 Tratamento do Desbalanceamento de Classes 42
3.4 Módulo de Previsão Temporal 43

3.5 Algoritmo Genético Melhorado e Otimização do XGBoost 44
3.5.1 Representação Cromossômica e Operadores Genéticos 44
3.5.2 Função de Aptidão e Critérios de Parada 45
3.6 Protocolo Experimental e Rigor Estatístico 45
3.6.1 Desenho Experimental e Ablação no Track A 45
3.6.2 Desenho Experimental no Track B 46
3.6.3 Procedimentos de Bootstrap Pareado e Validação Cruzada Repetida 46
3.7 Protocolo de Interpretabilidade e Validação Físico-Química . . . 47

4 RESULTADOS E DISCUSSÃO 49
4.1 Desempenho do Módulo de Previsão Temporal 49
4.2 Resultados do Track A: Desempenho e Avaliação da Hipótese Temporal 52
4.3 Resultados do Track B: Diagnóstico Multiclasse e Limites dos Dados 56
4.4 Auditoria Normativa: Divergência dos Métodos Tradicionais . . . 60
4.5 Interpretabilidade Físico-Química via SHAP 62
4.5.1 Estabilidade do Ranking Global 62
4.5.2 Relevância por Classe e Agrupamento por Famílias Químicas 62
4.5.3 Extração de Limiares Físicos Marginais 65
4.5.4 Visualização Espacial no Triângulo de Duval 66
4.5.5 Análise Local de Erros de Classificação 67
4.5.6 Migração de Crédito e Avaliação da Hipótese Temporal 69

5 CONCLUSÃO 71
5.1 Síntese das Contribuições 71
5.2 Avaliação da Hipótese Temporal e Resultados Negativos 72
5.3 Limitações da Pesquisa 73
5.4 Direcionamentos para Trabalhos Futuros 74

REFERÊNCIAS 76

1 INTRODUÇÃO

O fornecimento contínuo de energia elétrica sustenta a operação de infraestruturas críticas em setores industriais, hospitalares e de telecomunicações. Nesse contexto, os transformadores de potência constituem elementos fundamentais das redes de transmissão e distribuição. Como operam de forma contínua e, muitas vezes, sob condições elevadas de carga, esses equipamentos sofrem desgaste ao longo do tempo, o que pode comprometer sua estrutura interna. Falhas nesse tipo de equipamento podem causar interrupções no fornecimento de energia, além de gerar prejuízos significativos. Por isso, o monitoramento e a manutenção dos transformadores são aspectos importantes para o setor elétrico (TIGHTIZ et al., 2020).

A degradação dos materiais isolantes do transformador ocorre principalmente devido a estresses térmicos e elétricos durante a operação normal. Esse processo de envelhecimento leva à formação de gases dissolvidos no óleo isolante, como hidrogênio (H_2), o metano (CH_4), o etano (C_2H_6), o etileno (C_2H_4) e o acetileno (C_2H_2), além do monóxido de carbono (CO), cuja composição e concentração estão diretamente relacionadas ao tipo e à severidade das anomalias internas. A análise dessas substâncias, conhecida como Análise de Gases Dissolvidos (DGA - *Dissolved Gas Analysis*), é amplamente utilizada para avaliar a condição interna do equipamento, da qual é possível identificar indícios de falhas em estágio inicial (ALI et al., 2023).

A Figura 1 ilustra a cadeia causal que conecta a operação do transformador ao diagnóstico de falhas. Os estresses térmicos e elétricos atuam continuamente sobre o sistema de isolamento, provocando a degradação progressiva do óleo mineral e do papel celulósico. Esse processo resulta na formação de gases dissolvidos cujas concentrações são analisadas pela DGA. A figura também destaca a diferença prática que motiva este trabalho. Enquanto os métodos normativos tradicionais avaliam o equipamento apenas após a elevação dos gases, a abordagem com aprendizado de máquina busca projetar a evolução das concentrações e automatizar a identificação de falhas.

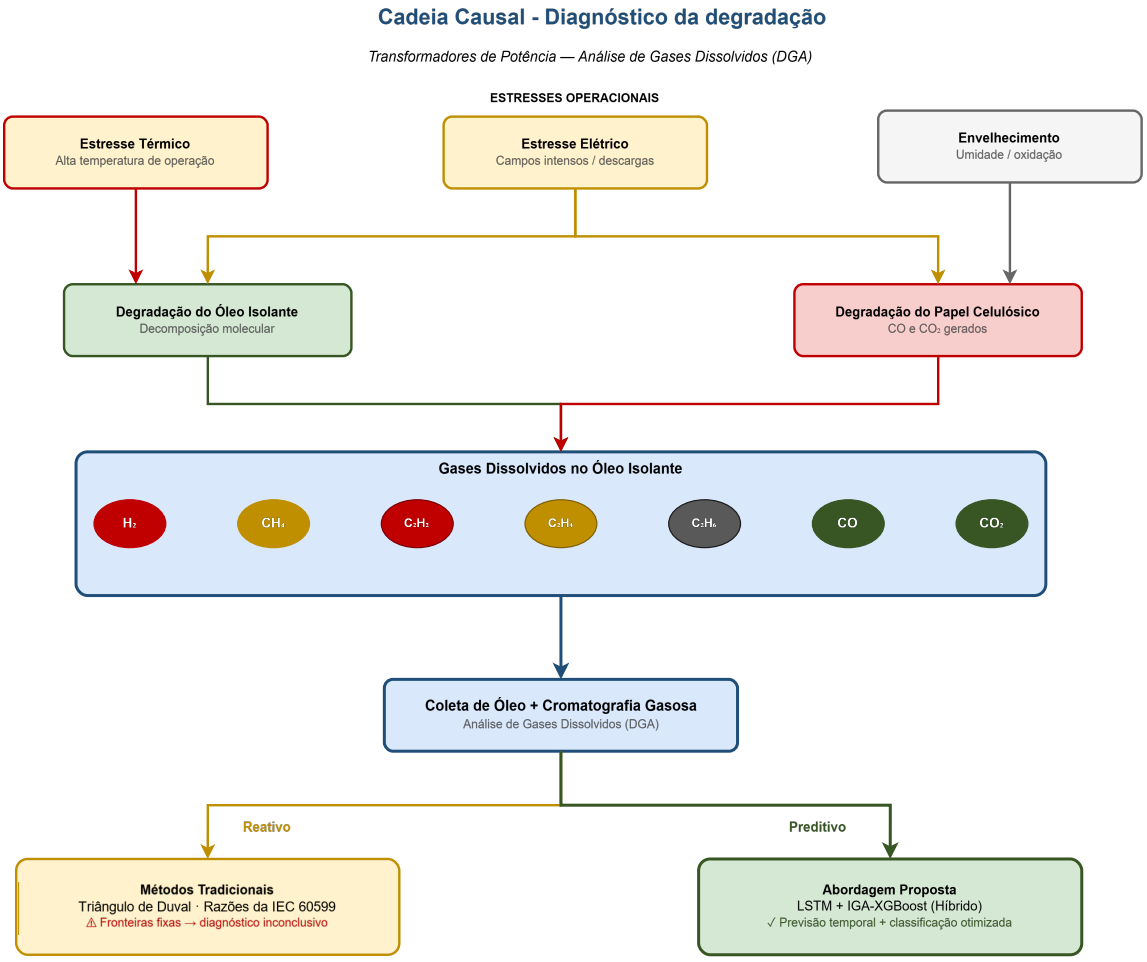


Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA, confrontando a abordagem normativa reativa com a modelagem preditiva orientada a dados.

Fonte: Elaborado pelo autor.

O desenvolvimento prático de modelos de aprendizado de máquina em DGA enfrenta, contudo, a heterogeneidade das bases de dados abertas disponíveis na área. Enquanto os registros com séries temporais frequentes provêm de sensores online com medição limitada a poucos gases, as bases com diagnósticos completos de falhas cobrem todos os gases normativos, mas consistem em registros pontuais, sem histórico temporal. Diante desse cenário, este trabalho estrutura sua investigação em dois eixos experimentais complementares. Cabe delimitar que a etapa temporal no Track A investiga se as projeções futuras de concentrações de gases estimadas pela rede neural auxiliam a classificação do estado de integridade associado à série temporal (dado que as séries industriais disponíveis mantêm rótulo de condição constante ao longo do histórico), e não a predição do instante exato de transição de um equipamento sadio até o momento de falha. Dessa forma, avaliam-se o papel prático das previsões

temporais, a simplificação de atributos e a interpretação física dos padrões aprendidos pelos algoritmos.

1.1 TEMA

Desenvolvimento e a avaliação de uma abordagem baseada em aprendizado de máquina para o diagnóstico de falhas em transformadores de potência a partir da Análise de Gases Dissolvidos, integrando redes neurais recorrentes (LSTM) para previsão de concentrações gasosas, o classificador XGBoost otimizado por algoritmo genético para identificação de falhas e técnicas de explicabilidade para interpretação física das decisões.

1.2 JUSTIFICATIVA

Tradicionalmente, a interpretação dos dados de DGA é feita por meio de métodos baseados em regras e limites predefinidos, como o Triângulo de Duval e as razões da norma IEC 60599. Apesar de serem amplamente utilizados, esses métodos apresentam limitações, principalmente quando os dados não se enquadram claramente nos padrões estabelecidos. Nesses casos, o diagnóstico pode se tornar impreciso ou inconclusivo (AL-SAKINI et al., 2025). Além disso, tais métodos operam de forma estática, desconsiderando a evolução temporal das concentrações de gases - informação relevante para a detecção precoce de falhas incipientes. Para contornar essas limitações, diversos estudos passaram a empregar algoritmos de aprendizado de máquina, como o XGBoost, capazes de identificar fronteiras de decisão complexas a partir das concentrações cromatográficas (WU et al., 2021).

Apesar do avanço desses modelos na literatura, a maioria dessas abordagens analisa apenas leituras isoladas no tempo, desconsiderando a evolução histórica da degradação. Por outro lado, modelos baseados em séries temporais, como redes neurais do tipo Long Short-Term Memory (LSTM), permitem capturar dependências temporais e prever a evolução futura dos gases, mas frequentemente carecem de um estágio de classificação otimizado (WANG; LITTLER; LIU, 2023).

Dessa forma, justifica-se uma investigação experimental que avalie o real impacto das previsões temporais no diagnóstico, quantifique a capacidade de algoritmos genéticos na seleção de conjuntos reduzidos de atributos e utilize métodos de interpretabilidade para aproximar os resultados dos modelos à prática da engenharia de manutenção.

1.3 OBJETIVOS

O objetivo geral deste trabalho consiste em desenvolver e avaliar uma metodologia computacional para o diagnóstico de falhas em transformadores de potência com base em dados de DGA, investigando a contribuição de previsões temporais obtidas por redes LSTM, a simplificação do conjunto de atributos por Algoritmo Genético Melhorado (IGA) acoplado ao XGBoost e a coerência físico-química dos padrões aprendidos frente às normas técnicas do setor elétrico.

Para atingir o objetivo geral, definem-se os seguintes objetivos específicos:

- Auditar e preparar bases de dados industriais de DGA, tratando amostras duplicadas e organizando os experimentos em dois eixos analíticos (Track A e Track B) de acordo com a disponibilidade de variáveis temporais e físico-químicas;
- Implementar e avaliar um módulo de previsão temporal baseado em redes neurais recorrentes *Long Short-Term Memory* (LSTM) (HOCHREITER; SCHMIDHUBER, 1997) para estimar a evolução de concentrações de gases em diferentes horizontes futuros;
- Avaliar experimentalmente, por meio de testes pareados com reamostragem estatística (*bootstrap*), se a inclusão das projeções da LSTM melhora o desempenho do classificador *Extreme Gradient Boosting* (XGBoost) (CHEN; GUESTRIN, 2016) no diagnóstico pontual;
- Avaliar a capacidade do Algoritmo Genético Melhorado (IGA) (WU et al., 2021) em selecionar subconjuntos reduzidos de variáveis para o XGBoost, buscando simplificar o modelo sem perda de desempenho diagnóstico;
- Analisar a coerência físico-química dos padrões de decisão do XGBoost em relação à norma técnica IEC 60599 (*Mineral oil-filled electrical equipment in service – Guidance on the interpretation of dissolved and free gases analysis*) (IEC, 2022) e ao método do Triângulo de Duval (DUVAL, 2002), empregando valores de Shapley (SHAPLEY, 1953; LUNDBERG; LEE, 2017) por meio do algoritmo TreeSHAP (LUNDBERG et al., 2020).

1.4 ORGANIZAÇÃO DO TEXTO

O trabalho está estruturado em cinco capítulos organizados da seguinte forma:

o Capítulo 2 apresenta a fundamentação teórica, abordando os conceitos de transformadores de potência, os processos de degradação do sistema de isolamento, os métodos normativos clássicos de DGA, algoritmos de aprendizado de máquina

aplicados à DGA (classificadores clássicos, ensembles, redes neurais, modelos de séries temporais e otimização evolutiva), os fundamentos das redes LSTM, do classificador XGBoost e dos algoritmos genéticos, além dos conceitos de interpretabilidade baseados no TreeSHAP e a revisão dos trabalhos correlatos.

O Capítulo 3 descreve a metodologia da pesquisa, detalhando a separação dos experimentos nos eixos Track A e Track B, o pré-processamento dos dados, as técnicas de engenharia de atributos, a configuração e o treinamento dos modelos, os procedimentos de validação estatística e o protocolo de interpretabilidade.

O Capítulo 4 apresenta os resultados e as discussões técnicas, incluindo a avaliação da rede LSTM na previsão temporal, o teste controlado da hipótese híbrida, a classificação multiclasse de falhas com o modelo IGA-XGBoost, a comparação com os métodos normativos e a análise interpretável das decisões por meio do TreeSHAP.

O Capítulo 5 reúne as conclusões do trabalho, destacando os aprendizados obtidos a partir dos dados experimentais, as limitações identificadas nos conjuntos de dados disponíveis e as oportunidades para pesquisas futuras na área.

A partir do contexto operacional definido, a justificativa e os objetivos da investigação, o próximo capítulo apresenta a fundamentação teórica que embasa os processos de degradação do sistema de isolamento de transformadores, os critérios normativos clássicos de DGA e os fundamentos computacionais dos modelos preditivos, evolutivos e interpretáveis empregados neste estudo.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos teóricos fundamentais para o desenvolvimento deste trabalho. Inicialmente, são abordados os transformadores de potência, a composição do seu sistema de isolamento e os processos físico-químicos que levam à formação de gases no óleo mineral. Em seguida, são detalhados os métodos normativos de diagnóstico mais utilizados na indústria, com destaque para o Triângulo de Duval e o Método das Razões da norma IEC 60599. Na sequência, são descritos os algoritmos de aprendizado de máquina adotados: o classificador XGBoost, as redes neurais recorrentes LSTM para previsão de séries temporais e o Algoritmo Genético Melhorado (IGA) para seleção de atributos e otimização. Também são apresentados os conceitos de explicabilidade baseados em valores de Shapley e no algoritmo TreeSHAP. Por fim, são apresentados trabalhos relacionados ao tema, com o objetivo de compreender como a literatura recente tem tratado o problema e de evidenciar o espaço em que a proposta deste estudo se insere.

2.1 TRANSFORMADORES DE POTÊNCIA

Os transformadores de potência são dispositivos eletromagnéticos estáticos responsáveis pela transferência de energia elétrica entre circuitos, por meio do princípio da indução eletromagnética (ALI et al., 2023). Esses equipamentos desempenham um papel fundamental nos sistemas elétricos de potência, permitindo a elevação ou redução dos níveis de tensão para transmissão e distribuição de energia de forma eficiente.

O funcionamento de um transformador baseia-se na Lei de Indução Eletromagnética de Faraday, segundo a qual uma variação temporal de fluxo magnético em um circuito induz uma força eletromotriz em outro circuito acoplado magneticamente (CHAPMAN, 2013). Estruturalmente, um transformador é composto por um núcleo magnético e enrolamentos isolados entre si. Do ponto de vista do diagnóstico por aprendizado de máquina, destacam-se três características operacionais principais, que são a composição do sistema de isolamento, os mecanismos de geração de gases dissolvidos e a taxonomia das falhas internas.

2.1.1 SISTEMA DE ISOLAMENTO E MECANISMOS DE DEGRADAÇÃO

O sistema de isolamento dos transformadores imersos em óleo combina materiais sólidos e fluidos dielétricos (ALI et al., 2023). A parte sólida é formada por papel

celulósico Kraft e papelão prensado (*pressboard*), que isolam as espiras e os enrolamentos das diferentes fases. A parte líquida é composta por óleo mineral isolante, que preenche os espaços internos do tanque, garantindo a rigidez dielétrica e auxiliando no resfriamento do transformador ao dissipar o calor gerado pelas perdas elétricas e magnéticas.

Ao longo dos anos de operação, o sistema de isolamento se degrada gradualmente devido à combinação de estresses térmicos, elétricos e químicos. O contato do óleo com o oxigênio residual e eventuais contaminantes provoca a oxidação do fluido, gerando ácidos e borras que reduzem sua capacidade isolante. Paralelamente, o papel celulósico sofre degradação por calor e umidade, perdendo resistência mecânica e tornando o isolamento sólido mais suscetível a rupturas em situações de sobrecarga ou curto-circuito.

2.1.2 GERAÇÃO DE GASES DISSOLVIDOS

A decomposição térmica e elétrica do óleo mineral e do papel celulósico provoca a quebra molecular desses materiais, liberando gases que se dissolvem no fluido isolante (ALI et al., 2023). Os principais gases formados são o hidrogênio (H_2), o metano (CH_4), o etano (C_2H_6), o etileno (C_2H_4) e o acetileno (C_2H_2), além do monóxido de carbono (CO) e dióxido de carbono (CO_2), associados principalmente à degradação do papel celulósico.

A concentração e a proporção relativa entre esses gases dependem da temperatura local e da intensidade energética do evento. Descargas parciais de baixa energia geram predominantemente hidrogênio e pequenas frações de metano. Aquecimentos em temperaturas mais amenas decompõem as moléculas de óleo gerando principalmente metano e etano. Em temperaturas mais elevadas, aumenta significativamente a formação de etileno. Por fim, arcos elétricos e descargas disruptivas de alta energia, onde as temperaturas locais passam de $1.000\ ^\circ$C, produzem concentrações expressivas de acetileno. A quantificação laboratorial periódica dessas substâncias via cromatografia gasosa constitui a Análise de Gases Dissolvidos (*Dissolved Gas Analysis*, DGA), ferramenta essencial para a manutenção preditiva de transformadores.

2.1.3 TAXONOMIA E SEVERIDADE DE FALHAS INTERNAS

A literatura e as normas internacionais categorizam os defeitos internos em transformadores em três classes fundamentais: falhas elétricas, falhas térmicas e defeitos combinados (AL-SAKINI et al., 2025).

- **Falhas térmicas**: associadas ao superaquecimento do óleo ou do papel isolante, são subdivididas de acordo com a temperatura estimada no ponto crítico. A classe

T1 abrange sobreaquecimentos térmicos com temperaturas inferiores a 300 °C, associados a fluxos restritos de circulação de óleo ou correntes induzidas em partes metálicas. A classe T2 corresponde a sobreaquecimentos entre 300 °C e 700 °C, comuns em maus contatos de conexões aparafusadas e derivações. A classe T3 define falhas térmicas severas, com temperaturas superiores a 700 °C, originadas por correntes circulantes intensas no tanque ou curtos-circuitos entre espiras;

- **Falhas elétricas**: englobam as descargas parciais (PD), que ocorrem em microcavidades com falhas de impregnação no papel ou pequenas bolhas de gás; as descargas de baixa energia (D1), caracterizadas por centelhamentos intermitentes de baixa corrente e as descargas de alta energia (D2), representadas por arcos elétricos intensos com queima perceptível de óleo e papel;
- **Falhas combinadas**: envolvem a ocorrência simultânea de solicitações dielétricas e térmicas na mesma região do equipamento. Na prática operacional, a distribuição dessas falhas nos bancos de dados históricos apresenta grande desbalanceamento, pois ocorrências de arcos elétricos severos ou descargas parciais são registradas com frequência muito menor do que casos de operação normal ou de sobreaquecimentos térmicos leves.

Compreendidos os mecanismos físico-químicos de geração de gases e a taxonomia das falhas internas, a seção seguinte apresenta os métodos normativos tradicionalmente adotados pela engenharia de manutenção para interpretar essas concentrações gasosas.

2.2 MÉTODOS NORMATIVOS DE DIAGNÓSTICO EM DGA

A interpretação técnica dos ensaios de DGA baseia-se tradicionalmente em métodos gráficos e tabelas padronizadas que correlacionam as proporções e razões entre os gases dissolvidos com os diferentes tipos de falha.

2.2.1 TRIÂNGULO DE DUVAL

O Triângulo de Duval, consolidado no Anexo B da norma IEC 60599 (IEC, 2022) e em diretrizes técnicas correlatas (DUVAL, 2002), é um método gráfico fundamentado em coordenadas triangulares. A formulação utiliza a concentração relativa em partes por milhão (ppm) de três gases: metano (CH_4), etileno (C_2H_4) e acetileno (C_2H_2). A soma percentual dessas três espécies define o total de referência:

$$TH_{Duval} = [CH_4] + [C_2H_4] + [C_2H_2] \tag{2.1}$$

As coordenadas percentuais de cada ponto são calculadas por:

$$\%\mathrm{CH_4} = 100 \cdot \frac{[\mathrm{CH_4}]}{\mathrm{TH_{Duval}}}, \quad \%\mathrm{C_2H_4} = 100 \cdot \frac{[\mathrm{C_2H_4}]}{\mathrm{TH_{Duval}}}, \quad \%\mathrm{C_2H_2} = 100 \cdot \frac{[\mathrm{C_2H_2}]}{\mathrm{TH_{Duval}}} \tag{2.2}$$

A soma dessas três coordenadas totaliza 100%, definindo um ponto no interior de um triângulo equilátero, conforme ilustrado na Figura 2.

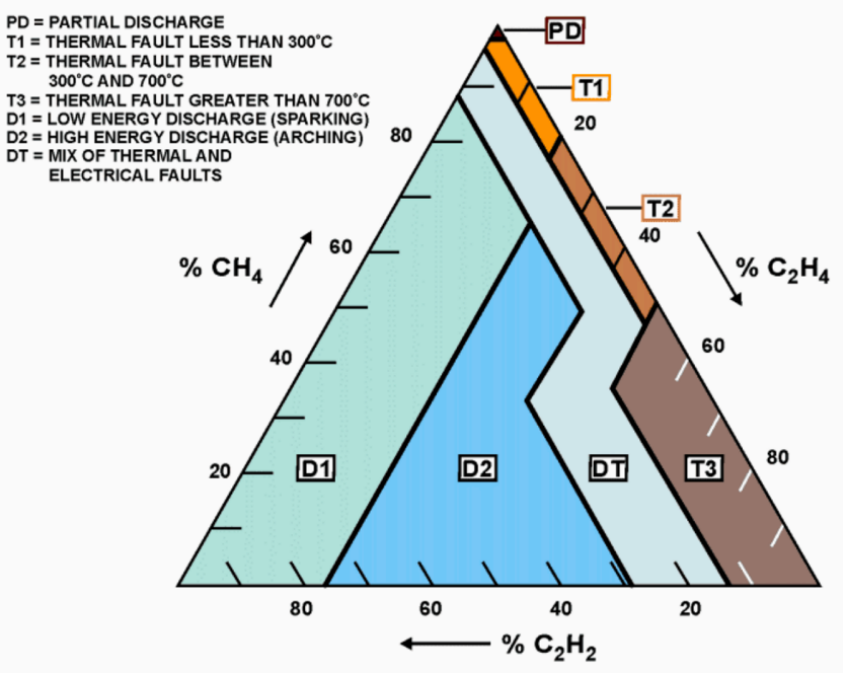


Figura 2 – Triângulo de Duval para interpretação de gases dissolvidos em óleo mineral.

Fonte: Extraído de Ali et al. (2023, p. 4).

A área do triângulo é particionada em sete regiões correspondentes a diferentes mecanismos de falha:

- descargas parciais (PD), delimitadas pela região superior com $\%\mathrm{CH_4} \geq 98\%$;
- descargas de baixa energia (D1), definidas pela região com $\%\mathrm{C_2H_2} \geq 13\%$ e $\%\mathrm{C_2H_4} < 23\%$;
- descargas de alta energia (D2), delimitadas pela região poligonal com $\%\mathrm{C_2H_2} \geq 13\%$ na faixa $23\% \leq \%\mathrm{C_2H_4} < 40\%$ e $\%\mathrm{C_2H_2} \geq 29\%$ para $\%\mathrm{C_2H_4} \geq 40\%$;
- falhas térmicas inferiores a 300 °C (T1), condicionadas a $\%\mathrm{CH_4} < 98\%$, $\%\mathrm{C_2H_2} < 4\%$ e $\%\mathrm{C_2H_4} < 20\%$;
- falhas térmicas entre 300 °C e 700 °C (T2), delimitadas por $\%\mathrm{C_2H_2} < 4\%$ e $20\% \leq \%\mathrm{C_2H_4} < 50\%$;

- falhas térmicas superiores a 700 °C (T3), caracterizadas por $\%C_2H_2 < 15\%$ e $\%C_2H_4 \geq 50\%$;
- e a zona de transição térmica e elétrica combinada (DT), situada de forma intermediária entre as zonas térmicas e de descarga ($4\% \leq \%C_2H_2 < 13\%$ para $\%C_2H_4 < 40\%$, $4\% \leq \%C_2H_2 < 29\%$ para $40\% \leq \%C_2H_4 < 50\%$ e $15\% \leq \%C_2H_2 < 29\%$ para $\%C_2H_4 \geq 50\%$).

A principal limitação do Triângulo de Duval é a inexistência de uma região destinada à operação normal. Dessa forma, qualquer amostra projetada sobre o gráfico é classificada em alguma categoria de falha, podendo gerar falsos positivos em transformadores saudáveis que apresentem apenas taxas normais de gaseificação. Além disso, amostras localizadas muito próximas às linhas de fronteira sofrem com a sensibilidade a pequenas incertezas de medição, em que pequenas variações nas concentrações podem alterar a classe atribuída.

2.2.2 MÉTODO DAS RAZÕES DA IEC 60599

O método analítico estabelecido pela norma IEC 60599 (IEC, 2022) fundamenta-se no cálculo de três razões entre as concentrações dos gases dissolvidos:

$$r_1 = \frac{[C_2H_2]}{[C_2H_4]}, \quad r_2 = \frac{[CH_4]}{[H_2]}, \quad r_3 = \frac{[C_2H_4]}{[C_2H_6]} \tag{2.3}$$

A relação r_1 avalia a presença de acetileno em relação ao etileno, permitindo distinguir centelhamentos elétricos de sobreaquecimentos térmicos puros. A relação r_2 compara o metano com o hidrogênio, auxiliando na identificação do regime térmico de descargas ou aquecimentos iniciais. A relação r_3 confronta hidrocarbonetos insaturados com saturados, oferecendo sensibilidade direta à temperatura de degradação do óleo.

A norma estabelece intervalos discretos de valores para cada uma das razões, associando suas combinações aos tipos clássicos de falha. As descargas parciais (PD) exigem $r_1 < 0,1$; $r_2 < 0,1$; e $r_3 < 0,2$. As descargas de baixa energia (D1) requerem $r_1 > 1$; $0,1 \leq r_2 \leq 0,5$; e $r_3 > 1$, enquanto as descargas de alta energia (D2) são caracterizadas por $0,6 \leq r_1 \leq 2,5$; $0,1 \leq r_2 \leq 1$; e $r_3 > 2$. Para as falhas térmicas, a degradação de baixa temperatura inferior a 300 °C (T1) demanda $r_1 < 0,1$; $r_2 > 1$; e $r_3 < 1$. A faixa intermediária entre 300 °C e 700 °C (T2) requer $r_1 < 0,1$; $r_2 > 1$; e $1 \leq r_3 \leq 4$, enquanto as falhas de alta temperatura superiores a 700 °C (T3) exigem $r_1 < 0,2$; $r_2 > 1$; e $r_3 > 4$.

Caso a combinação de razões (r_1, r_2, r_3) não corresponda a nenhum dos padrões catalogados na tabela da norma, o diagnóstico é classificado como Não Determinado (ND). Em dados de campo, em casos de transformadores com falhas múltiplas

combinadas ou ruídos de medição, há uma limitação na eficácia do método quando utilizado de maneira isolada. Assim como no Triângulo de Duval, a norma IEC 60599 não possui uma combinação específica para indicar condição normal de operação, exigindo que o diagnóstico por razões seja aplicado apenas após as concentrações ultrapassarem os limites típicos de atenção estabelecidos.

Para superar essas restrições geométricas e a ocorrência de diagnósticos inconclusivos nos métodos normativos, a seção a seguir descreve os algoritmos de aprendizado de máquina e de otimização evolutiva aplicados à classificação automatizada e à modelagem preditiva em DGA.

2.3 ALGORITMOS DE APRENDIZADO DE MÁQUINA APLICADOS À DGA

Diante das limitações das abordagens normativas tradicionais, técnicas de aprendizado de máquina têm sido aplicadas para aprender fronteiras de decisão não lineares a partir de bancos de dados históricos de cromatografia.

2.3.1 PANORAMA E CLASSIFICADORES CLÁSSICOS

A Tabela 1 apresenta um panorama comparativo das principais famílias de algoritmos avaliadas na literatura de diagnóstico em transformadores, destacando referências representativas, principais vantagens e limitações para a aplicação em DGA.

Tabela 1 – Comparação entre algoritmos de aprendizado de máquina aplicados à DGA

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
Classificadores clássicos			
SVM	Al-Sakini et al. (2025)	Maximização de margem de separação em alta dimensão	Dificuldade em classes sobrepostas e expansão multiclasse não nativa

Continua na próxima página

Tabela 1 – continuação

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
KNN	Ali et al. (2023)	Simplicidade de implementação e independência da distribuição dos dados	Sensibilidade a ruídos locais e custo computacional alto na predição
Árvore de Decisão	Ali et al. (2023)	Facilidade de interpretação e extração direta de regras	Instabilidade a pequenas perturbações e tendência a sobreajuste
Random Forest	Al-Sakini et al. (2025)	Redução de variância por combinação de árvores	Dificuldade de sintonia simultânea de atributos e hiperparâmetros
Naive Bayes	Ali et al. (2023)	Simplicidade de cálculo e treinamento rápido	Suposição irrealista de independência entre os gases
Ensembles e boosting			
XGBoost ✓	Wu et al. (2021)	Regularização explícita e ponderação para dados desbalanceados	Necessidade de ajuste hiperparamétrico e ausência de memória temporal
LightGBM	–	Treinamento rápido em grandes bases por crescimento focado nas folhas	Risco de sobreajuste em conjuntos com poucas centenas de amostras
Redes neurais			
MLP	Ali et al. (2023)	Capacidade de aproximação de funções não lineares	Ausência de mecanismos para modelar sequências temporais

Continua na próxima página

Tabela 1 – continuação

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
CNN	LeCun et al. (1998)	Extração hierárquica de correlações espaciais	Estrutura voltada a matrizes espaciais, pouco natural para tabelas de gases
Modelos de séries temporais			
ARIMA	Ali et al. (2023)	Modelo estatístico linear simples e bem fundamentado	Premissa de linearidade e dificuldade de modelagem multivariada
LSTM ✓	Katser et al. (2022)	Captura de dependências temporais longas por mecanismos de portas	Custo de treino superior e necessidade de séries regulares
Transformer	Zhou et al. (2021)	Mecanismos de atenção em horizontes longos	Exigência de grandes volumes de dados, indisponíveis em DGA aberta
Otimização evolutiva			
AG padrão	Ali et al. (2023)	Busca estocástica global sem necessidade de derivadas	Risco de estagnar cedo em ótimos locais
IGA ✓	Wu et al. (2021)	Cruzamento adaptativo, operadores mistos e elitismo	Custo computacional elevado pela validação cruzada iterativa

Otimização Bayesiana	–	Amostragem baseada em processos gaussianos	Menor flexibilidade para otimizar conjuntamente variáveis binárias e contínuas

Fonte: elaborado pelo autor com base em Ali et al. (2023), Al-Sakini et al. (2025), Wu et al. (2021), Zhou et al. (2021) e LeCun et al. (1998).

Nota: ✓ indica as técnicas adotadas na formulação experimental deste estudo.

Entre os classificadores clássicos, as Máquinas de Vetores de Suporte (SVM) apresentam bom desempenho em espaço de alta dimensão, mas têm dificuldade em regiões com forte sobreposição entre classes vizinhas, como as falhas térmicas T2 e T3 (AL-SAKINI et al., 2025). Modelos baseados em vizinhos mais próximos (KNN) e árvores de decisão simples sofrem com a presença de ruído e alta variância. O Random Forest ameniza essa variância ao combinar múltiplas árvores independentes por amostragem com reposição (*bagging*), contudo não dispõe de um mecanismo integrado para selecionar atributos e otimizar hiperparâmetros de forma conjunta. Por fim, o Naive Bayes, embora útil como linha de base probabilística, assume independência entre as variáveis de entrada, premissa que é claramente violada em dados de DGA, onde os gases co-evoluem por um mecanismo físico comum (ALI et al., 2023).

2.3.2 ENSEMBLES DE ÁRVORES E O ALGORITMO XGBOOST

Os métodos de *gradient boosting* constroem modelos preditivos por meio da combinação sequencial aditiva de estimadores fracos, tipicamente árvores de decisão de profundidade moderada (FRIEDMAN, 2001). A cada iteração k, uma nova árvore $f_k(x)$ é ajustada para estimar o gradiente negativo da função de perda em relação à predição atual, reduzindo progressivamente os erros residuais, conforme ilustrado na Figura 3.

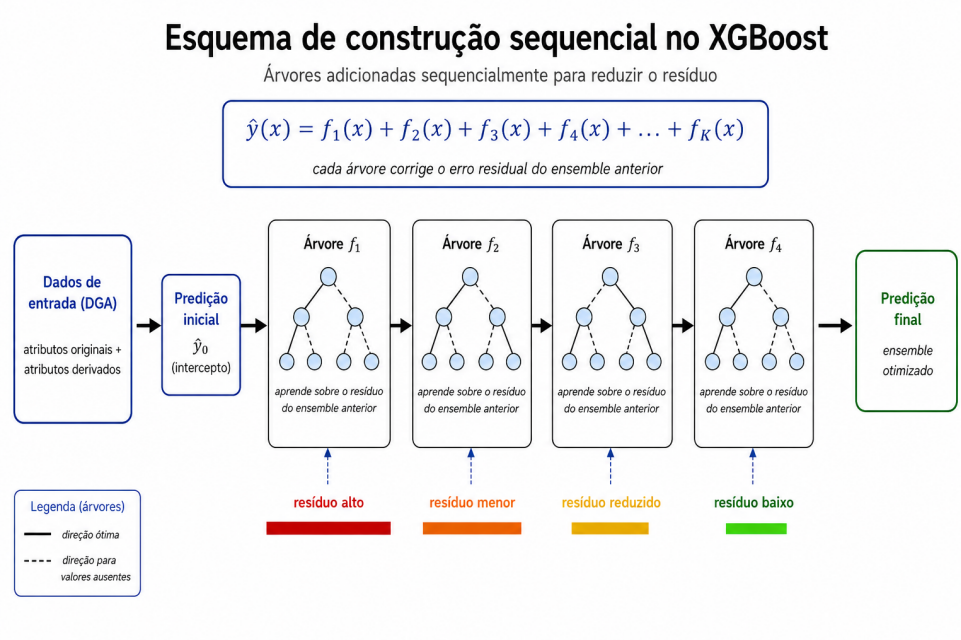


Figura 3 – Esquema conceitual do processo iterativo de minimização de resíduos em ensembles de gradient boosting.

Fonte: Gerada por ChatGPT / GPT 5.6 Terra, 2026.

A predição final de uma amostra x após a inclusão de K árvores é obtida pela soma das contribuições de cada estimador:

$$\hat{y}(x) = \sum_{k=1}^{K} f_k(x), \quad f_k \in \mathcal{F} \tag{2.4}$$

O algoritmo XGBoost (*Extreme Gradient Boosting*) introduz formulações que melhoram a estabilidade, a precisão e a velocidade de convergência em relação ao boosting tradicional (CHEN; GUESTRIN, 2016). A função objetivo minimizada na iteração t incorpora termos explícitos de regularização sobre a estrutura das árvores:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \sum_{k=1}^{t} \Omega(f_k) \tag{2.5}$$

Em que l representa a função de perda diferenciável e $\Omega(f)$ define o termo de regularização da árvore, expresso por:

$$\Omega(f) = \gamma T_L + \frac{1}{2}\lambda_{\text{reg}} \sum_{j=1}^{T_L} w_j^2 + \alpha_{\text{reg}} \sum_{j=1}^{T_L} |w_j| \tag{2.6}$$

Nessa expressão, T_L denota o número de folhas da árvore, w_j é o peso associado à folha j, γ representa o custo de complexidade para a criação de novas

folhas e os parâmetros λ_{reg} e α_{reg} correspondem aos termos de regularização L_2 e L_1, respectivamente. O uso das derivadas de primeira e segunda ordem da função de perda permite calcular diretamente o ganho de cada divisão nos nós e o peso ideal das folhas, acelerando o treinamento e ajudando a evitar o sobreajuste.

Para lidar com o desbalanceamento característico de bases de dados de DGA, o XGBoost suporta a atribuição de pesos diferenciados por instância (`sample_weight`), permitindo ponderar a contribuição das amostras na função de perda de forma inversamente proporcional à frequência de cada classe.

2.3.3 REDES NEURAIS RECORRENTES E MODELAGEM TEMPORAL

Redes neurais artificiais tradicionais assumem independência entre as amostras de entrada, não sendo capazes de processar ordenamento temporal contínuo. As Redes Neurais Recorrentes (RNN) superam essa restrição ao incorporar conexões de realimentação que mantêm um vetor de estado oculto h_t, atualizado a cada passo de tempo t a partir da entrada atual x_t e do estado anterior h_{t-1}:

$$h_t = \tanh\left(W_x x_t + W_h h_{t-1} + b\right) \tag{2.7}$$

No treinamento de RNNs convencionais pelo algoritmo de retropropagação no tempo (*Backpropagation Through Time*, BPTT), a multiplicação sucessiva de matrizes de pesos ao longo de muitos passos temporais tende a provocar o desaparecimento do gradiente (*vanishing gradient*), reduzindo a capacidade do modelo em capturar dependências de longo prazo (HOCHREITER; SCHMIDHUBER, 1997).

A arquitetura *Long Short-Term Memory* (LSTM) soluciona essa dificuldade por meio de uma célula de memória dedicada, regulada por mecanismos de portas (*gates*) que controlam o fluxo de informação com conexões aditivas diretas (HOCHREITER; SCHMIDHUBER, 1997). O funcionamento da célula LSTM, detalhado na Figura 4, é descrito pelo seguinte conjunto de equações:

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right) \tag{2.8}$$

$$i_t = \sigma\left(W_i[h_{t-1}, x_t] + b_i\right) \tag{2.9}$$

$$\tilde{C}_t = \tanh\left(W_c[h_{t-1}, x_t] + b_c\right) \tag{2.10}$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{2.11}$$

$$o_t = \sigma\left(W_o[h_{t-1}, x_t] + b_o\right) \tag{2.12}$$

$$h_t = o_t \odot \tanh(C_t) \tag{2.13}$$

Nas Equações (2.8) a (2.13), σ denota a função sigmoide, $\odot$ representa a multiplicação elemento a elemento entre vetores, f_t é a porta de esquecimento que controla o descarte de informações da célula anterior C_{t-1}, i_t é a porta de entrada que regula a absorção do novo candidato $\tilde{C}_t$, C_t é o estado interno da célula e o_t é a porta de saída que determina a parcela de informação exposta no estado oculto h_t.

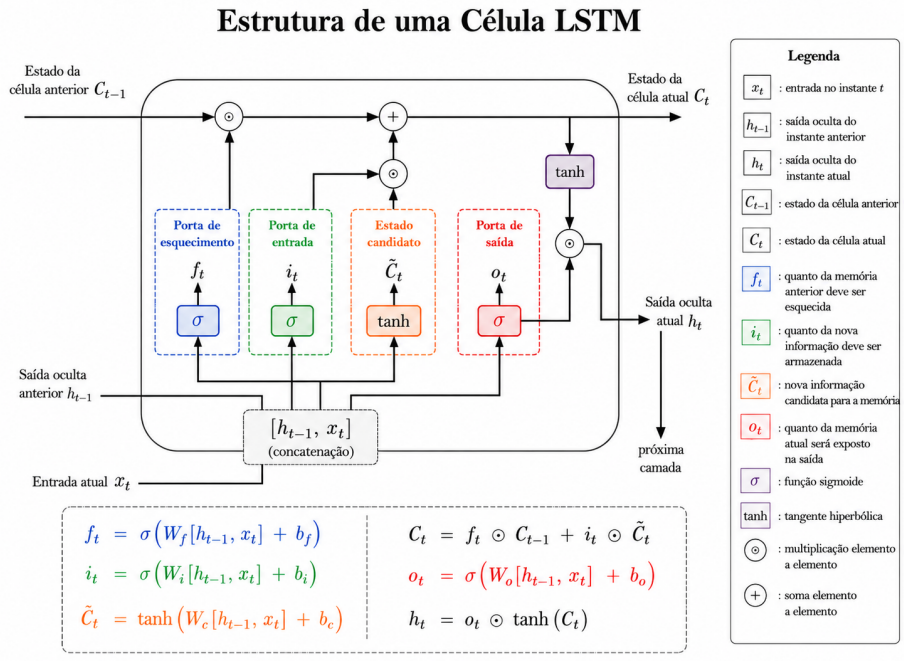


Figura 4 – Diagrama conceitual da arquitetura interna de uma célula de memória recorrente LSTM.

Fonte: Gerada por ChatGPT / GPT 5.6 Terra, 2026.

Para modelar o comportamento de séries temporais de gases com maior capacidade de representação, emprega-se a LSTM empilhada (*Stacked LSTM*), que conecta múltiplas camadas recorrentes em série, conforme mostrado na Figura 5. Nesse formato, as saídas ocultas da primeira camada servem como sequência de entrada para a camada subsequente, permitindo capturar padrões de evolução das concentrações gasosas ao longo do tempo.

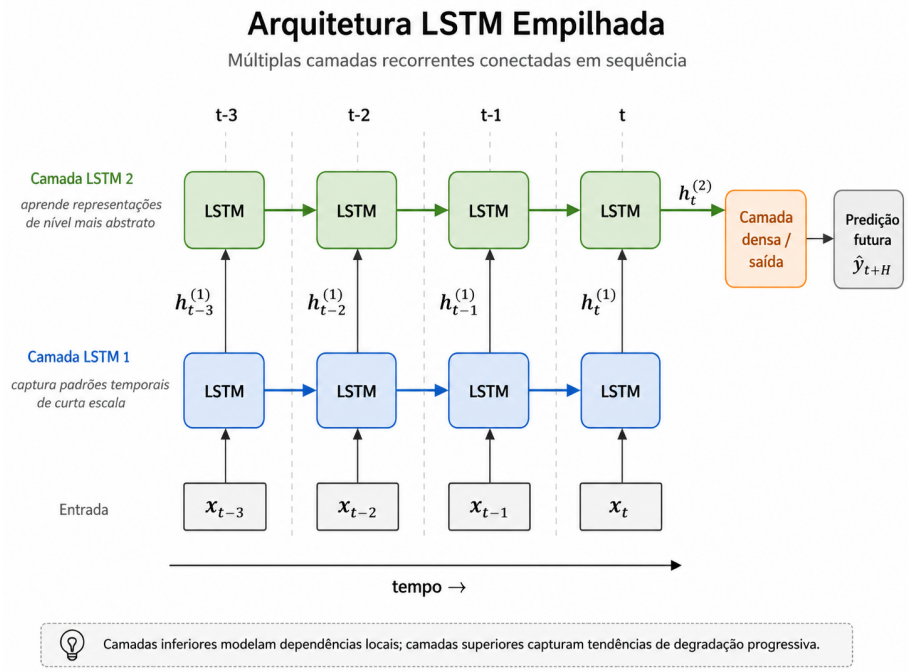


Figura 5 – Diagrama conceitual da topologia de rede neural recorrente LSTM empilhada para modelagem temporal.

Fonte: Gerada por ChatGPT / GPT 5.6 Terra, 2026.

2.3.4 OTIMIZAÇÃO EVOLUTIVA POR ALGORITMO GENÉTICO MELHORADO (IGA)

O ajuste de um classificador XGBoost envolve uma escolha simultânea entre os atributos de entrada mais relevantes e a calibração de seus hiperparâmetros de complexidade e regularização. Os Algoritmos Genéticos (AG) constituem uma técnica de busca estocástica global inspirada nos princípios da evolução natural e da seleção dos indivíduos mais aptos (ALI et al., 2023). O procedimento mantém uma população de soluções candidatas ao longo de sucessivas gerações, aplicando operadores de seleção por aptidão, recombinação por cruzamento (*crossover*) e mutação.

Em matrizes de dados de DGA, o algoritmo genético clássico pode sofrer com convergência prematura em mínimos locais. O Algoritmo Genético Melhorado (IGA) contorna essa limitação incorporando mecanismos específicos de diversidade e conservação, conforme ilustrado na Figura 6 (WU et al., 2021).

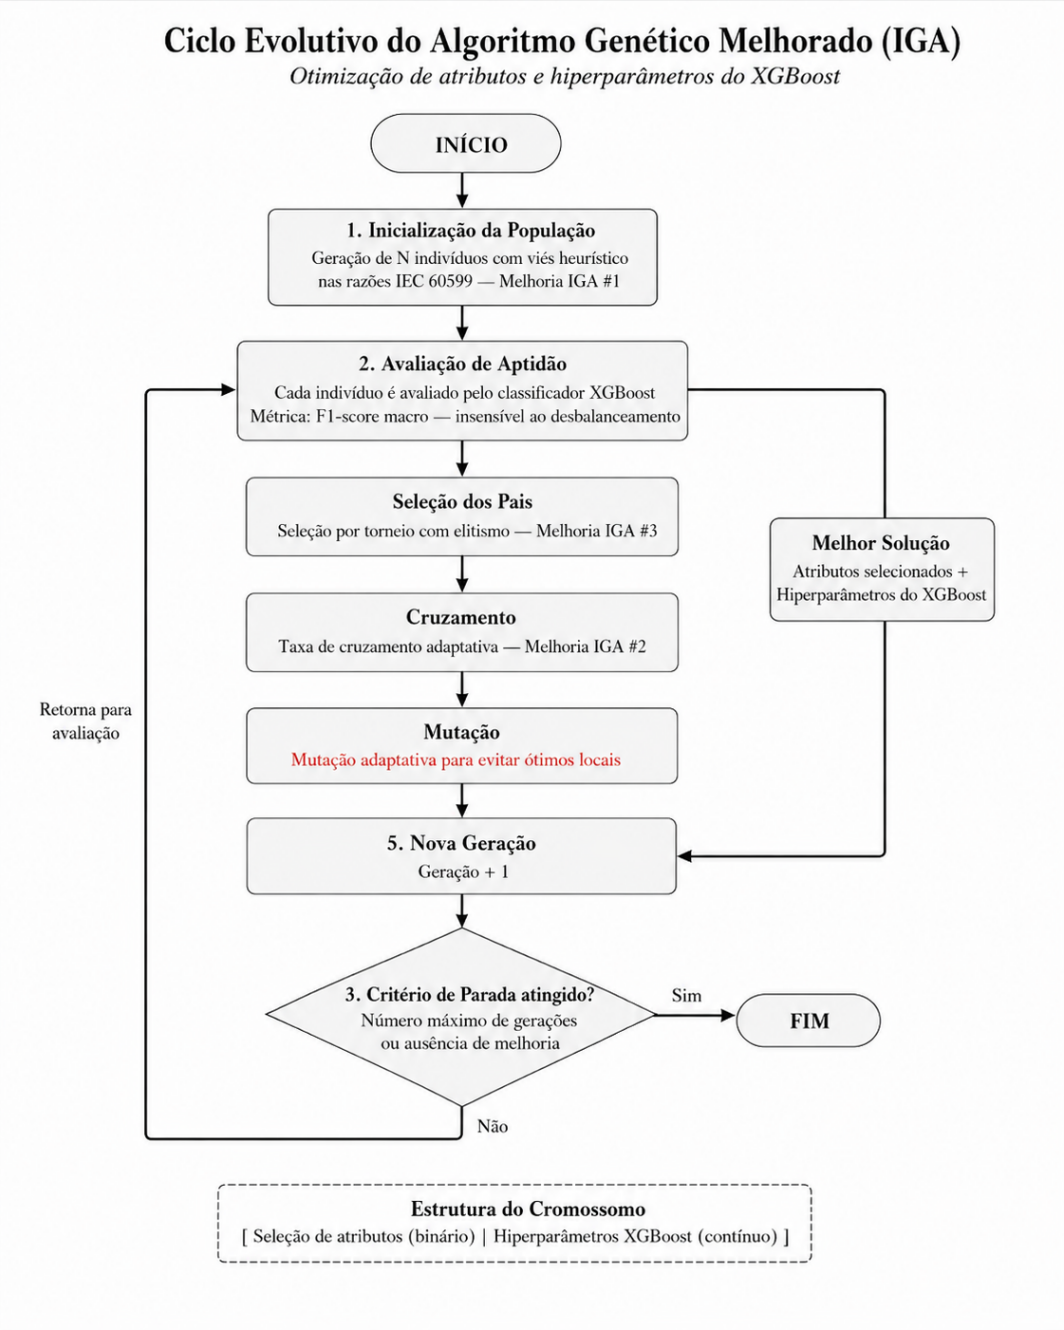


Figura 6 – Fluxo operacional do Algoritmo Genético Melhorado para busca conjunta.

Fonte: Elaborado pelo autor, com base em Wu et al. (2021).

No IGA, cada indivíduo é estruturado por um cromossomo bipartido composto por uma máscara binária (que define quais variáveis são utilizadas) e por um vetor de números reais (correspondente aos hiperparâmetros contínuos do XGBoost). Na etapa de recombinação, aplica-se cruzamento uniforme sobre a máscara binária e cruzamento linear adaptativo (*Blend Crossover*, BLX-α) sobre os genes contínuos, associados a perturbações gaussianas para mutação contínua e inversão probabilística de bits para a parte discreta. A preservação por elitismo garante que as melhores

soluções encontradas sejam repassadas diretamente para a geração seguinte, guiando a busca para configurações de alta precisão e menor complexidade.

Embora a combinação entre ensembles de árvores e otimização evolutiva proporcione elevado poder discriminativo, sua adoção segura em diagnósticos industriais requer transparência sobre os critérios internos de decisão, tema abordado na próxima seção por meio das técnicas de interpretabilidade em aprendizado de máquina.

2.4 INTERPRETABILIDADE EM APRENDIZADO DE MÁQUINA (XAI)

Na aplicação de aprendizado de máquina em sistemas críticos como redes elétricas de alta tensão, a compreensão dos fatores que determinam cada diagnóstico é essencial para que os resultados sejam aceitos e validados por equipes de engenharia. A área de inteligência artificial explicável (*Explainable Artificial Intelligence*, XAI) fornece fundamentos matemáticos para quantificar a contribuição individual de cada variável de DGA nas predições geradas pelos modelos.

2.4.1 FUNDAMENTOS CONCEITUAIS DOS VALORES DE SHAPLEY

A formulação dos valores de Shapley origina-se na teoria dos jogos cooperativos (SHAPLEY, 1953), sendo adaptada para o aprendizado de máquina por Lundberg e Lee (2017) para quantificar a contribuição justa de cada atributo preditor na saída de um modelo. Em vez de avaliar uma variável de forma isolada, o método considera o ganho marginal que a inclusão dessa variável proporciona a todas as possíveis combinações de atributos (coalizões).

A grande vantagem teórica dos valores de Shapley reside nas propriedades de **eficiência** e **aditividade local**. A soma das contribuições ϕ_i atribuídas a cada uma das variáveis de entrada i corresponde exatamente à diferença entre a predição pontual do modelo $f(x)$ para uma dada amostra e o valor médio esperado basal $\mathbb{E}[f(X)]$ em toda a base:

$$\sum_{i=1}^{M} \phi_i(x) = f(x) - \mathbb{E}[f(X)] \tag{2.14}$$

Essa propriedade assegura que nenhuma parcela da decisão do algoritmo seja artificialmente inflada ou omitida, distribuindo o crédito preditivo de forma proporcional e consistente entre as variáveis monitoradas.

2.4.2 O ALGORITMO TREESHAP E DECOMPOSIÇÃO DE CONTRIBUIÇÕES

O cálculo exato dos valores de Shapley pela formulação combinatória clássica possui complexidade exponencial com o número de atributos, tornando-se computacionalmente custoso. Para ensembles baseados em árvores de decisão, Lundberg et al. (2020) desenvolveram o algoritmo TreeSHAP, que otimiza essa avaliação para tempo polinomial ao percorrer recursivamente a estrutura dos nós das árvores.

Em classificadores multiclasse como o XGBoost, o TreeSHAP opera diretamente no espaço linear das margens de decisão (*log-odds*) antes da conversão probabilística pela função softmax (`pred_contribs`). Para cada classe diagnóstica c, a pontuação contínua $f_c(x)$ da amostra x é decomposta de forma aditiva exata:

$$f_c(x) = \phi_{0,c} + \sum_{i=1}^{M} \phi_{i,c}(x) \tag{2.15}$$

Em que $\phi_{0,c} = \mathbb{E}[f_c(X)]$ denota o valor médio basal da classe c sobre a base de treinamento, e $\phi_{i,c}(x)$ corresponde à contribuição aditiva individual da variável i. O valor de Shapley indica diretamente se a variável atua a favor ($\phi > 0$) ou contra ($\phi < 0$) a probabilidade daquela classe específica, enquanto a classe final prevista corresponde àquela com maior escore conjunto via $\arg\max_c f_c(x)$.

Além da contribuição total de cada atributo, o TreeSHAP permite separar o efeito isolado de uma variável das suas combinações com as demais. Por meio da matriz de interações (`pred_interactions`), obtém-se o efeito individual $\phi_{i,i}(x)$ de cada gás ou razão após descontar as interações cruzadas com os outros atributos, conforme expresso por

$$\phi_{i,i}(x) = \phi_i(x) - \sum_{j \neq i} \phi_{i,j}(x) \tag{2.16}$$

Ao relacionar esse efeito isolado $\phi_{i,i}(x)$ com o valor físico real da variável em ppm ou em percentual relativo, identifica-se o ponto exato em que sua contribuição passa de contrária ($\phi_{i,i} < 0$) para favorável ($\phi_{i,i} > 0$) àquela classe de falha ($\phi_{i,i} = 0$). Esse ponto de transição revela o limite prático aprendido pelo XGBoost, permitindo compará-lo diretamente com as fronteiras da norma IEC 60599 e do Triângulo de Duval.

Apresentados os fundamentos teóricos dos modelos preditivos, da busca evolutiva e da decomposição aditiva por valores de Shapley, a seção seguinte analisa como os trabalhos recentes da literatura têm integrado essas técnicas no diagnóstico de transformadores de potência.

2.5 TRABALHOS RELACIONADOS

O diagnóstico preditivo de falhas em transformadores por meio de DGA tem evoluído de métodos gráficos tradicionais para técnicas baseadas em modelos computacionais de aprendizado de máquina. A Tabela 2 sintetiza os principais estudos representativos da literatura recente, comparando suas abordagens, dados utilizados, principais vantagens e limitações observadas.

Tabela 2 – Comparação entre trabalhos relacionados e o escopo investigado neste estudo.

Trabalho	**Abordagem**	**Tipo**	**Vantagens**	**Limitações**
Wu et al. (2021)	IGA + XGBoost	Classificação	Otimização simultânea de atributos e hiperparâmetros com acurácia elevada	Diagnóstico puramente estático, ausência de avaliação temporal e métricas globais sem detalhamento por classe
Wang et al. (2023)	LSTM + Classificadores	Previsão + Classificação	Modelagem da evolução temporal de gases para antecipação de falhas	Classificação desacoplada da etapa preditiva e uso de base de dados restrita
Ali et al. (2023)	Métodos Tradicionais e Revisão de ML	Revisão	Levantamento abrangente de normas de DGA e métodos inteligentes	Ausência de validação experimental direta e sem modelo computacional proposto
Al-Sakini et al. (2025)	Aprendizado de Máquina Supervisionado	Classificação	Validação empírica sobre registros laboratoriais reais de transformadores	Abordagem exclusivamente estática e sensibilidade a sobreposição de classes
Tightiz et al. (2020)	ANFIS + Regras de Associação	Classificação	Integração de inferência neuro-fuzzy com regras de diagnóstico	Ajuste complexo de muitas regras e ausência de componente temporal
Zhou et al. (2021)	Transformer (Informer) em Séries Temporais	Previsão	Mecanismo de autoatenção eficiente para dependências longas em transformadores	Custo computacional elevado e demanda de grandes volumes de dados
Abordagem deste Trabalho	LSTM Empilhada + IGA-XGBoost + TreeSHAP	Híbrido em Dois Eixos	Avaliação do impacto de previsões temporais, seleção de atributos por IGA e interpretação física com TreeSHAP	Separação em dois eixos devido às características distintas das bases de dados públicas disponíveis

Fonte: Elaborado pelo autor.

A análise crítica dos estudos da literatura indica que os trabalhos costumam apresentar lacunas metodológicas importantes. O estudo de Wu et al. (2021) obteve bons resultados ao combinar seleção de variáveis e ajuste de hiperparâmetros por IGA

com o XGBoost, reportando acurácias superiores a 99% em dados normativos. No entanto, o trabalho avaliou apenas dados estáticos pontuais, sem considerar séries temporais, além de reportar métricas globais de acurácia que podem mascarar o desempenho em classes minoritárias.

Por outro lado, o trabalho de Wang, Littler e Liu (2023) focou na modelagem temporal com redes LSTM para estimar concentrações futuras de gases. Contudo, a etapa de previsão foi avaliada de forma desvinculada do classificador final, sem um teste controlado para verificar se a inclusão das estimativas futuras realmente melhorava a precisão do diagnóstico em relação aos gases já conhecidos no momento presente. Além disso, a base de dados utilizada era de acesso restrito, dificultando comparações diretas.

Por sua vez, Al-Sakini et al. (2025) testaram diversos modelos de aprendizado supervisionado em dados laboratoriais reais, confirmando que ensembles de árvores superam modelos simples em conjuntos com ruído, mas também se limitaram a diagnósticos pontuais estáticos. Já as revisões conduzidas por Ali et al. (2023) apontam que as principais carências da área incluem a falta de protocolos estatísticos para lidar com o desbalanceamento real das classes, a escassez de modelos que combinem dinâmicas temporais com classificadores otimizados e a ausência de análises que interpretem fisicamente as decisões dos algoritmos à luz das normas técnicas.

Por fim, o uso de arquiteturas Transformer em séries temporais de transformadores, a exemplo do modelo Informer proposto por Zhou et al. (2021), confirma a utilidade dos mecanismos de autoatenção para sequências longas, mas esbarra na exigência de grandes volumes de dados de treinamento, raramente disponíveis em bases públicas abertas de DGA.

Com base nesse panorama, este trabalho testa de forma controlada o impacto de previsões temporais da LSTM acopladas ao XGBoost, emprega o algoritmo genético para selecionar subconjuntos enxutos de atributos e analisa as regras aprendidas pelo modelo com base em valores de Shapley, aproximando as decisões dos algoritmos dos critérios estabelecidos pelas normas técnicas de DGA.

No próximo capítulo, detalham-se os procedimentos metodológicos estruturados para operacionalizar essa investigação, abrangendo a arquitetura experimental em dois eixos (Track A e Track B), a auditoria e o pré-processamento das bases de dados, a engenharia de atributos, a modelagem preditiva e os protocolos de validação estatística e de interpretabilidade.

3 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados no desenvolvimento, otimização e avaliação experimental do sistema de diagnóstico de falhas em transformadores de potência. Apresenta-se o desenho da pesquisa estruturado em dois eixos complementares, justificando essa organização a partir das características das bases de dados industriais abertas disponíveis. Em seguida, detalham-se os procedimentos de auditoria e limpeza dos dados, as técnicas de pré-processamento e engenharia de atributos, a modelagem temporal com redes neurais recorrentes, a configuração do algoritmo genético para seleção de variáveis e ajuste de hiperparâmetros, bem como os protocolos de validação estatística e interpretabilidade por meio do TreeSHAP.

3.1 DESENHO METODOLÓGICO E ARQUITETURA EM DOIS EIXOS

O desenho experimental deste trabalho foi definido a partir das características e limitações reais dos conjuntos de dados públicos de Análise de Gases Dissolvidos (DGA). Na prática da literatura, não existe um repositório aberto único que reúna, ao mesmo tempo, séries temporais longas com coletas regulares e laudos completos cobrindo todos os gases normativos e todas as classes de defeitos. As bases temporais disponíveis publicamente, como a divulgada por Katser et al. (2022), registram leituras periódicas de sensores online, porém monitoram apenas quatro gases (sem metano e etano) e rotulam apenas quatro categorias de estado operacional. Por outro lado, as bases de dados multiclasse que contemplam os cinco gases clássicos e as sete categorias de operação da norma IEC 60599 são formadas por medições pontuais de laboratório, sem histórico temporal contínuo da taxa de evolução dos gases.

Diante dessas características distintas, a pesquisa foi estruturada em dois eixos complementares, denominados Track A e Track B, cuja visão geral está esquematizada na Figura 7. O Track A investiga o acoplamento preditivo temporal, empregando uma rede LSTM empilhada para modelar a evolução multivariada de quatro gases e gerar projeções futuras de concentração, as quais alimentam um classificador XGBoost submetido a teste de ablação sobre quatro classes de severidade. Cabe sublinhar que esse experimento testa especificamente se o fornecimento de concentrações futuras auxilia na discriminação da condição operacional associada a cada série (a qual mantém rótulo constante ao longo de suas 420 leituras), e não a predição do instante exato de transição de estado ou tempo até a falha. Já o Track B estabelece um referencial comparativo de classificação multiclasse sobre sete categorias da norma

IEC 60599, permitindo confrontar o classificador XGBoost otimizado por Algoritmo Genético Melhorado (IGA) contra métodos tradicionais de normas técnicas, modelos da literatura e configurações simplificadas, complementando a análise com técnicas de interpretabilidade baseadas em valores de Shapley.

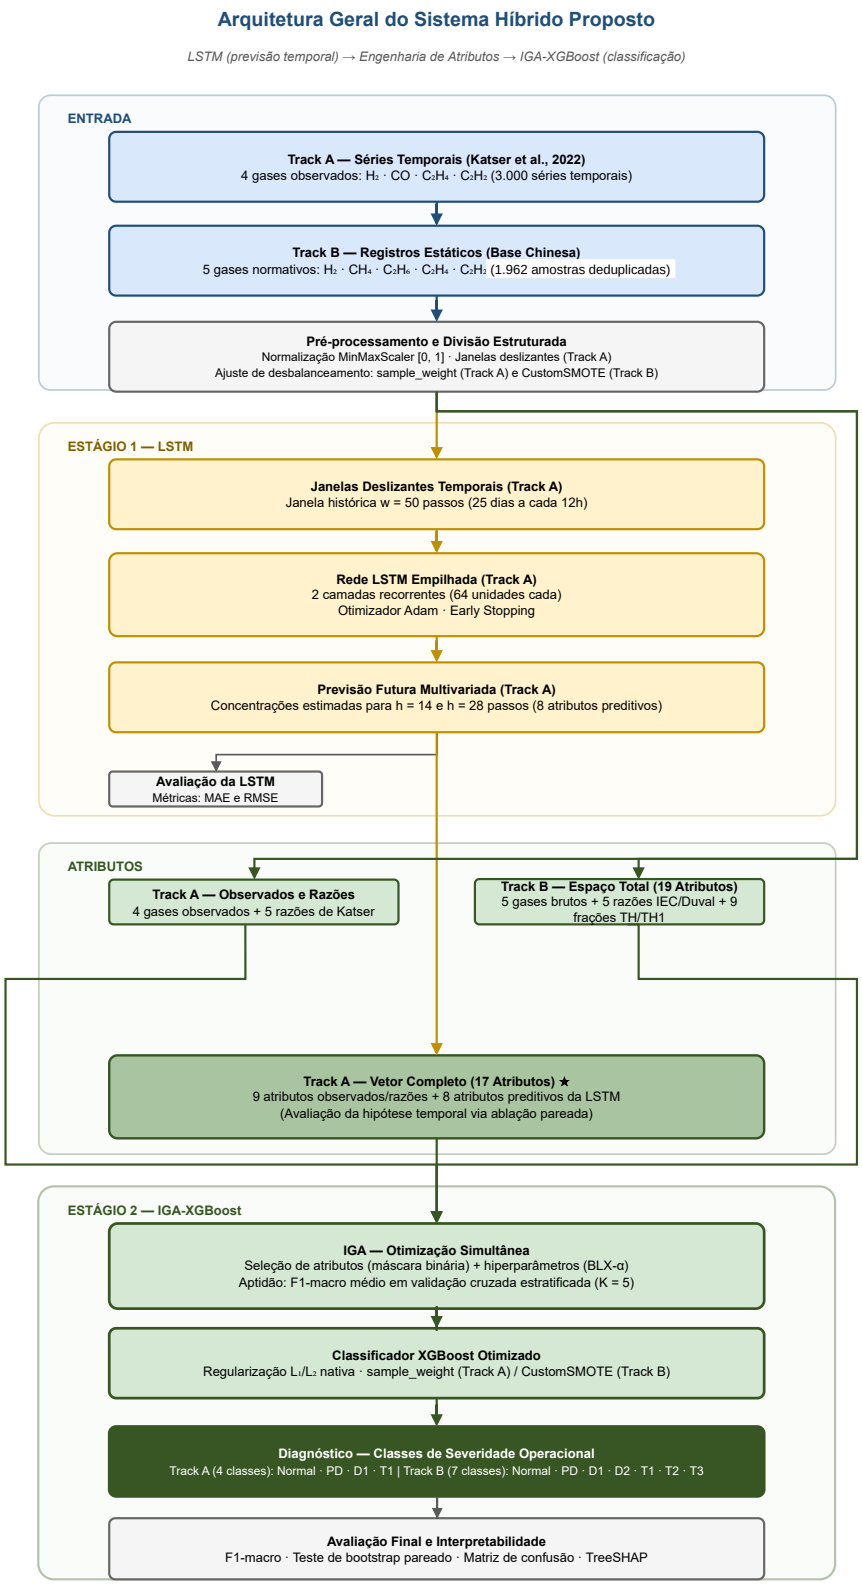


Figura 7 – Fluxograma metodológico do trabalho estruturado na divisão entre os eixos Track A e Track B.

Fonte: Elaborado pelo autor.

Para viabilizar a execução dos dois eixos ilustrados na Figura 7, a próxima seção

detalha a proveniência, a distribuição de classes e os procedimentos de auditoria e deduplicação aplicados às bases de dados de cada trilha experimental.

3.2 BASES DE DADOS E PROCEDIMENTOS DE AUDITORIA

A experimentação utiliza dois conjuntos de dados reais e independentes, que passaram por etapas de conferência e tratamento para garantir a confiabilidade dos testes.

3.2.1 BASE DE SÉRIES TEMPORAIS INDUSTRIAIS (TRACK A)

O Track A adota o conjunto de medições contínuas divulgado por Katser et al. (2022), associado a transformadores de potência de instalações de geração energética do consórcio Skoltech e Rosatom. O conjunto reúne 3.000 séries temporais com leituras a cada 12 horas, totalizando 420 passos de tempo por série (equivalente a 210 dias de histórico contínuo). A divisão oficial fornecida pelos autores é composta por 2.100 séries destinadas a treino e validação, reservando-se 900 séries exclusivamente para a partição final de teste.

Essa base monitora quatro gases, sendo eles: hidrogênio (H_2), monóxido de carbono (CO), etileno (C_2H_4) e acetileno (C_2H_2). Cada série temporal possui um diagnóstico operacional constante ao longo de todo o período, categorizando o equipamento em quatro classes, cuja distribuição no conjunto de teste é: 731 amostras normais (Normal), 38 eventos de descarga parcial (PD), 49 casos de descarga de baixa energia (D1) e 82 ocorrências de sobreaquecimento térmico incipiente (T1). Os valores de concentração dessa base encontram-se em escala normalizada (da ordem de 10^{-3}), formato disponibilizado originalmente pelos autores a partir das leituras dos sensores online.

Como a condição operacional de integridade permanece constante ao longo de todo o período monitorado ($T = 420$ passos) para cada transformador, a amostragem tabular pontual destinada ao treinamento e teste dos classificadores XGBoost é extraída no instante final ($t = 420$). Utiliza-se a sequência dos últimos 50 passos temporais contíguos ($w = 50$, correspondente aos passos 371 a 420) como janela de entrada para alimentar a rede LSTM e gerar as previsões correspondentes aos horizontes futuros de 14 e 28 passos ($h = 14$ e $h = 28$).

3.2.2 BASE COMPILADA DE DIAGNÓSTICO ESTÁTICO (TRACK B)

O Track B adota uma base de dados estáticos compilada originalmente por Li, Wang e Song (2019) no IEEE DataPort (e reunida com rotinas de diagnóstico da ferramenta DGALab (IBRAHIM; GHONEIM; TAHA, 2018) no repositório mantido por

ALAN-456 (2021)), a qual reúne medições pontuais cobrindo as concentrações absolutas em partes por milhão (ppm) de cinco gases normativos: hidrogênio (H_2), metano (CH_4), etano (C_2H_6), etileno (C_2H_4) e acetileno (C_2H_2), acompanhados pelo respectivo rótulo de integridade. A compilação abrange registros históricos provenientes de casos de literatura, inspeções visuais de falhas em serviço (IEC TC 10), desmontagem de transformadores em campo e ensaios laboratoriais.

Na etapa de auditoria dos dados brutos, constatou-se que a base original continha 2.321 amostras com ocorrência de duplicidades e inconsistências de anotação. Aplicaram-se dois critérios objetivos para saneamento dos dados:

1. para registros com concentrações idênticas nos cinco gases e mesmo laudo diagnóstico, manteve-se apenas a primeira ocorrência, descartando 303 réplicas redundantes;

2. para perfis com concentrações idênticas mas rótulos diagnósticos conflitantes entre si, descartaram-se todas as 56 amostras envolvidas, eliminando ruído de anotação. Esse procedimento removeu 359 registros (taxa de exclusão de 15,5%), consolidando uma base de 1.962 amostras únicas.

Os rótulos diagnósticos da base foram adotados conforme catalogados originalmente no repositório público. Como essa base reúne registros de diferentes origens (inspeções em campo, literatura e laboratório), os dados apresentam sobreposições naturais e casos de fronteira entre tipos de falha. Na classe de falha térmica de alta temperatura (T3), por exemplo, a mediana da razão C_2H_4/C_2H_6 é de apenas 0,25, distante do valor superior a 4,0 exigido pela norma IEC 60599. Essa mistura entre classes em dados reais levou Li, Wang e Song (2019) a utilizarem lógica difusa (*membership degree*) no estudo original da base, o que também explica por que o desempenho dos classificadores neste trabalho se estabiliza na faixa de 76% a 78% de F_1-macro.

Esse conjunto consolidado foi dividido de forma estratificada por tipo de falha na proporção 70/15/15: treino com 1.372 amostras (70,0%), validação com 295 amostras (15,0%) e teste independente com 295 amostras (15,0%). As 1.962 instâncias distribuem-se entre as sete classes da norma IEC 60599: 707 normais, 111 de descargas parciais (PD), 273 de descargas de baixa energia (D1), 221 de descargas de alta energia (D2), 107 de falhas térmicas inferiores a 300 °C (T1), 108 de falhas térmicas entre 300 °C e 700 °C (T2) e 435 de falhas térmicas superiores a 700 °C (T3).

3.2.3 CRITÉRIOS DE EXCLUSÃO E DESCARTE DE BASES DE DADOS

Durante o planejamento experimental, algumas fontes de dados identificadas na literatura foram descartadas de forma justificada. A base descrita por Wang, Littler e Liu (2023) foi descartada por não ser pública, tratando-se de dados proprietários protegidos por sigilo de concessionária. Da mesma forma, bases com volume reduzido (em torno de 430 amostras) foram descartadas devido a inconsistências de documentação sobre a proveniência dos transformadores.

Optou-se também por não utilizar bases sintéticas geradas por simulação aleatória (como Monte Carlo puro), uma vez que dados gerados artificialmente sem restrições termodinâmicas não reproduzem as relações reais de decomposição molecular do óleo, criando distribuições homogêneas inexistentes no campo. A preferência por bases reais e auditadas assegura maior confiabilidade prática às conclusões obtidas.

Definidas e saneadas as bases de dados dos eixos Track A e Track B, a seção seguinte descreve os procedimentos de normalização de escala, engenharia de atributos físico-químicos e balanceamento de classes aplicados previamente ao treinamento dos modelos.

3.3 PRÉ-PROCESSAMENTO E ENGENHARIA DE ATRIBUTOS

Para alimentar os modelos de aprendizado de máquina, as concentrações de gases passam por etapas de transformação de escala e derivação de variáveis.

3.3.1 TRATAMENTO DE ESCALA E NORMALIZAÇÃO

O tratamento de escala foi conduzido de acordo com as especificidades de cada conjunto de dados. No Track A, como as leituras já se encontravam em escala contínua normalizada (da ordem de 10^{-3}), aplicou-se diretamente a normalização Min-Max calculada por gás sobre o conjunto de treino.

No Track B, as concentrações em ppm apresentam ampla variação dinâmica (de frações unitárias a dezenas de milhares de ppm em arcos elétricos). Para atenuar a assimetria sem descartar amostras, aplicou-se a transformação logarítmica com deslocamento unitário $x_{\log} = \ln(x + 1)$, em que a adição de 1 evita divergências numéricas em concentrações nulas. Em seguida, os valores foram reescalonados para o intervalo $[0, 1]$ por meio da normalização Min-Max dada por $(x_{\log} - x_{\min})/(x_{\max} - x_{\min})$.

Ressalta-se que todas as razões físico-químicas normativas (CH_4/H_2, C_2H_2/C_2H_4, C_2H_4/C_2H_6, etc.), as somas de hidrocarbonetos (TH e TH_1) e as proporções percentuais relativas foram estritamente calculadas a partir das concentrações originais dos

gases em partes por milhão (escala física desnormalizada). Somente após a derivação analítica dessas variáveis é que a transformação logarítmica e a normalização Min-Max tabular foram aplicadas sobre cada coluna, preservando integralmente a integridade física e termodinâmica das proporções molares.

Para evitar vazamento de dados (*data leakage*), os parâmetros x_{min} e x_{max} foram ajustados exclusivamente no conjunto de treino e aplicados de forma consistente nas partições de validação e teste. Caso alguma leitura no conjunto de teste ultrapasse o valor máximo de treino, o valor resultante fica ligeiramente superior a $1,0$, mantendo a fidelidade física sem truncamentos artificiais.

3.3.2 ESPAÇO DE ATRIBUTOS DO TRACK A

Para o Track A, definiu-se um espaço candidato com 17 variáveis divididas em três grupos:

1. Os quatro gases brutos observados no instante presente ($H_{2,\text{obs}}$, CO_{obs}, $C_2H_{4,\text{obs}}$ e $C_2H_{2,\text{obs}}$);
2. Cinco atributos derivados adaptados aos gases monitorados, compreendendo a razão clássica C_2H_2/C_2H_4, a razão adaptada H_2/C_2H_2, a soma dos hidrocarbonetos disponíveis ($TH_{\text{katser}} = C_2H_4 + C_2H_2$) e as proporções parciais $C_2H_2/TH_{\text{katser}}$ e $C_2H_4/TH_{\text{katser}}$;
3. Oito projeções futuras estimadas pela rede LSTM, correspondentes às concentrações previstas dos quatro gases para horizontes de uma semana ($h = 14$ passos) e duas semanas ($h = 28$ passos): $H_{2,\text{h14}}$, CO_{h14}, $C_2H_{4,\text{h14}}$, $C_2H_{2,\text{h14}}$, $H_{2,\text{h28}}$, CO_{h28}, $C_2H_{4,\text{h28}}$ e $C_2H_{2,\text{h28}}$.

3.3.3 ESPAÇO DE ATRIBUTOS DO TRACK B

Para a classificação de sete estados no Track B, estruturou-se um conjunto de 19 atributos candidatos com base na norma IEC 60599, no método de Doernenburg e na formulação de Wu et al. (2021). O vetor inclui:

1. As cinco concentrações brutas de gases (H_2, CH_4, C_2H_6, C_2H_4 e C_2H_2);
2. Cinco razões diagnósticas normativas e da literatura (CH_4/H_2, C_2H_2/C_2H_4, C_2H_4/C_2H_6, C_2H_2/CH_4 e C_2H_2/C_2H_6);
3. Duas somas de hidrocarbonetos: a soma dos gases do Triângulo de Duval ($TH = CH_4 + C_2H_4 + C_2H_2$) e o total de hidrocarbonetos combustíveis ($TH_1 = TH + C_2H_6$);

4. Sete percentuais relativos calculados sobre as somas de hidrocarbonetos: as três proporções sobre TH ($\%CH_4/TH$, $\%C_2H_4/TH$ e $\%C_2H_2/TH$) e as quatro proporções sobre TH_1 ($\%CH_4/TH_1$, $\%C_2H_6/TH_1$, $\%C_2H_4/TH_1$ e $\%C_2H_2/TH_1$). Em conjunto, as 2 somas e os 7 percentuais integram os 9 atributos da família TH/TH_1 representados na Figura 7, totalizando 14 variáveis derivadas que, somadas aos 5 gases brutos, compõem os 19 atributos candidatos.

Para evitar problemas de divisão por zero na ausência de determinadas espécies gasosas no denominador, convencionou-se que a razão assume o valor zero $(0, 0)$ caso o denominador seja nulo.

3.3.4 TRATAMENTO DO DESBALANCEAMENTO DE CLASSES

O desbalanceamento entre falhas raras e casos de operação normal exige estratégias apropriadas para que o classificador não ignore as classes minoritárias. No Track A, utilizou-se a atribuição de pesos diferenciados por instância (`sample_weight`) no XGBoost, onde o peso da amostra pertencente à classe c é definido pelo inverso de sua frequência relativa no treino, segundo a relação $w_c = N/(C \cdot N_c)$, em que N é o total de amostras de treino, C é o número de classes e N_c é a quantidade de amostras da classe c. Essa abordagem equilibra o impacto das classes na função de perda sem criar amostras artificiais nas séries temporais.

No Track B, como a base é estática e apresenta poucas amostras para falhas como T1 e T2, implementou-se um procedimento denominado `CustomSMOTE`. Como as 14 variáveis derivadas (razões e percentuais) têm dependência matemática não linear em relação aos gases originais, a interpolação linear direta do SMOTE sobre as razões geraria inconsistências matemáticas (a razão das médias não é igual à média das razões). Por isso, o `CustomSMOTE` aplica a superamostragem apenas sobre os cinco gases brutos no conjunto de treino e recalcula analiticamente todas as 14 variáveis derivadas para cada nova amostra sintética a partir de suas expressões físicas, reaplicando a normalização em seguida. Durante a busca evolutiva do IGA, esse procedimento foi estritamente encapsulado por meio de um pipeline de aprendizado (`imblearn.pipeline.Pipeline`) dentro de cada dobra da validação cruzada ($K = 5$), garantindo que a geração sintética e o recálculo das variáveis ocorram exclusivamente sobre as quatro dobras internas de treino, deixando a dobra de validação 100% com dados reais e sem vazamento de informação. As partições de validação global e de teste independente permaneceram exclusivamente com as distribuições reais de campo, sem qualquer síntese de dados.

Concluída a estruturação dos espaços de atributos e o tratamento do desbalanceamento, as próximas seções especificam a configuração dos algoritmos de

modelagem, iniciando pela arquitetura e pelo protocolo de treinamento da rede neural recorrente LSTM responsável pelas projeções temporais do Track A.

3.4 MÓDULO DE PREVISÃO TEMPORAL

O módulo preditivo temporal do Track A utiliza uma rede neural recorrente LSTM empilhada para aprender o comportamento temporal dos gases e projetar suas concentrações para passos futuros. Os dados de entrada são formatados por meio de uma janela deslizante multivariada. A rede recebe o histórico de $w = 50$ passos regulares contíguos (equivalente a 25 dias de medição a cada 12 horas), formando uma matriz 50×4. A definição de $w = 50$ passos equilibra a capacidade de capturar a recente evolução dos gases sem impor sobrecarga computacional ao modelo. A arquitetura é ajustada para estimar as quatro concentrações no passo imediatamente subsequente ($h = 1$), sendo as previsões para múltiplos passos à frente ($h > 1$) obtidas de forma recursiva, em que cada valor estimado $\hat{y}$ é inserido no final da janela de 50 leituras (descartando-se a leitura mais antiga) para prever o passo seguinte.

A arquitetura da rede é composta por duas camadas recorrentes LSTM empilhadas de 64 unidades cada, utilizando tangente hiperbólica como função de ativação e sigmoide nas portas internas. Entre as camadas, incluiu-se uma regularização por *dropout* com taxa de 0,2 para evitar sobreajuste. A camada de saída é uma densa linear com 4 neurônios, fornecendo as previsões dos quatro gases.

O modelo foi treinado com o otimizador Adam e taxa de aprendizado inicial de 10^{-3}, minimizando o erro quadrático médio (MSE) com lotes de 1.024 amostras. As 2.100 séries temporais reservadas para ajuste foram divididas internamente em 1.785 séries para treino (85%) e 315 séries para validação (15%), atingindo convergência por parada antecipada (*early stopping*) tipicamente em torno de 16 épocas com paciência de 15 épocas. Empregou-se adicionalmente o mecanismo de redução da taxa de aprendizado (`ReduceLROnPlateau`) com fator de 0,5 após 7 épocas sem melhoria na perda de validação.

Para mapear o alcance temporal da rede, foram avaliados 12 horizontes preditivos recursivos: $h \in \{1, 2, 4, 7, 14, 28, 42, 56, 70, 84, 98, 112\}$ passos (de 12 horas a 8 semanas de projeção contínua). Adotou-se o coeficiente de determinação $R^2 \geq 0,80$ como patamar operacional de corte de confiabilidade para as séries de manutenção preditiva, assegurando que as estimativas futuras acompanhem com precisão a evolução das séries antes de alimentarem o classificador. A partir dessa análise, selecionaram-se os horizontes de 1 e 2 semanas ($h = 14$ e $h = 28$ passos) para os testes de ablação com o classificador.

Uma vez geradas as projeções temporais pela rede LSTM e consolidados

os vetores de atributos candidatos, a seção a seguir detalha o Algoritmo Genético Melhorado (IGA) empregado para selecionar as variáveis mais relevantes e calibrar os hiperparâmetros do classificador XGBoost.

3.5 ALGORITMO GENÉTICO MELHORADO E OTIMIZAÇÃO DO XGBOOST

Para buscar de forma automatizada configurações equilibradas para o classificador, utilizou-se o Algoritmo Genético Melhorado (IGA), implementado em linguagem Python 3.10 com suporte das bibliotecas NumPy (versão 1.26.4), Scikit-Learn (versão 1.4.2), Imbalanced-Learn (versão 0.12.3) e XGBoost (versão 2.0.3). O módulo de previsão temporal com redes neurais recorrentes utilizou a biblioteca TensorFlow (versão 2.15) e o protocolo de interpretabilidade por valores de Shapley foi desenvolvido com a biblioteca SHAP (versão 0.45.0). O algoritmo realiza a seleção das variáveis mais informativas e sintoniza simultaneamente os principais hiperparâmetros do XGBoost.

3.5.1 REPRESENTAÇÃO CROMOSSÔMICA E OPERADORES GENÉTICOS

Cada solução candidata é codificada por um cromossomo dividido em duas partes:

- Uma máscara binária de tamanho p, em que o bit 1 indica a utilização da variável correspondente e o bit 0 indica sua exclusão;
- Um vetor de 9 valores contínuos reais no intervalo $[0, 1]$, mapeados para as faixas de busca dos hiperparâmetros do XGBoost: taxa de aprendizado (0,01 a 0,30), profundidade máxima das árvores (3 a 12), número de estimadores (50 a 500), fração de amostragem de instâncias (0,50 a 1,00), proporção de atributos por árvore (0,30 a 1,00), ganho mínimo para divisão de nós γ (0,0 a 5,0), peso mínimo foliar (1 a 10) e termos de regularização L_1 (0,0 a 1,0) e L_2 (0,0 a 5,0).

A probabilidade de cruzamento global foi estabelecida em $P_c = 0,90$. O cromossomo bipartido utiliza operadores específicos para cada parte. Na máscara binária de seleção de atributos, aplicam-se o cruzamento uniforme e a mutação por inversão de bits com probabilidade $P_m = 0,10$. No vetor de hiperparâmetros contínuos, aplicam-se o cruzamento BLX-α ($\alpha = 0,50$) e a mutação gaussiana (adição de ruído aleatório com média zero e desvio padrão $\sigma = 0,10$). A escolha dos pais é feita por torneio de tamanho $k = 3$, no qual três indivíduos são sorteados e seleciona-se o de maior aptidão,

enquanto as duas melhores soluções de cada geração são mantidas diretamente para a próxima por elitismo.

3.5.2 FUNÇÃO DE APTIDÃO E CRITÉRIOS DE PARADA

A função de aptidão (*fitness*) foi definida como a média do F_1-macro obtida por validação cruzada estratificada em 5 dobras ($K = 5$) calculada exclusivamente sobre o conjunto de treinamento. No Track B, a superamostragem e o recálculo físico do `CustomSMOTE` foram acoplados dentro de cada dobra de treino por meio do `Pipeline` da biblioteca Imbalanced-Learn, assegurando que a dobra de validação de cada iteração permanecesse 100% com dados reais e sem contaminação sintética. Esse desenho metodológico assegura que o conjunto de teste independente permaneça estritamente isolado e intocado durante todo o processo evolutivo de seleção de atributos e ajuste de hiperparâmetros, prevenindo qualquer vazamento de dados (*data leakage*). A escolha do F_1-macro garante que a otimização valorize o acerto em todas as classes de falha, sem favorecer a classe de operação normal. A busca evolutiva foi configurada com população de 50 indivíduos por até 100 gerações, incluindo critério de parada se a melhor aptidão não apresentar melhoria após 20 gerações consecutivas.

Para avaliar de forma rigorosa o desempenho das configurações obtidas pelo IGA e testar a hipótese de hibridização temporal sem viés amostral, a próxima seção define o desenho dos experimentos de ablação e os testes estatísticos de significância.

3.6 PROTOCOLO EXPERIMENTAL E RIGOR ESTATÍSTICO

Para garantir a validade dos resultados e evitar conclusões influenciadas por variações pontuais de amostragem, definiu-se um protocolo estruturado em testes de ablação pareados e validação cruzada repetida. As configurações baseadas em hiperparâmetros fixos utilizam valores de referência representativos da literatura prática (`learning_rate` = 0,10, `max_depth` = 6, `n_estimators` = 100, `subsample` = 0,90 e `colsample_bytree` = 1,0), permitindo isolar o ganho da otimização evolutiva e das variáveis adicionadas.

3.6.1 DESENHO EXPERIMENTAL E ABLAÇÃO NO TRACK A

O protocolo do Track A foi estruturado para avaliar de forma isolada se as previsões temporais da LSTM trazem benefício real ao diagnóstico pontual do XGBoost. Para isso, compararam-se cinco configurações experimentais:

- **C2**: XGBoost com configuração fixa de referência operando sobre todos os 17 atributos (4 gases observados, 5 razões adaptadas e 8 previsões da LSTM para

$h = 14$ e $h = 28$);

- **C1**: modelo proposto IGA-XGBoost aplicado sobre o espaço completo de 17 atributos, selecionando variáveis e hiperparâmetros de forma conjunta;
- **C5a**: XGBoost com configuração fixa de referência restrito apenas aos 9 atributos estáticos observados, sem receber nenhuma informação da LSTM;
- **C5b**: modelo IGA-XGBoost restrito aos 9 atributos estáticos observados, operando a otimização evolutiva sem dados temporais;
- **C6**: XGBoost com configuração fixa treinado unicamente com as 8 variáveis preditas pela LSTM, sem acesso aos gases observados no instante presente.

Ressalta-se como particularidade metodológica que, na partição de treino do XGBoost, as variáveis preditas da LSTM foram geradas sobre séries integrantes do treinamento da própria rede recorrente, ao passo que a partição de teste foi avaliada sobre 900 séries independentes.

3.6.2 DESENHO EXPERIMENTAL NO TRACK B

No Track B, o experimento avaliou o diagnóstico multiclasse entre as sete categorias da norma IEC 60599, designando os métodos comparativos por prefixo M para distingui-los das classes térmicas T1, T2 e T3:

- **C3**: modelo proposto IGA-XGBoost avaliado sobre os 19 atributos candidatos;
- **C4**: XGBoost com configuração fixa de referência avaliado sobre os mesmos 19 atributos;
- **M3**: modelo de referência IGA-XGBoost configurado sobre o espaço de 18 atributos candidatos de Wu et al. (2021) (que difere de C3 unicamente por não incluir a razão C_2H_2/CH_4), resultando em 14 variáveis selecionadas pelo algoritmo genético;
- **M2**: regras normativas do Triângulo de Duval;
- **M1**: regras do Método das Razões da norma IEC 60599.

3.6.3 PROCEDIMENTOS DE BOOTSTRAP PAREADO E VALIDAÇÃO CRUZADA REPETIDA

Para verificar se as diferenças entre os modelos são estatisticamente significativas, aplicou-se o método de reamostragem por *bootstrap* pareado e estratificado por

classe com 5.000 repetições sobre o conjunto de teste independente. O desenho estratificado realiza a amostragem com reposição internamente a cada categoria, fixando o suporte exato por classe e evitando réplicas degeneradas sem amostras de falhas raras.

Em cada iteração com reposição, calcularam-se o F_1-macro de cada modelo e a diferença exata $\Delta F_1 = F_1(A) - F_1(B)$ sobre os mesmos índices reamostrados, gerando a distribuição das diferenças pareadas. O intervalo de confiança de 95% foi obtido pelos percentuais 2,5% e 97,5% dessa distribuição. A diferença é considerada estatisticamente significativa apenas quando o intervalo não engloba o valor zero ($\Delta F_1 = 0$) e o teste bilateral pareado resulta em $p < 0,05$.

Além disso, para avaliar a estabilidade do desempenho e investigar a existência de limites práticos na base do Track B, os modelos C3, C4, M3 e a linha de base com os cinco gases brutos (treinada diretamente sobre as concentrações em ppm sem engenharia de razões e sem sobreamostragem sintética) foram avaliados por validação cruzada estratificada repetida em 5 repetições de 5 dobras (*Repeated Stratified K-Fold* 5×5, totalizando 25 avaliações sobre as 1.667 amostras de desenvolvimento combinando treino e validação). Cabe salientar que, para viabilizar computacionalmente as 25 rodadas e medir a estabilidade intrínseca dos subconjuntos de atributos sem influência de geração sintética entre dobras, a seleção de variáveis pelo IGA precedeu o protocolo de validação cruzada repetida, avaliando-se as 25 partições sob parametrização fixa e sem aplicação interna do `CustomSMOTE`. Dessa forma, esse procedimento atua como um diagnóstico de estabilidade paramétrica e variabilidade entre dobras, ao passo que a avaliação isenta de viés de seleção é assegurada pela partição final de teste independente com 295 amostras, mantida totalmente intocada durante toda a etapa de modelagem.

Complementando a avaliação quantitativa de desempenho estatístico, a seção seguinte estabelece o protocolo de interpretabilidade via TreeSHAP destinado a auditar a coerência físico-química das regras aprendidas pelo classificador frente às normas técnicas.

3.7 PROTOCOLO DE INTERPRETABILIDADE E VALIDAÇÃO FÍSICO-QUÍMICA

A conformidade física do modelo XGBoost foi verificada por meio do método TreeSHAP (LUNDBERG et al., 2020). O cálculo dos valores de Shapley foi feito na escala de log-odds (antes da softmax), o que permite que a soma das contribuições de cada característica explique diretamente a pontuação contínua gerada pelas árvores a partir de um valor médio basal.

O protocolo de interpretabilidade compreendeu cinco análises consecutivas:

1. **Estabilidade das importâncias**: avaliação da estabilidade do ranking de variáveis por meio do coeficiente de correlação de postos de Spearman (ρ) entre os vetores médios de importância obtidos em modelos treinados sob cinco sementes aleatórias distintas, considerando $\rho > 0,80$ indicativo de estabilidade;

2. **Agrupamento por famílias químicas**: soma das contribuições dos atributos agrupados em famílias funcionais (derivados de acetileno, etileno, metano e gases brutos), permitindo analisar a importância de cada grupo químico sem distorções provocadas por correlações entre variáveis semelhantes;

3. **Curvas de efeito principal univariado**: utilização da matriz de interações para isolar o efeito univariado ($\phi_{i,i}$), descartando efeitos conjuntos com outros atributos. Ao traçar esse efeito contra a concentração real desnormalizada da variável, identifica-se o ponto em que ela transita de inibidora para promotora da falha ($\phi_{i,i} = 0$), permitindo confrontar os limiares aprendidos pelo modelo com os valores de corte das normas técnicas;

4. **Mapeamento espacial dos erros**: projeção das amostras classificadas incorretamente sobre as coordenadas baricêntricas do Triângulo de Duval, permitindo visualizar se os erros de classificação ocorrem principalmente nas zonas de transição geométrica entre classes vizinhas;

5. **Análise de migração de crédito**: exame de amostras individuais no Track A onde gases observados e projeções da LSTM disputam importância nas divisões das árvores, avaliando se a adição da projeção temporal traz contribuição independente ou apenas redistribui o peso da leitura atual.

Estabelecidos os conjuntos de dados auditados, a arquitetura dos modelos preditivos e os critérios de validação estatística e físico-química, o Capítulo 4 apresenta e discute os resultados experimentais obtidos nos eixos Track A e Track B.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados experimentais obtidos nos dois eixos de investigação estabelecidos no trabalho. Inicialmente, avalia-se o módulo de previsão temporal baseado em redes LSTM, analisando a precisão das estimativas de concentração e o comportamento do erro à medida que o horizonte preditivo avança. Em seguida, discutem-se os experimentos do Track A sobre as séries temporais de quatro classes, avaliando por meio de testes pareados o real impacto da inclusão das projeções da LSTM e a redução do número de atributos alcançada pelo Algoritmo Genético Melhorado (IGA). Na sequência, apresentam-se os resultados do Track B no diagnóstico multiclasse de sete estados operacionais, confrontando os classificadores com os métodos normativos tradicionais e com limites práticos observados nos dados. Por fim, detalham-se a auditoria das divergências normativas e a análise de interpretabilidade das decisões por meio de valores de Shapley aplicados ao XGBoost.

4.1 DESEMPENHO DO MÓDULO DE PREVISÃO TEMPORAL

O primeiro módulo do sistema consiste em uma rede neural recorrente LSTM empilhada com duas camadas de 64 unidades cada, utilizando regularização por *dropout* com taxa de 0,2 e o otimizador Adam. O treinamento foi configurado com taxa de aprendizado inicial de 0,001, minimizando o erro quadrático médio (MSE) com critério de parada antecipada com paciência de 15 épocas. Para evitar vazamento de dados, a normalização dos dados foi ajustada exclusivamente no conjunto de treino, aplicando-se os mesmos parâmetros às amostras de validação e teste.

A avaliação do modelo foi realizada sobre a partição oficial de teste da base de Katser et al. (2022), composta por 900 séries temporais independentes com 420 medições registradas em intervalos regulares de 12 horas. Utilizando uma janela de 50 passos históricos ($w = 50$, equivalente a 25 dias de operação), foram geradas 333.000 janelas de teste para a previsão de um passo à frente ($h = 1$, correspondente a 12 horas). A Tabela 3 resume as métricas de erro absoluto médio (MAE), raiz do erro quadrático médio (RMSE) e coeficiente de determinação (R^2), reportadas a partir da média e do desvio padrão obtidos em cinco sementes aleatórias distintas.

Tabela 3 – Desempenho do módulo LSTM no conjunto de teste oficial para previsão de um passo ($h = 1$, escala normalizada).

Gás Analisado	**MAE ($\times 10^{-5}$)**	**RMSE ($\times 10^{-4}$)**	R^2
Hidrogênio (H_2)	$1,44 \pm 0,13$	$0,18 \pm 0,02$	$0,9995 \pm 0,0001$
Monóxido de Carbono (CO)	$16,15 \pm 2,72$	$2,06 \pm 0,31$	$0,9997 \pm 0,0001$
Etileno (C_2H_4)	$4,58 \pm 0,59$	$0,58 \pm 0,07$	$0,9996 \pm 0,0001$
Acetileno (C_2H_2)	$0,19 \pm 0,01$	$0,02 \pm 0,01$	$0,9996 \pm 0,0001$
Média Agregada	$5,59 \pm 0,74$	$1,07 \pm 0,15$	$0,9996 \pm 0,0001$

Fonte: Elaborado pelo autor.

Os resultados indicam que o erro de regressão manteve-se baixo, na ordem de 10^{-5} para o MAE e 10^{-4} para o RMSE na escala normalizada dos dados. A relação equilibrada entre MAE e RMSE aponta para uma distribuição uniforme dos resíduos, sem grandes picos de erro concentrados. O monóxido de carbono apresentou maior erro absoluto médio em razão da amplitude naturalmente mais ampla dessa espécie química no conjunto de dados, enquanto o acetileno registrou os menores valores absolutos de erro, condizente com suas concentrações basais muito baixas na maioria dos equipamentos em regime estável. Para todos os gases, o coeficiente de determinação superou 0,999, confirmando que a rede capturou satisfatoriamente a tendência de curto prazo das séries.

Para verificar a estabilidade das estimativas em prazos mais longos, avaliou-se a propagação preditiva ao longo de 12 horizontes temporais recursivos, variando de 12 horas ($h = 1$) até 8 semanas ($h = 112$, correspondente a 1.344 horas de operação contínua). Treinou-se um modelo de um passo à frente ($h = 1$, janela histórica de entrada $w = 50$) para cada uma de cinco sementes aleatórias ($42, 123, 456, 789, 2024$), projetando-se os horizontes futuros por extrapolação recursiva iterada (na qual as predições $\hat{y}$ são sucessivamente realimentadas na janela). A Tabela 4 sintetiza os resultados de R^2 médio e erro percentual médio relativo (MAE%), contrastando-os diretamente com um preditor ingênuo de persistência temporal ($\hat{y}_{t+h} = y_t$). A Figura 8 apresenta a trajetória de redução do R^2 em relação ao critério operacional de confiabilidade ($R^2 \geq 0,80$).

Tabela 4 – Desempenho da LSTM recursiva e do baseline de persistência em função do horizonte temporal (5 sementes, 200 séries/semente).

Passos (h)	**Intervalo Temporal**	**R^2 Persistência**	**R^2 Médio LSTM**	**MAE% Médio LSTM**	**Condição ($R^2 \geq 0,80$)**
1	12 horas (0,07 semana)	1,0000	0,9996	0,90%	Conforme
2	24 horas (0,14 semana)	0,9999	0,9996	0,93%	Conforme
4	48 horas (0,29 semana)	0,9998	0,9994	1,05%	Conforme
7	84 horas (0,50 semana)	0,9992	0,9991	1,31%	Conforme
14	168 horas (1,00 semana)	0,9970	0,9979	2,05%	Conforme
28	336 horas (2,00 semanas)	0,9886	0,9928	3,76%	Conforme
42	504 horas (3,00 semanas)	0,9756	0,9836	5,67%	Conforme
56	672 horas (4,00 semanas)	0,9588	0,9691	7,76%	Conforme
70	840 horas (5,00 semanas)	0,9391	0,9485	10,01%	Conforme
84	1.008 horas (6,00 semanas)	0,9173	0,9207	12,41%	Conforme
98	1.176 horas (7,00 semanas)	0,8940	0,8846	14,96%	Conforme
112	1.344 horas (8,00 semanas)	0,8696	0,8380	17,68%	Limite ($R^2_{H_2} < 0,80$)

Fonte: Elaborado pelo autor.

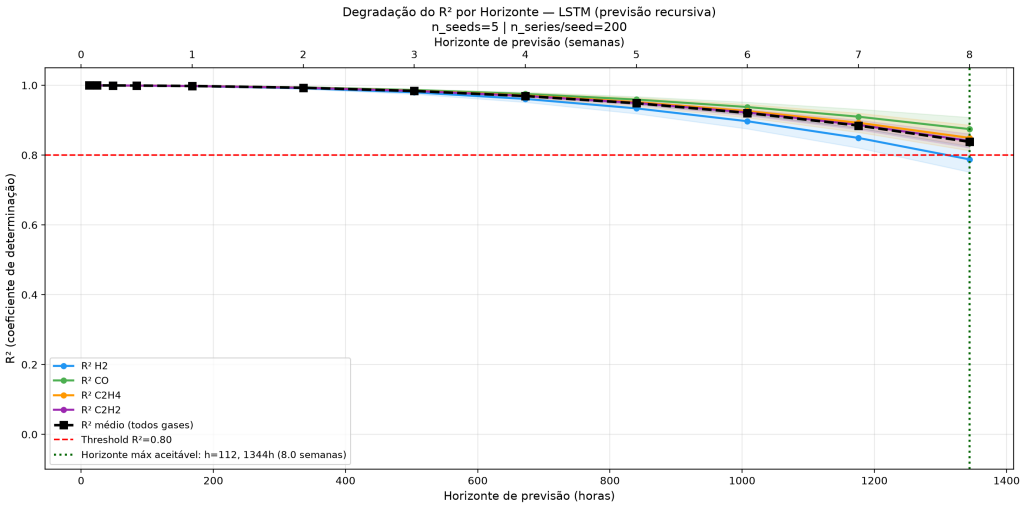


Figura 8 – Evolução do coeficiente de determinação (R^2) da LSTM em múltiplos horizontes temporais no conjunto de teste oficial.

Fonte: Elaborado pelo autor.

A análise da evolução multi-horizonte mostra a degradação gradual da acurácia com o distanciamento temporal, padrão esperado devido ao acúmulo de resíduos na realimentação recursiva. Até duas semanas ($h = 28$), a LSTM mantém $R^2 \geq 0,9928$ com MAE% de 3,76%. Em sete semanas ($h = 98$), o R^2 médio situa-se em 0,8846, sendo esse o último horizonte no qual todos os quatro gases atendem individualmente ao patamar de corte ($R^2 \geq 0,80$, sendo $H_2 = 0,8483$). No horizonte de oito semanas ($h = 112$), embora a média agregada ainda seja $0,8380$, o hidrogênio rompe o patamar mínimo ($R^2 = 0,7877 < 0,80$), justificando $h = 98$ como o horizonte máximo operacional de prognóstico com confiabilidade uniforme entre os gases.

E, a comparação com o baseline de persistência temporal ($\hat{y}_{t+h} = y_t$) revela que a própria dinâmica física das séries monitoradas por Katser et al. (2022) apresenta inércia temporal extremamente elevada, porque a simples repetição do valor atual já assegura $R^2 = 0,9970$ em 1 semana ($h = 14$) e $R^2 = 0,9886$ em 2 semanas ($h = 28$). A rede LSTM supera marginalmente a persistência entre 1 e 6 semanas (ganho modesto de $\Delta R^2 \approx +0,0009$ a $+0,0103$), mas nos horizontes mais longos ($h \geq 98$) o acúmulo de resíduos recursivos faz a rede decair ligeiramente abaixo da persistência. Dessa maneira, como as concentrações evoluem de forma muito lenta sob regime contínuo, as projeções de curto prazo aproximam-se fortemente das medições observadas no instante atual, aspecto avaliado em detalhe nos testes de classificação a seguir.

Estabelecida a caracterização do horizonte preditivo e a dinâmica de inércia das séries temporais, a seção seguinte detalha os experimentos do Track A, testando formalmente o impacto dessas projeções temporais na classificação de falhas e a capacidade de simplificação dimensional proporcionada pelo algoritmo genético.

4.2 RESULTADOS DO TRACK A: DESEMPENHO E AVALIAÇÃO DA HIPÓTESE TEMPORAL

O Track A avalia o diagnóstico em quatro classes de integridade operacional (Normal, Descarga Parcial – PD, Descarga de Baixa Energia – D1 e Falha Térmica de Baixa Temperatura – T1) utilizando os dados de telemetria de Katser et al. (2022). O conjunto de teste contém 900 séries rotuladas: 731 casos normais, 38 de PD, 49 de D1 e 82 de T1. A hipótese investigada estabelecia que o fornecimento de concentrações futuras previstas pela LSTM enriqueceria os atributos de entrada do classificador XGBoost, gerando melhoria no diagnóstico pontual.

Para testar essa hipótese de forma controlada, compararam-se cinco configurações experimentais por meio de reamostragem por *bootstrap* pareado e estratificado (5.000 iterações com reposição) sobre o conjunto de teste. A configuração C2 emprega o XGBoost com configuração fixa de referência sobre todos os 17 atributos (4 gases observados, 5 razões adaptadas e 8 previsões da LSTM para $h = 14$ e $h = 28$). A configuração C1 utiliza o Algoritmo Genético Melhorado (IGA) para selecionar variáveis e otimizar os hiperparâmetros sobre o mesmo espaço de 17 atributos. As configurações C5a e C5b avaliam o modelo puramente com os 9 atributos estáticos observados (sem dados da LSTM), sob parametrização de referência e otimizada por IGA, respectivamente. Por fim, a configuração C6 avalia o XGBoost treinado exclusivamente com as 8 previsões da LSTM. A Tabela 5 consolida os resultados obtidos.

Tabela 5 – Desempenho comparativo e teste de ablação da hipótese temporal no Track A (900 amostras de teste, 5 sementes).

Configuração Avaliada	**Atributos (p)**	**F_1-macro Teste**	**Desvio (σ)**	**IC 95% Bootstrap**
C2: Ref. fixa com LSTM	17	0,8911	0,0034	$[0,8574; 0,9229]$
C1: IGA com LSTM	8	0,8909	0,0011	$[0,8549; 0,9230]$
C6: Ref. fixa apenas LSTM	8	0,8888	0,0011	$[0,8547; 0,9212]$
C5a: Ref. fixa sem LSTM	9	0,8855	0,0029	$[0,8507; 0,9177]$
C5b: IGA sem LSTM	8	0,8796	0,0051	$[0,8469; 0,9110]$
C1 sem LSTM (pós-hoc)	4	0,8280	0,0030	$[0,7876; 0,8656]$

Fonte: Elaborado pelo autor.

A pequena variação observada entre as sementes nas configurações de referência C2 ($\sigma = 0,0034$) e C5a ($\sigma = 0,0029$) decorre da subamostragem aleatória de instâncias (`subsample` = 0,90) adotada nessa parametrização. Ao comparar as configurações C2 e C5a para isolar o efeito da adição das previsões da LSTM com hiperparâmetros fixos, verifica-se (Tabela 6) que a diferença pontual foi de $\Delta F_1 = +0,0056$ ($+0,56\%$), com intervalo de confiança de 95% entre $-0,0037$ e $+0,0150$, e valor de $p \approx 0,2384$. Como o intervalo de confiança engloba o valor zero ($p > 0,05$), conclui-se que a inclusão das projeções futuras da LSTM não trouxe ganho estatisticamente significativo para o diagnóstico pontual.

Tabela 6 – Comparações pareadas via bootstrap (5.000 iterações) no Track A.

Contraste Pareado	**ΔF_1 Pontual**	**IC 95% Bootstrap**	**Valor p**	**Significância**
C2 vs. C5a (efeito LSTM na ref. fixa)	$+0,0056$	$[-0,0037; +0,0150]$	0,2384	Não significativa
C2 vs. C6 (todos vs. apenas LSTM)	$+0,0023$	$[-0,0081; +0,0131]$	0,6604	Não significativa
C1 vs. C2 (IGA vs. ref. fixa completa)	$-0,0003$	$[-0,0137; +0,0124]$	0,9956	Não significativa
C1 vs. C5b (efeito LSTM sob IGA)	$+0,0112$	$[-0,0103; +0,0339]$	0,3308	Não significativa
C5b vs. C5a (IGA vs. ref. fixa sem LSTM)	$-0,0059$	$[-0,0247; +0,0118]$	0,5412	Não significativa

Fonte: Elaborado pelo autor.

A razão física e matemática para a ausência de ganho adicional reside na forte correlação entre as leituras observadas no momento atual e as projeções estimadas pela rede neural. No conjunto de treino, o coeficiente de correlação de Pearson (r) entre o valor observado e a projeção futura foi de 0,9993 e 0,9974 para o H_2 nos horizontes de 14 e 28 passos, 0,9997 e 0,9990 para o CO, 0,9994 e 0,9981 para o C_2H_4, e 0,9995 e 0,9985 para o C_2H_2. Em todas as séries, r^2 superou 0,994. Isso mostra que, em transformadores com taxas graduais de degradação, as medições do instante presente já contêm quase toda a informação necessária para a classificação, de modo que a

projeção futura atua na prática como uma variável fortemente redundante em relação à leitura atual.

Por outro lado, o Algoritmo Genético Melhorado (IGA) demonstrou utilidade na seleção de atributos do modelo. A comparação entre C1 e C2 resultou em diferença mínima ($\Delta F_1 = -0,0003$ e $p \approx 0,9956$), configurando ausência de diferença estatisticamente significativa sob o nível adotado de 5%. Enquanto o modelo C2 utiliza 17 variáveis, o algoritmo genético selecionou em C1 um subconjunto enxuto de 8 variáveis (CO_{obs}, H_2/C_2H_2, C_2H_2/TH_{katser}, C_2H_4/TH_{katser}, $H_{2,h14}$, $H_{2,h28}$, $C_2H_{4,h28}$ e $C_2H_{2,h28}$), em conjunto com os hiperparâmetros calibrados `learning_rate` $= 0,1282$, `max_depth` $= 12$, `n_estimators` $= 422$, `subsample` $= 1,00$, `colsample_bytree` $= 0,9453$, $\gamma = 0,0$, `min_child_weight` $= 3$, $\alpha_{reg} = 0,1054$ e $\lambda_{reg} = 1,5461$.

Esse resultado explica também o comportamento da linha "C1 sem LSTM (pós-hoc)" na Tabela 5, visto que a simples exclusão forçada das 4 variáveis da LSTM de um conjunto previamente ajustado pelo IGA derruba o escore para $F_1 = 0,8280$. Isso ocorre porque a busca evolutiva havia selecionado esses preditores temporais em substituição às variáveis observadas correspondentes (como o $H_{2,obs}$); ao eliminá-los arbitrariamente, o modelo fica desprovido da informação básica do gás. Em contrapartida, quando o IGA é executado desde o início sem as variáveis temporais (configuração C5b), o algoritmo resgata as leituras estáticas e atinge $F_1 = 0,8796$.

Como ilustrado na Figura 9, obteve-se uma redução de 53% no número de atributos em relação ao espaço inicial de 17 variáveis. Cabe ponderar, todavia, que essa redução dimensional em C1 elimina entradas colineares na tabela do classificador, mas não diminui a demanda de sensores físicos em campo (os quatro gases continuam sendo requeridos) e não extingue a sobrecarga computacional de manter a rede LSTM inferindo a cada passo, visto que quatro dos oito atributos selecionados provêm da rede recorrente. Ademais, o C1 gerou uma floresta mais profunda com 422 árvores de profundidade 12, contra 100 árvores de profundidade 6 na referência fixa C2. Por conseguinte, a verdadeira simplificação operacional e redução de latência é obtida pelos modelos puramente estáticos, a exemplo do C5a (9 variáveis observadas e 100 árvores, com $F_1 = 0,8855$) e do C5b ($F_1 = 0,8796$, sem acoplamento à LSTM).

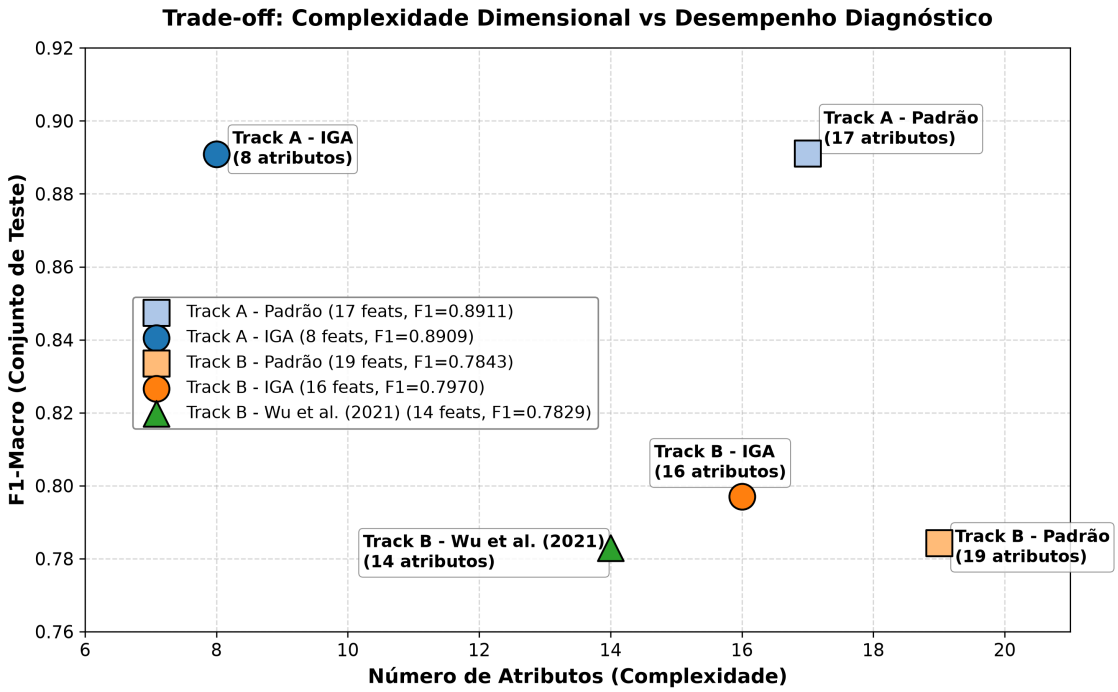


Figura 9 – Relação entre complexidade dimensional e desempenho diagnóstico nos Tracks A e B.

Fonte: Elaborado pelo autor.

A matriz de confusão apresentada na Figura 10 mostra boa capacidade de acerto nas classes avaliadas, registrando 709 acertos em 731 amostras na condição Normal (recall de 97,0% e $F_1 = 0,979$), 34 acertos em 38 amostras em Descargas Parciais (PD, com recall de 89,5% e $F_1 = 0,895$) e 47 acertos em 49 amostras em Descargas de Baixa Energia (D1, com recall de 95,9% e $F_1 = 0,904$). Na classe de falhas térmicas incipientes T1, registraram-se 67 acertos em 82 casos (recall de 81,7% e $F_1 = 0,779$). As principais confusões ocorreram entre a condição Normal e a classe T1 (17 amostras normais classificadas como T1 e 8 amostras de T1 classificadas como normais). Esse padrão é condizente com a física do problema, pois sobreaquecimentos térmicos leves em temperaturas inferiores a 300 °C geram pequenas quantidades de gás, que se misturam facilmente com as concentrações residuais do envelhecimento natural do óleo isolante.

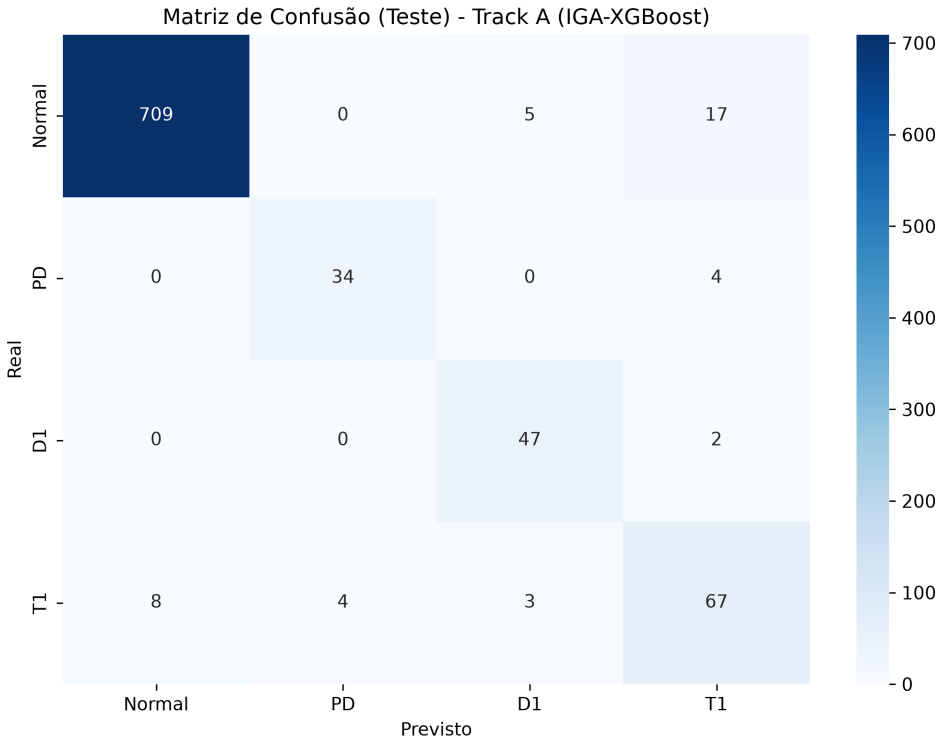


Figura 10 – Matriz de confusão das predições diagnósticas para o Track A no conjunto de teste oficial.

Fonte: Elaborado pelo autor.

Encerrada a avaliação da hipótese temporal e da redução dimensional sobre os quatro estados operacionais do Track A, a seção seguinte investiga o desempenho diagnóstico do modelo IGA-XGBoost no cenário estático multiclasse de sete categorias da norma IEC 60599 (Track B), confrontando-o com métodos normativos clássicos e configurações da literatura.

4.3 RESULTADOS DO TRACK B: DIAGNÓSTICO MULTICLASSE E LIMITES DOS DADOS

O Track B avalia a classificação entre os sete estados operacionais da norma IEC 60599 (Normal, PD, D1, D2, T1, T2 e T3) a partir da base estática consolidada de 1.962 amostras únicas, após o procedimento de saneamento e remoção das 359 amostras redundantes ou conflitantes. O conjunto de teste contém 295 amostras: 106 normais, 17 de PD, 41 de D1, 33 de D2, 16 de T1, 16 de T2 e 66 de T3. O objetivo foi analisar o desempenho de modelos baseados em árvores em comparação com os métodos normativos e com a formulação de referência de Wu et al. (2021).

Avaliaram-se cinco abordagens: o modelo IGA-XGBoost deste estudo (C3), o

XGBoost com configuração fixa de referência sobre os 19 atributos candidatos (C4), a adaptação do espaço de 18 atributos candidatos de Wu et al. (2021) com 14 variáveis selecionadas pelo IGA (M3), o Triângulo 1 de Duval (M2) e o Método das Razões da norma IEC 60599 (M1). A Tabela 7 apresenta as métricas obtidas no conjunto de teste, contemplando tanto a classificação global entre as sete categorias operacionais quanto o cenário restrito às seis classes de falhas ativas ($N = 189$, excluindo a condição Normal para permitir uma comparação equânime com as regras normativas), além do resultado consolidado em validação cruzada repetida em 5 repetições com 5 dobras (Repeated Stratified 5×5 CV, totalizando 25 dobras).

Tabela 7 – Desempenho diagnóstico multiclasse no Track B sobre o conjunto de teste e validação cruzada.

Modelo / Método	**Atributos**	F_1 **Teste (7 classes)**	**IC 95% Teste**	F_1 **Falhas (6 classes)**	**IC 95% Falhas**	F_1 **CV** 5×5
C3: IGA-XGBoost	16	0,7970	$[0,7392; 0,8515]$	0,8000	$[0,7323; 0,8578]$	0,7516
C4: XGBoost Ref. Fixa	19	0,7843	$[0,7259; 0,8376]$	0,7780	$[0,7100; 0,8395]$	0,7616
M3: Wu et al. (2021)	14	0,7829	$[0,7261; 0,8376]$	0,7845	$[0,7175; 0,8448]$	0,7654
M2: Triângulo de Duval	3 gases	0,3634	$[0,3101; 0,4135]$	0,4499	$[0,3815; 0,5157]$	–
M1: Razões IEC 60599	5 gases	0,2569	$[0,1944; 0,3143]$	0,3301	$[0,2519; 0,4020]$	–
Linha de base (5 gases)	5	0,7250	$[0,6587; 0,7851]$	–	–	0,7082

Fonte: Elaborado pelo autor. Nota: a coluna de 6 classes (somente falhas, $N = 189$) avalia exclusivamente as amostras de defeito real, proporcionando uma comparação metodologicamente aderente às premissas normativas do Triângulo de Duval e da IEC 60599.

No modelo C3, o algoritmo genético selecionou 16 dos 19 atributos candidatos (descartando apenas C_2H_2 bruto, C_2H_2/CH_4 e $\%CH_4/TH_1$) e convergiu para a configuração de hiperparâmetros `learning_rate` $= 0,0596$, `max_depth` $= 12$, `n_estimators` $= 342$, `subsample` $= 0,9654$, `colsample_bytree` $= 0,3433$, $\gamma = 1,4356$, `min_child_weight` $= 3$, $\alpha_{\text{reg}} = 0,3182$ e $\lambda_{\text{reg}} = 3,9425$. A comparação pareada por *bootstrap* no conjunto de teste mostrou que a diferença entre o modelo C3 e o modelo adaptado de Wu et al. (M3) foi de $\Delta F_1 = +0,0141$, com intervalo de confiança $[-0,0054; +0,0368]$ e $p \approx 0,1824$. Do mesmo modo, o contraste entre C3 e o XGBoost de referência C4 resultou em $\Delta F_1 = +0,0127$ com intervalo $[-0,0211; +0,0490]$ e $p \approx 0,4680$. Em ambos os casos, o valor zero está incluído dentro do intervalo de confiança de 95% ($p > 0,05$), o que indica ausência de diferença estatisticamente significativa entre os modelos baseados em árvores na partição avaliada.

Para confrontar esses modelos de forma equânime com as regras normativas tradicionais, que não preveem a classe Normal e são aplicadas na prática apenas sob suspeita prévia de defeito, realizou-se a avaliação pareada restrita às 189 amostras de falhas ativas do conjunto de teste (6 classes). Sob esse protocolo estrito, o desempenho do Triângulo de Duval sobe para $F_1 = 0,4499$ (com 93,1% de cobertura fora da zona mista DT) e o das Razões IEC 60599 avança para $F_1 = 0,3301$ (com 57,1% de laudos

conclusivos fora de ND). Ainda assim, os modelos baseados em árvores sustentam patamar estatisticamente superior ($F_1 = 0,8000$ em C3, $F_1 = 0,7845$ em M3 e $F_1 = 0,7780$ em C4), demonstrando que a vantagem dos classificadores supervisionados decorre não apenas da triagem do estado Normal, mas também de uma discriminação mais precisa entre os próprios tipos de falha.

Cabe notar que o tamanho moderado da partição de teste ($N = 295$, contendo apenas 16 amostras em T1 e 16 em T2) amplia a largura dos intervalos de confiança e reduz o poder estatístico para detectar pequenas variações no teste isolado. Por essa razão, a análise foi complementada pela validação cruzada repetida em 25 dobras sobre as 1.667 amostras de desenvolvimento (executada sem sobreamostragem sintética nas dobras e mantendo fixos os hiperparâmetros de C3 e a configuração de referência para C4 e M3), na qual os intervalos de C3 ($0,7516 \pm 0,0281$), C4 ($0,7616 \pm 0,0226$) e M3 ($0,7654 \pm 0,0252$) apresentam sobreposição quase completa (em que $\pm$ indica o desvio-padrão entre as 25 dobras). A ligeira diferença numérica de C3 nessa avaliação sem `CustomSMOTE` explica-se pelo fato de seus hiperparâmetros terem sido sintonizados pelo IGA especificamente para o conjunto de treino balanceado por sobreamostragem.

Essa estabilidade de resultados em torno de 76% a 78% de F_1-macro aponta para um teto empírico condicionado às características do conjunto de dados avaliado. Essa barreira decorre da ação simultânea de dois fatores: a sobreposição física real entre faixas térmicas e tipos de descarga a partir de apenas cinco gases, e o ruído histórico inerente à anotação de bases industriais abertas e heterogêneas (como evidenciado pela divergência na mediana da razão C_2H_4/C_2H_6 de 0,25 para a classe T3). Portanto, esse patamar reflete os limites práticos das medições convencionais dessa base, e não uma constante física universal. Essa constatação contrasta com índices de acurácia superiores a 99% frequentemente reportados na literatura, a exemplo de Wu et al. (2021), cujos experimentos foram conduzidos sobre conjuntos amostrais reduzidos (125 amostras de treino e 25 de teste). Além disso, uma hipótese plausível para explicar métricas infladas em estudos empíricos é a ausência de auditoria de duplicatas, uma vez que, em bases como a do Track B, a presença de 15,5% de registros repetidos geraria vazamento espúrio de dados caso a divisão entre treino e teste ocorresse sem deduplicação prévia.

Como todas as variáveis derivadas (razões e percentuais) são obtidas a partir das mesmas cinco concentrações primárias (H_2, CH_4, C_2H_6, C_2H_4 e C_2H_2), a engenharia de atributos não adiciona informação externa nova. Quando combinada à transformação logarítmica e ao balanceamento via `CustomSMOTE`, ela auxilia o classificador ao explicitar relações físico-químicas e equilibrar as classes minoritárias (superando a linha de base treinada apenas com os cinco gases brutos em ppm sem sobreamostragem, que obteve $F_1 = 0,7250$ no teste e $0,7082$ na validação cruzada), mas não

elimina a sobreposição física entre falhas que geram perfis de gases muito semelhantes. Essa sobreposição intrínseca e as fronteiras difusas entre subtipos térmicos e de descarga foram documentadas por Li, Wang e Song (2019), os quais destacam que equipamentos operacionais exibem zonas contínuas de transição térmica (300 °C e 700 °C) e energética (centelhamento e arco elétrico), corroborando o patamar empírico de estabilização de 76% a 78% obtido pelos modelos XGBoost neste estudo. Note-se ainda que o conjunto de 18 atributos candidatos de Wu et al. difere do espaço de C3 unicamente pela omissão da razão C_2H_2/CH_4, o que justifica a proximidade estreita de comportamento entre M3 e C3.

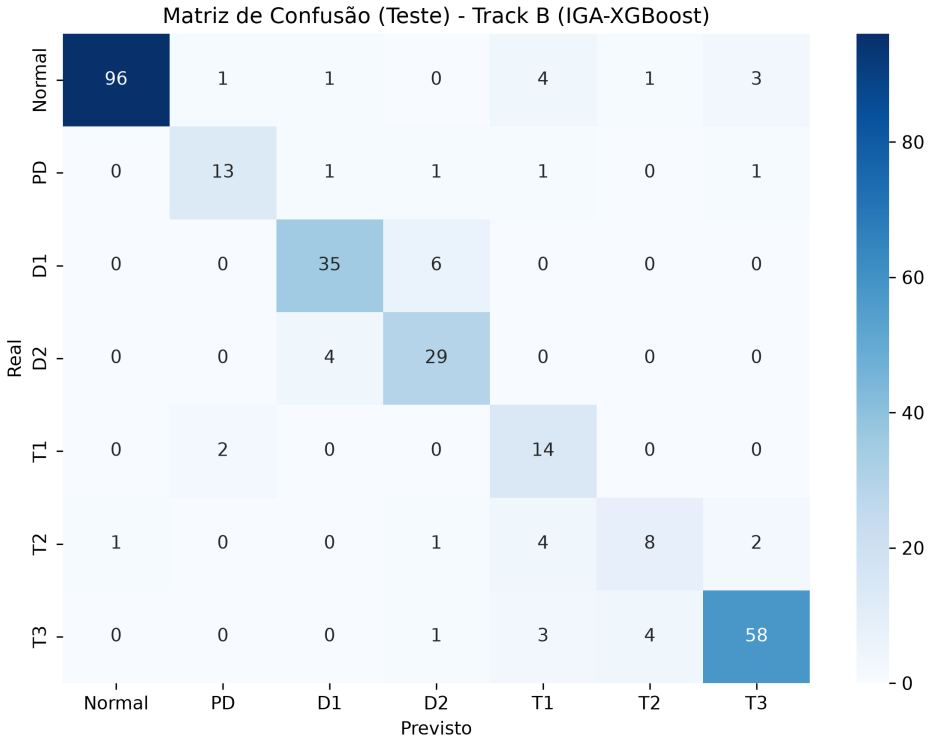


Figura 11 – Matriz de confusão do modelo C3 (IGA-XGBoost) no teste de sete classes do Track B.

Fonte: Elaborado pelo autor.

A matriz de confusão do modelo C3 (Figura 11) ilustra os principais pontos de confusão no Track B. Observam-se 10 erros entre descargas de baixa energia (D1) e alta energia (D2), sendo 6 amostras de D1 previstas como D2 e 4 amostras de D2 previstas como D1. Essa troca reflete uma transição contínua entre centelhamentos intermitentes e arcos elétricos mais intensos, onde a proporção de acetileno e etileno pode variar sutilmente. Além disso, as classes térmicas incipientes T1 e T2 registraram acertos mais modestos ($F_1 = 0,667$ em T1 com 14 acertos em 16 casos, e $F_1 = 0,552$ em T2 com 8 acertos em 16 casos), refletindo tanto a menor quantidade de amostras

dessas classes na base quanto a proximidade das faixas térmicas de degradação do óleo. Em contrapartida, as classes Normal e T3 sustentaram desempenhos elevados, com índices superiores a 0,90.

Além da estabilidade observada entre os modelos baseados em árvores, os resultados da Tabela 7 evidenciaram um baixo desempenho absoluto dos métodos normativos tradicionais sobre a base avaliada, cuja investigação detalhada é apresentada na seção a seguir.

4.4 AUDITORIA NORMATIVA: DIVERGÊNCIA DOS MÉTODOS TRADICIONAIS

Os índices de desempenho obtidos pelos métodos normativos tradicionais na Tabela 7 ($F_1 = 0,3634$ para o Triângulo 1 de Duval e $F_1 = 0,2569$ para a IEC 60599) são sensivelmente inferiores às taxas comumente citadas na literatura técnica, frequentemente reportadas entre 70% e 90%. Essa diferença motivou uma verificação cuidadosa tanto da implementação dos algoritmos quanto das características dos dados de campo.

Para verificar a conformidade dos algoritmos normativos implementados, as regras de classificação foram confrontadas analiticamente com os parâmetros da norma IEC 60599 e com a partição geométrica do Triângulo 1 de Duval. A rotina do Triângulo 1 reproduziu as regiões canônicas centrais, sendo que variações pontuais em casos de teste decorrem de fronteiras limítrofes entre zonas vizinhas (como a transição entre T1 e T2 em $\%C_2H_4 \approx 20\%$) e da zona mista DT. Do mesmo modo, a rotina das Razões da IEC 60599 foi confrontada diretamente com os intervalos tabulares da norma, confirmando a correspondência lógica dos critérios de decisão.

A auditoria sobre a base consolidada de 1.962 amostras, resumida na Tabela 8, evidenciou duas razões principais para a divergência observada.

Tabela 8 – Concordância entre os rótulos da base e os diagnósticos da IEC 60599 e do Triângulo de Duval.

Classe	Total	IEC 60599		Triângulo 1 de Duval		
Rotulada	(N)	Concordância	Não Determinado	Concordância	Zona DT	Principal Desvio
Normal	707	0,0%	14,0%	0,0%	0,7%	89,0% predito como T1
PD	111	14,4%	80,2%	14,4%	4,5%	52,3% predito como T1
D1	273	24,2%	71,4%	76,2%	4,8%	14,7% predito como D2
D2	221	15,8%	40,7%	58,4%	10,0%	24,4% predito como D1
T1	107	48,6%	36,4%	31,8%	2,8%	41,1% predito como T2
T2	108	64,8%	17,6%	38,9%	10,2%	39,8% predito como T3
T3	435	31,3%	14,0%	38,4%	8,5%	39,1% predito como T2

Fonte: Elaborado pelo autor. Nota: na IEC 60599, 83,6% do total de amostras normais foram diagnosticadas como T1 e 2,4% como outras categorias de falha.

A primeira causa decorre do próprio escopo das normas, visto que tanto o Triângulo de Duval quanto as razões da IEC foram projetados para determinar o tipo de defeito em transformadores que já apresentaram gases totais acima dos limites normais de atenção. Por essa razão, esses métodos não possuem uma classe para o estado Normal em suas tabelas e regiões. Quando aplicados a uma base completa que contém equipamentos saudáveis, o Triângulo de Duval classifica 89,0% das amostras normais como falha térmica T1, e a IEC 60599 classifica 83,6% como T1, zerando a precisão nessa classe (que é a mais numerosa). Além disso, a IEC 60599 resulta em elevados índices de diagnóstico Não Determinado nas descargas (80,2% em PD e 71,4% em D1, além de 36,4% em T1 e 40,7% em D2), gerando laudos inconclusivos para grande parte dos registros práticos. Conforme demonstrado na Tabela 7, quando a avaliação é restringida às amostras que contêm falha confirmada ($N = 189$, 6 classes), o F_1-macro do Triângulo de Duval sobe para 0,4499 e o da IEC 60599 avança para 0,3301. Essa melhoria confirma que a ausência de uma classe Normal era o principal fator redutor dos métodos normativos na matriz completa; contudo, mesmo nesse cenário restrito de falhas puras, persistem limitações operacionais decorrentes da alta proporção de diagnósticos inconclusivos na IEC (42,9% de casos Não Determinados no teste) e de sobreposições em zonas fronteiriças do Triângulo de Duval.

A segunda causa envolve uma divergência nas características das amostras rotuladas como T3 na base compilada. Pelos critérios clássicos da IEC 60599, uma falha térmica severa ($T > 700$ °C) provoca intensa quebra de etano em etileno, exigindo razão $C_2H_4/C_2H_6 > 4$. Contudo, na base analisada, a mediana dessa razão para os casos anotados como T3 foi de apenas 0,25. Por essa razão, os métodos normativos acabam classificando grande parte desses casos como sobreaquecimentos moderados (T1 ou T2). O XGBoost reproduz os rótulos desta base com maior taxa de acerto do que os métodos normativos, embora isso reflita o ajuste supervisionado à distribuição

anotada e não garanta, por si só, que todos os laudos originais estejam fisicamente corretos.

Diante dessa diferença de comportamento entre as regras normativas estritas e o ajuste supervisionado, torna-se fundamental inspecionar internamente os critérios aprendidos pelo XGBoost, análise conduzida na próxima seção por meio da decomposição de valores de Shapley (TreeSHAP).

4.5 INTERPRETABILIDADE FÍSICO-QUÍMICA VIA SHAP

Para que modelos de aprendizado de máquina sejam adotados com segurança em sistemas elétricos de potência, é fundamental compreender a coerência física das decisões. Para analisar essa relação, aplicou-se o algoritmo TreeSHAP (LUNDBERG et al., 2020) ao modelo XGBoost. As contribuições parciais (ϕ_i) foram calculadas diretamente no espaço aditivo de margens lineares (*log-odds*) de cada classe, garantindo que a soma dos valores de Shapley somada ao valor médio basal reproduza a pontuação contínua do modelo antes da softmax ($\sum_{i=1}^{M} \phi_i + \phi_0 = f(x)$).

4.5.1 ESTABILIDADE DO RANKING GLOBAL

Antes de analisar as regras aprendidas, avaliou-se a estabilidade do ordenamento de importância em relação a variações aleatórias de treinamento. Para cada uma das cinco sementes do modelo C3 no Track B, calculou-se o vetor de importância global média absoluta ($E[|\phi_i|]$). A correlação de postos de Spearman (ρ) entre os rankings das cinco sementes alcançou média de $\rho = 0,9541$. O alto valor de correlação confirma que o modelo aprendeu critérios consistentes a partir dos dados, e não padrões instáveis decorrentes da amostragem.

4.5.2 RELEVÂNCIA POR CLASSE E AGRUPAMENTO POR FAMÍLIAS QUÍMICAS

Para contornar a dificuldade de interpretação gerada pela correlação entre variáveis derivadas do mesmo gás, somou-se a contribuição dos atributos nas quatro famílias funcionais estruturadas no modelo: *Gases puros* (concentrações brutas), *Razões IEC/Duval* (razões normativas clássicas), *Família TH* (proporções calculadas sobre TH) e *Família TH1* (proporções calculadas sobre TH_1). Pela aditividade do TreeSHAP, a soma dos valores de ϕ dentro de cada grupo reflete o peso total daquela família na decisão. A Figura 12 apresenta o mapa de calor com a importância de cada variável por classe, e a Figura 13 resume as importâncias agregadas por essas quatro famílias de atributos.

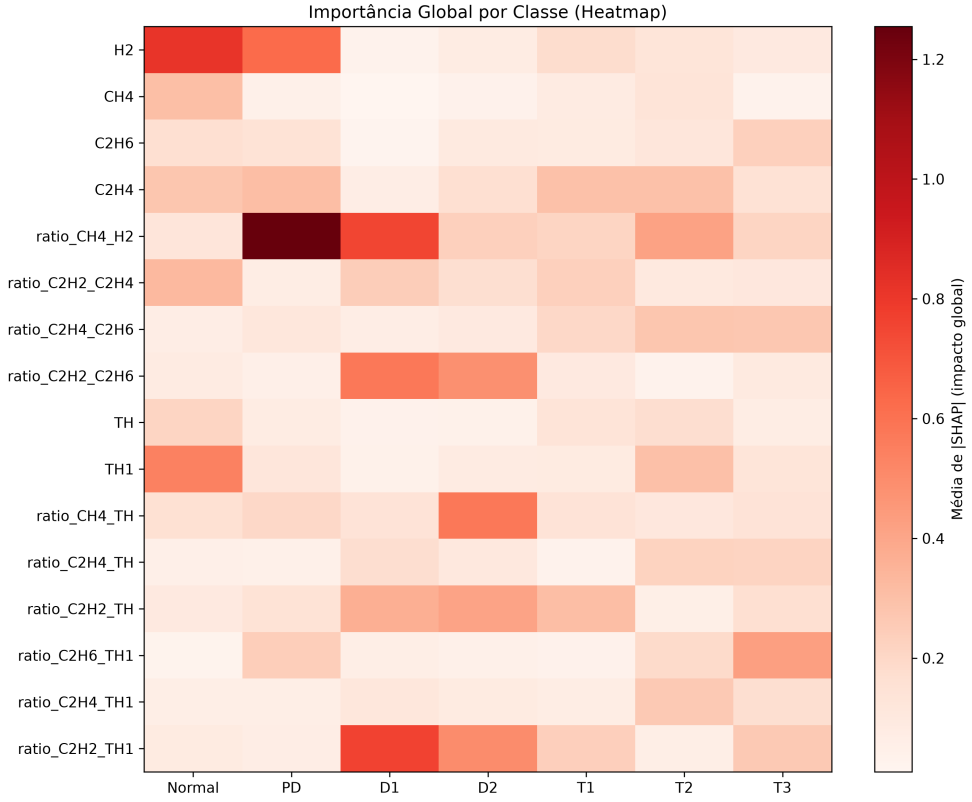


Figura 12 – Mapa de calor da importância média absoluta do SHAP por classe operacional no Track B.

Fonte: Elaborado pelo autor.

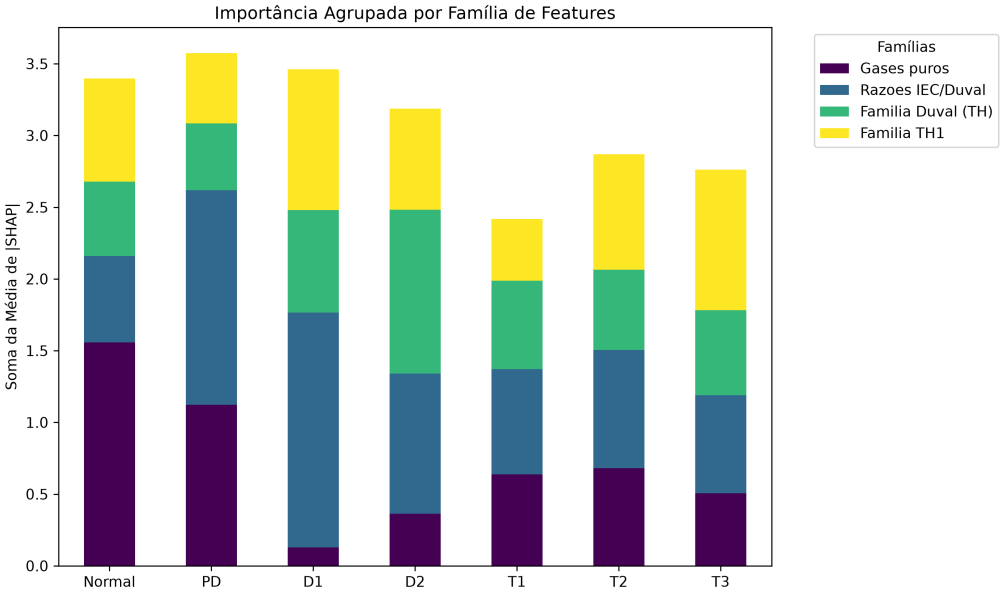


Figura 13 – Importância agregada por famílias de gases para as sete categorias de integridade operacional.

Fonte: Elaborado pelo autor.

A análise agregada evidencia que as descargas elétricas no óleo (D1 e D2) são governadas pelas proporções das famílias TH e TH1 associadas ao acetileno (C_2H_2/TH e C_2H_2/TH_1), complementadas pelas razões normativas clássicas de acetileno e etileno. Em contraste, as descargas parciais (PD) concentram a relevância nos gases puros e na razão CH_4/H_2, condizente com a geração de hidrogênio e metano sob descargas incipientes de baixa energia. Por sua vez, as falhas térmicas (T1, T2 e T3) dividem o peso decisório entre a família das razões normativas (C_2H_4/C_2H_6) e os percentuais de etileno e etano sobre TH e TH1, refletindo o gradiente térmico de degradação do óleo.

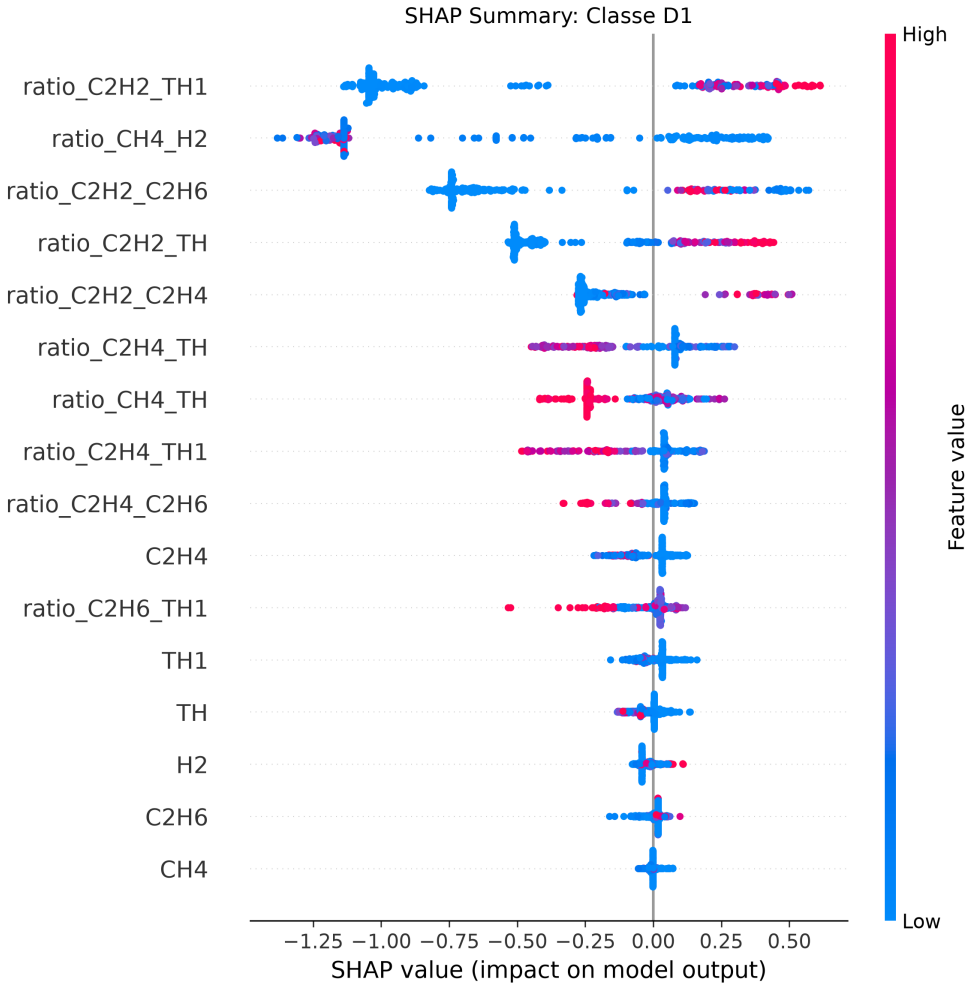


Figura 14 – Distribuição dos valores de SHAP para a classe de Descargas de Baixa Energia (D1).

Fonte: Elaborado pelo autor.

O gráfico de dispersão (*beeswarm*) para a classe D1 (Figura 14) detalha esse comportamento em nível de amostra individual. Valores altos de C_2H_2/TH e da razão C_2H_2/C_2H_4 deslocam a previsão fortemente na direção positiva da classe D1, enquanto proporções baixas ou nulas de acetileno reduzem a probabilidade dessa falha,

confirmando o papel do acetileno como principal indicador de descargas elétricas.

4.5.3 EXTRAÇÃO DE LIMIARES FÍSICOS MARGINAIS

Utilizando a matriz de interações (`pred_interactions`), isolou-se o efeito principal univariado ($\phi_{i,i}$) de cada variável diagnóstica na escala física original. O ponto em que a curva cruza a linha de contribuição nula ($\phi_{i,i} = 0$) identifica o limiar a partir do qual a variável passa a atuar a favor da ocorrência daquela falha. A Tabela 9 compara esses pontos de transição aprendidos pelo XGBoost com os limites fixados pelo Triângulo 1 de Duval e pela norma IEC 60599.

Tabela 9 – Comparação entre limiares analíticos normativos e pontos de transição marginal do TreeSHAP.

Parâmetro Químico	**Falha Alvo**	**Limiar Normativo**	**Limiar Marginal Extraído**
Percentual $\%C_2H_4$ (C_2H_4/TH)	D1	$< 23\%$ (Duval)	Faixa entre 20% e 25%
Percentual $\%C_2H_2$ (C_2H_2/TH)	D1	$\geq 13\%$ (Duval)	$\approx 8,0\%$
Percentual $\%C_2H_2$ (C_2H_2/TH)	D2	$\geq 13\%$ ou 29% (Duval)	$\approx 8,6\%$
Razão C_2H_4/C_2H_6	T3	$> 4,0$ (IEC 60599)	$\approx 2,97$

Fonte: Elaborado pelo autor.

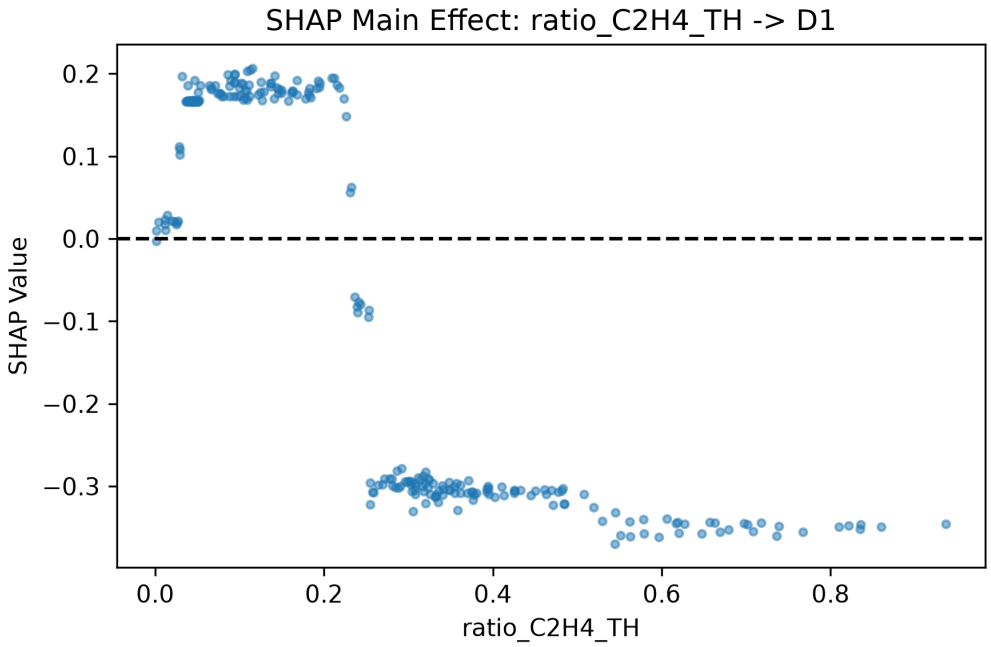


Figura 15 – Efeito principal isolado do TreeSHAP para a razão C_2H_4/TH na classe D1.

Fonte: Elaborado pelo autor.

Conforme ilustrado na Figura 15, o efeito principal da razão C_2H_4/TH na identificação de D1 cruza a linha neutra $\phi_{i,i} = 0$ na faixa entre 0,20 e 0,25 (20% a 25%), convergindo diretamente para o limite normativo canônico de 23% fixado pelo Triângulo 1 de Duval para separar descargas de baixa energia de falhas com componente térmico.

Por outro lado, os pontos de transição aprendidos pelo modelo para a porcentagem de acetileno em D1 e D2 ($\approx 8,0\%$ e $8,6\%$) e para a razão C_2H_4/C_2H_6 em T3 ($\approx 2,97$) são mais baixos que os limites fixos das normas (13% e 4,0, respectivamente). Isso acontece porque o classificador se ajustou aos dados reais da base, na qual existem transformadores com laudo de descarga elétrica mesmo com teores menores de C_2H_2, ou falhas térmicas T3 com menor proporção de etileno. Nesses casos de T3, o modelo compensa utilizando também o percentual de etano (`ratio_C2H6_TH1`), como visto na Figura 12. Cabe lembrar que o ponto $\phi_{i,i} = 0$ marca apenas o valor a partir do qual aquele gás passa a somar pontos a favor da falha nas árvores, e não uma linha divisória única como nas normas.

4.5.4 VISUALIZAÇÃO ESPACIAL NO TRIÂNGULO DE DUVAL

Para visualizar o comportamento do classificador no espaço geométrico tradicional, as 295 amostras do conjunto de teste foram projetadas sobre as coordenadas do Triângulo 1 de Duval ($\%CH_4$, $\%C_2H_4$ e $\%C_2H_2$). A Figura 16 apresenta essa projeção, destacando a localização dos acertos e dos erros diagnósticos.

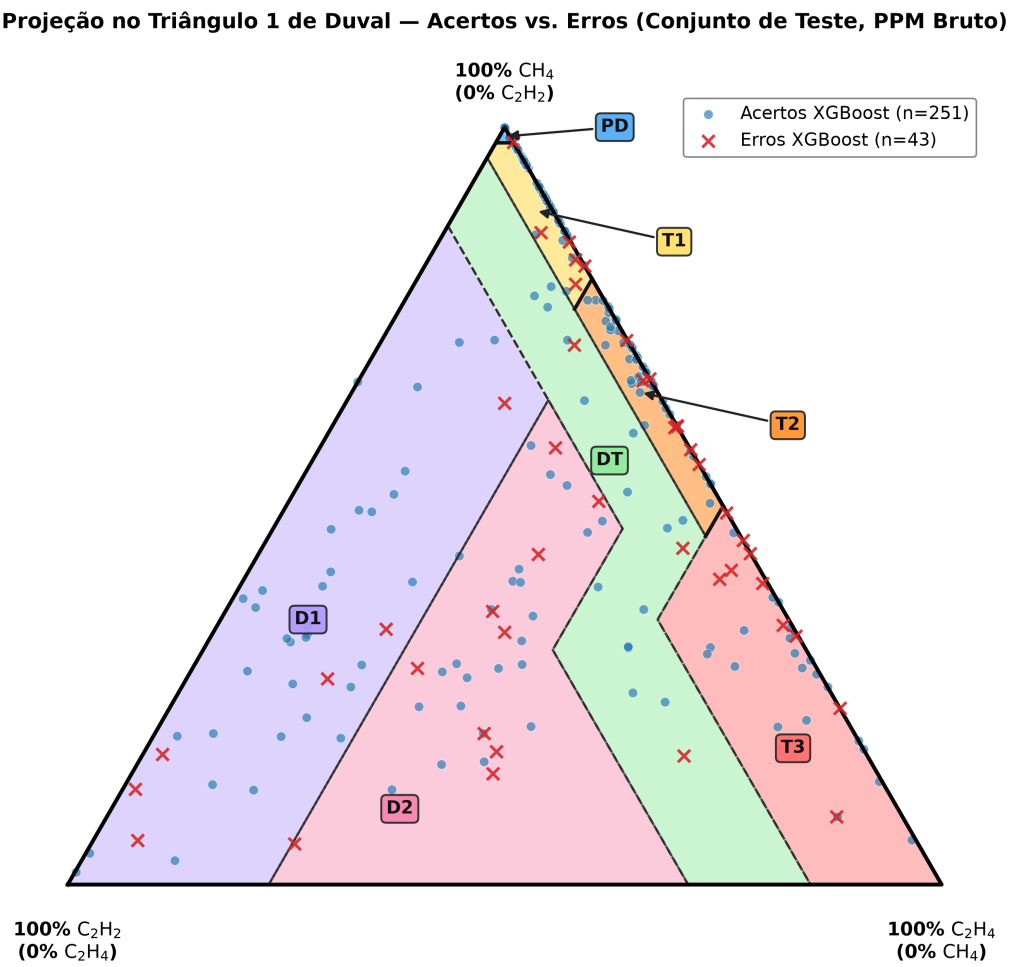


Figura 16 – Mapeamento das amostras de teste no Triângulo 1 de Duval com a localização dos erros diagnósticos.

Fonte: Elaborado pelo autor.

A visualização em escala física (ppm bruto) evidencia que os erros do XGBoost concentram-se principalmente nas imediações das fronteiras que separam as zonas de descarga (D1 e D2) e de transição mista (DT), e ao longo da borda direita do triângulo ($\%C_2H_2 \approx 0$, zonas T1, T2 e T3), onde ocorre sobreposição entre faixas térmicas adjacentes e amostras normais sem presença de acetileno.

4.5.5 ANÁLISE LOCAL DE ERROS DE CLASSIFICAÇÃO

A decomposição aditiva local por gráficos em cascata (*waterfall plots*) permite examinar em detalhe os fatores que levaram o modelo a uma determinada previsão. A Figura 17 apresenta essa análise para a amostra de índice 11 do conjunto de teste, cujo diagnóstico original de campo era D1, mas que foi classificada pelo modelo como D2.

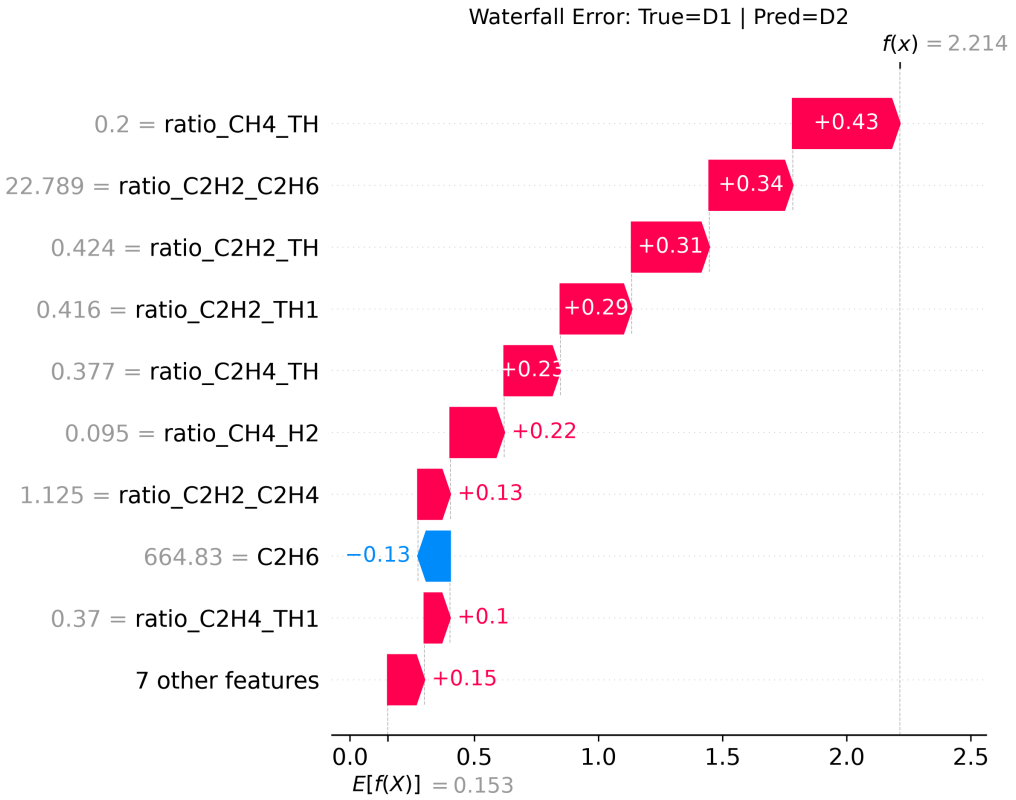


Figura 17 – Decomposição aditiva via Waterfall plot de um caso classificado de D1 para D2 (amostra 11).

Fonte: Elaborado pelo autor.

O gráfico da Figura 17 mostra a evolução a partir do valor basal $\mathbb{E}[f(X)] = 0,153$ até a margem final de predição $f(x) = 2,214$ em favor da classe D2. Observa-se que a proporção de etileno (`ratio_C2H4_TH`) foi de 0,377 (37,7%), exercendo um impacto positivo de $+0,23$ para a classificação em D2, o que é coerente com a regra do Triângulo de Duval em que teores de etileno acima de 23% saem da faixa de descargas de baixa energia D1. Além disso, a presença expressiva de acetileno gerou contribuições positivas adicionais para D2 ($+0,34$ em `ratio_C2H2_C2H6`, $+0,31$ em `ratio_C2H2_TH` e $+0,29$ em `ratio_C2H2_TH1`). A concentração de etano ($C_2H_6 = 664,83$ ppm) exerceu leve papel redutor ($-0,13$), mas insuficiente para conter a tendência geral. Cabe sublinhar que, com teores relativos de acetileno ($\approx 42\%$) e etileno ($\approx 37,7\%$), a amostra 11 recai na zona D2 segundo a própria geometria canônica do Triângulo 1 de Duval. Portanto, a divergência do classificador XGBoost não reflete necessariamente uma falha preditiva do algoritmo, mas sugere um forte indício de inconsistência de anotação ou caso fronteiriço no laudo original da base, que havia registrado a ocorrência como D1.

4.5.6 MIGRAÇÃO DE CRÉDITO E AVALIAÇÃO DA HIPÓTESE TEMPORAL

Para concluir a investigação sobre o papel das previsões da LSTM no Track A, avaliou-se como a importância atribuída pelo TreeSHAP se distribui entre variáveis medidas e variáveis previstas. A Figura 18 ilustra a distribuição média de crédito do hidrogênio entre as previsões gêmeas da LSTM ($H_{2,h14}$ e $H_{2,h28}$) para o modelo vencedor C1 (XGBoost otimizado por IGA, 8 atributos), avaliado ao longo das cinco sementes aleatórias.

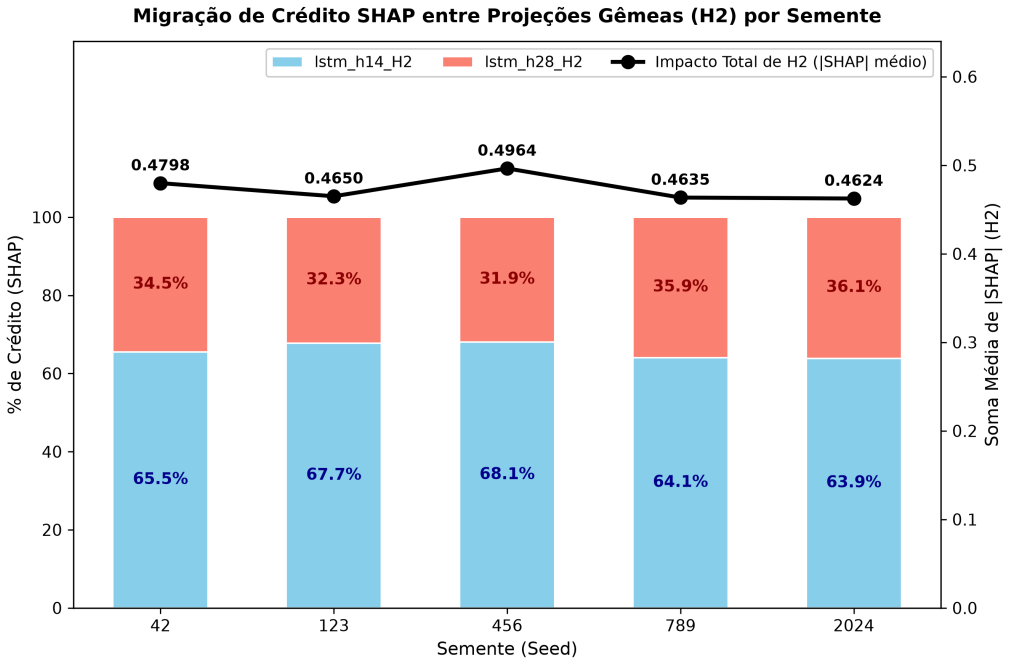


Figura 18 – Divisão da importância média absoluta do SHAP entre as projeções temporais de hidrogênio no modelo C1.

Fonte: Elaborado pelo autor.

O comportamento ilustrado na Figura 18 elucida a dinâmica de divisão de crédito no Track A. No modelo C1, o algoritmo genético selecionou 8 atributos, descartando a leitura observada $H_{2,obs}$ e retendo conjuntamente as projeções $H_{2,h14}$ e $H_{2,h28}$. Ao variar a semente de treinamento, a importância atribuída pelo TreeSHAP oscila entre as duas variáveis temporais do mesmo gás. Na semente 42, $65,5\%$ do crédito recai em $h = 14$ $(0,3144)$ e $34,5\%$ em $h = 28$ $(0,1653)$, enquanto na semente 456 a proporção é de $68,1\%$ $(0,3378)$ e $31,9\%$ $(0,1586)$. Contudo, o impacto total somado de hidrogênio (linha preta superior) permanece notavelmente constante entre as cinco sementes, situando-se em $0,4734 \pm 0,0131$ (variando estritamente entre $0,4624$ e $0,4964$, com média de $65,9\%$ do peso em $h = 14$ e $34,1\%$ em $h = 28$).

Esse comportamento confirma que as projeções da LSTM disputam a divisão nos nós das árvores sem fornecer informação discriminativa complementar, fazendo com que o modelo aloque o crédito preditivo de forma intercambiável entre as variáveis colineares e preserve o impacto total do sinal físico subjacente. Esse mesmo comportamento de partilha de crédito foi verificado para o modelo C2 (17 atributos), no qual o hidrogênio observado isolado na referência sem LSTM ($H_{2,obs} = 0,3085$ em C5a) tem sua importância individual diluída para $H_{2,obs} = 0,1921$ quando as projeções são adicionadas, dividindo o peso remanescente com $H_{2,h14}$ $(0,1277)$ e $H_{2,h28}$ $(0,1045)$, perfazendo uma soma de $0,4243$. Essa fragmentação confirma que variáveis colineares dispersam o peso atribuído ao sinal físico medido no presente, sem que a magnitude absoluta somada entre modelos arquiteturalmente distintos configure conservação numérica exata, a qual se manifesta com rigor na estabilidade da soma do gás entre diferentes sementes de treinamento dentro do mesmo modelo ($0,4734 \pm 0,0131$ em C1).

Em conjunto, os resultados experimentais dos eixos Track A e Track B demonstram a viabilidade da simplificação dimensional via IGA e a consistência físico-química capturada pelo TreeSHAP, ao mesmo tempo em que evidenciam as limitações práticas da inclusão de projeções temporais em séries de alta inércia e o teto de desempenho imposto pela sobreposição entre classes em dados estáticos. Com base nessas evidências, o Capítulo 5 sintetiza as conclusões gerais do trabalho, sistematiza as limitações identificadas e propõe direcionamentos para pesquisas futuras.

5 CONCLUSÃO

Este trabalho apresentou uma investigação experimental sobre o diagnóstico de falhas incipientes em transformadores de potência por Análise de Gases Dissolvidos (DGA). O estudo combinou redes neurais LSTM para previsão temporal de concentrações gasosas, árvores com aumento de gradiente (XGBoost) para classificação dos estados de integridade, busca evolutiva por meio do Algoritmo Genético Melhorado (IGA) para seleção de variáveis e ajuste de hiperparâmetros, e análise de interpretabilidade com TreeSHAP. A pesquisa buscou avaliar empiricamente a real eficácia de arquiteturas híbridas e o impacto da inclusão de previsões temporais frente aos métodos normativos tradicionais e às características dos dados práticos de campo.

5.1 SÍNTESE DAS CONTRIBUIÇÕES

A primeira contribuição metodológica do trabalho foi a estruturação da análise em dois eixos independentes de investigação (Track A e Track B), respeitando as naturezas distintas das bases de dados disponíveis na literatura de DGA. A verificação prévia e a deduplicação dos dados removeram cerca de 15% de amostras repetidas na base estática, assegurando que as partições de treino e teste fossem estritamente independentes e evitando estimativas infladas de desempenho.

No aspecto da otimização algorítmica, o acoplamento do IGA ao classificador XGBoost mostrou que o principal benefício da abordagem evolutiva esteve na simplificação dimensional do espaço de atributos. No Track A, o IGA reduziu o conjunto de variáveis de 17 para 8 atributos (uma redução de 53%), eliminando entradas colineares e mantendo um escore F_1-macro de 0,891, embora a verdadeira simplificação de custo operacional e latência computacional venha de dispensar a etapa de inferência da LSTM e utilizar a referência puramente estática (C5a), que atinge $F_1 = 0,8855$ com 9 variáveis observadas e árvores com menor profundidade.

No diagnóstico multiclasse do Track B (sete classes da norma IEC 60599), a avaliação por validação cruzada repetida em 25 dobras revelou um patamar estável de desempenho entre $F_1 \approx 0,75$ e $0,76$. Os modelos baseados em XGBoost superaram as regras normativas tradicionais tanto no teste global de sete classes quanto no protocolo comparativo justo restrito às 189 amostras de falhas ativas (no qual o Triângulo 1 de Duval atinge $F_1 = 0,450$ e as Razões IEC 60599 alcançam $F_1 = 0,330$, frente a $F_1 \approx 0,800$ do IGA-XGBoost). No entanto, os diferentes algoritmos de aprendizado supervisionado não apresentaram diferenças estatisticamente detectáveis entre si sob o nível de significância adotado, apontando para um teto empírico imposto tanto pelo

uso exclusivo dos cinco gases convencionais quanto pelas sobreposições físicas e ruídos de anotação histórica da base.

Por fim, a análise de interpretabilidade com o algoritmo TreeSHAP permitiu verificar a coerência físico-química das decisões aprendidas pelo XGBoost. O modelo identificou de forma consistente o acetileno como o principal indicador de descargas elétricas e o etileno como marcador de falhas térmicas, alinhando-se aos princípios da termodinâmica de degradação do óleo. Além disso, a extração de limiares marginais identificou que a transição para descargas de baixa energia ocorre na faixa entre 20% e 25% de etileno, o que coincide de maneira direta com o limite de 23% estabelecido empiricamente no Triângulo 1 de Duval.

Paralelamente às contribuições obtidas na simplificação e na interpretabilidade dos classificadores, a investigação empírica sobre a hibridização temporal forneceu subsídios decisivos sobre a real eficácia desse acoplamento, conforme discutido a seguir.

5.2 AVALIAÇÃO DA HIPÓTESE TEMPORAL E RESULTADOS NEGATIVOS

Um resultado relevante desta pesquisa foi a constatação empírica de que o fornecimento de concentrações futuras estimadas pela rede LSTM não gerou ganho estatisticamente significativo no diagnóstico pontual de falhas no Track A. O contraste pareado por *bootstrap* com 5.000 iterações indicou uma variação marginal de apenas $\Delta F_1 = +0,0056$, com intervalo de confiança de 95% entre $-0,0037$ e $+0,0150$ ($p \approx 0,238$). Como o intervalo engloba o zero ($p > 0,05$), não se detectou diferença estatisticamente significativa entre os modelos com e sem projeções da LSTM sob o nível adotado.

A razão física e matemática para a ausência de ganho detectável reside no comportamento de longo prazo dos transformadores analisados. Em equipamentos sob regime operacional contínuo, a evolução das concentrações ocorre de forma gradual, de modo que as leituras atuais e as projeções de curto prazo apresentam coeficientes de correlação superiores a 0,997. Consequentemente, as previsões futuras fornecidas pela rede neural atuam na prática como variáveis fortemente redundantes em relação às medições observadas no momento, comportamento confirmado pela migração de crédito observada nos valores de Shapley.

Esse resultado mostra na prática que, para a base avaliada, incluir as previsões da rede LSTM como entrada do XGBoost não traz ganho que justifique o custo extra de treinar e manter os dois modelos acoplados apenas para classificar o estado atual do transformador. Enquanto a LSTM modela com fidelidade a evolução quantitativa

das séries ($R^2 > 0,99$ em curto prazo), as projeções atuam como variáveis fortemente colineares às leituras do instante presente ($r > 0,997$). Dessa forma, o classificador alimentado unicamente pelas medições do momento atinge desempenho similar com arquitetura mais simples e menor esforço de implantação.

A interpretação conjunta dessas evidências deve, todavia, ser contextualizada diante das restrições metodológicas e das particularidades dos dados abertos utilizados no trabalho, cujos fatores são sistematizados na seção seguinte.

5.3 LIMITAÇÕES DA PESQUISA

Os resultados e as conclusões apresentadas devem ser interpretados considerando as limitações metodológicas e dos dados públicos disponíveis na literatura de DGA:

1. **Fragmentação das bases e escopo dos eixos analíticos:** A indisponibilidade de um repositório aberto que una séries temporais longas com os sete laudos multiclasse da IEC 60599 motivou a partição do estudo em dois eixos complementares. Por conseguinte, o Track B avalia exclusivamente o classificador XGBoost otimizado por IGA e interpretado via TreeSHAP sobre dados estáticos multiclasse, enquanto a hipótese de hibridização temporal com a rede LSTM foi avaliada no Track A.

2. **Escopo restrito e inércia temporal no Track A:** O conjunto temporal de Katser et al. (2022) monitora apenas quatro gases (H_2, CO, C_2H_4 e C_2H_2), possui rótulo diagnóstico constante ao longo dos 420 passos e reflete alta inércia temporal, conforme comprovado pelo baseline de persistência ($\hat{y}_{t+h} = y_t$, com $R^2 \geq 0,9886$ até 14 dias), o que limita o ganho preditivo adicional das projeções. Ademais, as estimativas da LSTM utilizadas no treino do XGBoost foram geradas sobre as próprias séries de treinamento da rede recorrente; embora um esquema *out-of-fold* fosse mais estrito para evitar previsões otimistas no treino, constatou-se que mesmo nesse cenário favorável as projeções não agregaram ganho estatístico na partição de teste independente.

3. **Normalização nas séries temporais:** Na base pública de Katser et al. (2022) utilizada no Track A, os arquivos originais já são disponibilizados pelos autores em escala pré-normalizada (da ordem de 10^{-3}), o que impede a recuperação dos valores absolutos em partes por milhão (ppm). No pipeline experimental desenvolvido neste trabalho, contudo, o reescalonamento Min-Max por gás para o intervalo $[0, 1]$ foi ajustado exclusivamente sobre as 1.785 séries de treinamento e aplicado sem vazamento às partições de validação e teste.

4. **Heterogeneidade e sobreposição física no Track B:** A base estática compilada por Li, Wang e Song (2019) reúne registros de literatura, inspeções visuais em serviço (IEC TC 10), desmontagem de transformadores e ensaios laboratoriais. Conforme destacado por Li, Wang e Song (2019), essa heterogeneidade prática acarreta sobreposições físico-químicas e fronteiras difusas naturais entre subtipos térmicos (T1/T2/T3) e de descarga (D1/D2), além de ruídos de anotação de campo (a exemplo da classe T3 com mediana de $C_2H_4/C_2H_6 = 0,25$). Esses fatores explicam o estabelecimento de um teto empírico em torno de 76% a 78% de F_1-macro para modelos supervisionados alimentados unicamente pelos cinco gases clássicos nessa base, e não uma barreira física universal.

5. **Isolamento do teste e escopo da validação cruzada repetida:** A seleção de atributos pelo IGA foi conduzida com validação cruzada de 5 dobras restrita ao conjunto de treinamento (com o `CustomSMOTE` encapsulado por dobra), mantendo a partição de teste independente ($N = 295$) 100% isolada de vazamento. De modo complementar, tanto a validação cruzada repetida 5×5 (executada com subconjuntos de atributos fixos sobre as 1.667 amostras de desenvolvimento) quanto a projeção espacial de erros no Triângulo 1 de Duval e a auditoria de concordância normativa foram conduzidas como diagnósticos de estabilidade e de consistência físico-química pós-seleção, sem interferir no treinamento dos modelos finais.

6. **Escopo comparativo da busca hiperparamétrica:** A calibração conjunta de atributos e hiperparâmetros pelo IGA teve como referência comparativa direta as configurações fixas representativas da literatura prática (a exemplo de Wu et al., 2021). A comparação experimental controlada contra outros métodos estocásticos, como amostragem aleatória (*Random Search*) e otimização bayesiana, não foi contemplada no escopo deste trabalho e constitui oportunidade de aprofundamento futuro.

Reconhecidas essas restrições e consolidados os achados analíticos, identificam-se oportunidades claras de aprimoramento metodológico para investigações subsequentes, detalhadas a seguir.

5.4 DIRECIONAMENTOS PARA TRABALHOS FUTUROS

A partir das constatações e limitações identificadas neste estudo, sugerem-se os seguintes caminhos para continuidade da pesquisa:

1. **Estimativa de tempo até a falha e vida útil remanescente:** Em vez de utilizar as projeções da rede LSTM para alimentar um classificador de estado pontual,

a capacidade preditiva temporal pode ser direcionada para estimar quando as concentrações de gases cruzarão os limites críticos de atenção das normas técnicas, auxiliando diretamente o planejamento de paradas de manutenção.

2. **Análise da taxa de variação dos gases:** Desenvolver modelos focados na velocidade diária ou mensal de geração dos gases (Δppm$/$tempo), que na prática das concessionárias é um indicador de severidade frequentemente mais sensível do que as concentrações absolutas isoladas.

3. **Integração com variáveis operacionais externas:** Incorporar variáveis de operação dos transformadores, como histórico de carregamento elétrico, temperatura do topo do óleo e umidade, permitindo contextualizar a produção de gases com o estresse térmico e elétrico suportado pelo equipamento.

4. **Validação com bases temporais completas:** Conduzir novos testes caso venham a ser disponibilizados conjuntos de dados temporais de campo que incluam o espectro completo dos gases combustíveis e registros de equipamentos submetidos a diferentes regimes industriais.

REFERÊNCIAS

AL-SAKINI, S. R. et al. Dissolved gas analysis for fault prediction in power transformers using machine learning techniques. *Applied Sciences*, MDPI, v. 15, n. 1, p. 118, 2025. Citado 4 vezes nas páginas 14, 18, 25 e 34.

ALAN-456. *Transformer Fault Dataset*. [S.l.]: GitHub, 2021. <https://github.com/alan-456/transformer-fault-dataset>. Acesso em: 20 out. 2026. Citado na página 39.

ALI, M. S. et al. Conventional methods of dissolved gas analysis using oil-immersed power transformer for fault diagnosis: A review. *Electric Power Systems Research*, Elsevier, v. 216, p. 109064, 2023. Citado 7 vezes nas páginas 12, 17, 18, 20, 25, 29 e 34.

CHAPMAN, S. J. *Fundamentos de Máquinas Elétricas*. 5. ed. Porto Alegre: AMGH Editora / McGraw-Hill, 2013. ISBN 9788580552072. Citado na página 17.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*. ACM, 2016. p. 785–794. Disponível em: <https://www.kdd.org/kdd2016/papers/files/rfp0697-chenAemb.pdf>. Citado 2 vezes nas páginas 15 e 26.

DUVAL, M. A review of faults detectable by gas-in-oil analysis in transformers. *IEEE Electrical Insulation Magazine*, v. 18, n. 3, p. 8–17, 2002. Disponível em: <https://www.researchgate.net/publication/3258357_A_review_of_faults_detectable_by_gas-in-oil_analysis_in_transformers>. Citado 2 vezes nas páginas 15 e 19.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 25.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, MIT Press, v. 9, n. 8, p. 1735–1780, 1997. Citado 2 vezes nas páginas 15 e 27.

IBRAHIM, S. I.; GHONEIM, S. S. M.; TAHA, I. B. M. Dgalab: An extensible software implementation for dga. *IET Generation, Transmission & Distribution*, IET, v. 12, n. 18, p. 4117–4124, 2018. Citado na página 38.

IEC. *Mineral oil-filled electrical equipment in service – Guidance on the interpretation of dissolved and free gases analysis*. [S.l.], 2022. Edition 4.0. Publication date: 2022-05-25. 80 pages. ISBN: 9782832236963. Disponível em: <https://webstore.iec.ch/en/publication/66491>. Citado 3 vezes nas páginas 15, 19 e 21.

KATSER, I. et al. Machine learning methods for anomaly detection in nuclear power plant power transformers. *arXiv preprint arXiv:2211.11013*, 2022. Citado 5 vezes nas páginas 35, 38, 49, 52 e 73.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, IEEE, v. 86, n. 11, p. 2278–2324, 1998. Citado na página 25.

LI, E.; WANG, L.; SONG, B. Fault diagnosis of power transformers with membership degree. *IEEE Access*, IEEE, v. 7, p. 28791–28798, 2019. Citado 4 vezes nas páginas 38, 39, 59 e 74.

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, v. 2, n. 1, p. 56–67, 2020. Citado 4 vezes nas páginas 15, 32, 47 e 62.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30, p. 4765–4774. Citado 2 vezes nas páginas 15 e 31.

SHAPLEY, L. S. A value for n-person games. In: *Contributions to the Theory of Games*. [S.l.]: Princeton University Press, 1953. v. 2, p. 307–317. Citado 2 vezes nas páginas 15 e 31.

TIGHTIZ, L. et al. An intelligent system based on optimized anfis and association rules for power transformer fault diagnosis. *ISA Transactions*, Elsevier, v. 103, p. 63–74, 2020. Citado na página 12.

WANG, L.; LITTLER, T.; LIU, X. Dynamic incipient fault forecasting for power transformers using an lstm model. *IEEE Transactions on Dielectrics and Electrical Insulation*, IEEE, v. 30, n. 3, p. 1353–1361, 2023. Citado 3 vezes nas páginas 14, 34 e 40.

WU, Z. et al. Improved genetic algorithm and xgboost classifier for power transformer fault diagnosis. *Frontiers in Energy Research*, Frontiers Media, v. 9, 2021. Citado 11 vezes nas páginas 14, 15, 25, 29, 30, 33, 41, 46, 56, 57 e 58.

ZHOU, H. et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2021. v. 35, n. 12, p. 11106–11115. Citado 2 vezes nas páginas 25 e 34.