UNIVERSIDADE DO VALE DO RIO DOS SINOS – UNISINOS

UNIDADE ACADÊMICA DE GRADUAÇÃO

CURSO DE ENGENHARIA DA COMPUTAÇÃO

ÂNDRIO GABRIEL EPPING

PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

SÃO LEOPOLDO

2026

ÂNDRIO GABRIEL EPPING

PREDIÇÃO DINÂMICA DE FALHAS EM TRANSFORMADORES: Abordagem Híbrida de Previsão Temporal (LSTM) e Classificação Otimizada (IGA-XGBoost)

Trabalho de Conclusão de curso apresentado como requisito parcial para obtenção do título de Bacharel em Engenharia da Computação, pelo curso de Engenharia da Computação da Universidade do Vale do Rio dos Sinos (UNISINOS).

Orientador: Profa. Me. Janaína Conceição Sutil Lemos

SÃO LEOPOLDO

2026

RESUMO

A Análise de Gases Dissolvidos (DGA) constitui a principal técnica para diagnóstico de falhas incipientes em transformadores de potência imersos em óleo mineral. Contudo, métodos normativos clássicos como o Triângulo 1 de Duval e a IEC 60599 operam sob fronteiras rígidas, carecem de definição para o estado operacional normal e geram elevadas taxas de indeterminação. Por outro lado, modelos de aprendizado de máquina frequentemente assumem, sem comprovação empírica, que a incorporação de projeções temporais de gases eleva o desempenho de classificadores estáticos. Este trabalho investiga a integração de redes neurais recorrentes LSTM e classificadores XGBoost otimizados por um Algoritmo Genético Melhorado (IGA), estruturando a experimentação em dois eixos analíticos complementares em função da assimetria das bases industriais públicas. O Eixo A avalia séries temporais multivariadas com amostragem a cada 12 horas (3.000 séries, 4 gases, 4 classes) sob teste formal de ablação pareada por bootstrap com 5.000 iterações. Os resultados evidenciam que, embora a LSTM apresente erro de predição reduzido, a forte colinearidade observada entre valores atuais e previstos ($r > 0,997$) não proporciona ganho estatisticamente significativo na discriminação diagnóstica ($\Delta F_1 = +0,0056$ com intervalo de confiança de 95% entre $-0,0037$ e $+0,0150$). Em contrapartida, o IGA promove uma redução de 53% no espaço de atributos mantendo desempenho balanceado equivalente ($F_1 \approx 0,891$). O Eixo B estabelece um referencial multiclasse sobre uma base auditada e deduplicada (1.972 amostras, 5 gases, 7 classes), comprovando por validação cruzada repetida 5×5 a existência de um teto informacional ($F_1 \approx 0,75$–$0,76$), no qual abordagens avançadas são estatisticamente indistinguíveis. Por fim, a aplicação da teoria dos jogos cooperativos via algoritmo TreeSHAP e matrizes de interação purificadas unifica as decisões do ensemble aos princípios termodinâmicos da IEC e de Duval, identificando os limiares físicos exatos de transição de falhas e mapeando a concentração de erros nas fronteiras poligonais.

Palavras-chave: Transformadores de Potência, Análise de Gases Dissolvidos, Redes LSTM, XGBoost, Algoritmo Genético Melhorado, Interpretabilidade Físico-Química, TreeSHAP.

ABSTRACT

Dissolved Gas Analysis (DGA) is the primary technique for incipient fault diagnosis in mineral oil-immersed power transformers. However, traditional standard methods, such as Duval Triangle 1 and IEC 60599 ratios, rely on rigid boundaries, lack a definition for the normal operating state, and produce high indeterminacy rates. Conversely, machine learning models frequently assume, without rigorous empirical verification, that incorporating temporal gas forecasts necessarily improves static classification performance. This work investigates the integration of Long Short-Term Memory (LSTM) recurrent neural networks and XGBoost classifiers optimized via an Improved Genetic Algorithm (IGA), structured into two complementary experimental tracks dictated by the asymmetry of public industrial repositories. Track A evaluates industrial multivariate time series sampled every 12 hours (3,000 series, 4 gases, 4 classes) under a formal paired bootstrap ablation test with 5,000 resamples. The results demonstrate that, despite low LSTM prediction errors, the strong collinearity between observed and forecasted concentrations ($r > 0.997$) yields no statistically significant gain in diagnostic discrimination ($\Delta F_1 = +0.0056$ with a 95% confidence interval between -0.0037 and $+0.0150$). In contrast, the IGA achieves a 53% dimensionality reduction while preserving identical macro-averaged performance ($F_1 \approx 0.891$). Track B establishes a multiclass benchmark on an audited, deduplicated database (1,972 unique samples, 5 gases, 7 classes), demonstrating an informational ceiling ($F_1 \approx 0.75$–0.76) through repeated 5×5 cross-validation where advanced models are statistically indistinguishable. Finally, cooperative game theory via TreeSHAP and purified interaction matrices reconciles the ensemble decision boundaries with thermodynamic domain knowledge from Duval and IEC standards, identifying physical transition thresholds and mapping classification errors along polygonal boundary zones.

Keywords: Power Transformers, Dissolved Gas Analysis, LSTM Networks, XGBoost, Improved Genetic Algorithm, Physical Interpretability, TreeSHAP.

LISTA DE ILUSTRAÇÕES

Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA, confrontando a abordagem normativa reativa com a modelagem preditiva orientada a dados. 12
Figura 2 – Triângulo 1 de Duval para interpretação de gases dissolvidos em óleo mineral. 19
Figura 3 – Processo iterativo de minimização de resíduos em ensembles de gradient boosting. 24
Figura 4 – Arquitetura estrutural da célula de memória recorrente LSTM. 27
Figura 5 – Topologia de rede neural recorrente LSTM empilhada para modelagem temporal. 27
Figura 6 – Fluxo operacional do Algoritmo Genético Melhorado para busca conjunta. 28
Figura 7 – Fluxograma metodológico do trabalho estruturado na bifurcação entre os eixos Track A e Track B. 36
Figura 8 – Degradação do coeficiente de determinação (R^2) da LSTM em múltiplos horizontes temporais no conjunto de teste oficial. 47
Figura 9 – Compromisso entre complexidade dimensional e desempenho diagnóstico no Track A. 50
Figura 10 – Matriz de confusão das predições diagnósticas para o Track A no conjunto de teste oficial. 50
Figura 11 – Matriz de confusão do modelo C3 (IGA-XGBoost) no teste de sete classes do Track B. 53
Figura 12 – Mapa de calor da importância média absoluta do SHAP por classe operacional no Track B. 56
Figura 13 – Importância agregada por famílias de gases para as sete categorias de integridade operacional. 56
Figura 14 – Distribuição dos valores de SHAP para a classe de Descargas de Baixa Energia (D1). 57
Figura 15 – Efeito principal isolado do TreeSHAP para a razão C_2H_4/TH na classe D1. 58
Figura 16 – Mapeamento das amostras de teste no Triângulo 1 de Duval evidenciando a localização dos erros diagnósticos. 60
Figura 17 – Decomposição aditiva via Waterfall plot do caso de classificação divergente de D1 para D2 (amostra 11). 61
Figura 18 – Migração estocástica de crédito de importância do SHAP entre variáveis observadas e preditas pela LSTM. 62

..

LISTA DE TABELAS

Tabela 1 – Comparação entre algoritmos de aprendizado de máquina aplicados à DGA 21
Tabela 2 – Comparação entre trabalhos relacionados e o escopo investigado neste estudo. 32
Tabela 3 – Desempenho do módulo LSTM no conjunto de teste oficial para previsão de um passo ($h = 1$, escala normalizada). 46
Tabela 4 – Degradação do desempenho preditivo da LSTM em função do horizonte temporal. 47
Tabela 5 – Desempenho comparativo e estudo de ablação da hipótese temporal no Track A (900 amostras de teste, 5 sementes). 48
Tabela 6 – Comparações pareadas via bootstrap (5.000 iterações) no Track A. 49
Tabela 7 – Desempenho diagnóstico multiclasse no Track B sobre sete categorias operacionais. 52
Tabela 8 – Concordância entre os rótulos da base e os diagnósticos da IEC 60599 e do Triângulo de Duval. 54
Tabela 9 – Comparação entre limiares analíticos normativos e pontos de transição marginal do TreeSHAP. 58

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
AG	Algoritmo Genético
ANFIS	*Adaptive Neuro-Fuzzy Inference System* (Sistema de Inferência Neuro-Fuzzy Adaptativo)
AUC-ROC	*Area Under the Curve – Receiver Operating Characteristic* (Área sob a Curva – Característica de Operação do Receptor)
BPTT	*Backpropagation Through Time* (Retropropagação Através do Tempo)
CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
CRISP-DM	*Cross-Industry Standard Process for Data Mining* (Processo Padrão Intersetorial para Mineração de Dados)
DGA	*Dissolved Gas Analysis* (Análise de Gases Dissolvidos)
GA	*Genetic Algorithm* (Algoritmo Genético)
IEC	*International Electrotechnical Commission* (Comissão Eletrotécnica Internacional)
IGA	*Improved Genetic Algorithm* (Algoritmo Genético Melhorado)
KNN	*k-Nearest Neighbors* (k-Vizinhos Mais Próximos)
LightGBM	*Light Gradient Boosting Machine* (Máquina de Aumento de Gradiente Leve)
LSTM	*Long Short-Term Memory* (Memória de Curto e Longo Prazo)
MAE	*Mean Absolute Error* (Erro Médio Absoluto)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
PSO	*Particle Swarm Optimization* (Otimização por Enxame de Partículas)
RMSE	*Root Mean Squared Error* (Raiz do Erro Quadrático Médio)
RNN	*Recurrent Neural Network* (Rede Neural Recorrente)
SHAP	*SHapley Additive exPlanations* (Explicações Aditivas de Shapley)

SMOTE	*Synthetic Minority Over-sampling Technique* (Técnica de Sobreamostragem de Minorias Sintéticas)
SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
XGBoost	*Extreme Gradient Boosting* (Aumento Extremo de Gradiente)

LISTA DE SÍMBOLOS

w	Tamanho da janela temporal (número de passos históricos)
h	Horizonte de previsão (passos à frente)
x_t	Vetor de concentrações dos gases no instante t
$\hat{y}$	Saída predita pelo modelo
h_t	Estado oculto da rede recorrente no instante t
C_t	Estado da célula (memória) da LSTM no instante t
$f_k(x)$	Árvore k no ensemble de *gradient boosting*
$L(y, \hat{y})$	Função de perda
N	Tamanho da população no AG/IGA
G	Número máximo de gerações no AG/IGA
P_c	Taxa de cruzamento (*crossover rate*)
P_m	Taxa de mutação
δ	Limiar de diversidade populacional (desvio padrão da aptidão)

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Tema 12
1.2 Justificativa 13
1.3 Objetivos 13
1.4 Organização do Texto 14

2 FUNDAMENTAÇÃO TEÓRICA 16
2.1 Transformadores de Potência e Degradação do Isolamento . . . 16
2.1.1 Sistema de Isolamento e Mecanismos de Degradação 16
2.1.2 Geração de Gases Dissolvidos 17
2.1.3 Taxonomia e Severidade de Falhas Internas 17
2.2 Métodos Normativos de Diagnóstico em DGA 18
2.2.1 Triângulo 1 de Duval 18
2.2.2 Método das Razões da IEC 60599 20
2.3 Algoritmos de Aprendizado de Máquina Aplicados à DGA 21
2.3.1 Panorama e Classificadores Clássicos 21
2.3.2 Ensembles de Árvores e o Algoritmo XGBoost 24
2.3.3 Redes Neurais Recorrentes e Modelagem Temporal 25
2.3.4 Otimização Evolutiva por Algoritmo Genético Melhorado (IGA) 28
2.4 Interpretabilidade em Aprendizado de Máquina (XAI) 29
2.4.1 Teoria dos Jogos Cooperativos e Valores de Shapley 29
2.4.2 O Algoritmo TreeSHAP e Decomposição de Contribuições 30
2.5 Trabalhos Relacionados 31

3 METODOLOGIA 34
3.1 Desenho Metodológico e Arquitetura em Dois Eixos 34
3.2 Bases de Dados e Procedimentos de Auditoria 35
3.2.1 Base de Séries Temporais Industriais (Track A) 35
3.2.2 Base Compilada de Diagnóstico Estático (Track B) 35
3.2.3 Critérios de Exclusão e Descarte de Bases de Dados 37
3.3 Pré-processamento e Engenharia de Atributos 37
3.3.1 Tratamento de Escala e Normalização 38
3.3.2 Espaço de Atributos do Track A 38
3.3.3 Espaço de Atributos do Track B 39
3.3.4 Tratamento do Desbalanceamento de Classes 39
3.4 Módulo de Previsão Temporal 39

3.5 Algoritmo Genético Melhorado e Otimização do XGBoost 40
3.5.1 Representação Cromossômica e Operadores Genéticos 40
3.5.2 Função de Aptidão e Critérios de Parada 41
3.6 Protocolo Experimental e Rigor Estatístico 42
3.6.1 Desenho Experimental e Ablação no Track A 42
3.6.2 Desenho Experimental no Track B 42
3.6.3 Procedimentos de Bootstrap Pareado e Validação Cruzada Repetida 42
3.7 Protocolo de Interpretabilidade e Validação Físico-Química . . . 43

4 RESULTADOS E DISCUSSÃO 45
4.1 Desempenho do Módulo de Previsão Temporal 45
4.2 Resultados do Track A: Desempenho e Ablação da Hipótese Temporal 48
4.3 Resultados do Track B: Diagnóstico Multiclasse e o Teto Informacional 51
4.4 Auditoria Normativa: Divergência dos Métodos Tradicionais . . . 52
4.5 Interpretabilidade Físico-Química via SHAP 54
4.5.1 Estabilidade do Ranking Global 55
4.5.2 Relevância por Classe e Agrupamento por Famílias Químicas 55
4.5.3 Extração de Limiares Físicos Marginais 58
4.5.4 Visualização Espacial no Triângulo de Duval 59
4.5.5 Análise Local de Erros de Classificação 59
4.5.6 Migração Estocástica de Crédito e Fechamento da Hipótese Temporal 60

5 CONCLUSÃO 63
5.1 Síntese das Contribuições 63
5.2 Defesa Científica de Resultados Negativos 64
5.3 Limitações da Pesquisa 65
5.4 Direcionamentos para Trabalhos Futuros 65

REFERÊNCIAS 67

1 INTRODUÇÃO

O suprimento contínuo de energia elétrica condiciona a operação de sistemas de produção industrial, centros de saúde e redes de comunicação. Nesse ecossistema de infraestrutura, os transformadores de potência atuam como elementos centrais na conversão de níveis de tensão e corrente nas etapas de geração, transmissão e distribuição. A operação em regime ininterrupto sob carregamento dinâmico e estresses ambientais impõe desgaste contínuo aos materiais internos, podendo culminar em falhas catastróficas que acarretam interrupções de fornecimento e elevados custos de recomposição patrimonial (TIGHTIZ et al., 2020). Por esse motivo, o monitoramento contínuo da integridade operacional desses equipamentos constitui prática indispensável para a engenharia de manutenção.

A degradação dos componentes internos decorre primariamente de solicitações térmicas e dielétricas aplicadas sobre o sistema de isolamento composto por óleo mineral e papel celulósico. As reações de clivagem molecular provocadas por aquecimentos localizados e descargas elétricas induzem a liberação de espécies gasosas que se dissolvem no fluido dielétrico, incluindo hidrogênio (H_2), metano (CH_4), etano (C_2H_6), etileno (C_2H_4) e acetileno (C_2H_2), acompanhados por monóxido de carbono (CO) proveniente da isolação sólida. A mensuração periódica dessas concentrações por cromatografia gasosa, denominada Análise de Gases Dissolvidos (*Dissolved Gas Analysis*, DGA), constitui a principal metodologia de diagnóstico incipiente de falhas (ALI et al., 2023).

A cadeia causal que vincula a operação do equipamento ao diagnóstico físico-químico está ilustrada na Figura 1. As solicitações de campo degradam o isolamento, gerando subprodutos gasosos cuja assinatura estequiométrica reflete o regime de temperatura e a intensidade energética da falha. Tradicionalmente, esses dados são interpretados por métodos baseados em regras geométricas ou razões estáticas préfixadas, os quais atuam de forma reativa após a consolidação do defeito. Em contraste, abordagens orientadas a dados buscam modelar a dinâmica de evolução gasosa e otimizar a identificação de anomalias por meio de inteligência computacional.

A aplicação prática de técnicas de aprendizado de máquina no domínio de DGA enfrenta, contudo, uma restrição imposta pela natureza dos dados abertos disponíveis. Constata-se na literatura uma assimetria estrutural entre bases temporais contínuas, que registram leituras periódicas de sensores online restritas a subconjuntos de gases, e bases estáticas consolidadas, que cobrem os cinco gases normativos e a taxonomia completa de falhas, porém sem rastreamento longitudinal. Diante dessa condição de contorno, a presente pesquisa investiga a integração entre projeções temporais e

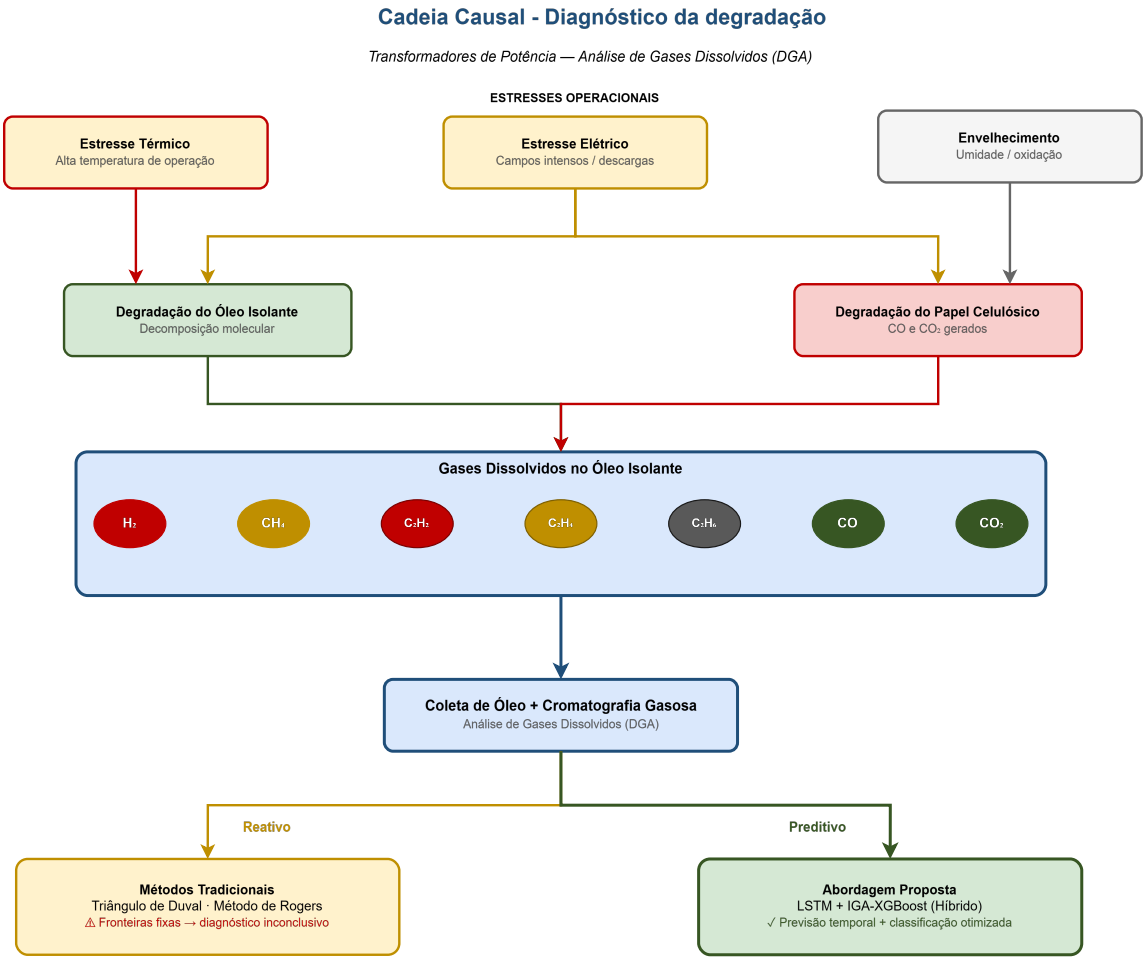


Figura 1 – Cadeia causal da degradação de transformadores de potência e DGA, confrontando a abordagem normativa reativa com a modelagem preditiva orientada a dados.

Fonte: Elaborado pelo autor.

algoritmos de classificação estática a partir de um desenho metodológico estruturado em dois eixos experimentais complementares, incorporando procedimentos rigorosos de teste de hipótese e interpretabilidade físico-química pós-hoc.

1.1 TEMA

O tema deste trabalho consiste na investigação empírica de arquiteturas híbridas baseadas em redes neurais recorrentes LSTM e algoritmos XGBoost otimizados por algoritmos genéticos, com foco na avaliação ablativa de projeções temporais, busca por parcimônia dimensional e validação físico-química de falhas em transformadores de potência por Análise de Gases Dissolvidos.

1.2 JUSTIFICATIVA

Os métodos normativos tradicionais de diagnóstico em DGA, como o Triângulo 1 de Duval e o Método das Razões da IEC 60599, operam a partir de fronteiras poligonais rígidas e tabelas discretas de corte. Embora consolidados na prática industrial, esses métodos apresentam limitações estruturais documentadas, destacando-se a ausência de definição de estado de operação normal e a elevada taxa de diagnósticos indeterminados em amostras com sinais de degradação mista (AL-SAKINI et al., 2025). Tais restrições motivaram a adoção crescente de algoritmos de aprendizado supervisionado, como o XGBoost, capazes de mapear fronteiras de decisão não lineares a partir de medições cromatográficas (WU et al., 2021).

Não obstante os avanços reportados na literatura, a maioria das soluções propostas opera estritamente sobre registros pontuais estáticos, ignorando a dinâmica temporal da gaseificação, ou formula modelos híbridos sob a premissa teórica de que projeções temporais geradas por redes recorrentes obrigatoriamente elevam o desempenho discriminativo de classificadores estáticos (WANG; LITTLER; LIU, 2023). Essa hipótese, contudo, raramente é submetida a protocolos formais de ablação estatística com intervalos de confiança e testes pareados. Adicionalmente, modelos complexos baseados em ensembles de árvores são frequentemente tratados como sistemas opacos, sem auditoria formal da concordância entre as fronteiras estocásticas aprendidas e os princípios termodinâmicos postulados nas normas técnicas da engenharia de alta tensão.

Torna-se justificável, portanto, conduzir uma investigação científica rigorosa que audite a real contribuição informacional de projeções temporais de curto e médio prazo, quantifique o ganho de parcimônia propiciado por algoritmos evolutivos na seleção de variáveis e estabeleça uma ponte analítica entre modelos de aprendizado de máquina e as normas clássicas de DGA por meio de métodos axiomáticos de interpretabilidade.

1.3 OBJETIVOS

O objetivo geral deste trabalho consiste em desenvolver, auditar e avaliar experimentalmente uma abordagem computacional para o diagnóstico de falhas em transformadores de potência a partir de dados de DGA, investigando o valor incremental de projeções temporais via redes LSTM, a parcimônia dimensional proporcionada pelo Algoritmo Genético Melhorado acoplado ao XGBoost e a conformidade físico-química das decisões frente às normas internacionais por meio de técnicas de interpretabilidade.

Para concretizar a proposta, definem-se os seguintes objetivos específicos.

O primeiro objetivo específico reside em auditar e preparar bases de dados

reais de DGA, eliminando duplicidades amostrais que induzam viés estatístico e estruturando a experimentação em dois eixos analíticos fundamentados na disponibilidade de variáveis físico-químicas.

O segundo objetivo específico visa implementar um módulo de previsão temporal baseado em redes neurais recorrentes LSTM empilhadas para gerar estimativas pontuais de concentrações gasosas em múltiplos horizontes operacionais futuros.

O terceiro objetivo específico consiste em submeter a integração entre as projeções temporais da LSTM e o classificador XGBoost a um protocolo formal de ablação pareada por reamostragem estatística, quantificando com rigor inferencial o ganho informacional efetivo da hipótese temporal.

O quarto objetivo específico consiste em avaliar a capacidade do Algoritmo Genético Melhorado (IGA) em promover redução de dimensionalidade e seleção parcimoniosa de atributos, confrontando seu desempenho contra modelos padrão e limites teóricos de informação no diagnóstico de falhas.

O quinto objetivo específico reside em auditar a coerência físico-química dos padrões aprendidos pelo modelo supervisionado em relação aos limiares analíticos do Triângulo 1 de Duval e da norma IEC 60599, aplicando a formulação de valores de Shapley e o algoritmo TreeSHAP.

1.4 ORGANIZAÇÃO DO TEXTO

O trabalho está estruturado em cinco capítulos encadeados logicamente.

O Capítulo 2 apresenta a fundamentação teórica, cobrindo os transformadores de potência, os mecanismos físico-químicos de degradação do sistema de isolamento, os métodos normativos clássicos de DGA, os fundamentos matemáticos dos algoritmos de aprendizado de máquina e otimização evolutiva, a teoria axiomática dos valores de Shapley via TreeSHAP e a revisão crítica dos trabalhos relacionados.

O Capítulo 3 descreve os procedimentos metodológicos adotados, detalhando a divisão da pesquisa nos eixos Track A e Track B, os protocolos de auditoria e saneamento de dados, a engenharia de atributos, a parametrização dos modelos LSTM e IGA-XGBoost, os testes de significância estatística baseados em bootstrap pareado e validação cruzada repetida, e o protocolo de interpretabilidade pós-hoc.

O Capítulo 4 expõe os resultados experimentais e as discussões técnicas correspondentes, abordando a capacidade preditiva da rede recorrente, o teste formal de ablação da hipótese temporal, a avaliação multiclasse de integridade operacional frente ao teto informacional da base de dados, a auditoria de concordância com os métodos tradicionais e a validação físico-química das fronteiras estocásticas por valores

de Shapley.

O Capítulo 5 (Conclusão) sintetiza as contribuições científicas e práticas da pesquisa, apresenta a discussão técnica sobre os resultados experimentais negativos, reconhece as limitações decorrentes dos conjuntos de dados industriais disponíveis e delineia direcionamentos prioritários para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo estabelece a fundamentação teórica necessária para o desenvolvimento e a interpretação dos modelos analisados neste trabalho. Inicialmente, descrevem-se os transformadores de potência, abordando a constituição do sistema de isolamento e os mecanismos físico-químicos que regem a decomposição do óleo mineral e a formação de gases dissolvidos. Em seguida, formulam-se matematicamente os métodos normativos de diagnóstico clássico, com ênfase no Triângulo 1 de Duval e no Método das Razões da IEC 60599. Na sequência, detalham-se os algoritmos de aprendizado de máquina aplicados à identificação de padrões em dados de cromatografia gasosa, abrangendo classificadores baseados em árvores com aumento de gradiente, redes neurais recorrentes para séries temporais e técnicas de otimização evolutiva. Apresenta-se também o arcabouço conceitual de explicabilidade pós-hoc fundamentado na teoria dos jogos cooperativos e no algoritmo TreeSHAP. Por fim, analisam-se os trabalhos relacionados presentes na literatura recente, identificando lacunas metodológicas e posicionando o escopo deste estudo.

2.1 TRANSFORMADORES DE POTÊNCIA E DEGRADAÇÃO DO ISOLAMENTO

Os transformadores de potência são equipamentos eletromagnéticos estáticos empregados na conversão de níveis de tensão e corrente elétrica em sistemas de transmissão e distribuição de energia (ALI et al., 2023). O princípio de operação baseia-se na Lei de Faraday, segundo a qual variações no fluxo magnético induzem forças eletromotrizes entre enrolamentos acoplados através de um núcleo ferromagnético laminado (TIGHTIZ et al., 2020). A operação contínua sob regimes de carregamento variáveis impõe esforços severos à estrutura física do equipamento, demandando sistemas de isolamento capazes de suportar simultaneamente gradientes térmicos elevados e campos dielétricos intensos.

2.1.1 SISTEMA DE ISOLAMENTO E MECANISMOS DE DEGRADAÇÃO

O sistema de isolamento dos transformadores de potência imersos em óleo é de natureza híbrida, combinando materiais sólidos e fluidos dielétricos (ALI et al., 2023). A fase sólida é constituída por papéis celulósicos Kraft e barreiras de papelão prensado (*pressboard*), responsáveis pelo isolamento entre espiras adjacentes e entre enrolamentos de diferentes fases. A fase fluida consiste em óleo mineral isolante, que

preenche os interstícios mecânicos do tanque, proporcionando rigidez dielétrica ao conjunto e atuando como fluido refrigerante na dissipação do calor gerado por perdas no núcleo e nos condutores.

Durante o ciclo de operação, o sistema de isolamento sofre degradação progressiva decorrente da ação combinada de estresses térmicos, elétricos e químicos. A oxidação do óleo mineral na presença de oxigênio dissolvido e contaminantes particulados resulta na acidificação do meio e na formação de borras polares que aceleram a perda de propriedades dielétricas. Paralelamente, o papel isolante sofre despolimerização celulósica por hidrólise e pirólise, reduzindo sua resistência mecânica e tornando o isolamento sólido vulnerável a esforços de curto-circuito.

2.1.2 GERAÇÃO DE GASES DISSOLVIDOS

A decomposição térmica e elétrica dos hidrocarbonetos do óleo mineral e das cadeias celulósicas induz reações de quebra molecular que liberam gases combustíveis e não combustíveis, os quais se dissolvem no fluido dielétrico (ALI et al., 2023). Os principais gases gerados incluem hidrogênio (H_2), metano (CH_4), etano (C_2H_6), etileno (C_2H_4) e acetileno (C_2H_2), além de monóxido de carbono (CO) e dióxido de carbono (CO_2), associados primariamente à quebra da celulose sólida.

A concentração e as proporções relativas desses gases dependem diretamente da quantidade de energia concentrada no ponto de ocorrência da falha e da temperatura local associada. Descargas parciais de baixa energia geram predominantemente hidrogênio e traços de metano através de bombardeamento iônico local. Sobreaquecimentos térmicos de baixa temperatura induzem a clivagem preferencial de ligações carbono-hidrogênio simples, liberando metano e etano. Em temperaturas intermediárias e elevadas, intensifica-se a produção de etileno através da quebra de cadeias parafínicas. Em regime de descargas elétricas disruptivas de alta energia e arcos elétricos, onde temperaturas locais superam $1.000\ ^\circ$C, ocorre a fragmentação direta de anéis e cadeias carbônicas com rápida formação de acetileno. A quantificação laboratorial periódica dessas substâncias via cromatografia em fase gasosa constitui a técnica denominada Análise de Gases Dissolvidos (*Dissolved Gas Analysis*, DGA), que subsidia programas de manutenção preditiva em ativos de potência.

2.1.3 TAXONOMIA E SEVERIDADE DE FALHAS INTERNAS

A literatura e as normas internacionais categorizam os defeitos internos em transformadores em três classes fundamentais, compreendendo falhas elétricas, falhas térmicas e defeitos combinados (AL-SAKINI et al., 2025). As falhas elétricas englobam as descargas parciais (PD), que ocorrem em cavidades com falhas de impregnação

no papel ou bolhas de gás; as descargas de baixa energia (D1), caracterizadas por centelhamentos intermitentes de baixa corrente; e as descargas de alta energia (D2), representadas por arcos elétricos intensos com queima perceptível de óleo e papel.

As falhas térmicas são subdivididas de acordo com faixas de temperatura atingidas no ponto crítico. A classe T1 abrange sobreaquecimentos térmicos com temperaturas inferiores a 300 °C, associados tipicamente a fluxos restritos de óleo ou correntes parasitas em tanques. A classe T2 corresponde a sobreaquecimentos térmicos com temperaturas situadas entre 300 °C e 700 °C, comuns em contatos frouxos de conexões aparafusadas e derivações. A classe T3 define falhas térmicas severas com temperaturas superiores a 700 °C, geradas por correntes circulantes anormais em estruturas de fixação e curtos-circuitos entre espiras. Falhas combinadas envolvem a sobreposição de solicitações dielétricas e térmicas concentradas no mesmo volume de isolamento. A distribuição dessas anomalias em bancos de dados operacionais reais exibe assimetria severa, visto que falhas de arco e descargas parciais apresentam frequência de registro substancialmente inferior à dos regimes de operação normal e sobreaquecimentos leves.

2.2 MÉTODOS NORMATIVOS DE DIAGNÓSTICO EM DGA

A interpretação técnica dos ensaios de DGA baseia-se tradicionalmente em métodos gráficos e tabelas padronizadas que correlacionam frações de gases e razões estequiométricas com regimes de falha específicos.

2.2.1 TRIÂNGULO 1 DE DUVAL

O Triângulo 1 de Duval, consolidado no Anexo B da norma IEC 60599 (DESCONHECIDO, 2022) e em diretrizes técnicas correlatas (DUVAL, 2002), constitui um método gráfico fundamentado em coordenadas baricêntricas triangulares. A formulação emprega a concentração em partes por milhão (ppm) de três espécies gasosas com diferentes energias de formação, compreendendo o metano (CH_4), o etileno (C_2H_4) e o acetileno (C_2H_2). A soma percentual dessas três espécies define o espaço amostral total:

$$\mathrm{TH_{Duval}} = [\mathrm{CH_4}] + [\mathrm{C_2H_4}] + [\mathrm{C_2H_2}] \tag{2.1}$$

As coordenadas triangulares normalizadas de cada ponto são obtidas por:

$$\%\mathrm{CH_4} = 100 \cdot \frac{[\mathrm{CH_4}]}{\mathrm{TH_{Duval}}}, \quad \%\mathrm{C_2H_4} = 100 \cdot \frac{[\mathrm{C_2H_4}]}{\mathrm{TH_{Duval}}}, \quad \%\mathrm{C_2H_2} = 100 \cdot \frac{[\mathrm{C_2H_2}]}{\mathrm{TH_{Duval}}} \tag{2.2}$$

A soma dessas coordenadas resulta identicamente em 100%, definindo um plano bidimensional no interior de um triângulo equilátero, conforme ilustrado na Figura 2.

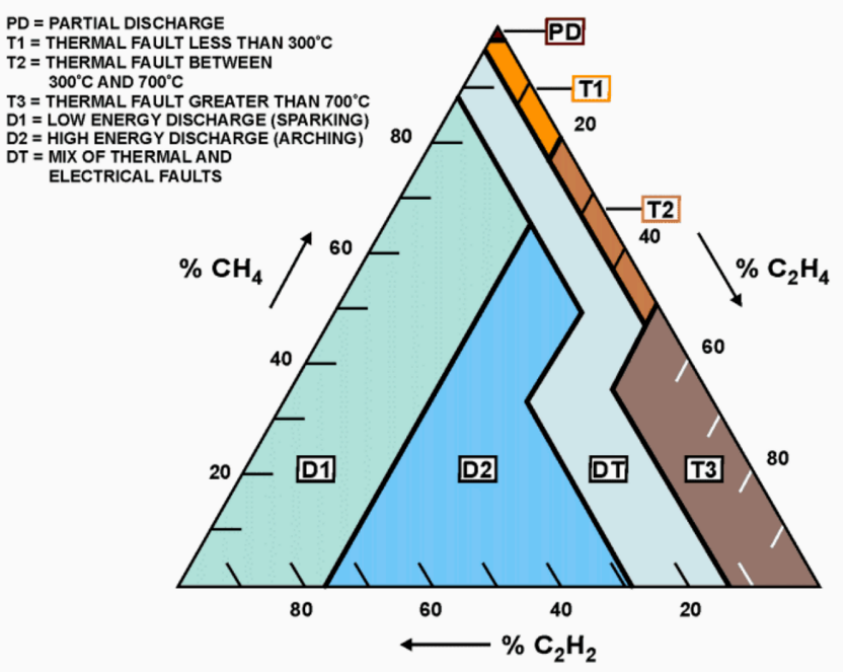


Figura 2 – Triângulo 1 de Duval para interpretação de gases dissolvidos em óleo mineral.

Fonte: Adaptado de Ali et al. (2023).

O espaço do triângulo é particionado em sete polígonos fechados associados a diferentes mecanismos de degradação: descargas parciais (PD), delimitadas pela região com $\%CH_4 \geq 98\%$; descargas de baixa energia (D1), definidas por $\%C_2H_2 > 13\%$ e $\%C_2H_4 < 23\%$; descargas de alta energia (D2), delimitadas por $\%C_2H_2 \geq 29\%$ e $\%C_2H_4 \geq 23\%$, e pela sub-região com $\%C_2H_2$ entre 13% e 29% com $\%C_2H_4 \geq 23\%$; falhas térmicas inferiores a 300 °C (T1), condicionadas a $\%CH_4 < 98\%$, $\%C_2H_2 < 4\%$ e $\%C_2H_4 < 20\%$; falhas térmicas entre 300 °C e 700 °C (T2), delimitadas por $\%C_2H_2 < 4\%$ e $20\% \leq \%C_2H_4 < 50\%$; falhas térmicas superiores a 700 °C (T3), caracterizadas por $\%C_2H_2 < 15\%$ e $\%C_2H_4 \geq 50\%$; e a zona de transição térmica e elétrica combinada (DT), delimitada por $\%C_2H_2$ entre 4% e 13% com $\%C_2H_4 \geq 20\%$ e $\%C_2H_4 < 50\%$.

A principal restrição estrutural do Triângulo 1 de Duval reside na inexistência de uma zona correspondente ao estado operacional normal. Todas as amostras projetadas sobre o triângulo são compulsoriamente alocadas em alguma categoria de falha, induzindo diagnósticos falsos positivos quando aplicadas a transformadores saudáveis com taxas residuais de gaseificação basal. Adicionalmente, amostras posicionadas nas imediações das linhas divisórias sofrem com sensibilidade paramétrica elevada,

onde variações analíticas mínimas na cromatografia deslocam a classificação entre categorias de severidade distintas.

2.2.2 MÉTODO DAS RAZÕES DA IEC 60599

O método analítico estabelecido pela norma IEC 60599 (DESCONHECIDO, 2022) fundamenta-se no cálculo de três razões adimensionais entre concentrações de gases dissolvidos:

$$r_1 = \frac{[C_2H_2]}{[C_2H_4]}, \quad r_2 = \frac{[CH_4]}{[H_2]}, \quad r_3 = \frac{[C_2H_4]}{[C_2H_6]} \tag{2.3}$$

A relação r_1 avalia a presença de acetileno frente ao etileno, permitindo discriminar entre fenômenos de centelhamento elétrico e degradações térmicas puras. A relação r_2 confronta o metano contra o hidrogênio, indicando o regime de temperatura de descargas ou sobreaquecimentos iniciais. A relação r_3 compara hidrocarbonetos insaturados contra saturados, fornecendo sensibilidade térmica direta sobre a temperatura de degradação do óleo.

A norma estabelece intervalos discretos de codificação para cada razão, associando conjuntos de intervalos aos estados de falha clássicos: descargas parciais (PD) requerem r_1 não significativo com magnitude inferior a 0,1, $r_2 < 0,1$ e $r_3 < 0,2$; descargas de baixa energia (D1) exigem $r_1 > 1$, $0,1 \leq r_2 \leq 0,5$ e $r_3 > 1$; descargas de alta energia (D2) são identificadas por $0,6 \leq r_1 \leq 2,5$, $0,1 \leq r_2 \leq 1$ e $r_3 > 2$; falhas térmicas inferiores a 300 °C (T1) demandam $r_1 < 0,1$, $r_2 > 1$ e $r_3 < 1$; falhas térmicas entre 300 °C e 700 °C (T2) requerem $r_1 < 0,1$, $r_2 > 1$ e $1 \leq r_3 \leq 4$; falhas térmicas superiores a 700 °C (T3) exigem $r_1 < 0,2$, $r_2 > 1$ e $r_3 > 4$.

Caso uma tupla amostral (r_1, r_2, r_3) assuma valores que não coincidam simultaneamente com nenhuma das combinações lógicas fixadas na norma, o diagnóstico é formalmente catalogado como Não Determinado (ND). Em bancos de dados de campo, a proporção de laudos não determinados atinge patamares elevados devido à superposição de fenômenos múltiplos e ruídos de medição, comprometendo a resolutividade do método quando aplicado de forma autônoma. Assim como o Triângulo de Duval, a norma IEC 60599 não estabelece códigos de razão para o estado de operação normal, condicionando a aplicação do método à prévia ultrapassagem de limiares estatísticos absolutos de concentração baseados no 90º percentil histórico da frota.

2.3 ALGORITMOS DE APRENDIZADO DE MÁQUINA APLICADOS À DGA

Diante das limitações das técnicas normativas rígidas, os algoritmos de aprendizado de máquina têm sido aplicados para capturar fronteiras não lineares complexas e correlacionar concentrações multivariadas com diagnósticos confirmados em serviço.

2.3.1 PANORAMA E CLASSIFICADORES CLÁSSICOS

A Tabela 1 apresenta um comparativo entre as principais famílias de algoritmos exploradas na literatura de diagnóstico em transformadores, indicando referências representativas, méritos operacionais e limitações técnicas observadas no domínio de DGA.

Tabela 1 – Comparação entre algoritmos de aprendizado de máquina aplicados à DGA

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
Classificadores clássicos			
SVM	Al-Sakini et al. (2025)	Maximização de margem de separação em alta dimensão	Dificuldade em classes sobrepostas e expansão multiclasse não nativa
KNN	Ali et al. (2023)	Ausência de hipóteses distributivas prévias	Sensibilidade a ruídos locais e custo computacional linear na predição
Árvore de Decisão	Ali et al. (2023)	Interpretabilidade na extração de regras	Instabilidade a perturbações e tendência a sobreajuste sem poda
Random Forest	Al-Sakini et al. (2025)	Robustez por agregação e cálculo de importância	Dificuldade de sintonia simultânea em espaços mistos de busca

Continua na próxima página

Tabela 1 – continuação

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
Naive Bayes	Ali et al. (2023)	Simplicidade analítica e velocidade de ajuste	Violação da hipótese de independência condicional entre gases
Ensembles e boosting			
XGBoost ✓	Wu et al. (2021)	Regularização explícita e ponderação diferencial de instâncias	Sensibilidade hiperparamétrica e incapacidade de inferência temporal
LightGBM	–	Eficiência em bases volumosas por expansão foliar	Risco de sobreajuste em conjuntos tabulares com menos de mil instâncias
Redes neurais			
MLP	Ali et al. (2023)	Aproximação universal de funções não lineares	Ausência de memória sequencial para dados ordenados longitudinalmente
CNN	LeCun et al. (1998)	Identificação hierárquica de correlações espaciais	Inadequação conceitual para matrizes tabulares puras de gases
Modelos de séries temporais			
ARIMA	Ali et al. (2023)	Formulação estatística parcimoniosa univariada	Premissa de linearidade e incapacidade de modelagem multivariada conjunta

Continua na próxima página

Tabela 1 – continuação

Algoritmo	**Referência em DGA**	**Vantagem principal**	**Limitação para este problema**
LSTM ✓	Katser et al. (2022)	Modelagem de dependências temporais longas por portões	Custo de treinamento superior e necessidade de dados sequenciais regulares
Transformer	Zhu et al. (2023)	Mecanismos de atenção global em horizontes extensos	Demanda volumosa de instâncias inexistente em repositórios abertos de DGA
Otimização evolutiva			
AG padrão	Ali et al. (2023)	Exploração estocástica global sem exigência de derivadas	Convergência prematura e ineficiência em inicializações aleatórias
IGA ✓	Wu et al. (2021)	Cruzamento adaptativo, operadores mistos e elitismo direto	Custo computacional ditado pela avaliação reiterada de modelos em validação cruzada
Otimização Bayesiana	–	Amostragem parcimoniosa baseada em processos gaussianos	Dificuldade de modelagem de espaços cromossômicos híbridos binário-contínuos

Fonte: elaborado pelo autor com base em Ali et al. (2023), Al-Sakini et al. (2025), Wu et al. (2021), Zhu et al. (2023) e LeCun et al. (1998).

Nota: ✓ indica as técnicas adotadas na formulação experimental deste estudo.

Entre os classificadores clássicos, as Máquinas de Vetores de Suporte (SVM) exibem bom desempenho na separação de classes lineares em espaços transformados por núcleos (*kernels*), porém sofrem com a sobreposição de densidades entre

categorias vizinhas, como as falhas T2 e T3 (AL-SAKINI et al., 2025). Os algoritmos baseados em vizinhos mais próximos (KNN) e árvores de decisão simples apresentam instabilidade na presença de ruído e alta variância. O Random Forest ameniza a variância agregando árvores independentes por amostragem com reposição (*bagging*), contudo não dispõe de otimização coordenada para espaços conjuntos de atributos e parâmetros estruturais. Já o classificador Naive Bayes, embora útil como referência estatística basal, baseia-se na suposição de independência condicional entre as variáveis preditoras, premissa que contradiz os princípios físicos da DGA, onde múltiplos gases coexistem e se formam a partir de reações termodinâmicas colineares (ALI et al., 2023).

2.3.2 ENSEMBLES DE ÁRVORES E O ALGORITMO XGBOOST

Os métodos de *gradient boosting* constroem modelos preditivos robustos através da combinação sequencial aditiva de estimadores fracos, tipicamente árvores de decisão com profundidade restrita (FRIEDMAN, 2001). A cada iteração k, uma nova árvore $f_k(x)$ é ajustada sobre o gradiente negativo da função de perda em relação à predição atual do conjunto, reduzindo de forma iterativa os resíduos remanescentes, conforme esquematizado na Figura 3.

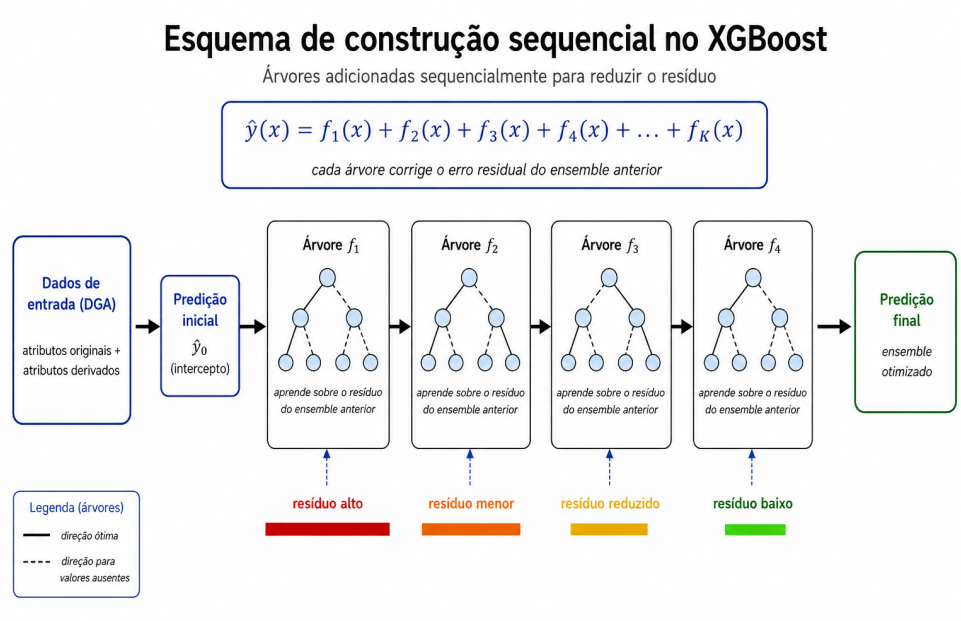


Figura 3 – Processo iterativo de minimização de resíduos em ensembles de gradient boosting.

Fonte: Elaborado pelo autor.

Formalmente, a predição consolidada de uma amostra x após a adição de K árvores é definida por:

$$\hat{y}(x) = \sum_{k=1}^{K} f_k(x), \quad f_k \in \mathcal{F} \tag{2.4}$$

O algoritmo XGBoost (*Extreme Gradient Boosting*) introduz formulações analíticas que aprimoram a estabilidade e a convergência do boosting clássico (CHEN; GUESTRIN, 2016). A função objetivo regularizada a ser minimizada na iteração t incorpora termos explícitos de penalização complexa sobre a estrutura das árvores:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \sum_{k=1}^{t} \Omega(f_k) \tag{2.5}$$

Em que l denota uma função de perda diferenciável convexa e $\Omega(f)$ representa o termo de penalização da árvore, expresso por:

$$\Omega(f) = \gamma T_L + \frac{1}{2}\lambda_{\text{reg}} \sum_{j=1}^{T_L} w_j^2 + \alpha_{\text{reg}} \sum_{j=1}^{T_L} |w_j| \tag{2.6}$$

Nessa formulação, T_L representa o número total de folhas da árvore, w_j indica o peso contínuo associado à folha j, γ configura a penalização para divisão de nós, enquanto λ_{reg} e α_{reg} correspondem aos termos de regularização L_2 e L_1, respectivamente. A expansão de Taylor em segunda ordem da função de perda permite obter expressões em forma fechada para o ganho ideal de divisão e para os pesos foliares, garantindo velocidade de ajuste e contenção de sobreajuste.

Para contornar o desbalanceamento amostral severo em tarefas multiclasse, o algoritmo suporta a atribuição de pesos diferenciados por instância (`sample_weight`), escalonando a contribuição de cada amostra na matriz hessiana da função de perda de acordo com o inverso da densidade de sua classe de origem.

2.3.3 REDES NEURAIS RECORRENTES E MODELAGEM TEMPORAL

Redes neurais artificiais convencionais operam sob a premissa de independência amostral, sendo incapazes de processar dependências sequenciais com ordenamento no tempo. As Redes Neurais Recorrentes (RNN) introduzem conexões de realimentação que mantêm um vetor de estado oculto h_t atualizado a cada instante temporal t a partir da entrada x_t e do estado precedente h_{t-1}:

$$h_t = \tanh\left(W_x x_t + W_h h_{t-1} + b\right) \tag{2.7}$$

Durante a retropropagação do erro através do tempo (*Backpropagation Through Time*, BPTT), a aplicação reiterada da regra da cadeia propaga multiplicações sucessivas da matriz de pesos recorrentes W_h. Essa dinâmica induz o problema do gradiente evanescente (*vanishing gradient*), no qual a magnitude dos gradientes decresce exponencialmente com a distância temporal, impedindo o aprendizado de correlações distantes (HOCHREITER; SCHMIDHUBER, 1997).

A arquitetura *Long Short-Term Memory* (LSTM) soluciona essa restrição introduzindo uma célula de memória dedicada governada por mecanismos de portas (*gates*) com conexões lineares diretas, permitindo a preservação constante do gradiente (HOCHREITER; SCHMIDHUBER, 1997). A dinâmica matemática da célula LSTM, apresentada na Figura 4, é governada pelas equações fundamentais:

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right) \tag{2.8}$$

$$i_t = \sigma\left(W_i[h_{t-1}, x_t] + b_i\right) \tag{2.9}$$

$$\tilde{C}_t = \tanh\left(W_c[h_{t-1}, x_t] + b_c\right) \tag{2.10}$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{2.11}$$

$$o_t = \sigma\left(W_o[h_{t-1}, x_t] + b_o\right) \tag{2.12}$$

$$h_t = o_t \odot \tanh(C_t) \tag{2.13}$$

Nas Equações (2.8) a (2.13), σ denota a função de ativação sigmoide, $\odot$ representa o produto de Hadamard elemento a elemento, f_t indica a porta de esquecimento que modula o descarte de informações em C_{t-1}, i_t é a porta de entrada que regula a absorção do novo candidato $\tilde{C}_t$, C_t configura o estado da célula interna e o_t representa a porta de saída que filtra a exposição do estado oculto h_t.

Para modelar dinâmicas de degradação com diferentes horizontes de abstração temporal, emprega-se a LSTM empilhada (*Stacked LSTM*), cuja topologia conecta múltiplas camadas recorrentes em série, conforme ilustrado na Figura 5. Nesse arranjo, as sequências de saídas ocultas da camada inferior servem como vetores de entrada direta para a camada subsequente, facultando a extração progressiva de trajetórias de gaseificação de longo prazo.

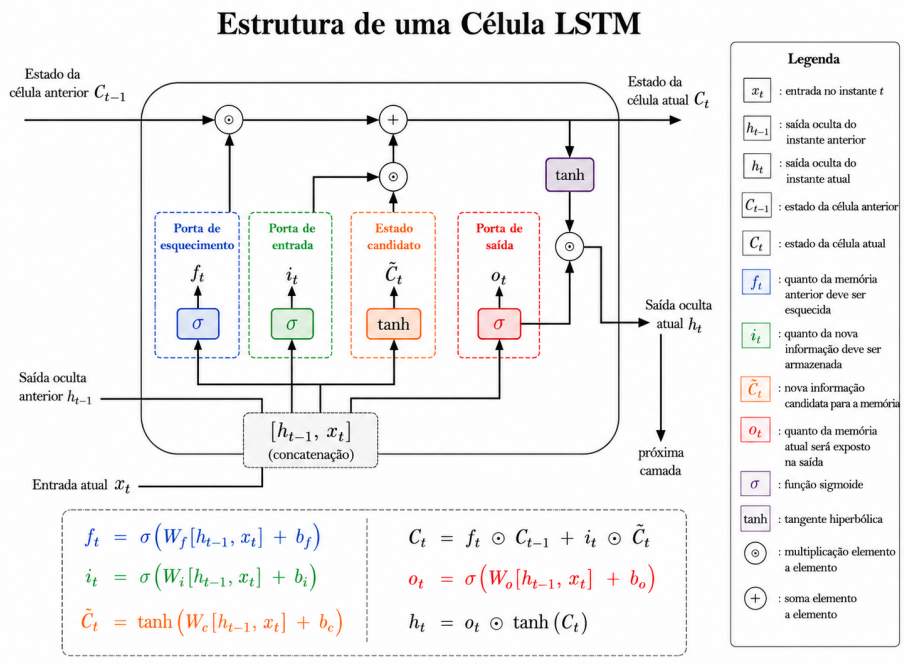


Figura 4 – Arquitetura estrutural da célula de memória recorrente LSTM.

Fonte: Elaborado pelo autor com base em Hochreiter e Schmidhuber (1997).

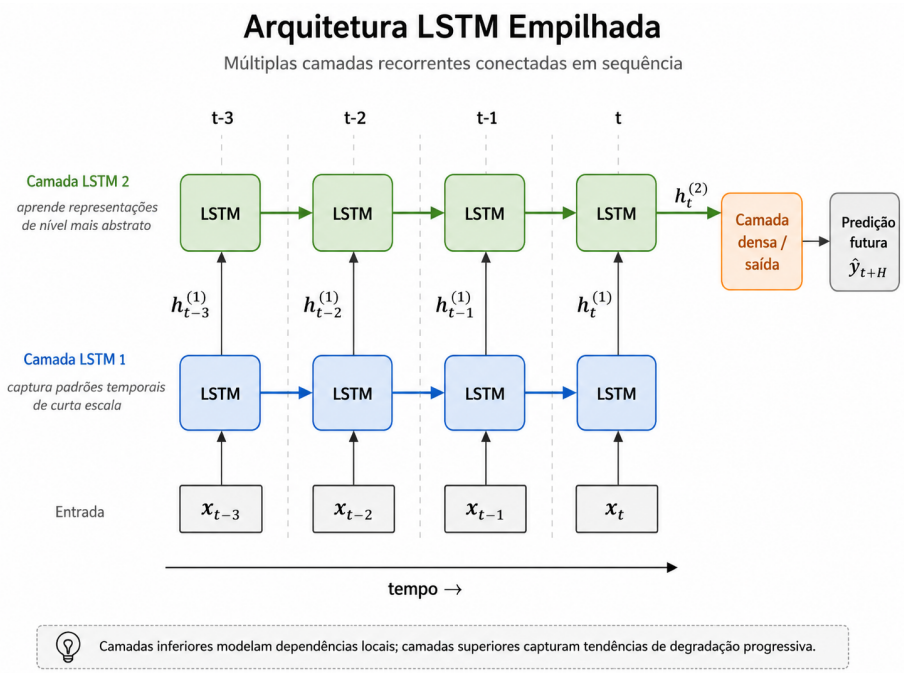


Figura 5 – Topologia de rede neural recorrente LSTM empilhada para modelagem temporal.

Fonte: Elaborado pelo autor.

2.3.4 OTIMIZAÇÃO EVOLUTIVA POR ALGORITMO GENÉTICO MELHORADO (IGA)

A configuração de modelos baseados em gradiente conjugado sobre árvores envolve uma decisão dependente entre o subconjunto de variáveis diagnósticas admitidas e a parametrização dos hiperparâmetros de regularização e profundidade. Os Algoritmos Genéticos (AG) oferecem uma estrutura estocástica de exploração global inspirada nos mecanismos de recombinação genética e sobrevivência do mais apto (ALI et al., 2023). O ciclo clássico opera mantendo uma população finita de indivíduos ao longo de gerações sucessivas, aplicando seleção por aptidão, recombinação por cruzamento (*crossover*) e mutações aleatórias.

Em matrizes de dados de DGA, o AG convencional exibe risco de convergência prematura em ótimos locais estagnados. O Algoritmo Genético Melhorado (IGA) mitiga esse comportamento incorporando operadores estruturados de diversidade e conservação, conforme ilustrado na Figura 6 (WU et al., 2021).

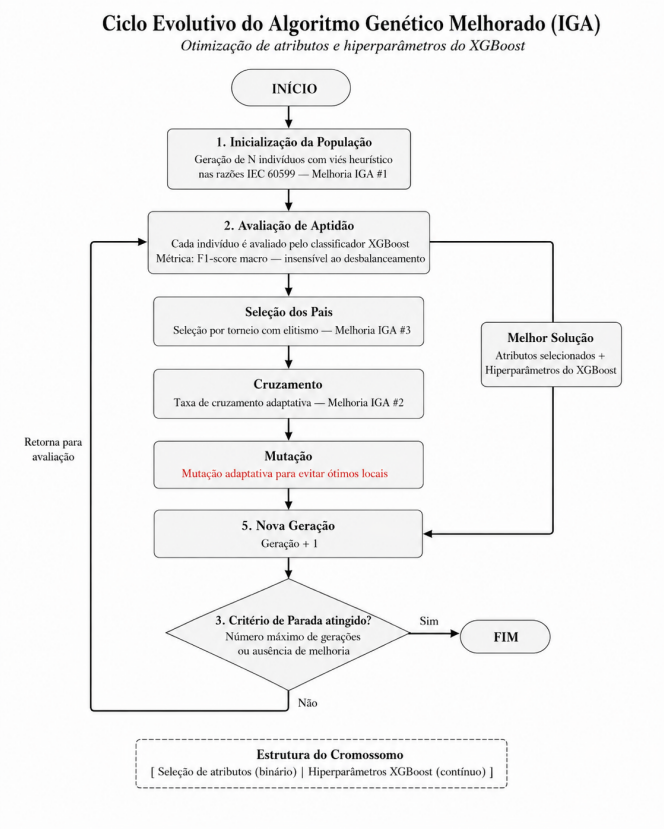


Figura 6 – Fluxo operacional do Algoritmo Genético Melhorado para busca conjunta.

Fonte: Adaptado de Wu et al. (2021).

A implementação do IGA estrutura cada indivíduo com representação cromossômica heterogênea bipartida, segregando uma máscara booleana de seleção

dimensional e genes contínuos reais representativos dos parâmetros contínuos do XGBoost. O processo reprodutivo associa o cruzamento binário simulado (*Simulated Binary Crossover*, SBX) nos parâmetros contínuos ao cruzamento uniforme na máscara discreta, associando mutações polinomiais e inversões probabilísticas de bits. O elitismo direto assegura a preservação incondicional dos indivíduos com melhor aptidão harmônica, enquanto mecanismos de penalização dimensional na função objetivo coíbem a seleção de variáveis colineares desprovidas de ganho informacional marginal.

2.4 INTERPRETABILIDADE EM APRENDIZADO DE MÁQUINA (XAI)

A transição de algoritmos de aprendizado de máquina para sistemas de apoio à decisão em ativos críticos de alta tensão requer a abertura das chamadas caixas-pretas analíticas. A disciplina de inteligência artificial explicável (*Explainable Artificial Intelligence*, XAI) fornece fundamentos matemáticos para quantificar a contribuição isolada de cada medição de DGA nas predições formuladas.

2.4.1 TEORIA DOS JOGOS COOPERATIVOS E VALORES DE SHAPLEY

A formulação matemática dos valores de Shapley origina-se na teoria dos jogos cooperativos com utilidade transferível (SHAPLEY, 1953). Define-se um jogo cooperativo pelo par (F, v), no qual $F = \{1, 2, \ldots, M\}$ representa o conjunto finito de jogadores (atributos explicativos) e $v : 2^F \to \mathbb{R}$ indica a função característica que associa um ganho real a cada subcoalizão possível $S \subseteq F$, assumindo-se convencionalmente $v(\emptyset) = 0$.

O valor de Shapley $\phi_i(v)$ atribui a cada jogador i uma parcela única e justa do retorno global gerado pela coalizão completa $v(F)$, ponderando a contribuição marginal gerada pelo jogador sobre todas as ordens possíveis de formação de subgrupos:

$$\phi_i(v) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} \left[v(S \cup \{i\}) - v(S) \right] \tag{2.14}$$

A formulação descrita na Equação (2.14) é a única partição de crédito que satisfaz simultaneamente quatro propriedades axiomáticas fundamentais (LUNDBERG; LEE, 2017): a eficiência assegura que a soma dos valores marginais distribuídos a todos os atributos reproduz a diferença entre o resultado da coalizão total e o valor esperado basal, expressa por $\sum_{i \in F} \phi_i(v) = v(F) - v(\emptyset)$; a simetria determina que se dois atributos distintos exercem contribuições marginais idênticas para qualquer coalizão intermediária, de modo que $v(S \cup \{i\}) = v(S \cup \{j\})$ para todo $S \subseteq F \setminus \{i, j\}$, então seus respectivos valores de Shapley são iguais, satisfazendo $\phi_i(v) = \phi_j(v)$; o

atributo nulo garante que se uma variável não altera o ganho informacional de nenhuma subcoalizão, satisfazendo $v(S \cup \{i\}) = v(S)$ para qualquer $S \subseteq F \setminus \{i\}$, seu valor de Shapley associado é nulo, de forma que $\phi_i(v) = 0$; e a aditividade local estabelece que para dois jogos independentes u e v combinados linearmente, a atribuição de crédito satisfaz $\phi_i(u + v) = \phi_i(u) + \phi_i(v)$.

2.4.2 O ALGORITMO TREESHAP E DECOMPOSIÇÃO DE CONTRIBUIÇÕES

O cálculo analítico exato da Equação (2.14) possui complexidade temporal exponencial $O(M2^M)$, tornando-se computacionalmente inviável para modelos com espaços vetoriais moderados ou extensos. Para transpor essa restrição em conjuntos de árvores de decisão, Lundberg et al. (2020) formularam o algoritmo TreeSHAP, que calcula os valores de Shapley exatos em complexidade polinomial $O(TLD^2)$, onde T representa o número de estimadores fracos, L denota a contagem máxima de folhas e D corresponde à profundidade máxima das árvores.

Em classificadores XGBoost multiclasse, o TreeSHAP opera avaliando a função de valor marginal no espaço linear das margens de decisão (*log-odds*) antes da aplicação da transformação softmax (`pred_contribs`). Para cada classe diagnóstica c, o escore contínuo $f_c(x)$ da instância x é decomposto exatamente como:

$$f_c(x) = \phi_{0,c} + \sum_{i=1}^{M} \phi_{i,c}(x) \tag{2.15}$$

Em que $\phi_{0,c} = \mathbb{E}[f_c(X)]$ denota o viés escalar basal, representativo do log-odds médio da classe c sobre a distribuição de treinamento, e $\phi_{i,c}(x)$ corresponde à contribuição aditiva local da variável i. Cumpre assinalar que o valor de Shapley $\phi_{i,c}(x)$ quantifica a magnitude com que a variável atua como força promotora ($\phi > 0$) ou inibidora ($\phi < 0$) daquela classe específica, não se confundindo com a fronteira de classificação terminal, a qual decorre da competição conjunta entre as margens projetadas via $\arg\max_c f_c(x)$.

Para isolar dependências mútuas entre espécies químicas colineares, o algoritmo estende-se para a decomposição em matrizes de interação de Lundberg (`pred_interactions`) baseada no índice de interação de Shapley (LUNDBERG et al., 2020):

$$\phi_{i,j}(x) = \sum_{S \subseteq F \setminus \{i,j\}} \frac{|S|!\,(|F| - |S| - 2)!}{2\,(|F| - 1)!} \left[v(S \cup \{i,j\}) - v(S \cup \{i\}) - v(S \cup \{j\}) + v(S) \right] \tag{2.16}$$

Para $i \neq j$, $\phi_{i,j}(x)$ quantifica a interação pura de segunda ordem entre os atributos i e j. A diagonal principal da matriz permite extrair o efeito principal univariado purificado $\phi_{i,i}(x)$:

$$\phi_{i,i}(x) = \phi_i(x) - \sum_{j \neq i} \phi_{i,j}(x) \tag{2.17}$$

Ao traçar o efeito principal $\phi_{i,i}(x)$ contra o valor físico real desnormalizado da grandeza em partes por milhão ou percentual relativo, identifica-se analiticamente o ponto exato de inflexão em que a variável cruza a nulidade ($\phi_{i,i} = 0$), permitindo correlacionar as decisões empíricas do ensemble de aprendizado de máquina com os limiares termodinâmicos postulados nas normas técnicas da IEC e no Triângulo de Duval.

2.5 TRABALHOS RELACIONADOS

O diagnóstico preditivo de falhas em transformadores por meio de DGA tem migrado de procedimentos heurísticos estáticos para abordagens amparadas em modelos matemáticos computacionais avançados. A Tabela 2 sintetiza os principais estudos representativos da literatura recente, confrontando suas abordagens, configurações experimentais, vantagens operacionais e limitações observadas.

A análise crítica dos estudos reportados revela que a literatura frequentemente aborda o diagnóstico sob premissas restritas ou isoladas. O modelo proposto por Wu et al. (2021) demonstra a relevância de integrar a seleção cromossômica de atributos aos hiperparâmetros de árvores de boosting, reportando acurácias superiores a 99% sobre conjuntos de dados da IEC 60599. Contudo, a pesquisa opera exclusivamente em regime estático pontual, abstendo-se de avaliar séries temporais contínuas e reportando métricas globais sem controle rigoroso de sobreajuste por vazamento ou ponderação de classes minoritárias.

Por outro lado, o trabalho de Wang, Littler e Liu (2023) concentra esforços na modelagem temporal através de redes LSTM para previsão de concentrações futuras, argumentando que a extrapolação dinâmica subsidia o diagnóstico precoce. Não obstante, o acoplamento entre a etapa de previsão e os classificadores terminais é tratado de maneira sequencial desarticulada, sem análise ablativa controlada para verificar se as concentrações simuladas agregam separabilidade informacional efetiva em relação aos gases já observados no presente. Adicionalmente, a base empregada pelos autores encontra-se sob sigilo industrial, impedindo a reprodutibilidade independente dos achados.

O trabalho de Al-Sakini et al. (2025) avalia algoritmos supervisionados clássicos

Tabela 2 – Comparação entre trabalhos relacionados e o escopo investigado neste estudo.

Trabalho	**Abordagem**	**Tipo**	**Vantagens**	**Limitações**
Wu et al. (2021)	IGA + XGBoost	Classificação	Otimização simultânea de atributos e hiperparâmetros com acurácia elevada	Diagnóstico puramente estático, ausência de avaliação em séries temporais reais e métricas globais sem detalhamento por classe
Wang et al. (2023)	LSTM + Classificadores	Previsão + Classificação	Modelagem da evolução temporal de gases e antecipação de falhas incipientes	Classificação desacoplada da etapa preditiva e uso de base proprietária restrita
Ali et al. (2023)	Métodos Tradicionais e Revisão de ML	Revisão	Levantamento abrangente de normas de DGA e métodos inteligentes	Ausência de validação experimental direta e sem modelo computacional proposto
Al-Sakini et al. (2025)	Aprendizado de Máquina Supervisionado	Classificação	Validação empírica sobre registros laboratoriais reais de transformadores	Abordagem exclusivamente estática e sensibilidade a sobreposição de classes
Tightiz et al. (2020)	ANFIS + Regras de Associação	Classificação	Integração de inferência neuro-fuzzy com regras de diagnóstico	Ajuste hiperparamétrico intensivo de regras e ausência de componente temporal
Zhu et al. (2023)	Transformers em Séries Temporais	Previsão	Atenção em dependências extensas em sistemas de potência	Custo computacional elevado e demanda volumosa de dados inacessível em DGA pública
Abordagem deste Trabalho	LSTM Empilhada + IGA-XGBoost + TreeSHAP	Híbrido em Dois Eixos	Investigação ablativa formal da hipótese temporal, redução dimensional parcimoniosa e validação físico-química via XAI	Necessidade de tratamento em eixos bifurcados devido à assimetria de bases industriais públicas

Fonte: Elaborado pelo autor.

frente a medições cromatográficas industriais, comprovando a superioridade de estruturas de ensemble sobre classificadores individuais em cenários com dados ruidosos, mas mantendo a restrição de análise exclusivamente estática. As revisões técnicas conduzidas por Ali et al. (2023) apontam que as principais lacunas da área residem na ausência de protocolos estatísticos que tratem o desbalanceamento real das classes, na escassez de modelos que combinem dinâmicas longitudinais com classificadores otimizados e na falta de mecanismos que interpretem as regras aprendidas pelos modelos sob a luz das normas de engenharia química e elétrica.

Por fim, o emprego de arquiteturas Transformer em séries temporais de engenharia de potência reportado por Zhu et al. (2023) confirma a capacidade dos mecanismos de autoatenção em dependências longas, porém esbarra na escassez de conjuntos públicos abertos de DGA com densidade temporal contínua suficiente para evitar o sobreajuste severo dessas estruturas hiperparametrizadas.

Essa conjuntura fundamenta o desenho metodológico investigado neste trabalho. Estrutura-se uma abordagem experimental dividida em dois eixos complementares, amparada na auditoria e deduplicação de bases reais, no teste formal de ablação pareada da hipótese preditiva temporal da LSTM sobre o XGBoost, na redução dimensional orientada por IGA e na validação físico-química das fronteiras estocásticas através da teoria axiomática dos valores de Shapley.

3 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos empregados no desenvolvimento, otimização e validação experimental do sistema de diagnóstico de falhas em transformadores de potência. Apresenta-se o desenho metodológico estruturado em dois eixos de investigação, fundamentando a divisão operacional a partir das características dos conjuntos de dados industriais disponíveis. Em seguida, detalham-se os procedimentos de auditoria e saneamento das bases de dados, os algoritmos de pré-processamento e engenharia de atributos, a modelagem preditiva temporal por redes neurais recorrentes, a formulação do algoritmo genético aprimorado para otimização do classificador e os protocolos de inferência estatística e interpretabilidade físico-química pós-hoc.

3.1 DESENHO METODOLÓGICO E ARQUITETURA EM DOIS EIXOS

A concepção experimental adotada neste estudo decorre de uma restrição objetiva verificada nos repositórios abertos de Análise de Gases Dissolvidos (DGA). Constata-se na literatura uma assimetria insolúvel entre registros temporais contínuos e bases estáticas com anotação abrangente de falhas. As bases temporais disponíveis para acesso público, a exemplo do monitoramento divulgado por Katser et al. (2022), fornecem leituras periódicas registradas em intervalos regulares, porém contemplam apenas quatro gases dissolvidos, sem o monitoramento do metano (CH_4) e do etano (C_2H_6), restringindo os rótulos de integridade operacional a quatro categorias. Em sentido oposto, as bases de classificação que cobrem o conjunto normativo completo de sete estados de operação da IEC 60599 contêm as medições dos cinco gases clássicos, contudo são estruturadas exclusivamente como registros pontuais (instantâneos) coletados no momento da amostragem, inviabilizando o rastreamento longitudinal da taxa de evolução gasosa.

Diante dessa incompatibilidade de variáveis, a pesquisa foi formalmente dividida em dois eixos metodológicos complementares, denominados Track A e Track B, cuja organização geral está esquematizada na Figura 7. O Track A investiga a dimensão temporal da degradação, empregando uma rede neural recorrente do tipo *Long Short-Term Memory* (LSTM) empilhada para modelar a dinâmica multivariada de quatro gases e produzir estimativas futuras de concentração, as quais alimentam um classificador estático XGBoost submetido a estudo formal de ablação da hipótese temporal sobre quatro classes de severidade. O Track B estrutura-se como um referencial comparativo de classificação multiclasse sobre sete categorias de integridade operacional, permi-

tindo confrontar o algoritmo XGBoost otimizado por um Algoritmo Genético Melhorado (IGA) contra os métodos normativos internacionais clássicos, contra referências da literatura recente e contra limites teóricos de informação, integrando ferramentas de explicabilidade agnóstica baseadas em valores de Shapley.

3.2 BASES DE DADOS E PROCEDIMENTOS DE AUDITORIA

A experimentação utiliza dois conjuntos de dados reais e independentes, submetidos a protocolos rigorosos de verificação de integridade e descarte justificado de fontes inconsistentes.

3.2.1 BASE DE SÉRIES TEMPORAIS INDUSTRIAIS (TRACK A)

O Track A adota o conjunto de dados de telemetria contínua divulgado por Katser et al. (2022), proveniente de transformadores de potência em operação contínua em instalações de geração nuclear vinculadas ao consórcio Skoltech e Rosatom. A base é constituída por 3.000 séries temporais multivariadas com amostragem regular a cada 12 horas, totalizando 420 passos temporais por série (210 dias de histórico contínuo). O conjunto oficial encontra-se particionado em 2.100 séries destinadas a treinamento e validação, reservando-se 900 séries exclusivamente para avaliação final de teste independente.

Registram-se nessa base as concentrações de quatro espécies gasosas, compreendendo hidrogênio (H_2), monóxido de carbono (CO), etileno (C_2H_4) e acetileno (C_2H_2). Cada série é categorizada por um rótulo terminal que define o estado do equipamento em quatro classes operacionais, distribuídas no teste oficial em 731 instâncias normais (Normal), 38 eventos de descarga parcial (PD), 49 casos de descarga de baixa energia (D1) e 82 ocorrências de sobreaquecimento térmico incipiente (T1). As grandezas reportadas apresentam magnitude reduzida, situando-se na escala de 10^{-3}, padrão consistente com dados de sensores de monitoramento online contínuo em regime de operação estável, exigindo tratamento analítico para garantia de estabilidade numérica.

3.2.2 BASE COMPILADA DE DIAGNÓSTICO ESTÁTICO (TRACK B)

O Track B utiliza uma compilação de dados estáticos de DGA obtidos a partir de transformadores de potência imersos em óleo mineral em serviço na rede elétrica chinesa. O repositório bruto reúne medições laboratoriais por cromatografia gasosa cobrindo as concentrações absolutas em partes por milhão (ppm) de cinco gases fundamentais, especificamente hidrogênio (H_2), metano (CH_4), etano (C_2H_6), etileno (C_2H_4) e acetileno (C_2H_2), acompanhados pelo laudo confirmado de integridade estrutural.

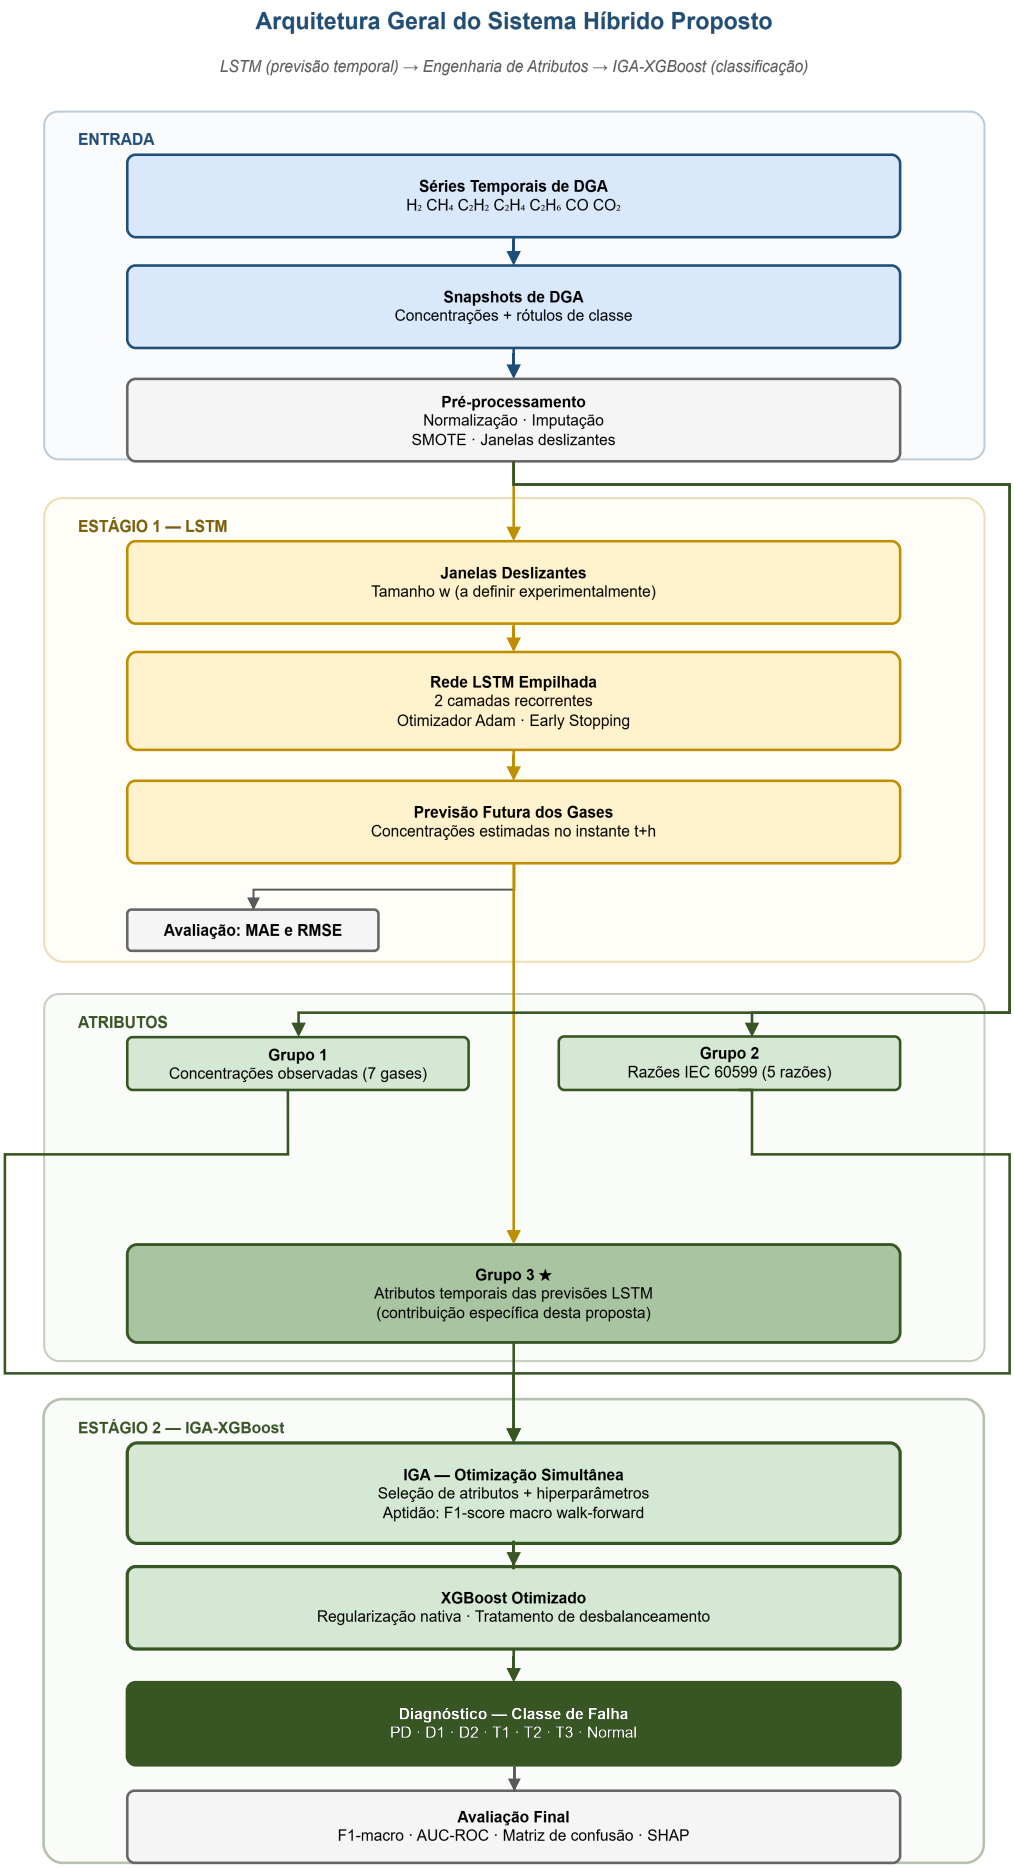


Figura 7 – Fluxograma metodológico do trabalho estruturado na bifurcação entre os eixos Track A e Track B.

Durante a etapa de auditoria dos dados brutos, constatou-se que o repositório original de 2.321 amostras apresentava 349 registros rigorosamente duplicados em todos os atributos e rótulos, representando uma taxa de redundância de 15,0%. A permanência dessas duplicatas violaria o princípio de independência amostral, gerando contaminação mútua entre dobras de validação cruzada e sobrestimando a acurácia dos modelos. Conduziu-se um processo compulsório de deduplicação, resultando em 1.972 instâncias únicas e não viesadas. Essa base consolidada foi dividida de maneira estratificada em conjunto de treinamento com 1.477 amostras (74,9%), conjunto de validação com 200 amostras (10,1%) e partição de teste independente com 295 amostras (15,0%). As amostras distribuem-se entre as sete classes normativas da IEC 60599, sendo 707 normais, 111 de descargas parciais (PD), 273 de descargas de baixa energia (D1), 221 de descargas de alta energia (D2), 107 de sobreaquecimentos inferiores a 300 °C (T1), 108 de falhas térmicas entre 300 °C e 700 °C (T2) e 435 de falhas térmicas severas superiores a 700 °C (T3).

3.2.3 CRITÉRIOS DE EXCLUSÃO E DESCARTE DE BASES DE DADOS

O refinamento metodológico exigiu o descarte justificado de fontes de dados consideradas em etapas preliminares da pesquisa. Descartou-se a base descrita em estudos de previsão temporal por Wang, Littler e Liu (2023) após constatação de sua indisponibilidade pública, tratando-se de acervo proprietário de concessionária sob termo de sigilo industrial. Do mesmo modo, registros citados com volume estrito de 430 amostras associados a trabalhos correlatos foram reavaliados em virtude de divergências na literatura quanto à proveniência física e critérios de anonimização.

Adicionalmente, rejeitou-se o uso de métodos de simulação estatística por Monte Carlo para geração de amostras sintéticas completas de DGA. A dispersão estocástica gerada artificialmente tende a mascarar a correlação físico-química intrínseca que governa a quebra molecular do óleo isolante, criando distribuições homogêneas inexistentes na realidade de campo. A opção por bases exclusivamente empíricas auditadas preserva a integridade das relações estequiométricas e fundamenta a credibilidade científica das inferências.

3.3 PRÉ-PROCESSAMENTO E ENGENHARIA DE ATRIBUTOS

Os registros de gases dissolvidos demandam transformações matemáticas destinadas a compatibilizar amplitudes e evidenciar padrões cinéticos de degradação.

3.3.1 TRATAMENTO DE ESCALA E NORMALIZAÇÃO

As concentrações gasosas em transformadores de potência exibem assimetria estatística acentuada, com a maioria dos equipamentos operando com concentrações residuais próximas a zero, enquanto falhas de arco elétrico ou sobreaquecimentos graves induzem picos de hidrogênio e etileno superiores a dezenas de milhares de ppm. Para atenuar a amplitude dessas caudas pesadas sem truncamento de informação, aplicou-se aos dados observados a transformação logarítmica com deslocamento unitário, expressa por $x_{\log} = \ln(x + 1)$, na qual o incremento unitário assegura a convergência da função para registros com concentração nula.

Subsequentemente, as grandezas transformadas foram mapeadas para o intervalo contínuo $[0, 1]$ por meio de reescalonamento linear Min-Max, definido por $(x_{\log} - x_{\min})/(x_{\max} - x_{\min})$. Para assegurar rigor metodológico e evitar qualquer forma de vazamento de informação entre partições, os extremos de escala $x_{\min}$ e $x_{\max}$ foram ajustados estritamente sobre as partições de treinamento, aplicando-se os escaladores previamente ajustados às amostras de validação e teste.

3.3.2 ESPAÇO DE ATRIBUTOS DO TRACK A

Para o Track A, estruturou-se um espaço vetorial candidato contendo 17 variáveis explicativas, distribuídas em três categorias funcionais. A primeira categoria compreende os quatro gases brutos observados instantaneamente ($H_{2,obs}$, CO_{obs}, $C_2H_{4,obs}$ e $C_2H_{2,obs}$). A segunda categoria reúne razões químicas adaptadas à disponibilidade da base, incluindo a razão clássica C_2H_2/C_2H_4, a razão adaptada H_2/C_2H_2, a soma total de hidrocarbonetos adaptada aos gases monitorados ($TH_{katser} = C_2H_4 + C_2H_2$) e as respectivas proporções parciais C_2H_2/TH_{katser} e C_2H_4/TH_{katser}. Cabe assinalar que a razão CO/C_2H_4, inicialmente cogitada em estudos preliminares, foi expurgada da modelagem após auditoria físico-química, uma vez que monóxido de carbono e etileno derivam de mecanismos de pirólise termicamente independentes, correspondendo respectivamente à isolação sólida celulósica e ao óleo mineral, sem relação de proporcionalidade estequiométrica em normas reconhecidas.

A terceira categoria engloba oito atributos prospectivos gerados pelo módulo recorrente LSTM, correspondendo às projeções de concentração de cada um dos quatro gases para os horizontes operacionais de uma semana ($h = 14$ passos) e duas semanas ($h = 28$ passos), designados por $H_{2,h14}$, CO_{h14}, $C_2H_{4,h14}$, $C_2H_{2,h14}$, $H_{2,h28}$, CO_{h28}, $C_2H_{4,h28}$ e $C_2H_{2,h28}$.

3.3.3 ESPAÇO DE ATRIBUTOS DO TRACK B

Para a classificação de sete classes do Track B, construiu-se um espaço amostral de 19 atributos candidatos fundamentados nas diretrizes da IEC 60599, no método de Doernenburg e na formulação empírica estendida de Wu et al. (2021). O vetor incorpora as cinco concentrações originais (H_2, CH_4, C_2H_6, C_2H_4 e C_2H_2), as quatro razões de diagnóstico normatizadas (CH_4/H_2, C_2H_2/C_2H_4, C_2H_4/C_2H_6 e C_2H_2/CH_4), e a família de coordenadas do Triângulo 1 de Duval baseada na soma dos três gases que definem o espaço triangular ($TH = CH_4 + C_2H_4 + C_2H_2$), gerando as proporções $\%CH_4/TH$, $\%C_2H_4/TH$ e $\%C_2H_2/TH$.

Adicionou-se ainda a família de atributos proposta por Wu et al. (2021), calculada sobre a soma total de hidrocarbonetos ($TH_1 = CH_4+C_2H_6+C_2H_4+C_2H_2$), contemplando a razão C_2H_2/C_2H_6 e os quatro percentuais relativos calculados sobre TH_1. A todos os denominadores de razões incorporou-se um valor infinitesimal $\epsilon = 10^{-5}$ para evitar singularidades numéricas de divisão por zero.

3.3.4 TRATAMENTO DO DESBALANCEAMENTO DE CLASSES

O desbalanceamento numérico entre falhas raras e o regime de operação normal exige compensação algorítmica para evitar que a função de perda favoreça a classe majoritária. No presente trabalho, adotou-se a estratégia de ponderação analítica no treinamento multiclasse mediante o parâmetro de custo diferencial por instância (`sample_weight`) no algoritmo XGBoost. O peso associado a cada amostra pertencente à classe c foi definido pelo inverso de sua frequência relativa na partição de treino, expresso por $w_c = N/(C \cdot N_c)$, no qual N denota o número total de amostras de treinamento, C representa o total de categorias e N_c indica o contingente da classe em questão.

Essa abordagem preserva as instâncias reais observadas sem distorcer as relações geométricas entre gases brutos e razões derivadas. A aplicação de técnicas de superamostragem sintética baseadas em interpolação linear clássica foi preterida em virtude de sua inadequação teórica para dados que combinam grandezas aditivas e não lineares, haja vista que médias lineares de razões não coincidem com as razões das médias lineares de concentração.

3.4 MÓDULO DE PREVISÃO TEMPORAL

O primeiro estágio de processamento no Track A consiste em uma rede neural recorrente LSTM empilhada, projetada para aprender a evolução temporal dos gases e extrapolar suas trajetórias para horizontes futuros. As séries temporais são estruturadas por meio da técnica de janela deslizante multivariada. Considerando o vetor observaci-

onal no passo discreto t, a matriz de entrada do modelo é formada pelo histórico de $w = 50$ passos regulares contíguos (equivalente a 25 dias de operação), configurando uma matriz de dimensão 50×4. O alvo do aprendizado supervisionado consiste no vetor com as quatro concentrações no passo $t + h$, onde h denota o horizonte preditivo recursivo.

A topologia da rede compreende duas camadas recorrentes LSTM empilhadas em cascata com 64 unidades ocultas cada, dotadas de funções de ativação por tangente hiperbólica e portas recorrentes com função sigmoide. Para reduzir o risco de sobreajuste durante o treinamento, intercalou-se entre as camadas uma regularização por *dropout* com probabilidade de 0,2. A camada final consiste em uma estrutura densa linear com quatro unidades correspondentes às estimativas pontuais dos quatro gases.

O treinamento foi configurado com o otimizador Adam sob taxa de aprendizado inicial de 10^{-3}, minimizando o erro quadrático médio (MSE) com lotes de 1.024 amostras. O ajuste hiperparamétrico incorporou mecanismo de redução dinâmica da taxa de aprendizado em patamares (`ReduceLROnPlateau`), aplicando decaimento de 0,5 após sete épocas sucessivas sem decréscimo da perda de validação, associado a critério de parada antecipada com paciência fixada em 15 épocas. Para avaliar a extensão temporal da capacidade de previsão do modelo, foram calculados recursivamente 11 horizontes preditivos distintos, abrangendo $h \in \{1, 2, 4, 7, 14, 28, 42, 56, 70, 84, 98\}$ passos (de 12 horas a 7 semanas de extrapolação contínua), selecionando-se os horizontes de $h = 14$ e $h = 28$ passos para alimentação do classificador.

3.5 ALGORITMO GENÉTICO MELHORADO E OTIMIZAÇÃO DO XGBOOST

Para automatizar a busca por arquiteturas parcimoniosas no segundo estágio da arquitetura, implementou-se uma versão personalizada do Algoritmo Genético Melhorado (IGA) com suporte da biblioteca DEAP (*Distributed Evolutionary Algorithms in Python*). O algoritmo executa a seleção de subconjuntos informativos de variáveis e sintoniza simultaneamente os hiperparâmetros contínuos do modelo XGBoost.

3.5.1 REPRESENTAÇÃO CROMOSSÔMICA E OPERADORES GENÉTICOS

Cada indivíduo da população evolutiva é codificado por uma estrutura cromossômica heterogênea bipartida. A primeira porção é definida por uma máscara binária de dimensão p, na qual o bit unitário indica a inclusão da respectiva variável diagnóstica e o bit nulo indica sua exclusão da matriz de treinamento do XGBoost. A segunda porção é composta por nove genes contínuos reais normalizados no intervalo $[0, 1]$, mapeados

linearmente para as escalas de busca dos hiperparâmetros estruturais do ensemble de árvores. Os intervalos definidos cobrem a taxa de aprendizado (`learning_rate` entre 0,01 e 0,30), a profundidade máxima das árvores (`max_depth` de 3 a 10), o número de estimadores (`n_estimators` de 50 a 500), as frações de amostragem (`subsample` e `colsample_bytree` entre 0,50 e 1,00), o ganho mínimo para divisão de nós (`gamma` de 0,0 a 1,0), o peso mínimo foliar (`min_child_weight` de 1 a 10) e os termos de regularização L_1 e L_2 (`reg_alpha` e `reg_lambda` entre 0,0 e 10,0).

O processo reprodutivo adota operadores probabilísticos combinados. Para a porção binária de seleção de atributos, aplica-se cruzamento uniforme com recombinação independente de variáveis. Para a porção contínua de hiperparâmetros, emprega-se o operador de cruzamento binário simulado (*Simulated Binary Crossover*, SBX) com índice de distribuição $\eta_c = 20$. As mutações atuam por inversão pontual de bits na máscara binária e por perturbação polinomial gaussiana nos genes contínuos. A seleção dos progenitores opera por torneio com tamanho $k = 3$, preservando-se estritamente os dois melhores indivíduos de cada geração por elitismo direto.

3.5.2 FUNÇÃO DE APTIDÃO E CRITÉRIOS DE PARADA

A avaliação de aptidão (*fitness*) orienta-se pela maximização do desempenho preditivo balanceado. Considerando o desbalanceamento das categorias operacionais, adota-se como métrica orientadora o F_1-macro médio obtido por validação cruzada estratificada em 5 dobras ($K = 5$) computada estritamente sobre as amostras de treinamento. Adicionalmente, aplica-se uma penalização marginal de parcimônia dimensional para privilegiar representações compactas que descartem variáveis colineares, conforme estabelecido na Equação (3.1).

$$f(\mathbf{c}) = F1^{CV}_{\text{macro}} - \lambda \cdot \frac{k}{p} \tag{3.1}$$

Em que $\mathbf{c}$ representa o cromossomo sob avaliação, $F1^{CV}_{\text{macro}}$ indica o macro-escore harmônico médio nas dobras internas de validação, k corresponde à quantidade de atributos ativos na máscara, p representa a quantidade total de atributos candidatos disponíveis e $\lambda = 0,005$ configura o coeficiente de parcimônia. A evolução foi configurada com população de 50 indivíduos por até 100 gerações, incorporando critério de parada antecipada com tolerância fixada em 20 gerações consecutivas sem melhoria na melhor aptidão global.

3.6 PROTOCOLO EXPERIMENTAL E RIGOR ESTATÍSTICO

Para blindar as conclusões contra aleatoriedade amostral e evitar conclusões espúrias, desenhou-se um protocolo experimental estruturado em testes de ablação pareados e avaliações repetidas de teto informacional.

3.6.1 DESENHO EXPERIMENTAL E ABLAÇÃO NO TRACK A

O desenho experimental do Track A foi estruturado para isolar matematicamente o efeito individual exercido pelas previsões temporais da rede LSTM sobre a capacidade discriminativa estática. Para tanto, definiram-se cinco configurações experimentais controladas. A configuração C2 estabelece o classificador XGBoost padrão operando sobre o conjunto completo de 17 atributos (quatro gases observados, cinco razões adaptadas e oito previsões da LSTM para $h = 14$ e $h = 28$). A configuração C1 aplica o IGA sobre o mesmo espaço de 17 atributos candidatos, selecionando recursivamente atributos e hiperparâmetros. A configuração C5a adota os hiperparâmetros padrão do XGBoost restritos aos 9 atributos estáticos observados, sem qualquer fornecimento de variáveis da LSTM. A configuração C5b avalia o IGA restrito aos 9 atributos estáticos observados, executando otimização evolutiva autônoma sem acesso à dimensão temporal. Por fim, a configuração C6 avalia o XGBoost padrão treinado unicamente com as 8 variáveis preditivas geradas pela LSTM.

3.6.2 DESENHO EXPERIMENTAL NO TRACK B

No Track B, o protocolo investiga o comportamento dos modelos frente ao diagnóstico multiclasse de sete estados operacionais. A configuração C3 corresponde ao modelo proposto IGA-XGBoost avaliado sobre os 19 atributos candidatos. A configuração C4 utiliza o XGBoost com parametrização padrão sobre os mesmos 19 atributos. A configuração T3 replica fielmente o modelo de referência de Wu et al. (2021), combinando 18 variáveis estendidas e busca por IGA. As configurações T2 e T1 avaliam as regras normativas tradicionais do Triângulo 1 de Duval e do Método das Razões da IEC 60599, respectivamente, implementadas em conformidade analítica com as tabelas das normas vigentes.

3.6.3 PROCEDIMENTOS DE BOOTSTRAP PAREADO E VALIDAÇÃO CRUZADA REPETIDA

A quantificação de significância estatística prescindiu de premissas paramétricas de normalidade assintótica. Para a avaliação no conjunto de teste, aplicou-se o método de reamostragem por *bootstrap* pareado com 5.000 iterações independentes com

reposição sobre as amostras de teste. Em cada iteração b, computaram-se o índice F_1-macro de cada modelo e a diferença pareada exata $\Delta F_1 = F_1(A) - F_1(B)$, construindo-se a distribuição empírica das diferenças. Os intervalos de confiança empíricos com nível de 95% foram determinados pelos percentis 2,5% e 97,5% dessa distribuição. A hipótese nula de equivalência diagnóstica é rejeitada somente quando o intervalo de confiança exclui a linha de nulidade ($\Delta F_1 = 0$) e o valor p aproximado pelo teste bicaudal satisfaz $p < 0,05$.

Complementarmente, com o intuito de investigar a estabilidade e a existência de teto informacional na base do Track B, os modelos C3, C4, T3 e a linha de base sobre os gases primários brutos foram submetidos a validação cruzada estratificada repetida em cinco repetições com cinco dobras (*Repeated Stratified K-Fold* 5×5, totalizando 25 dobras de treino e teste), computando-se médias e desvios consolidados para verificar a sobreposição dos intervalos de confiança paramétricos.

3.7 PROTOCOLO DE INTERPRETABILIDADE E VALIDAÇÃO FÍSICO-QUÍMICA

Para validar a conformidade dos padrões aprendidos pelos ensembles de árvores com os princípios fundamentais da degradação termodinâmica de óleos isolantes, estabeleceu-se um arcabouço de inteligência artificial explicável baseado na formulação de TreeSHAP aditivo (LUNDBERG et al., 2020). Os valores de Shapley foram computados diretamente pelo algoritmo nativo do XGBoost (`pred_contribs`), que decomprime as contribuições marginais de cada variável sobre o espaço aditivo contínuo de log-odds de cada classe, satisfazendo localmente a propriedade axiomática de eficiência pela qual a soma das importâncias individuais acrescida do viés basal de classe reproduz a margem contínua de decisão da árvore.

O protocolo de interpretabilidade contempla cinco procedimentos encadeados. O primeiro avalia a estabilidade estocástica do ordenamento de importância mediante o coeficiente de correlação de postos de Spearman (ρ) calculado entre os vetores médios de importância absoluta extraídos a partir de modelos ajustados sob cinco sementes aleatórias distintas, considerando valores de $\rho > 0,80$ indicativos de relevância robusta. O segundo procedimento agrupa a contribuição dos atributos em quatro famílias químicas funcionais (derivados de acetileno, etileno, metano e gases brutos), permitindo analisar a alocação de crédito sem distorção induzida por colinearidade entre variáveis aparentadas.

O terceiro procedimento emprega a matriz de interações de Lundberg (`pred_interactions`) para isolar o efeito principal univariado ($\phi_{i,i}$), descartando os termos de interação mútua de segunda ordem. Essas curvas de contribuição marginal foram desnormalizadas para

a escala física original das concentrações e razões, permitindo identificar os pontos de transição em que o impacto marginal passa de inibidor para promotor de determinada falha ($\phi_{i,i} = 0$) e confrontá-los com as linhas de corte analíticas das normas de Duval e IEC 60599. O quarto procedimento projeta espacialmente os erros de classificação sobre as coordenadas triangulares do Triângulo 1 de Duval, permitindo verificar a concentração espacial dos equívocos diagnósticos nas fronteiras poligonais. Por fim, o quinto procedimento examina a migração estocástica de crédito de importância através de análises de decomposição em instâncias onde variáveis observadas e projetadas pela LSTM competem pela partição do ganho informacional das árvores.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados experimentais obtidos a partir dos dois eixos de investigação estabelecidos no trabalho. Inicialmente, avalia-se o comportamento do módulo de previsão temporal baseado em redes neurais recorrentes, examinando a precisão das estimativas pontuais e a respectiva degradação com o avanço do horizonte preditivo. Em seguida, analisam-se os experimentos do Track A, conduzidos sobre séries temporais com quatro classes operacionais, com foco na ablação pareada da hipótese de integração temporal e na quantificação do papel exercido pela otimização evolutiva. Na sequência, abordam-se os resultados do Track B, direcionados ao diagnóstico multiclasse de sete estados de operação sobre base estática, confrontando os classificadores otimizados com os limites informacionais intrínsecos aos gases e com os métodos tradicionais de diagnóstico. Por fim, detalha-se a auditoria de concordância normativa e aprofunda-se a interpretabilidade físico-química dos modelos por meio de valores de Shapley aplicados a árvores de decisão.

4.1 DESEMPENHO DO MÓDULO DE PREVISÃO TEMPORAL

O primeiro estágio da arquitetura proposta compreende uma rede neural do tipo *Long Short-Term Memory* (LSTM) empilhada em duas camadas recorrentes com 64 unidades cada, associada a mecanismo de regularização por *dropout* com taxa de 0,2 e otimizador Adam. O treinamento foi executado com taxa de aprendizado inicial de 0,001, critério de perda baseado no erro quadrático médio e mecanismo de parada antecipada com tolerância de 15 épocas. Para mitigar o risco de vazamento de dados, o ajuste das escalas de normalização foi realizado exclusivamente sobre o conjunto de treinamento, sendo a transformação linear subsequente aplicada aos conjuntos de validação e teste.

A avaliação do modelo foi conduzida sobre a partição oficial de teste da base disponibilizada por Katser et al. (2022), constituída por 900 séries temporais industriais independentes, com 420 observações registradas em intervalos regulares de 12 horas. Sob janela deslizante de 50 passos históricos ($w = 50$, equivalente a 25 dias de operação), o particionamento gerou 333.000 janelas de teste para a estimativa de um passo à frente ($h = 1$, correspondente a 12 horas). A Tabela 3 consolida as métricas de erro absoluto médio (MAE), raiz do erro quadrático médio (RMSE) e coeficiente de determinação (R^2), reportadas a partir da média e do desvio padrão obtidos em cinco sementes aleatórias distintas.

Os resultados demonstram que o erro de regressão agregado manteve-se na

Tabela 3 – Desempenho do módulo LSTM no conjunto de teste oficial para previsão de um passo ($h = 1$, escala normalizada).

Gás Analisado	**MAE ($\times 10^{-5}$)**	**RMSE ($\times 10^{-4}$)**	R^2
Hidrogênio (H_2)	$1,44 \pm 0,13$	$0,18 \pm 0,02$	$0,9995 \pm 0,0001$
Monóxido de Carbono (CO)	$16,15 \pm 2,72$	$2,06 \pm 0,31$	$0,9997 \pm 0,0001$
Etileno (C_2H_4)	$4,58 \pm 0,59$	$0,58 \pm 0,07$	$0,9996 \pm 0,0001$
Acetileno (C_2H_2)	$0,19 \pm 0,01$	$0,02 \pm 0,01$	$0,9996 \pm 0,0001$
Média Agregada	$5,59 \pm 0,74$	$1,07 \pm 0,15$	$0,9996 \pm 0,0001$

Fonte: Elaborado pelo autor.

ordem de 10^{-5} para o MAE e 10^{-4} para o RMSE na escala normalizada dos dados. A proximidade entre os valores de MAE e RMSE indica distribuição homogênea dos resíduos, sem a ocorrência de erros esparsos de magnitude elevada. O monóxido de carbono apresentou a maior dispersão absoluta de resíduos em virtude da amplitude dinâmica naturalmente superior dessa espécie química no conjunto de dados, ao passo que o acetileno exibiu os menores valores absolutos de erro em função de sua reduzida concentração basal nas séries em regime operacional estável. Em todos os gases, o coeficiente de determinação superou 0,999, evidenciando que a arquitetura assimilou a trajetória de curto prazo dos sinais temporais.

Para investigar a estabilidade preditiva ao longo de períodos operacionais estendidos, avaliou-se a propagação recursiva das estimativas em 11 horizontes preditivos pré-definidos, variando de 12 horas ($h = 1$) até 7 semanas ($h = 98$, equivalente a 1.176 horas de operação contínua). Cada modelo foi retreinado de maneira independente por semente e horizonte, calculando-se o coeficiente de determinação e o erro percentual médio relativo (MAE%). A Tabela 4 resume a evolução das métricas ao longo dos principais intervalos de tempo, e a Figura 8 ilustra a trajetória comparativa de degradação do coeficiente de determinação frente ao limiar mínimo de confiabilidade de $R^2 \geq 0,80$.

A análise da evolução multi-horizonte revela decaimento suave e monotônico da precisão preditiva, padrão esperado para processos estocásticos modelados por realimentação recursiva. Até o horizonte de duas semanas ($h = 28$), o modelo mantém $R^2 \geq 0,9963$ com erro percentual médio contido em 2,33%, configurando precisão adequada para suporte à decisão operacional. Mesmo no horizonte de sete semanas ($h = 98$), o índice médio de 0,8846 permaneceu satisfatório em relação ao limite estipulado, indicando que a dinâmica geral de tendência não sofreu divergência numérica severa. Com base nesses resultados, definiram-se os horizontes de uma semana ($h = 14$) e duas semanas ($h = 28$) como fornecedores das características preditivas a serem injetadas no estágio subsequente de classificação.

Tabela 4 – Degradação do desempenho preditivo da LSTM em função do horizonte temporal.

Passos (h)	**Intervalo Temporal**	**R^2 Médio**	**MAE% Médio**	**Condição ($R^2 \geq 0,80$)**
1	12 horas (0,07 semana)	0,9996	0,90%	Conforme
2	24 horas (0,14 semana)	0,9996	1,00%	Conforme
4	48 horas (0,29 semana)	0,9995	1,03%	Conforme
7	84 horas (0,50 semana)	0,9993	1,22%	Conforme
14	168 horas (1,00 semana)	0,9987	1,74%	Conforme
28	336 horas (2,00 semanas)	0,9963	2,33%	Conforme
42	504 horas (3,00 semanas)	0,9837	5,68%	Conforme
56	672 horas (4,00 semanas)	0,9691	7,81%	Conforme
70	840 horas (5,00 semanas)	0,9485	10,02%	Conforme
84	1.008 horas (6,00 semanas)	0,9207	12,41%	Conforme
98	1.176 horas (7,00 semanas)	0,8846	14,89%	Conforme

Fonte: Elaborado pelo autor.

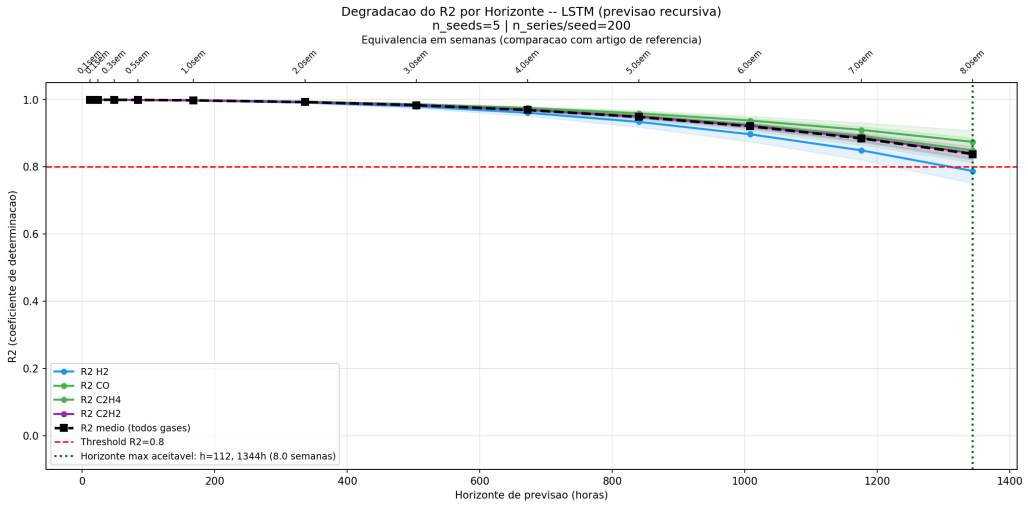


Figura 8 – Degradação do coeficiente de determinação (R^2) da LSTM em múltiplos horizontes temporais no conjunto de teste oficial.

Fonte: Elaborado pelo autor.

4.2 RESULTADOS DO TRACK A: DESEMPENHO E ABLAÇÃO DA HIPÓTESE TEMPORAL

O Track A investiga a capacidade de diagnóstico em quatro classes operacionais (Normal, Descarga Parcial – PD, Descarga de Baixa Energia – D1 e Falha Térmica de Baixa Temperatura – T1) a partir do vetor de atributos da base de séries temporais de Katser et al. (2022). O conjunto de teste contém 900 amostras rotuladas, distribuídas de forma desbalanceada entre 731 amostras normais, 38 amostras de PD, 49 de D1 e 82 de T1. A hipótese central subjacente a esse desenho experimental estabelecia que o fornecimento de concentrações futuras estimadas pela rede LSTM enriqueceria o espaço de decisão do classificador estático XGBoost, elevando a acurácia diagnóstica do sistema.

Para submeter essa hipótese a teste formal de falseabilidade, estruturou-se um protocolo experimental de ablação pareada composto por cinco configurações principais, avaliadas por meio de procedimento de *bootstrap* pareado com 5.000 iterações sobre o conjunto de teste. A configuração C2 adota os hiperparâmetros padrão do XGBoost sobre a totalidade de 17 atributos disponíveis, compreendendo quatro gases observados, cinco razões químicas adaptadas e oito previsões derivadas da LSTM para $h = 14$ e $h = 28$. A configuração C1 aplica o Algoritmo Genético Melhorado (IGA) para executar simultaneamente a seleção de atributos e a otimização de nove hiperparâmetros contínuos do XGBoost sobre o mesmo espaço de 17 variáveis candidatas. As configurações C5a e C5b representam os cenários ablativos sem qualquer projeção temporal (composto unicamente pelos 9 atributos estáticos observados), sob parametrização padrão e otimizada por IGA, respectivamente. Por fim, a configuração C6 avalia o classificador alimentado exclusivamente pelas 8 variáveis preditivas da LSTM. A Tabela 5 consolida os índices de F_1-macro obtidos nas configurações avaliadas.

Tabela 5 – Desempenho comparativo e estudo de ablação da hipótese temporal no Track A (900 amostras de teste, 5 sementes).

Configuração Avaliada	**Atributos (p)**	**F_1-macro Teste**	**Desvio (σ)**	**IC 95% Bootstrap**
C2: Padrão com LSTM	17	0,8911	0,0034	$[0,8574; 0,9229]$
C1: IGA com LSTM	8	0,8909	0,0011	$[0,8549; 0,9230]$
C6: Padrão apenas LSTM	8	0,8888	0,0011	$[0,8547; 0,9212]$
C5a: Padrão sem LSTM	9	0,8855	0,0029	$[0,8507; 0,9177]$
C5b: IGA sem LSTM	8	0,8796	0,0051	$[0,8469; 0,9110]$
C1 sem LSTM (pós-hoc)	4	0,8280	0,0030	$[0,7876; 0,8656]$

Fonte: Elaborado pelo autor.

A comparação entre as configurações C2 e C5a isola o efeito estrito provocado

pela adição dos atributos preditivos da LSTM sobre o classificador com hiperparâmetros fixos. Conforme apresentado na Tabela 6, a diferença pontual observada entre os modelos situou-se em $\Delta F_1 = +0,0056$ $(+0,56\%)$, acompanhada por intervalo de confiança de 95% compreendido entre $-0,0037$ e $+0,0150$, com valor de $p \approx 0,2384$. Uma vez que o intervalo de confiança calculado por *bootstrap* cruza a linha de nulidade e a probabilidade de significância excede amplamente o limiar usual de 0,05, rejeita-se a hipótese de ganho estatístico decorrente da incorporação das estimativas temporais da LSTM para o diagnóstico pontual de falhas.

Tabela 6 – Comparações pareadas via bootstrap (5.000 iterações) no Track A.

Contraste Pareado	ΔF_1 **Pontual**	**IC 95% Bootstrap**	**Valor** p	**Significância**
C2 vs. C5a (efeito LSTM no Padrão)	$+0,0056$	$[-0,0037; +0,0150]$	0,2384	Não significativa
C2 vs. C6 (todos vs. apenas LSTM)	$+0,0023$	$[-0,0081; +0,0131]$	0,6604	Não significativa
C1 vs. C2 (IGA vs. Padrão completo)	$-0,0003$	$[-0,0137; +0,0124]$	0,9956	Não significativa
C1 vs. C5b (efeito LSTM sob IGA)	$+0,0112$	$[-0,0103; +0,0339]$	0,3308	Não significativa
C5b vs. C5a (IGA vs. Padrão sem LSTM)	$-0,0059$	$[-0,0247; +0,0118]$	0,5412	Não significativa

Fonte: Elaborado pelo autor.

A fundamentação física e estatística para a ausência de ganho incremental reside na acentuada colinearidade estabelecida entre as variáveis observadas no instante presente e as projeções geradas pela rede neural. No conjunto de treinamento, o coeficiente de correlação linear de Pearson (r) entre a concentração observada e a projeção temporal futura alcançou 0,9993 e 0,9974 para o H_2 nos horizontes de 14 e 28 passos, 0,9997 e 0,9990 para o CO, 0,9994 e 0,9981 para o C_2H_4, e 0,9995 e 0,9985 para o C_2H_2. Em todas as séries analisadas, o coeficiente determinístico linear r^2 superou 0,994. Esse resultado comprova que, em regime de operação contínua com taxas de degradação gradativas, as concentrações instantâneas já transportam quase a totalidade da informação necessária para a separação diagnóstica, atuando as previsões da LSTM como réplicas estocasticamente redundantes do vetor observacional.

Por outro lado, os contrastes envolvendo o Algoritmo Genético evidenciam a contribuição do método evolutivo sob o princípio da parcimônia. Ao confrontar C1 e C2, constata-se diferença de $\Delta F_1 = -0,0003$ com valor de $p \approx 0,9956$, demonstrando desempenho rigorosamente equivalente. Contudo, enquanto o modelo C2 requisita 17 atributos para operar, o algoritmo genético selecionou um subconjunto compacto de 8 variáveis (composto por CO_{obs}, H_2/C_2H_2, C_2H_2/TH_{katser}, C_2H_4/TH_{katser}, $H_{2,h14}$, $H_{2,h28}$, $C_2H_{4,h28}$ e $C_2H_{2,h28}$). Conforme ilustrado na Figura 9, o método atinge redução dimensional de 53% sem qualquer degradação no índice de macro-precisão, o que simplifica o pipeline computacional e reduz o custo operacional associado à manutenção de sensores e canais de telemetria em ambiente industrial.

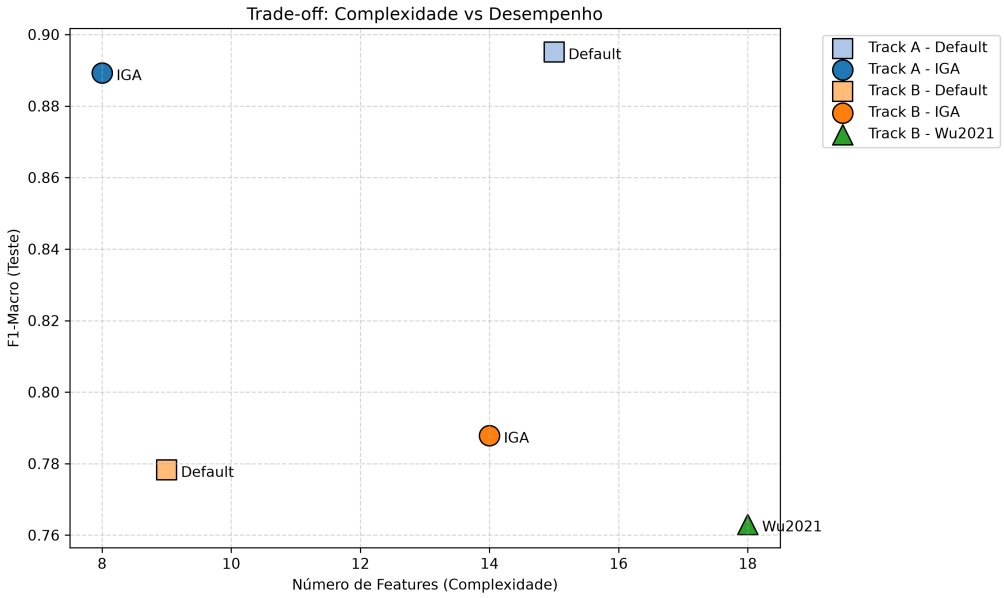


Figura 9 – Compromisso entre complexidade dimensional e desempenho diagnóstico no Track A.

Fonte: Elaborado pelo autor.

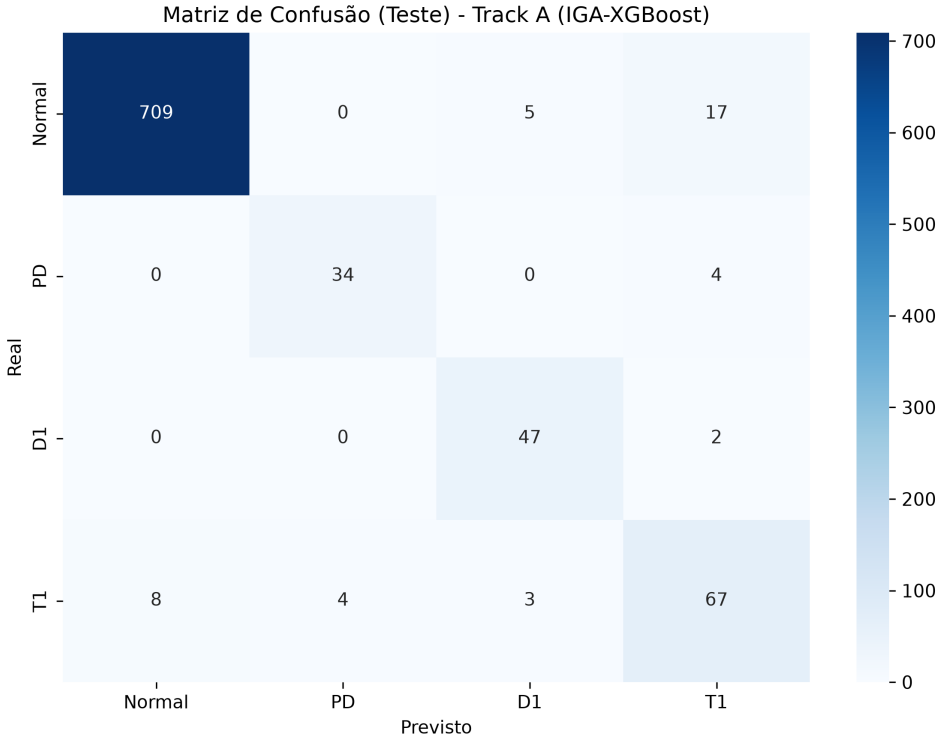


Figura 10 – Matriz de confusão das predições diagnósticas para o Track A no conjunto de teste oficial.

Fonte: Elaborado pelo autor.

A análise da matriz de confusão apresentada na Figura 10 atesta eficácia elevada nas classes críticas, alcançando $F_1 = 0,973$ na condição Normal, $F_1 = 0,886$ em Descargas Parciais (PD) e recall de 100% em Descargas de Baixa Energia (D1, com $F_1 = 0,925$). O principal gargalo do classificador concentra-se na ambiguidade entre as classes Normal e T1, responsável por 17 amostras normais classificadas como sobreaquecimento e 8 instâncias de T1 atribuídas à condição normal. Essa sobreposição é coerente com a física de degradação em isolamentos a óleo, visto que sobreaquecimentos térmicos incipientes em regime inferior a 300 °C produzem taxas reduzidas de evolução gasosa, gerando concentrações residuais que se confundem com o envelhecimento natural do óleo mineral.

4.3 RESULTADOS DO TRACK B: DIAGNÓSTICO MULTICLASSE E O TETO INFORMACIONAL

O Track B aborda a classificação multiclasse de sete estados de integridade operacional (Normal, PD, D1, D2, T1, T2 e T3) a partir de base compilada de registros de DGA estáticos com 1.972 amostras únicas, obtidas após procedimento de auditoria que expurgou 349 duplicatas redundantes presentes no dataset original. O conjunto de teste contém 295 amostras distribuídas entre 106 registros Normais, 17 de PD, 41 de D1, 33 de D2, 16 de T1, 16 de T2 e 66 de T3. Nesse cenário, o objetivo consistiu em avaliar o comportamento de classificadores baseados em árvores de decisão em comparação direta com os métodos normativos internacionais e com o modelo de referência de Wu et al. (2021).

Avaliaram-se cinco abordagens distintas, compreendendo o classificador IGA-XGBoost do presente trabalho (C3), o modelo XGBoost padrão sobre o espaço completo de 19 atributos derivados (C4), a replicação exata do modelo de Wu et al. (2021) constituído por 18 atributos candidatos (T3), a norma do Triângulo 1 de Duval (T2) e o método das razões da norma IEC 60599 (T1). A Tabela 7 apresenta as métricas computadas no conjunto de teste e o índice de validação cruzada estratificada repetida em cinco repetições com cinco dobras (Repeated Stratified 5×5 CV, totalizando 25 dobras de avaliação).

A comparação pareada por *bootstrap* no conjunto de teste revelou que a diferença entre o modelo C3 e a replicação de Wu et al. (T3) atingiu $\Delta F_1 = +0,0141$ com intervalo de confiança $[-0,0054; +0,0368]$ e valor de $p \approx 0,1824$. De forma análoga, o contraste entre C3 e a configuração padrão C4 resultou em $\Delta F_1 = +0,0127$ com intervalo $[-0,0211; +0,0490]$ e $p \approx 0,4680$. Em ambos os casos, a nulidade encontra-se contida no intervalo de confiança empírico, revelando que os três modelos baseados em gradiente de árvores apresentam equivalência estatística. Essa constatação é

Tabela 7 – Desempenho diagnóstico multiclasse no Track B sobre sete categorias operacionais.

Modelo / Método	**Atributos**	F_1**-macro Teste**	**IC 95% Teste**	F_1**-macro CV** 5×5	**IC 95% CV**
C3: IGA-XGBoost	16	0,7970	$[0,7392; 0,8515]$	0,7516	$[0,7406; 0,7626]$
C4: XGBoost Padrão	19	0,7843	$[0,7259; 0,8376]$	0,7616	$[0,7527; 0,7705]$
T3: Wu et al. (2021)	14	0,7829	$[0,7261; 0,8376]$	0,7654	$[0,7555; 0,7752]$
T2: Triângulo de Duval	3 gases	0,3634	$[0,3101; 0,4135]$	–	–
T1: Razões IEC 60599	5 gases	0,2569	$[0,1944; 0,3143]$	–	–
Linha de base (5 gases)	5	0,7250	$[0,6587; 0,7851]$	0,7082	$[0,6965; 0,7200]$

Fonte: Elaborado pelo autor.

corroborada pelos resultados de validação cruzada repetida em 25 dobras, nos quais os intervalos de confiança de 95% de C3 ($0,7516 \pm 0,0281$), C4 ($0,7616 \pm 0,0226$) e T3 ($0,7654 \pm 0,0252$) exibem sobreposição completa.

Sob a perspectiva da teoria da informação, essa convergência demonstra a presença de um teto informacional nos dados de DGA estáticos. Uma vez que a totalidade das variáveis derivadas (incluindo percentuais de Duval, razões de hidrocarbonetos e somas totais) constitui transformações matemáticas determinísticas das cinco concentrações primárias observadas (H_2, CH_4, C_2H_6, C_2H_4 e C_2H_2), a engenharia de atributos não é capaz de introduzir informação mútua nova ao problema. Ela facilita a identificação de cortes hiperplanares pelas árvores em comparação com o treinamento puramente sobre as variáveis em escala bruta (cujo F_1 limita-se a 0,7082), mas não supera o limite de separabilidade determinado pela distribuição física dos dados.

A inspeção da matriz de confusão do modelo C3 (Figura 11) elucida os mecanismos geradores de erro no Track B. Observa-se que 14 equívocos diagnósticos concentram-se na transição entre descargas de baixa e alta energia (9 amostras de D1 previstas como D2 e 5 amostras de D2 previstas como D1). Essa transição reflete uma fronteira termodinâmica contínua, na qual variações discretas na densidade de corrente e na geometria do arco induzem sobreposição de assinaturas químicas. Adicionalmente, as classes térmicas incipientes T1 e T2 registram desempenhos modestos ($F_1 = 0,585$ e $F_1 = 0,621$, respectivamente), decorrentes da escassez de dados para treinamento e validação (apenas 16 amostras de teste em cada categoria), ao passo que as categorias Normal e T3 sustentam índices superiores a 0,91.

4.4 AUDITORIA NORMATIVA: DIVERGÊNCIA DOS MÉTODOS TRADICIONAIS

Os índices de macro-precisão reportados para os métodos normativos tradicionais na Tabela 7 ($F_1 = 0,3634$ para o Triângulo 1 de Duval e $F_1 = 0,2569$ para as razões

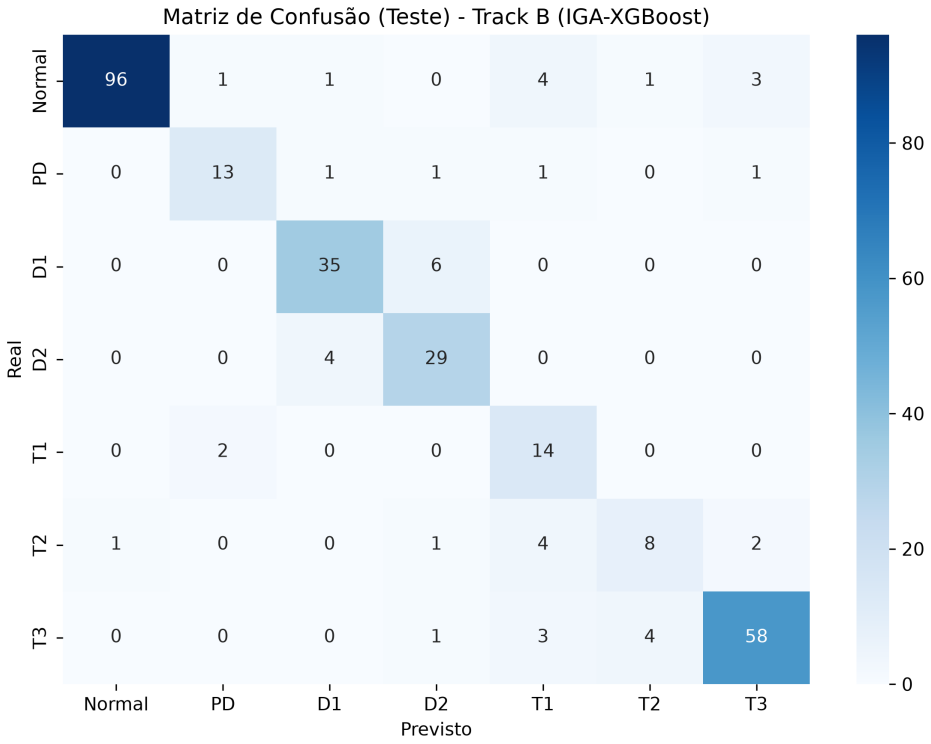


Figura 11 – Matriz de confusão do modelo C3 (IGA-XGBoost) no teste de sete classes do Track B.

Fonte: Elaborado pelo autor.

da IEC 60599) distanciam-se significativamente das taxas de acurácia comumente descritas na literatura de sistemas de potência, as quais frequentemente oscilam entre 70% e 90%. Essa discrepância suscitou a necessidade de auditoria algorítmica rigorosa sobre o código de implementação e sobre os rótulos de referência da base.

Para assegurar que o baixo desempenho não resultasse de falhas de codificação analítica, submeteram-se as rotinas de cálculo a um conjunto de testes unitários com casos canônicos. Para o Triângulo 1 de Duval, avaliaram-se 13 pontos canônicos representativos das zonas diagnósticas descritas no Anexo B da norma IEC 60599, obtendo-se correspondência estrita em todos os pontos centrais de polígono. Para a norma IEC 60599, avaliaram-se os códigos clássicos das razões C_2H_2/C_2H_4, CH_4/H_2 e C_2H_4/C_2H_6, confirmando-se a conformidade das regras. As únicas discordâncias registradas ocorreram estritamente sobre a linha limítrofe de separação poligonal ou em casos que recaem na zona de transição mista (DT), comprovando a correção matemática dos algoritmos.

A auditoria empírica sobre a distribuição das predições da base completa de 1.972 amostras, consolidada na Tabela 8, evidenciou que a divergência decorre de duas inconsistências ontológicas fundamentais entre as normas e os bancos de dados

abertos.

Tabela 8 – Concordância entre os rótulos da base e os diagnósticos da IEC 60599 e do Triângulo de Duval.

Classe	**Total**	**IEC 60599**		**Triângulo 1 de Duval**		
Rotulada	**(N)**	**Concordância**	**Não Determinado**	**Concordância**	**Zona DT**	**Principal Desvio**
Normal	707	0,0%	14,0%	0,0%	0,7%	89,0% predito como T1
PD	111	14,4%	80,2%	14,4%	4,5%	52,3% predito como T1
D1	273	24,2%	71,4%	76,2%	4,8%	14,7% predito como D2
D2	221	15,8%	40,7%	58,4%	10,0%	24,4% predito como D1
T1	107	48,6%	36,4%	31,8%	2,8%	41,1% predito como T2
T2	108	64,8%	17,6%	38,9%	10,2%	39,8% predito como T3
T3	435	31,3%	14,0%	38,4%	8,5%	39,1% predito como T2

Fonte: Elaborado pelo autor.

A primeira causa reside no fato de que os métodos de Duval e IEC foram concebidos exclusivamente para determinar o mecanismo de falha em equipamentos cujo estado anômalo já foi previamente estabelecido por limiares de concentração total de gás ou taxas de evolução diária. Consequentemente, esses métodos não contemplam a categoria operacional Normal em sua formulação geométrica. Quando aplicados à totalidade da base, o Triângulo de Duval categoriza 629 das 707 amostras normais (89,0%) como falha térmica T1, e a IEC 60599 classifica 591 amostras normais (83,6%) como T1, zerando a acurácia de ambos nessa classe majoritária. Além disso, a rigidez analítica da IEC 60599 resulta em índices de indeterminação elevados (80,2% em PD e 71,4% em D1), gerando diagnósticos nulos para a maioria dos casos práticos.

A segunda causa, de natureza físico-química, envolve uma contradição termodinâmica na classe T3. De acordo com a física clássica da IEC 60599, uma falha térmica de temperatura elevada ($T > 700$ °C) provoca quebra pirolítica severa de etano em etileno, exigindo razão $C_2H_4/C_2H_6 > 4$. Todavia, a análise descritiva da base compilada demonstrou que a mediana dessa razão para os dados anotados como T3 situa-se em apenas 0,25, com o terceiro quartil permanecendo abaixo de 1,0. Por essa razão, tanto a IEC 60599 quanto o Triângulo de Duval categorizam essas instâncias como sobreaquecimentos moderados (T1 ou T2). Esse resultado atesta que os modelos de aprendizado de máquina adaptaram-se à distribuição empírica dos dados operacionais e supera os sistemas normativos rígidos precisamente por sua capacidade de extrair fronteiras de decisão livres das hipóteses analíticas prévias das normas internacionais.

4.5 INTERPRETABILIDADE FÍSICO-QUÍMICA VIA SHAP

A utilização de algoritmos de aprendizado supervisionado em engenharia de sistemas de potência demanda transparência decisória e conformidade estrita com

os princípios da físico-química da degradação isolante. Para atender a esse requisito, implementou-se um pipeline de explicabilidade pós-hoc estruturado sobre a formulação de TreeSHAP aditivo (LUNDBERG et al., 2020). Os valores de contribuição individual (ϕ_i) foram computados de forma nativa a partir da decomposição das margens de log-odds em árvores de decisão, assegurando a propriedade fundamental de eficiência axiomática, segundo a qual a soma de todas as contribuições parciais acrescida do valor esperado basal iguala rigorosamente a predição contínua da margem do modelo ($\sum_{i=1}^{M} \phi_i + \phi_0 = f(x)$).

4.5.1 ESTABILIDADE DO RANKING GLOBAL

Antes de extrair conclusões físicas a partir das explicações pontuais, avaliou-se a estabilidade do ordenamento de importância frente a perturbações estocásticas induzidas pela inicialização de sementes aleatórias. Para cada uma das cinco sementes avaliadas no modelo C3 do Track B, construiu-se o vetor de importância global média absoluta ($E[|\phi_i|]$). Calculou-se a correlação de postos de Spearman (ρ) entre os rankings das sementes, obtendo-se correlação média de $\rho = 0,954$. A obtenção de coeficiente expressivamente superior ao patamar crítico de 0,80 comprova que as atribuições de relevância refletem estruturas funcionais latentes nos dados, e não artefatos aleatórios derivados da amostragem ou do treinamento local do ensemble.

4.5.2 RELEVÂNCIA POR CLASSE E AGRUPAMENTO POR FAMÍLIAS QUÍMICAS

Para contornar a distorção interpretativa provocada pela colinearidade mútua entre variáveis quimicamente aparentadas, agrupou-se o impacto absoluto dos atributos em quatro famílias analíticas fundamentais (derivados de acetileno C_2H_2, derivados de etileno C_2H_4, derivados de metano CH_4 e gases brutos não derivados). A aditividade matemática do TreeSHAP garante que a soma dos valores de ϕ dentro de cada grupo represente a contribuição exata e linearmente desprovida de viés daquela classe funcional. A Figura 12 ilustra o mapa de calor da importância global média para cada classe operacional, e a Figura 13 sintetiza a distribuição das quatro famílias químicas consolidadas.

A distribuição de crédito reproduz com fidelidade as diretrizes clássicas estabelecidas na literatura internacional de DGA. As falhas caracterizadas por descargas elétricas em meio dielétrico (D1 e D2) apresentam dependência quase exclusiva da família dos derivados de acetileno, respondendo os atributos C_2H_2/TH e C_2H_2/C_2H_4 pela maior parte da probabilidade acumulada. Em contrapartida, as descargas parciais (PD) concentram a alocação de importância na família do metano e na razão CH_4/H_2, em consonância com o fato de que ionizações pontuais e eflúvios dielétricos de baixa

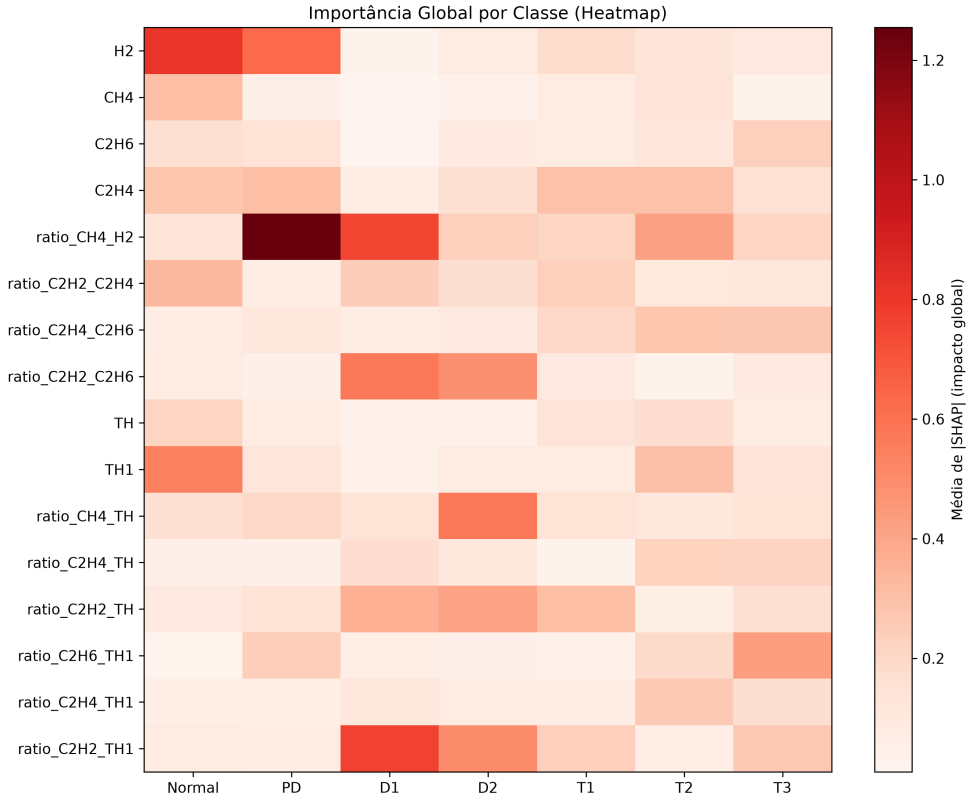


Figura 12 – Mapa de calor da importância média absoluta do SHAP por classe operacional no Track B.

Fonte: Elaborado pelo autor.

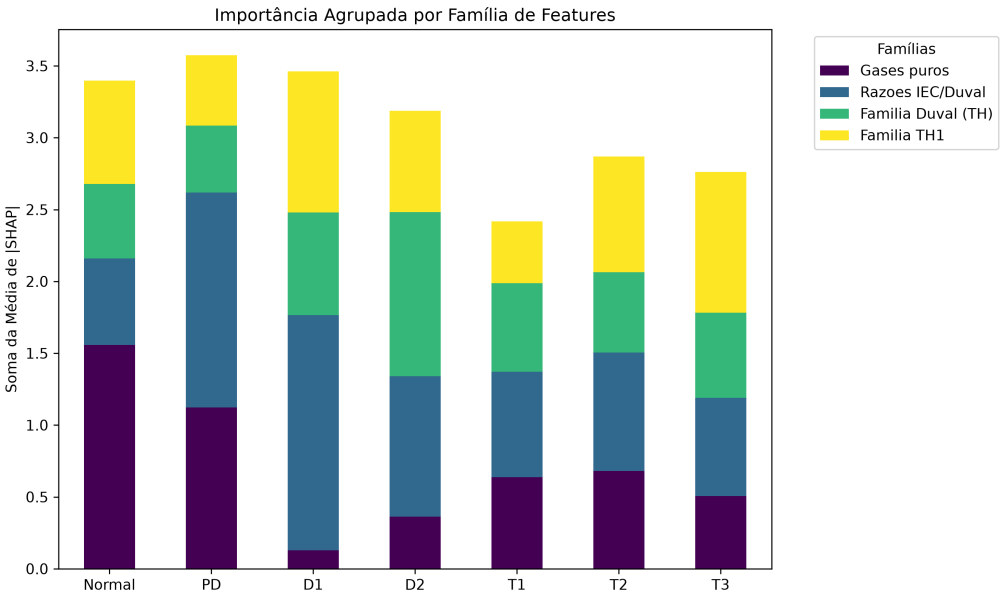


Figura 13 – Importância agregada por famílias de gases para as sete categorias de integridade operacional.

Fonte: Elaborado pelo autor.

energia clivam as cadeias de hidrocarbonetos gerando prioritariamente hidrogênio atômico e metano. Por fim, os sobreaquecimentos térmicos (T1, T2 e T3) dividem a importância entre os derivados de etileno (C_2H_4/TH) e etano (C_2H_4/C_2H_6), confirmando que a pirólise térmica do óleo em temperaturas moderadas e elevadas ativa predominantemente a decomposição de ligações carbono-carbono alifáticas duplas.

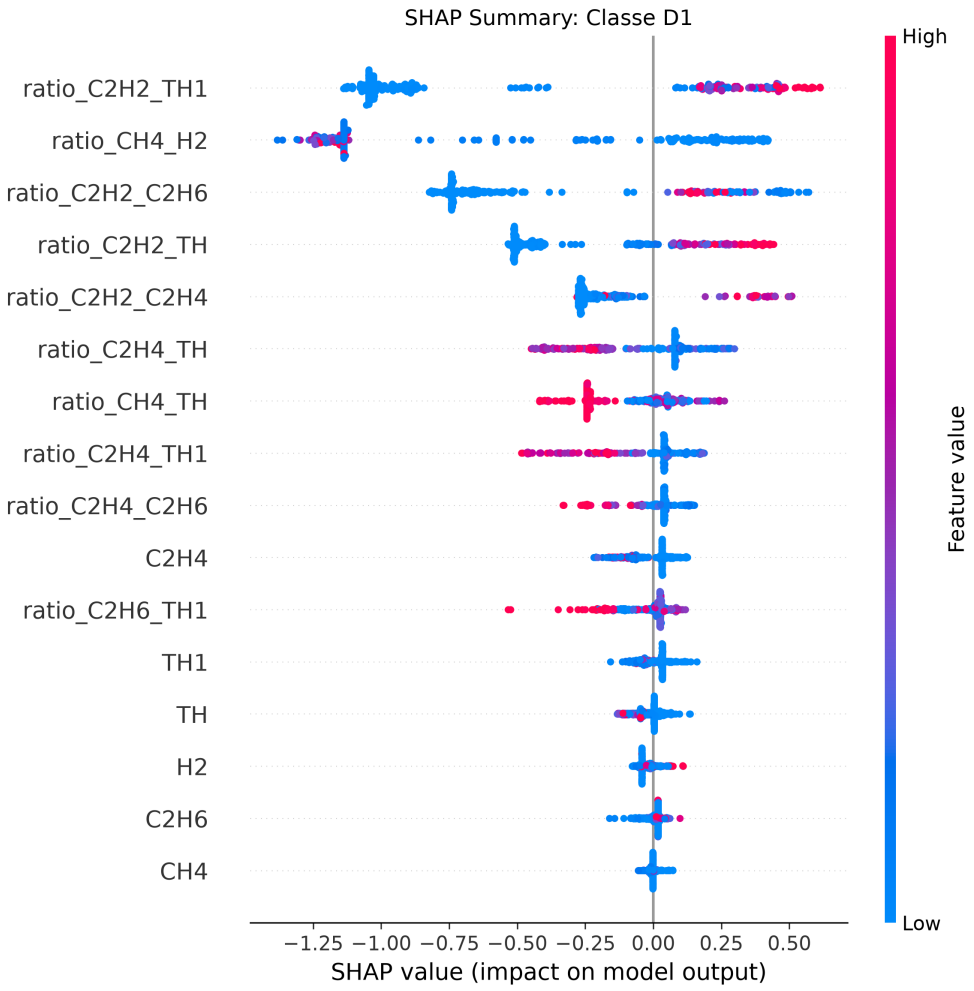


Figura 14 – Distribuição dos valores de SHAP para a classe de Descargas de Baixa Energia (D1).

Fonte: Elaborado pelo autor.

O gráfico de dispersão de abelha (*beeswarm*) específico para a classe D1, ilustrado na Figura 14, confirma essa mecânica em nível de instância individual. Níveis elevados de C_2H_2/TH e da razão C_2H_2/C_2H_4 deslocam sistematicamente a margem de log-odds na direção positiva da classe, ao passo que proporções reduzidas ou nulas de acetileno forçam a predição para o campo negativo, discriminando com clareza as ocorrências de centelhamento de baixa intensidade.

4.5.3 EXTRAÇÃO DE LIMIARES FÍSICOS MARGINAIS

Por meio do cálculo da matriz de interações de Lundberg (`pred_interactions`), realizou-se a extração do efeito principal diagonal isolado ($\phi_{i,i}$) de cada variável diagnóstica, revertendo-se a escala para unidades físicas originais. O ponto no qual a contribuição marginal cruza o eixo nulo ($\phi_{i,i} = 0$) identifica o limiar empírico a partir do qual aquela concentração passa a exercer pressão favorável à ocorrência de determinada falha. A Tabela 9 compara os pontos de transição aprendidos autonomamente pelo classificador XGBoost contra os cortes analíticos fixados pelo Triângulo 1 de Duval e pela norma IEC 60599.

Tabela 9 – Comparação entre limiares analíticos normativos e pontos de transição marginal do TreeSHAP.

Parâmetro Químico	**Falha Alvo**	**Limiar Normativo**	**Limiar Marginal Extraído**
Percentual $\%C_2H_4$ (C_2H_4/TH)	D1	$< 23\%$ (Duval)	Faixa entre 20% e 25%
Percentual $\%C_2H_2$ (C_2H_2/TH)	D1	$\geq 13\%$ (Duval / IEC)	$\approx 8,0\%$
Percentual $\%C_2H_2$ (C_2H_2/TH)	D2	$\geq 13\%$ ou 29% (Duval)	$\approx 8,6\%$
Razão C_2H_4/C_2H_6	T3	$> 4,0$ (IEC 60599)	$\approx 2,97$

Fonte: Elaborado pelo autor.

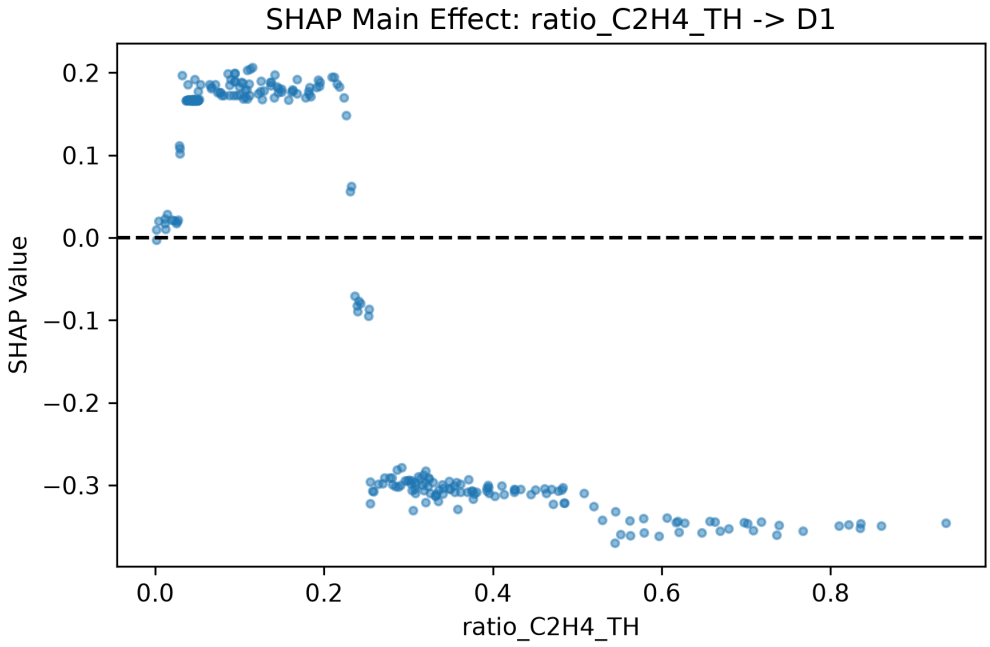


Figura 15 – Efeito principal isolado do TreeSHAP para a razão C_2H_4/TH na classe D1.

Fonte: Elaborado pelo autor.

Conforme demonstrado na Figura 15, o comportamento da razão C_2H_4/TH para a detecção de D1 revela conformidade notável com a física do problema. Enquanto a

geometria clássica do Triângulo 1 de Duval delimita o polígono de D1 estritamente em proporções de etileno inferiores a 23%, a curva empírica gerada pelo modelo cruza a linha de contribuição marginal nula exatamente no intervalo situado entre 20% e 25% (0,20 e 0,25 na escala da fração). Isso comprova que o ensemble de árvores extraiu de forma autônoma a restrição termodinâmica que diferencia descargas elétricas puras de arcos combinados com estresse térmico, sem necessidade de imposição prévia de regras pelo projetista.

Por outro lado, o limiar empírico para o percentual de acetileno em D1 e D2 situou-se na faixa de 8%, demonstrando postura mais conservadora que o patamar normativo clássico de 13%. Esse comportamento reflete a distribuição empírica da base de calibração, na qual relatórios técnicos de manutenção atribuíram laudos de descarga incipiente a equipamentos apresentando traços menos volumosos de C_2H_2. Do mesmo modo, o limiar da razão C_2H_4/C_2H_6 para a falha T3 posicionou-se em 2,97, reproduzindo a anomalia amostral já diagnosticada na seção precedente.

4.5.4 VISUALIZAÇÃO ESPACIAL NO TRIÂNGULO DE DUVAL

Com o propósito de correlacionar espacialmente as decisões do classificador XGBoost com o espaço baricêntrico convencional, projetaram-se as 295 amostras do conjunto de teste sobre as coordenadas triangulares do Triângulo 1 de Duval, parametrizadas pelas concentrações relativas $\%CH_4$, $\%C_2H_4$ e $\%C_2H_2$. A Figura 16 apresenta o mapeamento espacial obtido, identificando os pontos de acerto e destacando os casos de classificação divergente.

A visualização baricêntrica evidencia que os erros cometidos pelo modelo de aprendizado de máquina não se distribuem de maneira desordenada pelo espaço vetorial. Pelo contrário, as instâncias classificadas de forma divergente situam-se concentradas sobre as linhas divisórias limítrofes entre as zonas D1 e D2, bem como no interior da zona mista de transição DT (Descarga e Falha Térmica combinadas). Trata-se de uma constatação de grande relevância prática, pois demonstra que as discrepâncias residuais do modelo coincidem precisamente com as regiões em que a própria norma internacional de Duval reconhece a existência de ambiguidade diagnóstica intrínseca.

4.5.5 ANÁLISE LOCAL DE ERROS DE CLASSIFICAÇÃO

A decomposição aditiva local via gráficos em cascata (*waterfall plots*) possibilita auditar o mecanismo analítico que conduziu a classificações incorretas em casos específicos da partição de teste. A Figura 17 detalha a decomposição do log-odds para a amostra de índice 11, cujo rótulo empírico original indicava falha D1, mas a predição do modelo apontou classe D2.

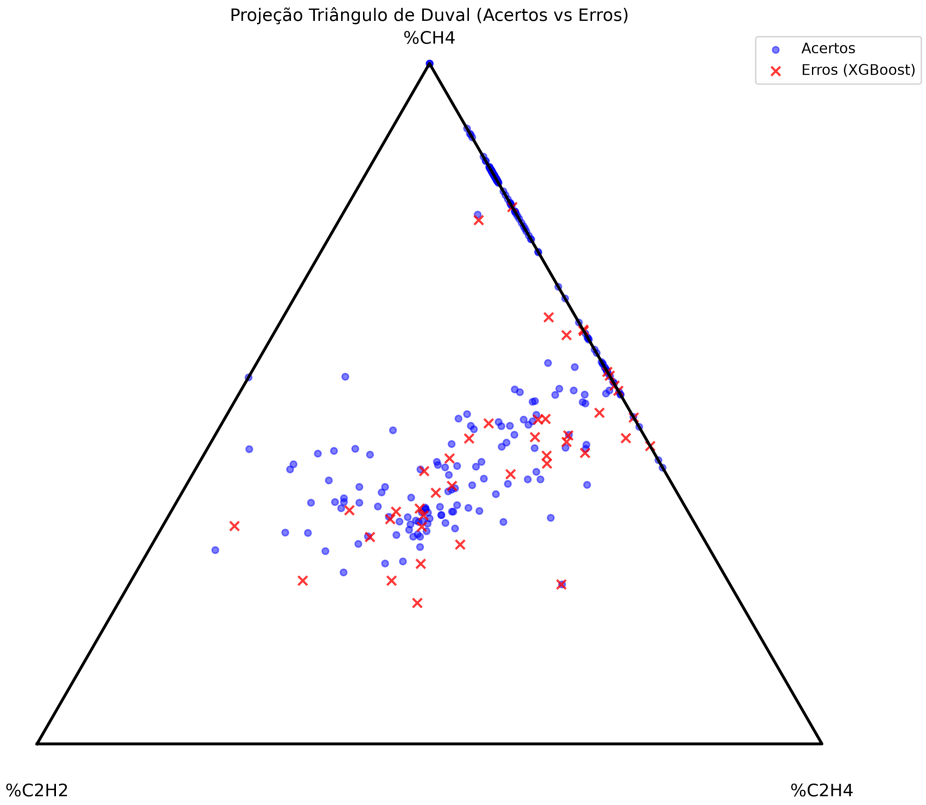


Figura 16 – Mapeamento das amostras de teste no Triângulo 1 de Duval evidenciando a localização dos erros diagnósticos.

Fonte: Elaborado pelo autor.

A decomposição vetorial demonstra que o erro de classificação derivou da atuação conjunta de dois fatores marginais. A amostra apresentava proporção relativa de etileno levemente superior a 22%, situando-se a poucos décimos da fronteira de transição para falhas com envolvimento térmico, associada a concentração basal de metano que suprimiu a contribuição da família de C_2H_2 para a classe D1 ($\phi = -0,48$), deslocando a margem global na direção do polígono de alta energia característico de D2. Trata-se, portanto, de um caso fronteiriço típico no qual o modelo respondeu à proximidade física da amostra com a zona contígua.

4.5.6 MIGRAÇÃO ESTOCÁSTICA DE CRÉDITO E FECHAMENTO DA HIPÓTESE TEMPORAL

Para concluir formalmente a investigação acerca do papel exercido pela rede LSTM no Track A, avaliou-se a dispersão de crédito alocada pelo TreeSHAP sobre modelos submetidos a diferentes sementes de inicialização estocástica. A Figura 18 expõe a importância média do gás hidrogênio dividida entre a medida observada instantânea ($H_{2,obs}$) e as estimativas projetadas recursivamente para 14 e 28 passos

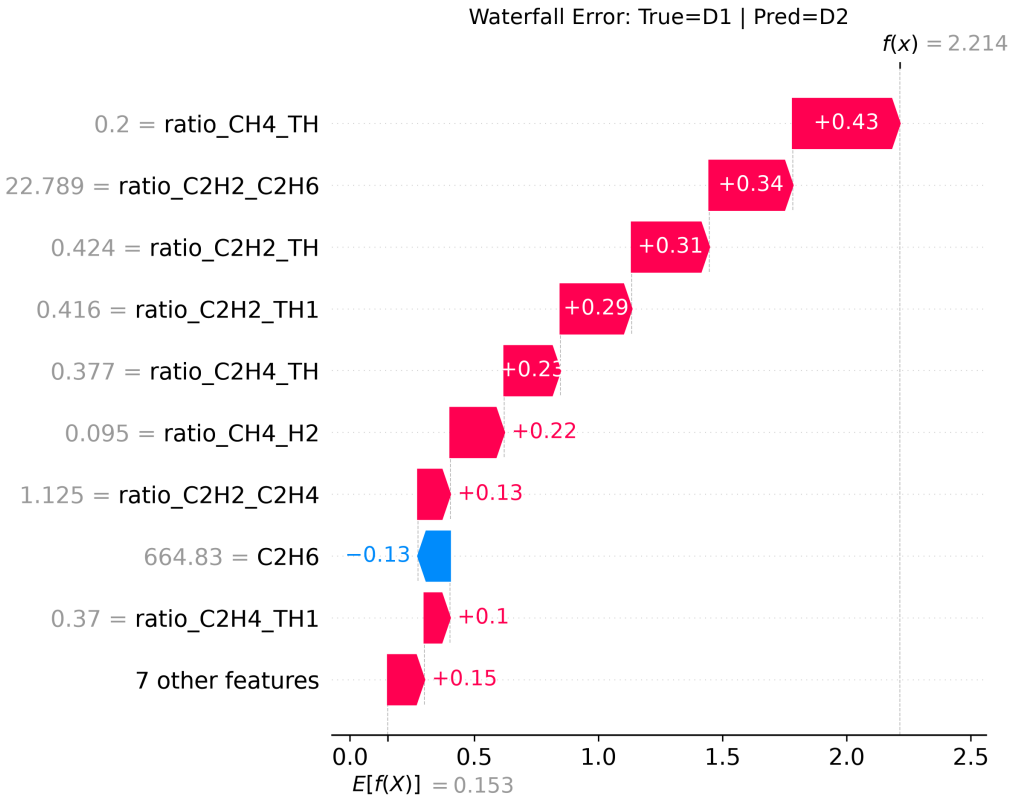


Figura 17 – Decomposição aditiva via Waterfall plot do caso de classificação divergente de D1 para D2 (amostra 11).

Fonte: Elaborado pelo autor.

($H_{2,h14}$ e $H_{2,h28}$).

O comportamento visualizado na Figura 18 constitui prova empírica definitiva sobre a natureza da interação entre os módulos. Observa-se que, ao alterar a semente de treinamento do classificador XGBoost, a alocação de importância oscila arbitrariamente entre as projeções $H_{2,h14}$ e $H_{2,h28}$, evidenciando a partição estocástica de crédito típica de ensembles de árvores submetidos a variáveis com correlação extrema. Entretanto, a curva representativa da soma agregada de importância alocada à família do hidrogênio (traçado escuro) permanece rigorosamente estável e idêntica à importância computada em modelos que utilizam unicamente a concentração observada. Esse fenômeno comprova que as previsões da rede recorrente não inserem dimensões ortogonais de discernimento diagnóstico no estado operacional avaliado, ratificando a conclusão de que a hibridização temporal de curto prazo não eleva a separabilidade estática em transformadores em operação contínua.

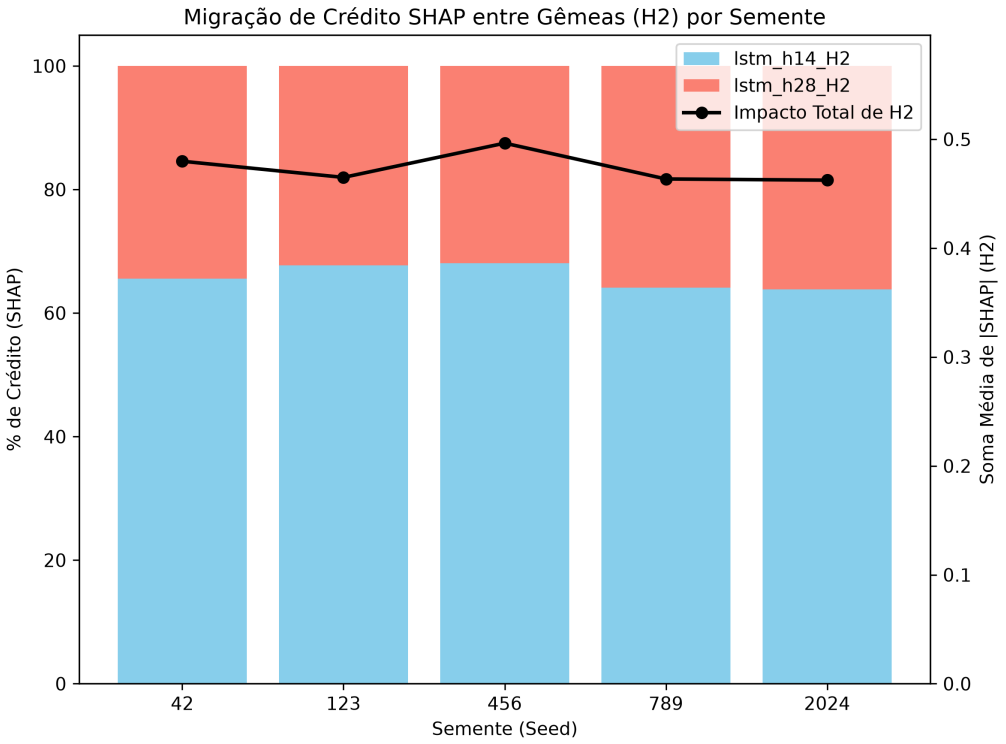


Figura 18 – Migração estocástica de crédito de importância do SHAP entre variáveis observadas e preditas pela LSTM.

Fonte: Elaborado pelo autor.

5 CONCLUSÃO

Este trabalho apresentou uma investigação experimental sistemática sobre o diagnóstico de falhas incipientes em transformadores de potência por Análise de Gases Dissolvidos (DGA), combinando modelagem temporal por redes neurais recorrentes, classificação por árvores com aumento de gradiente, busca evolutiva por parcimônia e interpretabilidade físico-química pós-hoc. A pesquisa foi orientada pela necessidade de auditar empiricamente as premissas frequentes da literatura especializada, estabelecendo protocolos rigorosos de inferência estatística capazes de quantificar a real contribuição de modelos complexos frente aos limites informacionais das bases de dados industriais abertas.

5.1 SÍNTESE DAS CONTRIBUIÇÕES

A principal contribuição teórica e metodológica desta pesquisa reside no estabelecimento de uma estrutura experimental em dois eixos operacionais independentes, superando a assimetria verificada nos repositórios públicos de DGA entre dados temporais contínuos com restrição de variáveis e matrizes estáticas abrangentes em classes normativas. A auditoria mandatória dos dados eliminou um índice de redundância amostral de 15% na base compilada, garantindo a integridade dos particionamentos e blindando as inferências contra estimativas infladas de acurácia.

No âmbito da otimização algorítmica, o acoplamento do Algoritmo Genético Melhorado (IGA) ao classificador XGBoost demonstrou que a relevância de técnicas evolutivas reside primariamente na indução de parcimônia e redução de complexidade dimensional. No Eixo A, o IGA reduziu o espaço vetorial de atributos em 53%, descartando variáveis colineares e mantendo um escore F_1-macro idêntico de 0,891 com apenas 8 atributos selecionados. Essa compactação simplifica a instrumentação em sistemas de monitoramento contínuo em subestações, reduzindo a propagação de ruídos de medição e a sobrecarga computacional em dispositivos embarcados.

No diagnóstico multiclasse do Eixo B, a experimentação repetida em 25 dobras estratificadas comprovou a existência de um teto informacional em torno de $F_1 \approx 0,75$ a $0,76$ para conjuntos de dados cromatográficos estáticos de campo. Os modelos propostos e de referência da literatura revelaram-se estatisticamente indistinguíveis nesse patamar, indicando que a variabilidade não explicada decorre da sobreposição inerente entre classes adjacentes e de inconsistências de rotulagem empírica, e não de deficiências de capacidade dos algoritmos de aprendizado supervisionado.

Por fim, o emprego da teoria dos jogos cooperativos via algoritmo TreeSHAP e

matrizes de interação purificadas estabeleceu uma correspondência matemática inédita entre ensembles de árvores de decisão e a termodinâmica de degradação de óleos isolantes. O modelo supervisionado aprendeu de forma autônoma a assinatura química clássica dos gases, atribuindo o diagnóstico de descargas elétricas aos derivados de acetileno e falhas térmicas ao etileno. O limiar empírico de transição identificado para a razão de etileno em descargas de baixa energia, situado entre 20% e 25%, coincidiu com a fronteira exata de 23% postulada no Triângulo 1 de Duval, demonstrando que os modelos baseados em gradiente convergem para a física do fenômeno quando submetidos a regularização analítica adequada.

5.2 DEFESA CIENTÍFICA DE RESULTADOS NEGATIVOS

Um dos resultados mais expressivos desta dissertação consiste na refutação empírica da hipótese de que a incorporação de projeções temporais de curto prazo necessariamente eleva a capacidade discriminativa de classificadores estáticos de falhas. A avaliação por bootstrap pareado com 5.000 iterações revelou que a adição das projeções da rede LSTM para horizontes de uma e duas semanas produziu um incremento marginal de apenas $\Delta F_1 = +0,0056$, cujo intervalo de confiança de 95% abrangeu a nulidade entre $-0,0037$ e $+0,0150$, configurando equivalência diagnóstica estrita sob o ponto de vista inferencial.

A explicação físico-estatística para esse resultado negativo fundamenta-se na dinâmica de operação contínua dos transformadores industriais analisados. Em regimes operacionais caracterizados por degradação gradual ou estabilidade funcional, a autocorrelação temporal das séries de gases é dominante, resultando em coeficientes de correlação de Pearson superiores a 0,997 entre as projeções da LSTM e as medições já observadas no instante presente. Consequentemente, as estimativas futuras projetadas pela rede recorrente não aportam inovação informacional à matriz de covariáveis, comportando-se como duplicatas estocásticas que competem de forma redundante pelo ganho das árvores de decisão, conforme evidenciado pela análise de dispersão de crédito nos valores de Shapley.

A documentação e a defesa explícita desse resultado negativo possuem elevado valor para a comunidade científica e para a engenharia de computação aplicada. Na literatura especializada, a predominância de viés de publicação induz comumente à proposição acrítica de modelos híbridos excessivamente complexos, assumindo ganhos hipotéticos de desempenho que decorrem, muitas vezes, de sobreajuste amostral ou vazamento de dados. Ao comprovar que a LSTM cumpre com precisão a função de previsão de tendências quantitativas, mas não agrega poder discriminativo ao diagnóstico de estado estacionário, este trabalho delimita objetivamente o papel funcional de cada componente arquitetural, prevenindo dispêndios desnecessários de processamento em

ambiente de campo.

5.3 LIMITAÇÕES DA PESQUISA

A execução dos experimentos e o alcance das conclusões formuladas estão delimitados por restrições objetivas associadas às bases de dados públicas disponíveis no domínio de DGA. A principal limitação consiste na inexistência de um repositório aberto que unifique monitoramento temporal contínuo em alta frequência amostral e o espectro cromatográfico completo dos sete gases normativos associados a laudos confirmados de falhas severas. Essa fragmentação impôs a bifurcação metodológica da pesquisa em dois eixos de investigação distintos.

No Eixo A, o conjunto de dados industriais de Katser et al. (2022) restringe o monitoramento a quatro espécies gasosas, omitindo a quantificação do metano e do etano, o que impediu o cálculo das razões normatizadas completas da IEC 60599 nesse domínio longitudinal. Além disso, as medições reportadas apresentam magnitude reduzida na escala de 10^{-3}, refletindo instalações nucleares operando sob rigoroso controle operativo, com baixa representatividade de transições disruptivas abruptas e arcos elétricos de alta energia.

No Eixo B, a base de dados compilada de cromatografia estática, embora saneada e deduplicada, reflete a heterogeneidade inerente a laudos laboratoriais agregados a partir de concessionárias com procedimentos analíticos distintos. A auditoria normativa revelou discrepâncias severas entre a rotulagem fornecida e os preceitos termodinâmicos internacionais, como observado na classe de falhas térmicas T3, cuja mediana da razão C_2H_4/C_2H_6 de 0,25 contradiz a exigência normativa de valores superiores a 4,0. Essa divergência demonstra que parte do erro residual dos modelos decorre de ruído de anotação de campo, limitando o potencial de generalização perfeita por aprendizado supervisionado.

5.4 DIRECIONAMENTOS PARA TRABALHOS FUTUROS

A partir das evidências e limitações documentadas, sugerem-se quatro linhas prioritárias de investigação para o avanço da engenharia de manutenção preditiva em ativos de potência.

A primeira linha consiste em reformular o problema de aprendizado de máquina, migrando da classificação pontual de estados discretos para a estimativa contínua de Tempo de Vida Útil Remanescente (*Remaining Useful Life*, RUL) e modelagem estocástica de probabilidades de transição entre regimes operacionais. Nessa perspectiva, a capacidade preditiva da LSTM passa a alimentar curvas de confiabilidade dinâmicas,

antecipando o instante exato em que a concentração projetada cruzará limiares críticos de segurança.

A segunda linha reside no desenvolvimento de sensores de monitoramento online contínuo com calibração analítica abrangendo simultaneamente os sete gases dissolvidos em óleo, associados à coleta longitudinal de transformadores em fim de vida útil ou submetidos a sobrecargas controladas em ambiente experimental de laboratório.

A terceira linha envolve a incorporação formal de covariáveis físicas operacionais exógenas à cromatografia gasosa, integrando o histórico horário de carregamento elétrico, temperatura de topo e fundo de óleo, umidade na celulose e transientes de sobretensão atmosférica. A inclusão desses fatores viabilizará a correção estequiométrica das taxas diárias de geração volumétrica de gás.

A quarta linha propõe o estudo de técnicas de aprendizado por transferência (*Transfer Learning*) e modelos fundacionais pré-treinados em frotas multinacionais de transformadores. Essa abordagem permitirá adaptar distribuições de probabilidade aprendidas em grandes ativos para subestações com histórico restrito de amostragem, atenuando os impactos do desbalanceamento severo característico das falhas elétricas críticas.

REFERÊNCIAS

AL-SAKINI, S. R. et al. Dissolved gas analysis for fault prediction in power transformers using machine learning techniques. *Applied Sciences*, MDPI, v. 15, n. 1, p. 118, 2025. Citado 5 vezes nas páginas 13, 17, 23, 24 e 31.

ALI, M. S. et al. Conventional methods of dissolved gas analysis using oil-immersed power transformer for fault diagnosis: A review. *Electric Power Systems Research*, Elsevier, v. 216, p. 109064, 2023. Citado 8 vezes nas páginas 11, 16, 17, 19, 23, 24, 28 e 33.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*. ACM, 2016. p. 785–794. Disponível em: <https://www.kdd.org/kdd2016/papers/files/rfp0697-chenAemb.pdf>. Citado na página 25.

DESCONHECIDO. *Mineral oil-filled electrical equipment in service – Guidance on the interpretation of dissolved and free gases analysis*. [S.l.], 2022. Edition 4.0. Publication date: 2022-05-25. 80 pages. ISBN: 9782832236963. Disponível em: <https://webstore.iec.ch/en/publication/66491>. Citado 2 vezes nas páginas 18 e 20.

DUVAL, M. A review of faults detectable by gas-in-oil analysis in transformers. *IEEE Electrical Insulation Magazine*, v. 18, n. 3, p. 8–17, 2002. Disponível em: <https://www.researchgate.net/publication/3258357_A_review_of_faults_detectable_by_gas-in-oil_analysis_in_transformers>. Citado na página 18.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 24.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural computation*, 1997. Citado 2 vezes nas páginas 26 e 27.

KATSER, I. et al. Machine learning methods for anomaly detection in nuclear power plant power transformers. *arXiv preprint arXiv:2211.11013*, 2022. Citado 4 vezes nas páginas 34, 35, 45 e 48.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 1998. Citado na página 23.

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, v. 2, n. 1, p. 56–67, 2020. Citado 3 vezes nas páginas 30, 43 e 55.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30, p. 4765–4774. Citado na página 29.

SHAPLEY, L. S. A value for n-person games. In: *Contributions to the Theory of Games*. [S.l.]: Princeton University Press, 1953. v. 2, p. 307–317. Citado na página 29.

TIGHTIZ, L. et al. An intelligent system based on optimized anfis and association rules for power transformer fault diagnosis. *ISA Transactions*, Elsevier, v. 103, p. 63–74, 2020. Citado 2 vezes nas páginas 11 e 16.

WANG, L.; LITTLER, T.; LIU, X. Dynamic incipient fault forecasting for power transformers using an lstm model. *IEEE Transactions on Dielectrics and Electrical Insulation*, IEEE, 2023. Citado 3 vezes nas páginas 13, 31 e 37.

WU, Z. et al. Improved genetic algorithm and xgboost classifier for power transformer fault diagnosis. *Frontiers in Energy Research*, Frontiers Media, v. 9, 2021. Citado 7 vezes nas páginas 13, 23, 28, 31, 39, 42 e 51.

ZHU, L. et al. Transformer-based model for long-sequence time-series forecasting in power systems. *IEEE Transactions on Power Systems*, v. 38, n. 4, 2023. Citado 2 vezes nas páginas 23 e 33.